



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Análisis exploratorio de datos- Parte I

Aprendizaje Esperado 1: Aplicar análisis exploratorio de datos distinguiendo sus principales técnicas y herramientas.


Learning Path

¿Cuáles temas trabajaremos hoy?




Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?





Objetivos de aprendizaje

¿Qué aprenderás?



- Comprender qué es el análisis exploratorio de datos (EDA) y cuál es su propósito.
- Diferenciar entre análisis inicial de datos (IDA) y análisis exploratorio.
- Identificar técnicas estadísticas y visuales utilizadas en el EDA.
- Reconocer herramientas adecuadas para aplicar estas técnicas.
- Comprender el rol del EDA en distintos contextos profesionales.

ANÁLISIS EXPLORATORIO DE DATOS



ANÁLISIS EXPLORATORIO DE DATOS

En el mundo actual, donde los datos son uno de los activos más importantes para la toma de decisiones, resulta fundamental conocer y dominar técnicas que permitan explorarlos, comprenderlos y validarlos antes de cualquier análisis complejo o modelado.

Introducción

El **Análisis Exploratorio de Datos (EDA)** representa una etapa crítica en el flujo de trabajo de la ciencia de datos, ya que permite identificar patrones, detectar errores, plantear hipótesis y establecer relaciones entre variables, todo a partir de una mirada preliminar e intuitiva sobre la información disponible.





ANÁLISIS EXPLORATORIO DE DATOS



¿Qué es el Análisis Exploratorio de Datos (EDA)?

El Análisis Exploratorio de Datos (EDA) es una metodología estadística que busca describir las características principales de un conjunto de datos utilizando métodos visuales y cuantitativos. Su propósito es obtener una comprensión inicial de los datos, sin suposiciones previas, con el fin de identificar patrones, tendencias, relaciones, valores atípicos y errores.

Características del EDA

Enfoque inductivo

A diferencia de los enfoques confirmatorios, el EDA es inductivo y abierto, lo que permite que el analista explore libremente el comportamiento de las variables antes de tomar decisiones sobre modelado o inferencia.

Primera etapa

El EDA suele ser la primera etapa en proyectos de análisis, ciencia de datos o aprendizaje automático.

Exploración visual


En lugar de aplicar modelos directamente, se examinan gráficos, resúmenes numéricos y relaciones entre variables para comprender la estructura de los datos.

Herramientas comunes del EDA


- Histogramas
- Diagramas de caja (boxplots)
- Gráficos de dispersión
- Medidas de tendencia central
- Matrices de correlación

Estas técnicas permiten formular hipótesis preliminares, verificar la validez de los datos y orientar las siguientes etapas del análisis.

Data Visualization Tools




Histogram



Box Plot



Scatter Plot



Importancia del EDA en la práctica

En la práctica, el EDA es fundamental para evitar errores en fases posteriores:

- Al observar un gráfico de dispersión se puede detectar una relación no lineal que requerirá transformar una variable.
- Al aplicar un histograma se puede evidenciar una distribución sesgada que justifica el uso de métodos robustos.

El valor del EDA no está solo en mostrar lo evidente, sino en **descubrir lo inesperado**, como diría John Tukey, su principal impulsor.



Rol del EDA

Su rol es clave para garantizar que los modelos y conclusiones estén bien fundamentados en la realidad de los datos.

¿Qué es el Análisis Inicial de Datos (IDA)?

El Análisis Inicial de Datos (IDA) es la etapa previa al análisis exploratorio, cuyo objetivo principal es **garantizar que los datos sean aptos para su análisis posterior**.

Esta fase se enfoca en aspectos técnicos como la estructura del dataset, la calidad de los registros, los tipos de datos y la presencia de valores faltantes o atípicos extremos.



Diferencias entre IDA y EDA



IDA

Se concentra en la validación, limpieza y transformación inicial para asegurar que los resultados futuros no se vean sesgados por errores u omisiones.



EDA

Busca interpretar los datos, descubrir patrones y relaciones entre variables para obtener insights.

Tareas clave del IDA

Verificación de formato

Comprobar el formato correcto de cada columna (numérica, categórica, fecha, etc.)

Detección de valores nulos

Identificar y cuantificar valores faltantes en el conjunto de datos

Identificación de inconsistencias

Detectar duplicados o errores de codificación en los datos

Detección de outliers


Identificar valores extremos que puedan alterar la interpretación


Herramientas para IDA

Es común generar reportes automáticos con herramientas como:

- pandas-profiling
- sweetviz

Estas permiten inspeccionar rápidamente las principales características estructurales del conjunto de datos.





2	Jane Emith	—	—	!
3	john doe	john do	—	!
4	Inactive	Inactive	—	!

Ejemplo práctico de IDA

- ❗ Un ejemplo práctico de IDA puede verse en un proyecto de análisis de clientes, donde el campo "edad" aparece con registros como "150", o el campo "email" contiene valores nulos o mal formateados.

Si no se detectan y corrigen estos errores, cualquier visualización o modelo posterior estaría sesgado o directamente equivocado. Por eso, el IDA **actúa como una etapa de control de calidad**, necesaria para comenzar el análisis con datos confiables y correctamente estructurados.



Contexto en el cual se utiliza el Análisis Exploratorio de Datos

El Análisis Exploratorio de Datos (EDA) se aplica en múltiples etapas de un proyecto de datos y en una variedad de industrias. Desde investigaciones científicas hasta campañas de marketing digital, el EDA permite **comprender la información antes de tomar decisiones importantes**.

Utilidad del EDA



Generación de hipótesis

Permite formular hipótesis iniciales basadas en patrones observados en los datos



Identificación de tendencias

Facilita la detección de tendencias preliminares en los datos



Orientación del análisis

Guía el análisis estadístico o predictivo posterior

EDA en la práctica profesional



Sector bancario

Se aplica EDA para revisar el comportamiento histórico de los clientes y detectar patrones de incumplimiento de pagos.



Medicina

Se usa para explorar variables clínicas antes de diseñar modelos diagnósticos.



Recursos humanos


Puede emplearse para visualizar correlaciones entre rotación de personal y condiciones laborales.

El EDA como puente

Más allá del ámbito, el EDA **funciona como puente entre los datos en crudo y la interpretación analítica.**


Su rol no es confirmar hipótesis sino descubrir relaciones inesperadas, ayudando al analista a entender la lógica del fenómeno subyacente.

Además, permite adaptar el tipo de visualizaciones y técnicas estadísticas que se utilizarán después, ajustando el enfoque según lo observado.



Ejemplo práctico de EDA

- ❏ Ejemplo práctico: al explorar un dataset de consumo eléctrico, se puede observar una caída sistemática los fines de semana, lo que sugiere una relación temporal útil para análisis posteriores.



Técnicas y herramientas para el análisis exploratorio



Estadísticas descriptivas


Permiten resumir la información mediante medidas como media, mediana, moda, desviación estándar, percentiles, valores máximos y mínimos.

Estas medidas ayudan a describir la forma y dispersión de los datos, y se aplican especialmente en el análisis univariado.

Visualización de datos


Aportan una comprensión intuitiva y permiten detectar patrones no visibles en tablas de números.

Visualizaciones más utilizadas




Histogramas

Para conocer la distribución de variables numéricas




Diagramas de caja

Para observar la dispersión y outliers



Gráficos de barras

Para comparar frecuencias de categorías



Gráficos de dispersión

Para explorar relaciones entre dos variables

Otras visualizaciones importantes

Mapas de calor

Útiles para visualizar matrices de correlación entre múltiples variables

Diagramas de violín

Combinan características de boxplots e histogramas para mostrar distribuciones

Gráficos de líneas temporales

Ideales para visualizar tendencias a lo largo del tiempo

Matrices de correlación

Muestran relaciones lineales entre pares de variables numéricas

Herramientas más comunes para realizar EDA

Python

Con librerías como pandas, matplotlib, seaborn, plotly, sweetviz, pandas-profiling.

R y RStudio

Con funciones como summary(), ggplot2, dplyr y tidyr.

Herramientas de visualización empresarial

Excel, Power BI o Tableau, para exploración visual empresarial.




Elección de herramientas

La elección de herramientas depende del perfil del analista, la complejidad del proyecto y el volumen de datos. Lo importante es seleccionar técnicas adecuadas al tipo de variables y objetivos del análisis.

Análisis univariado y sus objetivos


El análisis univariado consiste en examinar una única variable de forma independiente, sin relacionarla con otras. Es el primer paso del EDA y su objetivo es **comprender la distribución, tipo y comportamiento general** de cada variable.

Ayuda a identificar si una variable es numérica, categórica, ordinal o binaria, y qué tipo de medidas y gráficos pueden aplicarse para su estudio.



Análisis de variables numéricas

Numerical Variable Analysis



Medidas estadísticas

Se analizan medidas como media, mediana, rango, desviación estándar y percentiles.

Histogramas

Se utilizan para observar la forma de la distribución (simétrica, sesgada, con outliers).

Boxplots

Permiten detectar valores extremos y visualizar la dispersión de los datos.



Momento:

Time-out!



5 -10 min.





Ejercicio

Explorando lo que los datos “quieren decir”

Explorando lo que los datos “quieren decir”

Contexto: 🙌

Antes de aplicar técnicas estadísticas o modelos predictivos, es fundamental comprender qué contiene un conjunto de datos, cómo se comportan sus variables y si existen patrones o anomalías. El análisis exploratorio de datos (EDA) permite observar, descubrir y formular hipótesis sobre la información, aun sin hacer cálculos complejos. En esta instancia inicial del proceso analítico, la interpretación visual y la capacidad de cuestionamiento son las herramientas clave.

Consigna: 📝

A partir de un conjunto de datos simulado (por ejemplo: ventas, productos, fechas, zonas y montos), realice un análisis teórico. El objetivo es pensar qué tipo de preguntas podrías responder mediante técnicas de EDA, qué herramientas utilizarías para ello y por qué. Este desafío busca ejercitar tu razonamiento exploratorio, sin necesidad de programar ni utilizar software en esta etapa.

Paso a paso: ⚙️

- Imagine que recibe un dataset con 5 columnas: producto, monto, cantidad, fecha y zona.
- Piense al menos 3 preguntas que te gustaría responder explorando esos datos.
- Para cada pregunta, sugiere una técnica de EDA que podrías usar (por ejemplo: histograma, boxplot, matriz de correlación).
- Elige una herramienta posible (Excel, Power BI, Python) y explica brevemente por qué te resultaría útil.
- Cierre con una reflexión escrita: ¿por qué es importante explorar antes de concluir? ¿Qué podría pasar si no hacés EDA?

Tiempo 🕒: 45 Minutos

¿Alguna consulta?



Resumen

¿Qué logramos en esta clase?

- ✓ Entendimos qué es el EDA y por qué es una etapa clave del análisis de datos.
- ✓ Diferenciamos el análisis inicial de datos (IDA) como etapa previa de limpieza y validación.
- ✓ Exploramos técnicas como histogramas, diagramas de caja y mapas de calor.
- ✓ Revisamos herramientas como pandas, seaborn, Power BI y Excel.
- ✓ Discutimos cómo aplicar estas herramientas según el perfil del analista y el proyecto.



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

