



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Análisis exploratorio de datos- Parte II

Aprendizaje Esperado 1: Aplicar análisis exploratorio de datos distinguiendo sus principales técnicas y herramientas.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

1.

Aplicación de técnicas de análisis exploratorio

En esta clase profundizaremos en el análisis univariado y multivariado, incorporando técnicas visuales y estadísticas, y reflexionando sobre su utilidad en contextos reales

Análisis univariado y categórico

Técnicas aplicadas a variables categóricas

Importancia del análisis univariado para la calidad del modelo

Análisis multivariado y automatizado

Técnicas y visualizaciones multivariadas

Herramientas avanzadas y EDA automatizado

Objetivos de aprendizaje

¿Qué aprenderás?

- Aplicar técnicas específicas de análisis univariado y multivariado.
- Reconocer cuándo y cómo usar gráficos de barras, boxplots, scatter plots, mapas de calor, etc.
- Identificar herramientas tradicionales y avanzadas para el análisis exploratorio.
- Reflexionar sobre el valor del EDA en casos reales de negocio.
- Reconocer buenas prácticas y errores comunes al realizar EDA.

Repaso clase anterior

¿Quedó alguna duda?

- ✓ Entendimos qué es el EDA y por qué es una etapa clave del análisis de datos.
- ✓ Diferenciamos el análisis inicial de datos (IDA) como etapa previa de limpieza y validación.
- ✓ Exploramos técnicas como histogramas, diagramas de caja y mapas de calor.
- ✓ Revisamos herramientas como pandas, seaborn, Power BI y Excel.
- ✓ Discutimos cómo aplicar estas herramientas según el perfil del analista y el proyecto.

ANÁLISIS EXPLORATORIO DE DATOS

Análisis de variables categóricas



Para variables categóricas, se revisan:

- Frecuencias absolutas
- Frecuencias relativas

Se visualizan con gráficos de barras o pie charts.

Estas técnicas permiten entender cuán representativa o balanceada es una categoría en el conjunto.


CATEGORICAL VARIABLE ANALYSIS



Importancia del análisis univariado

Aplicar un análisis univariado es clave para evitar errores posteriores.


- Si una variable presenta muchos valores nulos o un único valor dominante, podría no ser útil en un modelo predictivo.
- Detectar asimetrías en la distribución puede justificar la transformación de la variable (logaritmo, raíz, etc.).
- Este análisis simple es esencial para decidir qué variables conservar, transformar o eliminar, y permite ganar una comprensión precisa del dataset.



Ejemplo de análisis univariado

Análisis multivariado

El análisis multivariado examina las relaciones entre dos o más variables simultáneamente. Permite identificar correlaciones, dependencias y patrones complejos que no son visibles al analizar variables de forma aislada.



Técnicas de análisis multivariado

Gráficos de dispersión

Muestran la relación entre dos variables numéricas, permitiendo identificar correlaciones lineales, no lineales o clusters.

Matrices de correlación

Visualizan el grado de asociación lineal entre múltiples variables numéricas simultáneamente.

Gráficos de pares

Combinan múltiples gráficos de dispersión para visualizar relaciones entre varias variables a la vez.

Más técnicas de análisis multivariado

Mapas de calor

Representan valores mediante colores, útiles para visualizar matrices de datos complejas.

Análisis de componentes principales


Reduce la dimensionalidad de los datos manteniendo la mayor variabilidad posible.

Clustering


Agrupar observaciones similares basándose en múltiples variables.

Beneficios del análisis multivariado

- Descubre relaciones complejas entre variables
- Identifica variables redundantes
- Detecta patrones y estructuras ocultas en los datos
- Facilita la selección de variables para modelado
- Permite entender interacciones y efectos combinados



Ejemplo de análisis multivariado



Un mapa de calor de correlación permite visualizar rápidamente las relaciones entre múltiples variables numéricas, identificando patrones que serían difíciles de detectar mediante análisis univariado.

Flujo de trabajo del EDA



Buenas prácticas en EDA

Comenzar con preguntas claras

Definir qué se busca entender antes de iniciar la exploración

Combinar técnicas

Utilizar tanto estadísticas descriptivas como visualizaciones

Iterar y profundizar

Explorar progresivamente, profundizando en hallazgos interesantes

Documentar el proceso

Registrar observaciones, decisiones y conclusiones

Errores comunes en EDA

- ☐ Ignorar la calidad de los datos antes de comenzar la exploración
- ☐ Confiar exclusivamente en estadísticas sin visualizar los datos
- ☐ Extraer conclusiones causales de correlaciones observadas
- ☐ No considerar el contexto del dominio al interpretar patrones
- ☐ Aplicar técnicas inapropiadas para el tipo de variable

Caso de estudio: EDA en retail

Escenario

Una cadena de tiendas quiere entender patrones de compra para optimizar inventario y promociones.


Datos disponibles

- Transacciones de ventas
- Información de productos
- Datos demográficos de clientes
- Información temporal (fechas, horas)


Retail data analysis

Total Sales
1,042,055


Sales by Category




Sales by Region




Sales -Profit



Sales by Year



Orders (thous.)



Caso de estudio: Proceso de EDA

Análisis univariado

Exploración de distribución de ventas, productos más vendidos, distribución de clientes por edad.

Análisis bivariado

Relación entre categorías de productos y demografía, patrones temporales de ventas.

Análisis multivariado

Segmentación de clientes basada en múltiples variables, análisis de canasta de compra.

Caso de estudio: Hallazgos



Patrones temporales

Identificación de picos de ventas en horarios específicos y días de la semana.



Segmentos de clientes

Descubrimiento de grupos de clientes con comportamientos de compra similares.



Asociaciones de productos

Identificación de productos frecuentemente comprados juntos.

Caso de estudio: Acciones basadas en EDA

- Optimización de inventario basada en patrones de demanda
- Diseño de promociones personalizadas por segmento
- Reorganización de productos en tienda según asociaciones
- Ajuste de horarios de personal según flujo de clientes

El EDA permitió tomar decisiones informadas que impactaron positivamente en ventas y eficiencia operativa.



EDA en la era del Big Data

El análisis exploratorio enfrenta nuevos desafíos y oportunidades con el crecimiento exponencial de datos:

- Necesidad de técnicas escalables
- Visualizaciones interactivas para explorar grandes volúmenes
- Combinación con técnicas de muestreo
- Uso de computación distribuida



Herramientas avanzadas para EDA



Dask y Vaex

Bibliotecas de Python para análisis exploratorio de grandes conjuntos de datos que no caben en memoria.



Plotly y Bokeh

Herramientas para crear visualizaciones interactivas que facilitan la exploración dinámica.



Apache Spark

Framework para procesamiento distribuido que permite EDA en conjuntos de datos masivos.


EDA automatizado

Herramientas que automatizan parte del proceso exploratorio:

- Pandas Profiling
- Sweetviz
- DataPrep
- AutoViz

Estas herramientas generan informes completos con visualizaciones y estadísticas, acelerando la fase inicial de exploración.

kunter 1.0	Sptices	
10	1,000	
Site-Mosch.	Blucotic pititer	Bartinator rove
120	1.2. %	0
Quantife for onnuary		Alcries record
93.2 kB		95 B




Missing values



Columns

Tijue	District	Missing	Historpam
stdftige eof	1-100N04	0 %	
Variable 1	8.44001E-09	258 %	
Variable 4	0.100101	872 %	
mample	2.0 roaces	84.0 %	
Variable 4	100 roaces	70 %	
Variable 3	100 roaces	0.51 %	
Variable 0	100 roaces	47.0 %	

Correlations



Limitaciones del EDA automatizado

- No sustituye el conocimiento del dominio y la interpretación humana
- No siempre adapta las visualizaciones al tipo específico de datos
- Puede pasar por alto relaciones complejas o contextuales
- Puede generar demasiada información, dificultando identificar lo relevante



El futuro del EDA

Inteligencia artificial asistida

Sistemas que sugieren visualizaciones y análisis relevantes basados en el tipo de datos

Realidad virtual y aumentada

Nuevas formas de visualizar y explorar datos en entornos inmersivos


Análisis en tiempo real

Exploración de datos en streaming para decisiones inmediatas

Habilidades clave para EDA efectivo

Conocimiento técnico
Dominio de herramientas y métodos estadísticos

Comunicación
Capacidad para explicar hallazgos a diferentes audiencias



Pensamiento crítico
Capacidad para cuestionar y validar hallazgos

Curiosidad
Disposición para explorar diferentes ángulos

Visualización
Habilidad para representar datos de forma efectiva



Resumen: El valor del EDA

El análisis exploratorio de datos (EDA) es mucho más que una etapa preliminar: es una herramienta esencial para desarrollar una comprensión profunda, crítica y visual de cualquier conjunto de datos. Lejos de limitarse a estadísticas simples, el EDA permite detectar errores, descubrir relaciones significativas, plantear hipótesis y tomar decisiones informadas antes de realizar modelados o reportes formales. Esta exploración inicial sienta las bases para un análisis más robusto y confiable.

Importancia de distinguir IDA y EDA

Distinguir correctamente entre el **análisis inicial de datos (IDA)** y el **EDA** permite estructurar mejor el proceso de trabajo: primero asegurar la calidad y limpieza del dataset, y luego aplicar técnicas exploratorias para obtener valor e interpretar su estructura interna.

Este orden lógico y metodológico permite evitar errores frecuentes como usar datos incompletos, interpretar mal una variable o construir modelos basados en suposiciones falsas.





Dominio de técnicas de análisis

Finalmente, dominar tanto el análisis **univariado** como el **multivariado**, y utilizar herramientas como Python, R o Power BI de forma adecuada, permite a los profesionales del dato desenvolverse con solvencia en proyectos reales. El EDA no es solo una etapa técnica: es un espacio para pensar, visualizar y conectar con los datos. Aplicarlo correctamente es una muestra de madurez profesional en el análisis y gestión de la información.



Momento:

Time-out!



5 -10 min.





Ejercicio

¿Qué técnica usarías?

¿Qué técnica usarías?

Contexto: 🙌

Una cadena de tiendas te comparte datos de productos, ventas, clientes y fechas. Buscan optimizar promociones y logística, pero no saben por dónde empezar. Vos estás a cargo del análisis exploratorio.

Consigna: 📝

- Realice un análisis teórico donde:
- Identifique qué tipo de variables tenés (categóricas, numéricas, temporales).
- Propongas una técnica de análisis univariado y una multivariada para explorar esos datos.
- Justifique por qué cada técnica es adecuada.
- Reflexiones sobre qué herramientas utilizarías y por qué.

Paso a paso: ⚙️

1. Clasifique las variables del caso.
2. Describe una técnica univariada útil (ej: boxplot, frecuencia, gráfico de barras).
3. Describe una técnica multivariada adecuada (ej: scatter plot, heatmap, clustering).
4. Elige una herramienta y explica cómo te ayudaría.
5. Concluye con una reflexión personal: ¿por qué el EDA es esencial antes de modelar?

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Aprendimos a diferenciar y aplicar técnicas univariadas y multivariadas**
- ✓ **Reconocimos las visualizaciones más usadas en análisis de relaciones**
- ✓ **Exploramos herramientas como Pandas Profiling, Plotly y Vaex**
- ✓ **Vimos buenas prácticas del EDA en casos reales**
- ✓ **Reflexionamos sobre errores comunes y la importancia del orden metodológico**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

