



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Conceptos básicos de estadística descriptiva- Parte II

Aprendizaje Esperado 2: Aplicar los conceptos fundamentales de estadística descriptiva para la caracterización de un conjunto de datos a partir de un problema dado.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

2.

Aplicar conceptos
fundamentales de
estadística descriptiva

Profundizaremos en las herramientas que permiten comprender la dispersión, posición y representación visual de un conjunto de datos. Aplicaremos estos recursos para detectar comportamientos, identificar valores atípicos y mejorar la interpretación de los resultados.

Medidas de posición y
puntos atípicos

Cuartiles, quintiles,
deciles y
percentiles

Detección de
outliers (IQR,
boxplot, Z-score)

Representación gráfica

Histogramas

Boxplots



Objetivos de aprendizaje

¿Qué aprenderás?



- Aplicar correctamente la corrección de Bessel en cálculos de varianza muestral.
- Calcular e interpretar medidas de posición como cuartiles, deciles y percentiles.
- Detectar valores atípicos mediante el método del rango intercuartílico, visual y Z-score.
- Construir e interpretar histogramas y boxplots para representar la distribución de datos.
- Analizar la utilidad de estas herramientas para caracterizar un conjunto de datos.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Identificamos los tipos de variables estadísticas y las clasificamos correctamente.
- Construimos tablas de frecuencia para organizar y representar datos.
- Calculamos medidas de tendencia central: media, mediana y moda.
- Analizamos un conjunto de datos simulados para interpretar su comportamiento central.

CONCEPTOS BÁSICOS DE ESTADÍSTICA DESCRIPTIVA

Corrección de Bessel

Cuando se trabaja con una muestra, los cálculos estadísticos deben ajustarse para evitar sesgos. Aquí entra en juego la **corrección de Bessel**.

Esta corrección consiste en dividir por $n-1$ en lugar de por n al calcular la varianza, lo que compensa el hecho de que las muestras tienden a subestimar la variabilidad real de la población.

$$s = \sqrt{\frac{\sum (x - \bar{x})^2}{n - 1}}$$

Ejemplo Práctico: Corrección de Bessel

Análisis del tiempo promedio que tardan 5 personas en completar una tarea: 12, 14, 15, 13 y 16 minutos.

Media = 14

Varianza muestral (con Bessel):

$$s^2 = \frac{(12 - 14)^2 + (14 - 14)^2 + (15 - 14)^2 + (13 - 14)^2 + (16 - 14)^2}{5 - 1} = \frac{10}{4} = 2.5$$

Importancia de la Corrección de Bessel

Análisis Riguroso

El uso correcto de la corrección de Bessel marca la diferencia entre un análisis riguroso y uno que podría conducir a decisiones erróneas.

Muestras Pequeñas

Es especialmente crucial en estudios con muestras pequeñas, donde la subestimación de la variabilidad podría afectar conclusiones importantes.

Base para Inferencia


Proporciona una base crítica para que todo el análisis estadístico posterior sea confiable y replicable.

Medidas de Posición

Las **medidas de posición** son herramientas estadísticas que permiten dividir un conjunto de datos ordenados en partes iguales para ubicar una observación relativa dentro de su contexto.

PERCENTILES AN QUARTILES

Statistical Position Measures



Tipos de Medidas de Posición



Cuartiles

Dividen los datos en cuatro partes iguales:

- Q1: primer cuartil, representa el 25% de los datos
- Q2: segundo cuartil, coincide con la mediana (50%)
- Q3: tercer cuartil, representa el 75%



Quintiles

Dividen los datos en cinco partes iguales (20% cada una)



Deciles

Dividen los datos en diez partes iguales (10% cada una)

4

Percentiles

Dividen el conjunto en 100 partes iguales (1% cada una)

Ejemplo Aplicado: Tiempos de Entrega

Tiempos de entrega de un servicio (en días) para 20 clientes:

2, 2, 3, 3, 3, 4, 4, 5, 5, 6, 6, 6, 7, 7, 8, 9, 10, 10, 12, 14

4

Q1 (25%)

El 25% de los clientes
recibieron su pedido en 4 días
o menos

6

Q2 (50%)

La mediana es 6 días

9

Q3 (75%)

El 75% de los clientes
recibieron su pedido en 9 días
o menos

12

Percentil 90

El 90% de los clientes
recibieron su pedido en 12
días o menos

Cuadro Comparativo de Medidas de Posición

Medida	División	Interpretación	Aplicación común
Cuartil	4 partes	Posición relativa (25%, 50%, 75%)	Comparar salarios, calificaciones
Quintil	5 partes	Segmentos del 20%	Estudios sociales, segmentación
Decil	10 partes	10% por grupo	Análisis de ingresos o desempeño
Percentil	100 partes	Precisión fina (P1 a P99)	Educación, salud, logística


Puntos Atípicos (Outliers)

Los **puntos atípicos** o **outliers** son valores que se encuentran significativamente alejados del resto de los datos.

Su presencia puede indicar:

- Un error de medición
- Una entrada incorrecta
- Una variación natural y válida dentro del conjunto

Detectarlos es crucial porque pueden alterar drásticamente los resultados de análisis estadísticos como la media, la desviación estándar y las regresiones.



Detección de Outliers

Método del Rango Intercuartílico

Se calcula el **rango intercuartílico (IQR)** como $Q3 - Q1$.

Se considera outlier cualquier valor que esté:

- Por debajo de $Q1 - 1.5 \times IQR$
- Por encima de $Q3 + 1.5 \times IQR$

Métodos Visuales

Utilizando un **boxplot** (diagrama de caja), donde los puntos fuera de los "bigotes" del gráfico suelen representar valores atípicos.

Z-Score

Evalúa cuántas desviaciones estándar se aleja un valor respecto a la media. Valores con $z > 3$ o $z < -3$ usualmente se consideran extremos.

Ejemplo Aplicado: Ingresos Mensuales

En un conjunto de ingresos mensuales: \$800, \$850, \$880, \$890, \$900, \$910, \$920, \$930, \$10,000




Sin outlier

- Media = \$896.25
- Mediana = \$905
- Desviación estándar = Baja

Con outlier (\$10,000)

- Media = \$1,776.67
- Mediana = \$905
- Desviación estándar = Mucho más alta

La mayoría de los valores se agrupan alrededor de los \$900, pero hay uno (\$10,000) que es claramente un outlier. Este valor aumenta la media significativamente, haciendo que el promedio no sea representativo del grupo.



Representación Gráfica

Las representaciones gráficas son una herramienta clave en estadística descriptiva, ya que permiten visualizar rápidamente la distribución y características de un conjunto de datos.


Histograma

Un **histograma** es un gráfico de barras donde el eje horizontal representa los intervalos de valores (clases) y el eje vertical la frecuencia (absoluta o relativa).

Es ideal para variables numéricas continuas, ya que muestra la forma de la distribución (simétrica, sesgada, uniforme, etc.) y permite detectar acumulaciones o huecos de datos.

No debe confundirse con el gráfico de barras: el histograma trabaja con intervalos y **las barras están unidas**, porque representa continuidad.

FREQUENCY DISTRIBUTION OF CONTINUOUS DATA




Boxplot (Diagrama de Caja)

Un **boxplot** resume cinco estadísticas importantes:

- El mínimo
- Q1 (primer cuartil)
- Mediana (Q2)
- Q3 (tercer cuartil)
- El máximo

Visualmente representa una "caja" entre Q1 y Q3, con una línea en la mediana, y dos líneas ("bigotes") que se extienden hasta los valores mínimos y máximos dentro del rango aceptado. Cualquier valor fuera de los bigotes se representa como puntos, los cuales se consideran **outliers**.



Ejemplo Práctico: Histograma Comparativo


Histograma comparativo de los puntajes de tres cursos:

Curso A se agrupa alrededor del puntaje 70.

Curso B presenta una distribución más amplia, extendida hacia valores más altos.

Curso C se concentra más estrechamente en valores cercanos a 65.

Este gráfico permite observar **cómo se distribuyen los datos dentro de cada grupo** y detectar fácilmente si hay concentraciones, simetrías o dispersiones distintas.



Ejemplo Práctico: Boxplot Comparativo


Boxplot comparativo para el ejemplo práctico:

Curso A: distribución más estable, centrada en 70 con poca variación.

Curso B: mayor dispersión y presencia de algunos valores más extremos.

Curso C: puntajes más concentrados, con menor varianza que los otros dos.

Este gráfico permite **visualizar de forma clara cuál curso tiene mayor variabilidad, si hay valores atípicos y cómo se comparan las medianas entre grupos.**



Comparación entre Histograma y Boxplot

Característica	Histograma	Boxplot
Tipo de datos	Cuantitativos continuos	Cuantitativos (distribución resumida)
Información mostrada	Frecuencia de clases	Mediana, cuartiles, outliers
Ideal para	Ver forma de la distribución	Comparar grupos o detectar atípicos

Aplicaciones Prácticas



Ciencia

Análisis de resultados experimentales, estudios clínicos, investigación básica



Salud

Estudios epidemiológicos, análisis de tratamientos, seguimiento de pacientes



Negocios

Análisis de ventas, comportamiento del consumidor, rendimiento financiero



Tecnología

Análisis de rendimiento, comportamiento de usuarios, optimización de sistemas


El dominio de estos conceptos resulta fundamental para cualquier disciplina que trabaje con datos.

Ecommerce Sales Data Analysis

Ecommerce Sales Data Analysis

Probbroad

Sales Overview



Revenue

1103,202

+15.3%

Orders

3,274

+173%

Customers


1,982

+4.4%


Sales by Region





Sales by Category



Orders



Sales by Category



Caso de Estudio: Análisis de Ventas

Escenario

Una empresa de comercio electrónico desea analizar sus ventas mensuales del último año para identificar patrones y tendencias.

Datos disponibles

- Ventas mensuales en dólares
- Número de transacciones por mes
- Categorías de productos vendidos
- Ubicación geográfica de los compradores

Análisis de Ventas: Variables Identificadas


Variables Cuantitativas

- Monto de ventas mensuales (continua)
- Número de transacciones (discreta)
- Valor promedio por transacción (continua)
- Tiempo entre compras (continua)

Variables Categóricas

- Categoría de producto (nominal)
- Ubicación geográfica (nominal)
- Nivel de satisfacción del cliente (ordinal)
- Método de pago (nominal)

Análisis de Ventas: Medidas de Tendencia Central



51667

Media
Ventas promedio mensuales


50000

Mediana
Valor central de ventas

8712

Desviación
Variabilidad de ventas

Análisis de Ventas: Distribución por Categoría



■ Electrónica

■ Ropa

■ Hogar

■ Deportes

■ Libros

La categoría de Electrónica representa el mayor porcentaje de ventas (35%), seguida por Ropa (25%) y Hogar (20%). Las categorías de Deportes y Libros tienen una participación menor, con 12% y 8% respectivamente.


Análisis de Ventas:

Detección de Outliers

Al analizar las transacciones individuales, se identificaron algunos valores atípicos que podrían afectar el análisis:

- Una compra corporativa de \$25,000 en marzo
- Tres devoluciones por productos defectuosos en febrero
- Una promoción especial en junio que generó un pico de ventas

Utilizando el método del rango intercuartílico, se confirmó que estos valores están fuera del rango normal de transacciones.



Análisis de Ventas: Conclusiones

Tendencia Creciente

Las ventas muestran una tendencia al alza durante el período analizado, con un crecimiento promedio mensual del 8%.

Concentración por Categoría

Tres categorías (Electrónica, Ropa y Hogar) representan el 80% de las ventas totales.

Estacionalidad

Se observa un incremento significativo en las ventas durante los meses de mayo y junio.

Valores Atípicos

Los outliers identificados tienen explicaciones específicas y no representan errores en los datos.

Caso de Estudio: Análisis de Rendimiento Académico

Escenario


Una institución educativa desea analizar el rendimiento de sus estudiantes en diferentes asignaturas para identificar áreas de mejora.

Datos disponibles

- Calificaciones por asignatura
- Horas de estudio semanales
- Asistencia a clases
- Nivel socioeconómico




Análisis Académico: Distribución de Calificaciones



La distribución de calificaciones muestra una forma aproximadamente normal, con la mayoría de los estudiantes obteniendo calificaciones entre 7 y 8. Hay menos estudiantes en los extremos (calificaciones muy bajas o muy altas).

Análisis Académico: Relación Horas de Estudio y Calificaciones



Se observa una clara correlación positiva entre las horas dedicadas al estudio y las calificaciones obtenidas. Sin embargo, el incremento en las calificaciones tiende a ser menos pronunciado a medida que aumentan las horas de estudio.

Análisis Académico: Comparación por Asignaturas



Matemáticas

Mayor dispersión en las calificaciones
(desviación estándar = 2.1)
Mediana: 7.0



Ciencias

Distribución más homogénea (desviación
estándar = 1.5)
Mediana: 7.8



Humanidades

Calificaciones generalmente más altas
(desviación estándar = 1.3)
Mediana: 8.2

Las asignaturas de Humanidades muestran las calificaciones más altas y la menor dispersión, mientras que Matemáticas presenta mayor variabilidad en los resultados.

Análisis Académico: Conclusiones

Correlación Estudio-Rendimiento

Existe una relación directa entre las horas de estudio y las calificaciones obtenidas, con un punto de rendimiento decreciente después de 9-11 horas semanales.

Diferencias por Asignatura

Las asignaturas de Matemáticas requieren atención especial debido a la mayor dispersión en las calificaciones, lo que sugiere diferentes niveles de dificultad para los estudiantes.

Distribución Normal

La distribución general de calificaciones sigue aproximadamente una curva normal, lo que indica una evaluación equilibrada.

Áreas de Mejora

Se recomienda implementar programas de apoyo específicos para estudiantes con calificaciones en el rango 0-4, que representan aproximadamente el 17% del total.

Resumen de Conceptos Clave

Tipos de Variables


Categóricas (nominales, ordinales) y
cuantitativas (discretas, continuas)

Representación Gráfica

Histogramas y boxplots para visualizar
distribuciones

Medidas de Posición

Cuartiles, quintiles, deciles y percentiles para
ubicar observaciones



Tablas de Frecuencia

Organización de datos mediante frecuencias
absolutas, relativas y acumuladas

Medidas de Tendencia Central

Media, mediana y moda como valores
representativos

Medidas de Dispersión

Rango, varianza y desviación estándar para
evaluar variabilidad

Conclusiones

La estadística descriptiva proporciona herramientas fundamentales para:

- Comprender y resumir conjuntos de datos complejos
- Identificar patrones, tendencias y valores atípicos
- Comunicar hallazgos de manera clara y efectiva
- Sentar las bases para análisis estadísticos más avanzados

El dominio de estos conceptos resulta esencial en cualquier campo que trabaje con datos, desde la investigación científica hasta los negocios, la salud y la tecnología.



Live Coding

¿En qué consistirá la Demo?

Durante esta demo el mentor usará un pequeño conjunto de datos (por ejemplo, puntajes de estudiantes o ingresos mensuales) para:

1. Calcule Q1, Q3 e IQR (rango intercuartílico).
2. Identifique si hay valores fuera del rango normal mediante la fórmula:
 - ♦ Inferior: $Q1 - 1.5 \times IQR$
 - ♦ Superior: $Q3 + 1.5 \times IQR$
3. Visualice los resultados con un boxplot (en papel o digital).
4. Interprete el gráfico y reflexione con el grupo:
 - ¿Ese outlier afecta la media?
 - ¿Es un error, o una observación válida?
5. Concluye si es necesario eliminarlo o considerarlo relevante en el análisis.



Momento:

Time-out!



5 -10 min.





Ejercicio

Detectando variabilidad y valores atípicos en un entorno educativo

Detectando variabilidad y valores atípicos en un entorno educativo

Contexto: 🙌

Una institución educativa está evaluando los resultados de tres materias en su programa. Se desea analizar la distribución de calificaciones para identificar materias con mayor dispersión, detectar posibles valores atípicos y proponer mejoras basadas en la caracterización de los datos.

Consigna: 📝

1. Genere datos para el análisis
2. Calcule el rango intercuartílico (IQR) de cada materia.
3. Identifique valores atípicos utilizando el método de $Q1 - 1.5 \times IQR$ y $Q3 + 1.5 \times IQR$.
4. Construye un boxplot comparativo entre materias.
5. Analice e interprete:

- ¿Que materia tiene mayor dispersión?

- ¿Cual presenta más valores extremos?

- ¿Que medida de tendencia central representa mejor cada conjunto?

Tiempo 🕒: 45 Minutos

Detectando variabilidad y valores atípicos en un entorno educativo

Paso a paso:

1. Ordene los datos de cada materia.
2. Calcule Q1, Q3 e IQR.
3. Determine los valores límite para detectar outliers.
4. Construye boxplots (puede ser digital o en hoja).
5. Redacte un breve informe interpretativo.

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Aplicamos la corrección de Bessel para calcular correctamente la varianza en una muestra.**
- ✓ **Calculamos e interpretamos medidas de posición como cuartiles, deciles y percentiles.**
- ✓ **Detectamos valores atípicos utilizando el método del rango intercuartílico (IQR).**
- ✓ **Representamos los datos con boxplots e histogramas para visualizar su distribución.**
- ✓ **Comparamos la dispersión y asimetría entre diferentes conjuntos de datos.**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

