



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Correlación - Parte I

Aprendizaje Esperado 3: Aplicar los conceptos de correlación para la caracterización de un conjunto de datos de una población a partir de un problema dado.


Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

3.

Aplicación de técnicas de correlación para el análisis de relaciones entre variables.

Aprenderemos a detectar relaciones entre variables a través del análisis de correlación. Trabajaremos con representaciones visuales y cálculos estadísticos que nos permitirán identificar patrones en los datos y evaluar su fuerza, dirección e interpretación.

Introducción a la correlación de variables

Tema 2

Tipos de correlación: positiva, negativa y nula.

Correlación vs. causalidad: ¿cómo distinguirlas?

Diagramas de dispersión (scatterplots) y tablas de contingencia.

Cálculo e interpretación del coeficiente de correlación de Pearson (R).

Objetivos de aprendizaje

¿Qué aprenderás?

- Comprender el concepto de correlación y sus distintos tipos.
- Representar gráficamente relaciones entre variables mediante scatterplots.
- Calcular e interpretar el coeficiente de correlación de Pearson.
- Distinguir entre correlación y causalidad.
- Detectar correlaciones espurias mediante pensamiento crítico.

Repaso clase anterior

¿Quedó alguna duda?


En la clase anterior trabajamos :

- Cómo representar datos con *histogramas* y *boxplots*.
- La utilidad de las medidas de *tendencia central* y *dispersión*.
- Cómo identificar *puntos atípicos* en un conjunto de datos.
- Cuándo aplicar cada tipo de gráfico para caracterizar datos numéricos.

Correlación

Correlación: Análisis de Relaciones entre Variables

La correlación es una herramienta estadística que permite analizar la relación entre dos variables cuantitativas. Comprender si existe una asociación entre variables —y cómo se comporta— es clave para caracterizar conjuntos de datos en estudios de salud, economía, ciencias sociales, educación y más.




¿Qué es la correlación?

La correlación es una herramienta estadística que permite analizar la relación entre dos variables cuantitativas. Evalúa si al cambiar una de ellas, la otra tiende a cambiar también, y en qué dirección. Esta relación puede ser:

- Positiva: ambas variables aumentan o disminuyen juntas.
- Negativa: una variable aumenta mientras la otra disminuye.
- Nula: no se observa una relación clara entre ambas.

La correlación no implica causalidad, es decir, aunque dos variables estén relacionadas, no significa que una cause la otra. Es un punto de partida para generar hipótesis y explorar tendencias.

CORRELATION CONCEPT DIAGRAM



Tipos de correlación

1

Correlación Positiva

Ambas variables aumentan o disminuyen juntas.

Ejemplo: Horas de estudio y nota de examen

2

Correlación Negativa

Una variable aumenta mientras la otra disminuye.

Ejemplo: Temperatura y consumo de calefacción

3

Correlación Nula

No hay relación clara entre las variables.

Ejemplo: Número de zapatos y nivel de estrés

Visualización de correlaciones

El siguiente conjunto de gráficos muestra ejemplos claros de los tres tipos principales de correlación:

- Izquierda: Correlación positiva — los puntos siguen una tendencia ascendente.
- Centro: Correlación negativa — la nube de puntos desciende.
- Derecha: Sin correlación — los puntos están completamente dispersos.




Estas visualizaciones ayudan a identificar rápidamente patrones en conjuntos de datos y son especialmente útiles en la etapa de análisis exploratorio.

Ejemplos visuales de correlación

```
import numpy as np
import matplotlib.pyplot as plt

np.random.seed(0)
x = np.linspace(0, 10, 50)
y_pos = 2 * x + np.random.normal(0, 2, 50)
y_neg = -2 * x + np.random.normal(0, 2, 50)
y_none = np.random.normal(10, 5, 50)

fig, ax = plt.subplots(1, 3, figsize=(18, 5))
ax[0].scatter(x, y_pos, color='green')
ax[0].set_title("Correlación positiva")
ax[1].scatter(x, y_neg, color='red')
ax[1].set_title("Correlación negativa")
ax[2].scatter(x, y_none, color='gray')
ax[2].set_title("Sin correlación")
plt.tight_layout()
plt.show()
```



Correlación positiva


Características

En una correlación positiva, ambas variables aumentan o disminuyen conjuntamente. Esto crea una tendencia ascendente en el gráfico de dispersión.


Cuando una variable crece, la otra también tiende a crecer. Esta relación puede ser fuerte (puntos muy alineados) o débil (puntos más dispersos).

Ejemplos comunes incluyen:

- Altura y peso en personas
- Horas de práctica y rendimiento
- Ingresos y gastos



Negative Correlation



Correlación negativa

Características

En una correlación negativa, cuando una variable aumenta, la otra tiende a disminuir. Esto crea una tendencia descendente en el gráfico de dispersión.

Esta relación inversa puede ser fuerte (puntos muy alineados en diagonal descendente) o débil (puntos más dispersos pero con tendencia a la baja).

Ejemplos comunes incluyen:

- Precio y demanda de un producto
- Temperatura exterior y consumo de calefacción
- Edad de un vehículo y su valor de reventa

Correlación nula


Características

En una correlación nula, no existe una relación clara entre las variables. Los puntos aparecen dispersos sin formar ningún patrón reconocible.

Cuando una variable cambia, la otra puede aumentar, disminuir o mantenerse igual sin seguir ninguna tendencia específica.

Ejemplos comunes incluyen:

- Número de zapatos y coeficiente intelectual
- Color de cabello y velocidad al correr
- Número de hermanos y preferencia musical



Tablas de contingencia

Las tablas de contingencia son una herramienta fundamental en el análisis exploratorio de datos categóricos. Permiten observar cómo se distribuyen dos variables cualitativas entre sí. Son especialmente útiles para identificar asociaciones o patrones entre grupos o categorías. Cada celda de la tabla muestra el número de observaciones que comparten una combinación específica de categorías entre dos variables. También pueden incluir porcentajes por fila, columna o total, para facilitar la interpretación.

Contingency Table

		Category 2		
		X	Y	Z
Category1	A	5	7	9
	B	3	8	2
	C	4	6	7

Ejemplo de tabla de contingencia

Supongamos que realizamos una encuesta a 10 personas preguntándoles su preferencia de transporte y su género. Los datos se resumen en la siguiente tabla de contingencia:

Género	Auto	Bicicleta	Bus
Femenino	1	1	2
Masculino	2	1	1
Otro	1	1	0

Esta tabla muestra cuántas personas de cada género prefieren cada tipo de transporte. Por ejemplo, 2 hombres prefieren auto, 2 mujeres eligen bus, y no hay personas del género "otro" que hayan elegido bus.

Representación gráfica de tablas de contingencia

La tabla de contingencia también puede visualizarse mediante un gráfico de barras apiladas. Este tipo de gráfico permite comparar categorías y observar rápidamente qué grupo presenta mayor preferencia por cada opción.

En este ejemplo, se puede ver que:

- El bus es preferido por más mujeres.
- El auto es más elegido por hombres.
- Bicicleta tiene una distribución equilibrada.

Estas observaciones son valiosas para entender comportamientos o segmentar audiencias.

```
import pandas as pd
import matplotlib.pyplot as plt

data = {
    "Preferencia": ["Auto", "Auto", "Bus", "Bicicleta", "Bus", "Bicicleta", "Auto", "Bus", "Auto", "Bicicleta"],
    "Género": ["Masculino", "Femenino", "Femenino", "Masculino", "Masculino", "Femenino", "Otro", "Femenino", "Masculino", "Otro"]
}


df = pd.DataFrame(data)
contingencia = pd.crosstab(df["Género"], df["Preferencia"])

contingencia.plot(kind='bar', stacked=True, colormap='Paired')
plt.title("Preferencia de transporte por género")
plt.xlabel("Género")
plt.ylabel("Cantidad")
plt.tight_layout()
plt.show()
```

Visualización de datos categóricos

Los gráficos de barras apiladas son especialmente útiles cuando queremos:

- Comparar la distribución de una variable entre diferentes categorías
- Visualizar proporciones relativas dentro de cada categoría
- Identificar patrones o tendencias en datos categóricos
- Presentar resultados de encuestas o estudios demográficos




Diagramas de dispersión (scatterplot)

El scatterplot o diagrama de dispersión es una herramienta gráfica clave en el análisis de correlación. Permite representar la relación entre dos variables numéricas. Cada punto del gráfico representa una observación: su posición horizontal indica el valor de una variable, y su posición vertical el valor de otra.

Este tipo de gráfico es útil para:

- Detectar relaciones (lineales o no lineales)
- Identificar patrones ascendentes, descendentes o nulos
- Visualizar outliers o valores atípicos
- Prever posibles correlaciones para cuantificar luego



Ejemplo de datos para scatterplot

A continuación, se muestra un fragmento de un conjunto de datos donde se analizan las horas de estudio y la nota obtenida en un examen:

Horas de estudio	Nota en el examen
4.75	22.90
7.48	33.03
1.00	5.22
3.72	21.52
2.32	6.10

Estos datos corresponden a una simulación donde la nota tiende a aumentar con las horas de estudio, aunque existe algo de dispersión debido a factores aleatorios (como motivación, salud, etc.).

Visualización de datos en scatterplot

El gráfico de dispersión presentado arriba muestra:

- Cada punto representa un estudiante.
- El eje X indica las horas de estudio.
- El eje Y muestra la nota obtenida.
- La línea azul representa la tendencia lineal, indicando una correlación positiva.

Esta representación visual permite observar que a mayor cantidad de estudio, la nota tiende a subir, aunque con variabilidad. Es un ejemplo clásico de correlación positiva moderada/fuerte.

```
import seaborn as sns

np.random.seed(1)
horas = np.random.uniform(1, 10, 30)
nota = 5 * horas + np.random.normal(0, 5, 30)
df = pd.DataFrame({"Horas de estudio": horas, "Nota en el examen": nota})

sns.regplot(data=df, x="Horas de estudio", y="Nota en el examen", scatter_kws={"color": "orange"}, line_kws={"color": "blue"})
plt.title("Relación entre horas de estudio y nota de examen")
plt.grid(True)
plt.show()
```


Scatterplot con línea de tendencia

La línea de tendencia (también llamada línea de regresión) es una herramienta visual que:

- Resume la relación general entre las variables
- Indica la dirección de la correlación (positiva o negativa)
- Permite estimar valores de una variable basados en la otra
- Ayuda a visualizar la fuerza de la relación (cuanto más cerca están los puntos de la línea, más fuerte es la correlación)



Interpretación de scatterplots



Forma

Observa si los puntos siguen un patrón lineal, curvilíneo o no tienen patrón.

La forma indica el tipo de relación entre las variables.

Dirección

Determina si la tendencia es ascendente (positiva), descendente (negativa) o sin dirección clara (nula).

Fuerza

Evalúa qué tan cerca están los puntos de seguir un patrón perfecto. Puntos muy dispersos indican correlación débil.

Outliers


Identifica puntos que se alejan significativamente del patrón general, pues pueden afectar la interpretación.

Coeficiente de correlación de Pearson (R)

El coeficiente de correlación de Pearson mide la fuerza y dirección de la relación lineal entre dos variables numéricas. Su valor varía entre -1 y 1:

- +1 → relación positiva perfecta
- 0 → sin relación lineal
- -1 → relación negativa perfecta

Este coeficiente permite cuantificar lo que vemos en un gráfico de dispersión. Se basa en la covarianza de las variables, estandarizada por sus desviaciones estándar, lo que lo hace insensible a la escala de los datos.



Cálculo del coeficiente de correlación

A partir del conjunto de datos anterior (horas de estudio vs. nota de examen), obtuvimos el siguiente resultado:

Indicador	Valor
Coeficiente de correlación (R)	0.96
Significado	Relación positiva fuerte

Este valor de 0.96 indica que existe una fuerte correlación positiva entre las horas de estudio y las calificaciones. Es decir, los estudiantes que estudiaron más horas tienden a obtener mejores resultados.

Interpretación del coeficiente de correlación

Correlación fuerte (0.7 a 1.0)

Los puntos se agrupan muy cerca de la línea de tendencia, indicando una relación consistente y predecible.

Correlación moderada (0.4 a 0.7)

Existe un patrón visible pero con mayor dispersión. La relación es notable pero menos predecible.

Correlación débil (0.1 a 0.4)

Hay una ligera tendencia pero con mucha variabilidad. La relación existe pero es tenue.

Sin correlación (0 a 0.1)

No existe un patrón discernible entre las variables. Los cambios en una no afectan a la otra.

Nota: Los mismos rangos aplican para correlaciones negativas (de -0.1 a -1.0).

Interpretación práctica

Una correlación de 0.96 implica que los puntos en el scatterplot se alinean de forma bastante cercana a una recta ascendente. Esto sugiere una tendencia consistente: a medida que aumenta una variable (estudio), también lo hace la otra (nota).

En contextos prácticos, este tipo de resultado puede utilizarse para:



Identificar predictores fuertes

Variables que pueden ayudar a anticipar el comportamiento de otras



Construir modelos de regresión

Desarrollar ecuaciones que permitan predecir valores futuros



Establecer estrategias de mejora

Por ejemplo, incentivar el tiempo de estudio para mejorar el rendimiento académico

Correlación vs. Causalidad

Una de las confusiones más comunes en el análisis de datos es asumir que una correlación implica causalidad. La correlación solo indica que existe una asociación entre dos variables, mientras que la causalidad implica que un cambio en una variable produce directamente un cambio en la otra.


Correlación $\neq$ Causalidad

Que dos variables se mueven juntas no significa que una cause la otra.


Es fundamental distinguir entre:

- A causa B (causalidad directa)
- B causa A (causalidad inversa)
- C causa tanto A como B (variable confusora)
- Coincidencia estadística (correlación espuria)

CORRELATION



CAUSATION



Ejemplo de correlación espuria

En el gráfico que se muestra arriba, vemos cómo las ventas de helado y los casos de ahogamiento parecen aumentar y disminuir en los mismos días del mes. Es posible que, al calcular el coeficiente de correlación entre ambas variables, obtengamos un valor alto y positivo.

Sin embargo, esto no significa que el consumo de helado cause ahogamientos. En realidad, ambas variables están influenciadas por una tercera variable oculta: el calor del verano. Esta relación no causal es un ejemplo clásico de lo que se conoce como correlación espuria.

```
dias = np.arange(1, 31)
helado = 100 + 15 * np.sin(dias / 2) + np.random.normal(0, 5, 30)
ahogo = 3 + 2 * np.sin(dias / 2) + np.random.normal(0, 1, 30)
df = pd.DataFrame({"Dia": dias, "Helado": helado, "Ahogamiento": ahogo})

plt.plot(df["Dia"], df["Helado"], label="Ventas de helado", marker='o')
plt.plot(df["Dia"], df["Ahogamiento"], label="Casos de ahogamiento", marker='s')
plt.title("Ejemplo de correlación espuria")
plt.legend()
plt.grid(True)
plt.show()
```

Datos de correlación espuria


Veamos algunos datos que muestran esta correlación aparente:

Día	Ventas de helado	Casos de ahogamiento
1	109.67	3.36
2	111.93	6.54
3	118.20	4.98
4	121.25	3.76
5	107.80	5.02

Aunque los números sugieren una relación, el factor causal real (temperatura) no está visible en estos datos.

Visualización de correlación espuria

Este gráfico muestra cómo dos variables pueden moverse juntas sin tener una relación causal directa. La temperatura alta del verano causa:



Más ventas de helado


- Mayor apetito por alimentos fríos
- Más personas en las calles
- Mayor actividad comercial al aire libre

Más casos de ahogamiento

- Mayor número de personas nadando
- Más visitas a playas y piscinas
- Más tiempo en actividades acuáticas

Otros ejemplos de correlaciones espurias

SPURIOUS CORRELATION EXAMPLES



Cigüeñas y nacimientos

En algunos países europeos, hay una correlación entre el número de cigüeñas y la tasa de natalidad. La variable oculta: las áreas rurales tienen más cigüeñas y, tradicionalmente, tasas de natalidad más altas.

Consumo de chocolate y premios Nobel

Existe una correlación entre el consumo de chocolate per cápita y el número de premios Nobel por país. Variable oculta: el desarrollo económico influye en ambos factores.

Películas de Nicolas Cage y ahogamientos

El número de películas protagonizadas por Nicolas Cage correlaciona con ahogamientos en piscinas. Pura coincidencia estadística sin relación real.

¿Cómo evitar este error?

Para establecer una relación de causalidad, se necesitan condiciones más rigurosas, como:



Diseño experimental

Realizar estudios controlados donde se manipula una variable y se observa el efecto en otra, manteniendo todo lo demás constante.



Evidencia temporal

Verificar que la causa potencial ocurre antes que el efecto, estableciendo una secuencia temporal clara.



Control de variables

Identificar y eliminar el efecto de variables confusoras o externas que puedan influir en ambas variables estudiadas.



Modelos estadísticos

Utilizar técnicas más complejas como regresión múltiple o análisis de covariables para aislar efectos específicos.

Importancia del pensamiento crítico

Este ejemplo demuestra que la correlación es una herramienta poderosa para detectar patrones, pero que debe ser usada con cuidado para evitar interpretaciones erróneas. Siempre que se observe una correlación, se deben considerar otros factores y no sacar conclusiones apresuradas.

El pensamiento crítico nos ayuda a:

- Cuestionar relaciones aparentes
- Buscar explicaciones alternativas
- Considerar variables ocultas
- Diseñar estudios más rigurosos



Live Coding

¿En qué consistirá la Demo?

Visualización e interpretación de correlación real

1. Explique qué es un scatterplot y para qué sirve.
2. Presente un dataset simple con dos variables: por ejemplo, horas de ejercicio semanal vs. nivel de energía diario.
3. Guíe a los estudiantes para que representen visualmente la relación con un gráfico de dispersión.
4. Pide calcular el coeficiente de correlación de Pearson.
5. Interprete el valor de R obtenido: ¿hay correlación fuerte? ¿moderada?
6. Discute posibles factores externos que podrían influir (¿es causal o espurio?).

Tiempo: 25 Minutos



Momento:

Time-out!



5 -10 min.





Ejercicio

**¿Cuánto se relacionan tus
hábitos diarios?**

¿Cuánto se relacionan tus hábitos diarios?

Contexto: 🙌

Un equipo de investigación en bienestar quiere conocer cómo se relacionan diferentes hábitos diarios (como horas de sueño, café consumido, uso de pantallas, actividad física) con la concentración en el trabajo. Para ello, encuestaron a 15 personas y registraron los datos durante una semana.

Consigna: 📝

A partir de los datos simulados, represente gráficamente las relaciones entre variables, calcule los coeficientes de correlación y analice si existe o no una relación significativa entre los hábitos registrados y el nivel de concentración.

🧩 Tu desafío es interpretar los resultados y reflexionar si hay correlación o solo coincidencia.

Tiempo 🕒: 45 Minutos

Paso a paso: ⚙️

1. Simule un DataFrame con estas columnas:
2. horas_sueño, cafes_por_día, uso_pantalla_hs, min_ejercicio, nivel_concentración
3. Represente las relaciones en gráficos de dispersión (scatterplot) para cada variable contra nivel_concentración.
4. Calcule el coeficiente de correlación de Pearson entre cada predictor y el nivel de concentración.
5. Identifique cuál es la relación más fuerte.
6. Reflexione: ¿hay causalidad o podría haber una variable oculta?

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Analizamos correlaciones positivas, negativas y nulas con ejemplos visuales.**
- ✓ **Interpretamos gráficos de dispersión con línea de tendencia.**
- ✓ **Calculamos el coeficiente R de Pearson y discutimos su significado.**
- ✓ **Exploramos casos de correlación espuria y aprendimos a evitarlos.**
- ✓ **Aprendimos a representar variables categóricas con tablas de contingencia.**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

