



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Correlación - Parte II

Aprendizaje Esperado 3: Aplicar los conceptos de correlación para la caracterización de un conjunto de datos de una población a partir de un problema dado.


Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

3.

Análisis de correlaciones en contextos avanzados

Profundizaremos en técnicas de correlación más allá del coeficiente de Pearson, explorando sus aplicaciones prácticas, limitaciones y variaciones según el tipo de datos. Se pondrá especial foco en cómo interpretar, visualizar y aplicar correlaciones de manera ética, crítica y contextualizada.

Correlación y su aplicación contextual

Correlación en investigación científica, salud, educación y marketing

Correlación en el mundo digital y machine learning

Técnicas y límites de la correlación

Correlación parcial, Spearman, tetracórica, ICC y canónica

Correlación en series temporales, espacial y multimodal



Objetivos de aprendizaje

¿Qué aprenderás?



- Identificar distintos tipos de correlación y su aplicación según el tipo de variable y contexto.
- Aplicar técnicas estadísticas como Spearman, correlación parcial y canónica.
- Reconocer y evaluar críticamente los límites del análisis de correlación.
- Explorar el uso ético y responsable de las correlaciones en entornos reales.
- Relacionar el análisis de correlación con disciplinas interdisciplinarias y escenarios contemporáneos.

Repaso clase anterior

¿Quedó alguna duda?

- ✓ Analizamos correlaciones positivas, negativas y nulas con ejemplos visuales.
- ✓ Interpretamos gráficos de dispersión con línea de tendencia.
- ✓ Calculamos el coeficiente R de Pearson y discutimos su significado.
- ✓ Exploramos casos de correlación espuria y aprendimos a evitarlos.
- ✓ Aprendimos a representar variables categóricas con tablas de contingencia.

Correlación

Aplicaciones prácticas de la correlación



Salud

Identificar factores de riesgo asociados con enfermedades, como la correlación entre presión arterial y riesgo cardiovascular.



Economía

Analizar relaciones entre indicadores económicos como inflación y desempleo, o tasas de interés e inversión.



Educación

Estudiar factores asociados con el rendimiento académico, como tiempo de estudio, asistencia o métodos de enseñanza.



Marketing

Descubrir relaciones entre comportamientos de compra y variables demográficas para segmentar mercados.

Correlación en investigación científica

Estudios observacionales


En muchos campos científicos, los estudios observacionales son el primer paso para identificar posibles relaciones causales. La correlación permite:

- Generar hipótesis para investigaciones futuras
- Identificar variables de interés para estudios experimentales
- Detectar patrones en grandes conjuntos de datos

Sin embargo, los científicos son cuidadosos al interpretar correlaciones, reconociendo que:

- La correlación es necesaria pero no suficiente para establecer causalidad
- Se requieren estudios adicionales para confirmar relaciones causales





Correlación en el mundo digital



Algoritmos de recomendación

Plataformas como Netflix o Spotify utilizan correlaciones entre preferencias de usuarios para recomendar contenido similar.



Motores de búsqueda

Google utiliza correlaciones entre términos de búsqueda y comportamiento de usuarios para mejorar resultados.



Publicidad dirigida

Las plataformas de redes sociales analizan correlaciones entre comportamientos para mostrar anuncios relevantes.



Detección de fraude

Los bancos identifican patrones correlacionados con actividades fraudulentas para proteger a sus clientes.

Limitaciones de la correlación

Relaciones no lineales

El coeficiente de Pearson solo mide relaciones lineales. Dos variables pueden tener una fuerte relación no lineal (como una curva en U) y mostrar una correlación cercana a cero.

Sensibilidad a outliers

Unos pocos valores extremos pueden distorsionar significativamente el coeficiente de correlación, llevando a conclusiones erróneas.

Restricción de rango


Si los datos solo cubren un rango limitado de valores posibles, la correlación puede subestimarse.

Agregación de datos


Correlaciones calculadas con datos agregados pueden diferir de las calculadas con datos individuales (falacia ecológica).

LIMITATIONS OF CORRELATION ANALYSIS


CORRELATION CAUSATION




LINEAR RELATIONSHIP ONLY



IGNORES NONLINEAR RELATIONSHIP



AFFECTED BY OUTLIERS



Correlación parcial

La correlación parcial es una técnica más avanzada que permite medir la relación entre dos variables mientras se controla el efecto de una o más variables adicionales.

Problema inicial

Se observa correlación entre consumo de helado (A) y ahogamientos (B).

Aplicación de correlación parcial

Se calcula la correlación entre A y B controlando C.

Identificación de variable confusora

Se sospecha que la temperatura (C) influye en ambas variables.

Resultado

La correlación parcial es cercana a cero, indicando que no hay relación directa entre A y B.

Correlación vs. regresión


Correlación

- Mide la fuerza y dirección de una relación
- Trata ambas variables simétricamente
- Resultado: un coeficiente entre -1 y 1
- No distingue entre variables dependientes e independientes

Regresión

- Modela cómo una variable predice otra
- Establece una relación asimétrica
- Resultado: una ecuación predictiva
- Distingue entre variable dependiente (Y) e independiente (X)

CORRELATION vs. REGRESSION ANALYSIS



Coeficiente de determinación (R^2)

El coeficiente de determinación (R^2) es el cuadrado del coeficiente de correlación de Pearson. Representa la proporción de la varianza en la variable dependiente que es predecible a partir de la variable independiente.

R^2 varía entre 0 y 1:


- $R^2 = 0$: la variable independiente no explica nada de la variabilidad
- $R^2 = 1$: la variable independiente explica toda la variabilidad

En nuestro ejemplo de horas de estudio vs. notas:

$R = 0.96$

$R^2 = 0.92$

Interpretación: El 92% de la variabilidad en las notas puede explicarse por las horas de estudio.



Correlación de Spearman

El coeficiente de correlación de Spearman (ρ) es una medida no paramétrica que evalúa la relación monótona entre dos variables, sin asumir que la relación es lineal.


Características principales:

- Basado en rangos, no en valores exactos
- Menos sensible a outliers que Pearson
- Adecuado para datos ordinales o no normales
- Detecta relaciones monótonas (crecientes o decrecientes)

Casos de uso:

- Evaluación de satisfacción (escalas Likert)
- Rankings deportivos
- Relaciones no lineales pero monótonas

Spearman Correlation with Monotonic Relationship



Correlación tetracórica


La correlación tetracórica es una técnica especializada para estimar la correlación entre dos variables dicotómicas (con solo dos valores posibles, como sí/no).

Variables dicotómicas

Datos con solo dos categorías posibles (ej. aprobado/reprobado, presente/ausente)

Aplicaciones

Útil en psicometría, epidemiología y ciencias sociales



Distribución subyacente

Asume que las variables dicotómicas representan una distribución normal continua subyacente

Tabla 2x2

Se basa en una tabla de contingencia con cuatro celdas (2x2)

Correlación intraclass (ICC)

La correlación intraclass es una medida de la fiabilidad de las mediciones o calificaciones. Se utiliza para evaluar la consistencia o reproducibilidad de mediciones cuantitativas organizadas en grupos.

Aplicaciones comunes:

- Acuerdo entre evaluadores
- Consistencia de mediciones repetidas
- Fiabilidad de instrumentos médicos
- Homogeneidad dentro de grupos

El ICC varía de 0 a 1, donde:

- < 0.5 : Fiabilidad pobre
- $0.5-0.75$: Fiabilidad moderada
- $0.75-0.9$: Fiabilidad buena
- > 0.9 : Fiabilidad excelente


Intraclass Correlation



Correlación canónica

La correlación canónica es una técnica estadística avanzada que analiza la relación entre dos conjuntos de variables, no solo entre dos variables individuales.

Canonical Correlation Analysis



Múltiples variables

Analiza la relación entre dos grupos de variables (ej. conjunto de características físicas vs. conjunto de medidas de rendimiento)

Combinaciones lineales

Busca combinaciones lineales de variables en cada conjunto que maximicen la correlación entre ellos

Aplicaciones

Útil en psicología, biología, economía y otras ciencias donde se miden múltiples variables relacionadas

Correlación en series temporales

Autocorrelación



Mide la correlación de una variable consigo misma a lo largo del tiempo. Útil para identificar patrones cíclicos o estacionales en datos temporales.

Correlación cruzada

Evalúa la relación entre dos series temporales diferentes, considerando posibles retrasos temporales entre ellas.


Aplicaciones:

- Pronóstico económico
- Análisis de mercados financieros
- Meteorología
- Procesamiento de señales



Correlación espacial

La correlación espacial analiza la relación entre observaciones basadas en su ubicación geográfica. Evalúa si los valores de una variable tienden a agruparse espacialmente.



Índice de Moran

Medida común de autocorrelación espacial global que indica si los valores similares tienden a agruparse geográficamente.



Estadístico LISA

Indicadores locales de asociación espacial que identifican clusters y outliers espaciales.



Variograma

Herramienta geoestadística que describe cómo la correlación entre puntos varía con la distancia.


Correlación en aprendizaje automático

En machine learning, la correlación juega un papel fundamental en:

- Selección de características: identificar variables relevantes y eliminar redundantes
- Reducción de dimensionalidad: simplificar modelos complejos
- Detección de multicolinealidad: evitar problemas en modelos predictivos
- Interpretación de resultados: entender relaciones entre variables

Técnicas comunes:

- Matrices de correlación
- Análisis de componentes principales (PCA)
- Selección de características basada en correlación




Matriz de correlación

Una matriz de correlación es una tabla que muestra los coeficientes de correlación entre múltiples variables. Es una herramienta visual poderosa para identificar patrones de relación en conjuntos de datos multivariados.

Características:


- Matriz simétrica con 1's en la diagonal (correlación perfecta de cada variable consigo misma)
- A menudo visualizada como un mapa de calor con colores que representan la fuerza y dirección de las correlaciones
- Útil para identificar rápidamente pares de variables con correlaciones fuertes
- Ayuda a detectar multicolinealidad en modelos estadísticos

Correlation Matrix



Correlación y causalidad: el modelo DAG

Los Gráficos Acíclicos Dirigidos (DAG, por sus siglas en inglés) son una herramienta para representar relaciones causales entre variables y distinguirlas de simples correlaciones.



Causalidad directa

$A \rightarrow B$: A causa directamente B (ej. fumar $\rightarrow$ cáncer de pulmón)



Causa común

$A \leftarrow C \rightarrow B$: C causa tanto A como B, creando una correlación espuria entre A y B



Mediación

$A \rightarrow C \rightarrow B$: A causa B a través de C como mediador



Colisión

$A \rightarrow C \leftarrow B$: A y B causan C, pero no están relacionados entre sí

Correlación en estudios longitudinales

Los estudios longitudinales siguen a los mismos sujetos a lo largo del tiempo, permitiendo analizar cómo evolucionan las correlaciones entre variables.


Ventajas para el análisis de correlación:

- Establecer secuencia temporal (precede B)
- Distinguir efectos a corto y largo plazo
- Identificar patrones de cambio correlacionados
- Controlar características individuales estables

Técnicas específicas:

- Correlación de medidas repetidas
- Modelos de crecimiento
- Análisis de series temporales

LONGITUDINAL STUDY: CORRELATION ANALYSIS OVER TIME



Correlación en big data

Desafíos

El análisis de correlaciones en conjuntos masivos de datos presenta retos computacionales y de interpretación debido al gran volumen de variables y observaciones.

Correlaciones espurias

Con miles de variables, aumenta la probabilidad de encontrar correlaciones por azar que no representan relaciones reales.


Técnicas avanzadas

Algoritmos distribuidos, métodos de muestreo y técnicas de regularización ayudan a manejar correlaciones en big data.

Visualización

Herramientas interactivas y técnicas de reducción dimensional permiten explorar correlaciones en datos multidimensionales.

BIG DATA CORRELATION ANALYSIS



Correlación y ética en el análisis de datos

El análisis de correlaciones plantea importantes consideraciones éticas, especialmente cuando se utiliza para tomar decisiones que afectan a personas:

- Riesgo de reforzar sesgos existentes
- Posibilidad de discriminación basada en correlaciones
- Interpretaciones causales incorrectas que llevan a políticas inadecuadas
- Privacidad y consentimiento en la recolección de datos correlacionados

Principios éticos:

- Transparencia en métodos y limitaciones
- Cautela en la interpretación
- Consideración de impactos sociales
- Validación con múltiples enfoques



Correlación en la era de la desinformación

Correlaciones engañosas

Las correlaciones pueden presentarse de forma selectiva o manipulada para respaldar narrativas falsas o engañosas.

Gráficos manipulados

La visualización de correlaciones puede distorsionarse mediante escalas inapropiadas o selección parcial de datos.

Pensamiento crítico

Es esencial evaluar la fuente, metodología y contexto de cualquier correlación presentada en medios o redes sociales.

Alfabetización estadística

Comprender los fundamentos de la correlación ayuda a identificar usos incorrectos o malintencionados de esta herramienta.

Herramientas para análisis de correlación



Python

Bibliotecas como Pandas, NumPy, SciPy y Seaborn ofrecen funciones para calcular y visualizar correlaciones de forma eficiente.



R

Funciones como `cor()`, `cor.test()` y paquetes como `corrplot` permiten análisis detallados de correlación con visualizaciones avanzadas.



Excel

La función `COEF.DE.CORREL()` calcula el coeficiente de Pearson, mientras que las tablas dinámicas ayudan a explorar relaciones entre variables.



Software estadístico

SPSS, SAS, Stata y otros programas especializados ofrecen herramientas completas para análisis de correlación y pruebas de hipótesis.

Correlación en la investigación interdisciplinaria

La correlación sirve como puente entre diferentes disciplinas, permitiendo identificar conexiones entre fenómenos aparentemente no relacionados:

- Neurociencia y comportamiento
- Economía y psicología (economía conductual)
- Genética y enfermedades
- Clima y patrones migratorios

Beneficios:

- Descubrimiento de relaciones inesperadas
- Generación de hipótesis novedosas
- Integración de conocimientos de múltiples campos
- Abordaje de problemas complejos desde diferentes perspectivas



Correlación en la toma de decisiones



Empresarial

Identificar factores correlacionados con el rendimiento, satisfacción del cliente o rotación de personal para orientar estrategias.



Política pública

Analizar correlaciones entre indicadores sociales, económicos y de salud para diseñar intervenciones más efectivas.



Salud

Utilizar correlaciones entre síntomas, tratamientos y resultados para mejorar protocolos clínicos y decisiones médicas.



Inversión

Estudiar correlaciones entre activos financieros para diversificar carteras y gestionar riesgos de manera más eficiente.

Correlación y causalidad: experimentos naturales

Los experimentos naturales son situaciones donde eventos aleatorios o políticas crean condiciones similares a un experimento controlado, permitiendo inferencias causales más sólidas a partir de correlaciones observadas.


Ejemplos:

- Cambios legislativos que afectan a algunas regiones pero no a otras
- Desastres naturales que impactan aleatoriamente a ciertas áreas
- Asignación aleatoria de estudiantes a diferentes clases o profesores

Ventajas:

- Mayor validez externa que los experimentos de laboratorio
- Posibilidad de estudiar fenómenos que no pueden manipularse éticamente
- Fortalecimiento de inferencias causales a partir de correlaciones

NATURAL EXPERIMENT RESEARCH METHOD



El futuro del análisis de correlación



Inteligencia artificial

Algoritmos avanzados que pueden detectar correlaciones complejas y no lineales en grandes conjuntos de datos multidimensionales.



Análisis causal

Desarrollo de métodos más sofisticados para distinguir correlaciones causales de las no causales utilizando inferencia causal algorítmica.



Redes complejas

Análisis de correlaciones en redes de interacciones complejas, como redes sociales, biológicas o financieras.



Visualización inmersiva

Técnicas de realidad virtual y aumentada para explorar correlaciones multidimensionales de forma más intuitiva.

Correlación en datos heterogéneos

El análisis de correlación tradicional se centra en variables del mismo tipo, pero los avances recientes permiten estudiar relaciones entre datos de naturaleza muy diferente:

Correlación texto-numérica

Análisis de la relación entre datos textuales (como sentimiento en redes sociales) y variables numéricas (como precios de acciones).


Correlación imagen-comportamiento

Estudio de asociaciones entre características visuales y patrones de comportamiento o respuestas fisiológicas.

Correlación multimodal

Técnicas que integran datos de múltiples fuentes (sensores, texto, imágenes, audio) para identificar patrones correlacionados complejos.

Heterogeneous Data Correlation Analysis




Correlación en tiempo real

Los avances tecnológicos permiten analizar correlaciones en flujos de datos continuos, posibilitando respuestas inmediatas a patrones emergentes:

- Monitoreo de mercados financieros
- Sistemas de alerta temprana
- Optimización de tráfico urbano
- Detección de anomalías en sistemas

Desafíos:

- Procesamiento eficiente de grandes volúmenes de datos
- Distinción entre correlaciones significativas y ruido
- Actualización dinámica de modelos
- Visualización efectiva de correlaciones cambiantes



Correlación y pensamiento sistémico


El pensamiento sistémico reconoce que las correlaciones observadas son a menudo parte de sistemas complejos con múltiples interacciones, retroalimentaciones y efectos emergentes.

Retroalimentación

Las correlaciones pueden reflejar ciclos de retroalimentación positiva o negativa dentro de un sistema

Emergencia

Patrones correlacionados que emergen de interacciones a nivel micro



Interconexión

Variables correlacionadas suelen formar parte de redes más amplias de relaciones

Retrasos temporales

Efectos que pueden manifestarse con desfases temporales significativos

Correlación en la ciencia ciudadana

La ciencia ciudadana involucra al público general en la recolección y análisis de datos, permitiendo estudiar correlaciones a escalas antes imposibles:


- Fenómenos astronómicos
- Monitoreo ambiental distribuido
- Observación de especies y biodiversidad
- Reportes de síntomas y condiciones de salud

Beneficios:


- Mayor cobertura geográfica y temporal
- Detección de correlaciones locales
- Participación pública en el proceso científico
- Educación sobre métodos estadísticos




COGNITIVE BIASES IN CORRELATION PERCEPTION




ILLUSORY CORRELATION



CONFIRMATION BIAS



OVERESTIMATION



UNDERESTIMATION

Correlación y sesgos cognitivos

Sesgo de confirmación

Tendencia a notar y recordar correlaciones que confirman nuestras creencias previas, ignorando las que las contradicen.

Ilusión de control

Sobreestimación de nuestra capacidad para influir en eventos basada en correlaciones percibidas entre nuestras acciones y resultados.

Correlación ilusoria

Percepción de correlaciones inexistentes entre eventos, especialmente cuando son inusuales o emocionalmente significativos.

Sesgo de disponibilidad

Tendencia a sobrevalorar correlaciones basadas en ejemplos que vienen fácilmente a la mente.

Correlación en la comunicación científica

La comunicación efectiva de correlaciones es esencial para que el público comprenda correctamente los hallazgos científicos:

- Explicar claramente las limitaciones
- Distinguir entre correlación y causalidad
- Presentar visualizaciones precisas y claras
- Contextualizar la fuerza y significado de las correlaciones

Desafíos:

- Simplificar sin distorsionar
- Comunicar la incertidumbre
- Contrarrestar interpretaciones sensacionalistas
- Adaptar el mensaje a diferentes audiencias

SCIENTIFIC COMMUNICATION OF STATISTICAL FINDINGS



Live Coding

¿En qué consistirá la Demo?

Visualizaremos y compararemos distintos tipos de correlaciones mediante Python, incluyendo la construcción de matrices de correlación, mapas de calor, y cálculo de coeficientes (Pearson, Spearman, parcia

1. Cargue dataset de ejemplo con múltiples variables.
2. Calcule matriz de correlación con pandas y seaborn.
3. Visualice mapa de calor con `sns.heatmap()`.
4. Calcule correlación de Spearman con `scipy.stats`.
5. Aplique correlación parcial con `pingouin`.
6. Discute cuándo aplicar cada tipo de correlación.
7. Muestre gráfico de correlación temporal con `plotly`.
8. Muestre gráfico de correlación espacial con datos simulados.



Momento:

Time-out!



5 -10 min.





Ejercicio

Explorando Relaciones Académicas: Correlaciones en el Rendimiento Estudiantil

Explorando Relaciones Académicas: Correlaciones en el Rendimiento Estudiantil

Contexto: 🙌

Una organización educativa desea comprender las relaciones entre variables como asistencia, cantidad de horas de estudio, participación en foros y desempeño académico. Sos parte del equipo de análisis y tu tarea es detectar posibles correlaciones útiles que orienten futuras decisiones pedagógicas.

Consigna: ✍️

Utilice un dataset simulado o real (como el de student-mat del repositorio UCI o uno propio creado con Pandas) que contenga al menos cinco variables relacionadas al rendimiento estudiantil. Aplique distintos tipos de correlación y visualización para analizar los vínculos entre ellas. Compruebe si hay evidencia de correlación parcial o no lineal, y construye una matriz de correlación completa para presentar resultados.

Tiempo 🕒: 45 Minutos

Explorando Relaciones Académicas: Correlaciones en el Rendimiento Estudiantil

Paso a paso:

1. Cargue el dataset en Visual Studio Code
2. Limpie y prepare los datos si es necesario.
3. Calcule coeficientes de Pearson y Spearman entre variables.
4. Cree una matriz de correlación y visualice con `seaborn.heatmap()`.
5. Identifique outliers o relaciones no lineales y graficar ejemplos.
6. Use `pingouin.partial_corr()` para calcular correlación parcial entre al menos 3 variables.
7. Interprete resultados y explicar qué tipo de correlación es más útil según cada caso.

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Exploramos múltiples formas de aplicar la correlación según el contexto.**
- ✓ **Analizamos técnicas específicas como ICC, Spearman y correlación espacial.**
- ✓ **Comparamos correlación vs. causalidad con ejemplos ilustrativos.**
- ✓ **Comprendimos los desafíos éticos del uso de correlaciones en big data.**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

