



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊




› Distribución de probabilidad

Aprendizaje esperado lección 3: Utilizar las funciones de distribución de probabilidades identificando su campo de utilización en el análisis estadístico.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?





Learning Path

¿Cuáles temas trabajaremos hoy?

3.

**Comprender y utilizar
distribuciones de
probabilidad**

En esta clase comenzaremos a identificar qué es una distribución de probabilidad, cómo se clasifica y qué características posee.

Esto permitirá modelar fenómenos aleatorios de forma más precisa y elegir el tipo adecuado de distribución según el contexto del análisis.

**Introducción a las
distribuciones de
probabilidad**

**Clasificación y ejemplos
de distribuciones**

**Qué es una
variable aleatoria y
para qué sirve**

**Diferencia entre
variable discreta y
continua**

**Distribuciones
discretas vs.
continuas**

**Casos de uso
típicos para cada
distribución**

Learning Path

¿Cuáles temas trabajaremos hoy?

3.

Seleccionar la distribución de probabilidad adecuada para un fenómeno aleatorio

En esta clase continuaremos explorando distribuciones de probabilidad.

Nos centraremos en dos distribuciones clave: binomial y Poisson, analizando sus características, fórmulas, diferencias y aplicaciones típicas.

También veremos ejemplos en código y simulaciones.

Distribución binomial

Ensayos independientes y número de éxitos

Parámetros y fórmula

Distribución Poisson

Conteo de eventos raros en intervalos

Parámetro lambda y forma de la distribución

Objetivos de aprendizaje

¿Qué aprenderás?

- Identificar el concepto de variable aleatoria y su uso
- Distinguir entre variables discretas y continuas
- Comprender qué es una distribución de probabilidad
- Reconocer las principales distribuciones discretas
- Asociar tipos de distribución con contextos de aplicación



Objetivos de aprendizaje

¿Qué aprenderás?



- Reconocer la estructura de un experimento binomial
- Aplicar la fórmula de la distribución binomial
- Comprender la distribución de Poisson y su parámetro
- Diferenciar cuándo conviene usar binomial o Poisson
- Interpretar resultados y tomar decisiones estadísticas simples

Distribución de probabilidad

“Si lanzo una moneda 100 veces... ¿qué creen que pasará?”

Pregunta:

- ¿Siempre saldrán exactamente 50 caras?
- ¿Podría salir 60?
- ¿Podría salir 40?

“Si yo quisiera describir matemáticamente cómo se comportan esos posibles resultados...
¿qué necesitaría?”

1) Necesito saber qué valores puede tomar la variable

2) Y qué probabilidad tiene cada valor

Eso es exactamente una distribución de probabilidad.

Una distribución de probabilidad es simplemente una forma organizada de describir todos los valores posibles de una variable y qué tan probable es cada uno.

Variable: número de caras al lanzar dos monedas.

¿Qué valores puede tomar?

Variable: número de caras al lanzar dos monedas.

¿Qué valores puede tomar?

Si lanzo dos monedas...

- **Puede salir cara-cara**
- **Cara-sello**
- **Sello-cara**
- **Sello-sello**

- ¿Cuántas caras hay en cada caso?

- ¿Cuántas caras hay en cada caso?

0, 1 o 2.

Tenemos los valores posibles:

$$X = \{0, 1, 2\}$$

¿Todos tienen la misma probabilidad?

Resultados posibles al lanzar dos monedas:

- **Cara–Cara $\rightarrow$ 2 caras**
- **Cara–Sello $\rightarrow$ 1 cara**
- **Sello–Cara $\rightarrow$ 1 cara**
- **Sello–Sello $\rightarrow$ 0 caras**

¿Cuántas combinaciones producen 1 cara?

Dos.

¿Y cuántas producen 0 caras?

Una.

¿Y 2 caras?

Una.

- ¿Qué probabilidad tendría una cara ?

- ¿Qué probabilidad tendría una cara ?

X (número de caras)	Probabilidad
0	$1/4$
1	$2/4 = 1/2$
2	$1/4$

- ¿Qué probabilidad tendría una cara ?

X (número de caras)	Probabilidad
0	$1/4$
1	$2/4 = 1/2$
2	$1/4$

Una distribución de probabilidad es simplemente una tabla (o función) que nos dice qué valores puede tomar una variable y qué probabilidad tiene cada uno.

Distribución de probabilidad

En el análisis estadístico, no basta con recolectar y describir datos: es esencial comprender cómo se comportan las **variables aleatorias** y cómo se distribuyen sus resultados posibles. Para ello, se utilizan las **distribuciones de probabilidad**, que permiten modelar fenómenos inciertos de manera matemática y predecir la ocurrencia de ciertos valores o rangos.

$$\int_{-\infty}^{\infty} f(x) dx = 1 \quad x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

$$\sum_{n=1}^{\infty} p(x) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad \pi \quad \pi$$

$$\ln x \quad e^x \quad f_f((x(t))) = \frac{1}{t} = 0$$

$$\frac{d}{dx} e^x = e^x \quad e^2 + b^2 = 1 = 0$$

$$f(x) \quad a^2 + b = C$$




$$f(x) = \frac{1}{\sigma \sqrt{2\pi}} \quad e^2 + 1 = 0$$

$$\sigma \quad \frac{d}{dx} = e^{-x} \quad \text{Var}(X)^2 = E[X]^2$$

Introducción a las distribuciones de probabilidad

Una distribución de probabilidad describe cómo se reparte la probabilidad entre los posibles valores de una variable aleatoria. Algunas distribuciones, como la binomial o la normal, se ajustan a patrones frecuentes en el mundo real, desde el lanzamiento de monedas hasta fenómenos físicos y sociales complejos.




Este manual se centra en identificar, describir y utilizar correctamente las distribuciones de probabilidad, tanto discretas como continuas, incluyendo sus fórmulas, condiciones de aplicación y ejemplos prácticos. También se abordará con profundidad la distribución normal, por ser una de las más importantes y utilizadas en estadística inferencial.

Variables aleatorias y sus tipos

Una **variable aleatoria** es una función que asigna un valor numérico a cada resultado de un experimento aleatorio. En otras palabras, es una manera de cuantificar los posibles resultados de fenómenos inciertos.

Estas variables son fundamentales en estadística y probabilidad, ya que permiten modelar y analizar eventos cuyos resultados no pueden preverse con certeza, pero sí con cierto grado de probabilidad.

RANDOM VARIABLE



Variables aleatorias discretas y continuas

Variables aleatorias discretas

Toman un número finito o numerable de valores. Por ejemplo, al lanzar un dado, la variable "resultado" puede ser 1, 2, 3, 4, 5 o 6.

Variables aleatorias continuas

Pueden tomar cualquier valor dentro de un intervalo, como el peso de una persona (68,2 kg, 68,21 kg, etc.), donde los valores posibles son infinitos dentro del rango.

La notación habitual para una variable aleatoria es X , y se denota su valor con letras minúsculas, como x .

Discreta = valores contables (se pueden enumerar).

Continua = valores en un intervalo (infinitos dentro del rango).

Funciones de probabilidad y densidad

Para variables discretas

Se define su función de probabilidad como $P(X=x)$, que indica la probabilidad de que la variable tome el valor x .

Para variables continuas

Se utiliza una **función de densidad** $f(x)$, y se calcula la probabilidad como el área bajo la curva entre dos valores:


$$P(a \leq X \leq b) = \int_a^b f(x), dx$$

Ejemplos de variables aleatorias

1

Variable discreta

Supongamos que tiramos dos monedas y contamos la cantidad de caras que salen. La variable aleatoria X puede tomar los valores 0, 1 o 2.




2

Variable continua

Si se mide el tiempo (en segundos) que tarda un semáforo en cambiar de rojo a verde, la variable puede tomar cualquier valor dentro de un rango como $[30, 90]$. Aquí no podemos hablar de $P(X=60)$, ya que en variables continuas la probabilidad puntual es cero. En su lugar, se calcula la probabilidad de que esté en un intervalo, como $P(50 \leq X \leq 70)$.

Probability Distribution



Distribución de probabilidad

Una **distribución de probabilidad** describe cómo se distribuyen los posibles valores de una variable aleatoria y la probabilidad asociada a cada uno de ellos. Para variables discretas, se utilizan funciones de probabilidad, mientras que para variables continuas se emplean funciones de densidad. Este concepto es clave en estadística, ya que permite entender el comportamiento esperado de un fenómeno aleatorio.

Funciones de probabilidad para variables discretas

En el caso de variables discretas, la **función de probabilidad** asigna una probabilidad a cada valor posible de la variable. Estas probabilidades deben cumplir dos condiciones:

- Cada probabilidad debe estar entre 0 y 1
- La suma total de todas las probabilidades debe ser igual a 1


Por ejemplo, al lanzar un dado justo de seis caras, cada valor del 1 al 6 tiene una probabilidad de $1/6$.

Funciones de densidad para variables continuas

Para variables continuas, la **función de densidad** $f(x)$ no asigna una probabilidad exacta a un valor único, sino que describe la probabilidad de que la variable tome un valor dentro de un intervalo. La probabilidad se calcula mediante una integral:

$$P(a \leq X \leq b) = \int_a^b f(x)dx$$

La función de densidad debe ser no negativa y su integral en todo el dominio debe ser igual a 1.



Ejemplos de distribuciones de probabilidad


Ejemplo de distribución discreta

Un ejemplo de distribución discreta es el número de caras al lanzar dos monedas. La variable puede tomar únicamente los valores 0, 1 o 2, ya que estamos contando resultados y no pueden existir valores intermedios como 1.5 caras. A cada uno de estos valores se le puede asignar una probabilidad exacta, por ejemplo, $P(X = 1) = 1/2$. Es discreta porque los valores posibles son contables y separados entre sí.

Ejemplo de distribución continua

Un ejemplo de distribución continua es la altura de las personas adultas. Esta variable puede tomar infinitos valores dentro de un intervalo, como 1,70 m, 1,701 m. o 1,7015 m. En este caso no se calculan probabilidades para un valor exacto, sino para intervalos, como la probabilidad de que la altura esté entre 1,65 m y 1,75 m. Es continua porque los valores posibles no se pueden enumerar uno por uno, sino que forman un rango infinito dentro de un intervalo.

Cumulative Distribution Function



Distribución acumulada de probabilidad

La distribución acumulada nos dice la probabilidad de que la variable tome un valor menor o igual que cierto número

Se define como: $F(x)=P(X\leq x)$

Es una función creciente que toma valores entre 0 y 1.

En el caso continuo, $F(x)$ corresponde al área acumulada bajo la curva de densidad hasta el punto x .

Cálculo de la distribución acumulada

Para variables discretas

$F(x)$ se construye sumando las probabilidades individuales de cada valor menor o igual a x . Por ejemplo, si X representa el número de caras al lanzar dos monedas, entonces:

$$F(x) = \sum_{k \leq x} P(X = k)$$

$$F(1) = P(X = 0) + P(X = 1) = \frac{1}{4} + \frac{2}{4} = \frac{3}{4}$$

Para variables continuas

La distribución acumulada se obtiene integrando la función de densidad:

$$F(x) = \int_{-\infty}^x f(t)dt$$


Esto representa el área bajo la curva de densidad desde el inicio hasta el punto x .

Ejemplo gráfico de distribución acumulada


La función acumulada crece de forma no decreciente y siempre está entre 0 y 1.

Para distribuciones normales, la forma de $F(x)$ es una curva sigmoide que se acerca asintóticamente a 0 y 1.

Comprender la función acumulada permite responder preguntas como: "¿Cuál es la probabilidad de que el valor esté por debajo de cierto umbral?" o "¿Qué valor corresponde al percentil 90?".



Distribuciones discretas



Distribuciones discretas

Modelan variables aleatorias que toman valores aislados, generalmente números enteros.

- Se utilizan cuando se cuentan ocurrencias.
- Cada valor posible tiene una probabilidad asociada:

$$P(X = x) = p(x)$$

- La suma total de probabilidades es 1:

$$\sum_x p(x) = 1$$

Ejemplos típicos: número de éxitos, número de defectos, número de clientes.

A continuación, explicaremos las distribuciones discretas más importantes y sus aplicaciones.

Distribución uniforme discreta

Se aplica cuando una variable aleatoria toma un número finito de valores y todos tienen la misma probabilidad.

Si X tiene n resultados posibles igualmente probables:

$$P(X = x_i) = \frac{1}{n}, \quad i = 1, 2, \dots, n$$

Se cumple que:

- Un ejemplo clásico es el lanzamiento de un dado justo, donde cada número del 1 al 6 tiene probabilidad $1/6$.

$$\sum_{i=1}^n P(X = x_i) = 1$$

Ejemplo de distribución uniforme discreta

Al lanzar un dado justo de 6 caras, la probabilidad de obtener cualquier número del 1 al 6 es igual:

$$P(X = 1) = P(X = 2) = \dots = P(X = 6) = \frac{1}{6}$$

La media y la varianza de una distribución uniforme discreta con valores desde a hasta b (enteros consecutivos) son:

$$\mu = \frac{a+b}{2} \quad \sigma^2 = \frac{(b-a+1)^2 - 1}{12}$$



Esta distribución se aplica en simulaciones, juegos de azar y algoritmos aleatorios. Es importante aclarar que solo se utiliza si se justifica la igualdad de probabilidades.



Comandos + Código + Texto ▶ Ejecutar todas




[3]


```
plt.bar(valores, frecuencias)
plt.xlabel("Valor obtenido")
plt.ylabel("Frecuencia relativa")
plt.title("Distribución Uniforme Discreta (Dado justo)")
plt.xticks(valores)
plt.show()
```

▼

```
... Probabilidades estimadas:
Valor 1: 0.166
Valor 2: 0.168
Valor 3: 0.164
Valor 4: 0.168
Valor 5: 0.168
Valor 6: 0.166
```



Bernoulli Distribution



Distribución de Bernoulli

Modela un experimento con dos resultados posibles:

- Éxito (1)
- Fracaso (0)

Si $X \sim \text{Bernoulli}(p)$, donde p es la probabilidad de éxito:

$$P(X = 1) = p$$

$$P(X = 0) = 1 - p$$

Función de probabilidad general:

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}$$

Propiedades:

$$E(X) = p$$

$$\text{Var}(X) = p(1 - p)$$

Es la base de la distribución binomial.

Propiedades de la distribución de Bernoulli

p

Media

La media de una variable Bernoulli es igual a la probabilidad de éxito p

p(1-p)

Varianza

La varianza de una variable Bernoulli es el producto de la probabilidad de éxito por la probabilidad de fracaso

Ejemplo: Lanzar una moneda cargada donde la probabilidad de cara (éxito) es 0,6 y cruz (fracaso) es 0,4.

Esta distribución es esencial para modelar ensayos binarios (sí/no, éxito/fracaso, correcto/incorrecto) y sirve como base para la distribución binomial.



Index_M5_AE3.ipynb ☆ ☁

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

Q Comandos + Código + Texto ▶ Ejecutar todas ▼



[4]

✓ 0 s




```
# Calculamos frecuencias
valores, conteos = np.unique(muestras, return_counts=True)
frecuencias = conteos / len(muestras)

# Graficamos
plt.bar(valores, frecuencias)
plt.xticks([0, 1])
plt.xlabel("Resultado (0 = fracaso, 1 = éxito)")
plt.ylabel("Frecuencia relativa")
plt.title("Distribución Bernoulli (p = 0.7)")
plt.show()
```



...

Distribución Bernoulli (p = 0.7)



Distribución binomial

Modela el número de éxitos al repetir un experimento de Bernoulli n veces.

Condiciones:

- Número fijo de ensayos n .
- Ensayos independientes.
- Probabilidad de éxito constante p .

Si $X \sim \text{Binomial}(n, p)$:

para $k = 0, 1, \dots, n$,

donde:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

Propiedades:

$$E(X) = np$$

$$\text{Var}(X) = np(1 - p)$$

Propiedades de la distribución binomial

Si $X \sim \text{Binomial}(n, p)$:

$$E(X) = np$$

$$\text{Var}(X) = np(1 - p)$$

Media: Valor esperado del número de éxitos en n ensayos independientes.

Varianza: Mide la dispersión de los posibles resultados alrededor de la media.

Ejemplo:

Moneda justa lanzada 10 veces ($p=0.5$)

$$P(X = 4) = \binom{10}{4} (0.5)^4 (0.5)^6 = 210 (0.5)^{10} \approx 0.205$$

La binomial puede interpretarse como la suma de n variables Bernoulli independientes.



Q Comandos + Código + Texto ▶ Ejecutar todas ▼




[6]

✓ 0 s

```
p = 0.7

# Simulamos 1000 experimentos (cada experimento = 10 ensayos)
np.random.seed(42)
muestras = np.random.binomial(n=n, p=p, size=1000)

# Graficamos histograma (frecuencia relativa)
plt.hist(muestras, bins=np.arange(-0.5, n + 1.5, 1), density=True)
plt.xlabel("Número de éxitos en 10 ensayos")
plt.ylabel("Frecuencia relativa")
plt.title("Distribución Binomial (n=10, p=0.7)")
plt.xticks(range(0, n + 1))
plt.show()
```



Distribución de Poisson

Modela el número de ocurrencias de un evento en un intervalo de tiempo o espacio.

Supuestos:

- Eventos independientes.
- Tasa promedio constante λ
- Eventos raros.

Si $X \sim \text{Poisson}(\lambda)$

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

donde λ es la media de ocurrencias por unidad.

Propiedades:

$$E(X) = \lambda$$

$$\text{Var}(X) = \lambda$$

Puede interpretarse como el límite de una binomial cuando $n \rightarrow \infty$, $p \rightarrow 0$ y $np = \lambda$

Ejemplo de distribución de Poisson

Si en promedio llegan 4 correos por hora, la probabilidad de que lleguen exactamente 2 correos en una hora es:

Sea $\lambda=4$ (media de correos por hora).


La probabilidad de recibir exactamente 2 correos en una hora es:

$$\begin{aligned}P(X = 2) &= \frac{e^{-4}4^2}{2!} \\&= \frac{e^{-4}16}{2} \\&= 8e^{-4} \\&\approx 0.1465\end{aligned}$$

Se aplica en teoría de colas, redes, llamadas telefónicas, fallos de equipos, etc.
También se usa como aproximación a la binomial cuando n es grande y p es pequeño.

Poisson Distribution

Probability of events occurring in fixed time interval





Index_M5_AE3.ipynb ☆ ☁

Archivo Editar Ver Insertar Entorno de ejecución Herramientas Ayuda

🔍 Comandos + Código ▾ + Texto ▶ Ejecutar todas ▾



[9]


✓ 0 s



```
# Graficamos
valores, conteos = np.unique(muestras, return_counts=True)
frecuencias = conteos / len(muestras)

plt.bar(valores, frecuencias)
plt.xlabel("Número de llamadas por minuto")
plt.ylabel("Frecuencia relativa")
plt.title("Distribución Poisson ( $\lambda = 4$ )")
plt.show()
```

... Media estimada: 3.923
Varianza estimada: 3.955071



Comparación de distribuciones discretas

Distribución	¿Qué modela?	Parámetros	Media	Varianza	Cuándo usar
Uniforme discreta	Resultados finitos equiprobables	n o a, b	$\frac{a+b}{2}$	$\frac{(b-a+1)^2-1}{12}$	Cuando todos los valores son igualmente probables
Bernoulli	Un solo ensayo con éxito/fracaso	p	p	$p(1-p)$	Experimentos binarios
Binomial	Número de éxitos en n ensayos	n, p	np	$np(1-p)$	Repetición de ensayos Bernoulli independientes
Poisson	Número de eventos en un intervalo	λ	λ	λ	Eventos raros con tasa constante

Clasifiquen cada uno como:

- Bernoulli
- Binomial
- Poisson

Justificando con la estructura:

- ✓ ¿Número fijo de ensayos?
- ✓ ¿Evento en intervalo?
- ✓ ¿Éxito/fracaso?
- ✓ ¿Tasa promedio?

- 1) Se lanza una moneda una vez y se registra si sale cara.
- 2) Se lanza una moneda 20 veces y se cuenta cuántas caras aparecen.
- 3) De 100 clientes que visitan una página web, se cuenta cuántos realizan una compra.
- 4) Se registra cuántos autos pasan por un peaje en una hora.
- 5) Una fábrica inspecciona 50 productos y cuenta cuántos son defectuosos.
- 6) Se mide el número de llamadas que llegan a un call center en 10 minutos.
- 7) Se analiza si un paciente responde o no a un tratamiento.
- 8) Se registra cuántos errores aparecen en una página de código cada 1000 líneas.
- 9) Una empresa envía 200 correos y cuenta cuántos son abiertos.
- 10) Se mide cuántos terremotos ocurren en una región durante un año.

1 Se lanza una moneda una vez y se registra si sale cara.

Bernoulli, Porque es un solo ensayo con dos posibles resultados.

2 Se lanza una moneda 20 veces y se cuenta cuántas caras aparecen.

Binomial, Número fijo de ensayos (20), probabilidad constante, contamos éxitos.

3 De 100 clientes que visitan una página web, se cuenta cuántos compran.

Binomial, Número fijo (100), cada cliente compra o no, probabilidad constante.

4 Se registra cuántos autos pasan por un peaje en una hora.

Poisson, Contamos eventos en un intervalo de tiempo.

5 Una fábrica inspecciona 50 productos y cuenta cuántos son defectuosos.

Binomial, Número fijo (50), cada producto es defectuoso o no.

6 Número de llamadas que llegan en 10 minutos.

Poisson, Eventos en intervalo de tiempo.

7 Se analiza si un paciente responde o no a un tratamiento.

Bernoulli, Un solo ensayo, éxito o fracaso.

8 Número de errores por cada 1000 líneas de código.

Poisson, Conteo de eventos en intervalo espacial.

9 Empresa envía 200 correos y cuenta cuántos son abiertos.

Binomial, Número fijo (200), éxito/fracaso por correo.

10 Número de terremotos en un año.

Poisson, Eventos en intervalo de tiempo.



Momento:

Time-out!



5 -10 min.



Distribuciones continuas

Distribuciones continuas

Las distribuciones continuas modelan variables aleatorias que pueden tomar cualquier valor dentro de un rango.

A diferencia de las distribuciones discretas, las continuas utilizan funciones de densidad para calcular probabilidades como áreas bajo la curva.

Las probabilidades se calculan como áreas:

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$


Se cumple que:

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

En variables continuas:

$$P(X = x) = 0$$

Estas distribuciones son fundamentales para analizar mediciones físicas, tiempos, distancias y muchos otros fenómenos naturales y sociales.



Distribución uniforme continua

La **distribución uniforme continua** describe variables aleatorias continuas donde **todos los valores en un intervalo tienen la misma probabilidad de ocurrir**. Es la contraparte continua de la distribución uniforme discreta.

Si $X \sim \text{Uniforme}(a, b)$, $a < b$

La densidad es constante:

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{en otro caso} \end{cases}$$

Interpretación:


- La probabilidad es proporcional a la longitud del intervalo.
- Intervalos de igual tamaño tienen igual probabilidad.

Propiedades:

$$\mu = \frac{a+b}{2}$$

$$\sigma^2 = \frac{(b-a)^2}{12}$$

Uniform Continuous Distribution



Propiedades de la distribución uniforme continua

La probabilidad de que X tome un valor en un subintervalo $[x_1, x_2] \subset [a, b]$ se calcula como:

$$P(x_1 \leq X \leq x_2) = \frac{x_2 - x_1}{b - a}$$

$$(a+b)/2$$

Media

El punto medio del intervalo $[a, b]$

$$(b-a)^2/12$$

Varianza


Medida de dispersión de la distribución uniforme

Ejemplo de distribución uniforme continua

Si el tiempo de espera para ser atendido en una ventanilla está uniformemente distribuido entre 5 y 15 minutos, la probabilidad de que alguien espere entre 6 y 10 minutos es:

$$P(6 \leq X \leq 10) = \frac{10 - 6}{15 - 5} = \frac{4}{10} = 0.4$$

Esta distribución se usa cuando no se tiene razón para pensar que algún valor sea más probable que otro dentro de un intervalo definido.





🔍 Comandos + Código ▾ + Texto ▶ Ejecutar todas ▾




[13]

```
▶ print("Media estimada:", np.mean(muestras))
  print("Media teórica:", (a + b) / 2)

# Histograma (densidad)
plt.hist(muestras, bins=30, density=True, edgecolor='black')
plt.axhline(1/(b-a), color='red', linestyle='--', label='Densidad teórica')
plt.title("Distribución Uniforme Continua U(2,8)")
plt.xlabel("Valores")
plt.ylabel("Densidad")
plt.legend()
plt.show()
```

▼ ... Media estimada: 5.002006917054289
Media teórica: 5.0



Distribución normal

La **distribución normal** o **gaussiana** es una de las más importantes en estadística. Representa fenómenos naturales y sociales donde los valores tienden a agruparse alrededor de la media.

La **distribución normal** aparece cuando los valores tienden a **acumularse cerca de un centro** y los valores extremos son cada vez menos frecuentes. Su forma es una **campana simétrica**.

Notación:


$$X \sim \mathcal{N}(\mu, \sigma^2)$$

entonces su función de densidad es:

- μ es la media.
- σ^2 es la varianza.
- σ es la desviación standard.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Propiedades de la distribución normal



Simetría

- La distribución es simétrica respecto a la media μ .
- Media = mediana = moda.
- Las áreas a ambos lados del centro son iguales.

Regla empírica

En una distribución normal:

- 68% de los datos están en $\mu \pm 1\sigma$
- 95% en $\mu \pm 2\sigma$
- 99,7% en $\mu \pm 3\sigma$

En cada cola extrema queda aproximadamente 0,15%.

Si una variable sigue una normal con:

$$\mu = 100$$

$$\sigma = 10$$

¿Entre qué valores estaría aproximadamente el 68% de los datos?

¿Entre qué valores estaría aproximadamente el 95%?

Si una persona está en 130, ¿está cerca del centro o es un valor extremo?



Comandos + Código + Texto ▶ Ejecutar todas



[15]

✓ 0 s



sigma = 10

np.random.seed(42)

Generamos datos

muestras = np.random.normal(mu, sigma, 10000)

Graficamos

plt.hist(muestras, bins=40, density=True, edgecolor='black')

plt.title("Distribución Normal ($\mu=100$, $\sigma=10$)")


plt.xlabel("Valores")

plt.ylabel("Densidad")

plt.show()

print("Media estimada:", np.mean(muestras))

print("Desviación estándar estimada:", np.std(muestras))

Distribución Normal ($\mu=100$, $\sigma=10$)

Distribución normal estándar

Cuando una variable aleatoria normal es transformada para que tenga media 0 y desviación estándar 1, se dice que sigue una **distribución normal estándar**.

$$Z \sim N(0, 1)$$

¿Para qué sirve?

Sirve para transformar cualquier normal a una **escala común**.

La transformación se realiza mediante:

$$Z = \frac{X - \mu}{\sigma}$$

La normal estándar nos permite comparar valores en distintas escalas usando una misma referencia: las desviaciones estándar.


Uso de la distribución normal estándar

La estandarización permite usar tablas estandarizadas de probabilidades (tablas Z), sin necesidad de integrar la función normal general cada vez.

Ejemplo: Si $X \sim N(100, 15^2)$, la probabilidad de que $X \leq 120$ se calcula transformando:

$$Z = \frac{120 - 100}{15} = 1.33$$

Buscando en la tabla Z, $P(Z \leq 1.33) = 0.9082$, es decir, hay un 90.82% de probabilidad de que $X \leq 120$.



Esta transformación es clave en pruebas de hipótesis, intervalos de confianza, y cálculo de p-valores.

Distribución chi-cuadrado (χ^2)

La distribución χ^2 se utiliza para medir qué tan grandes son las diferencias entre lo que observamos en los datos y lo que esperaríamos teóricamente.

¿Para qué se usa en la vida real?

Prueba	¿Qué hace?	Ejemplo
Bondad de ajuste	Evalúa si los datos siguen una distribución teórica	¿Un dado es justo?
Independencia	Determina si dos variables categóricas están relacionadas	¿Fumar se asocia al nivel de estrés?
Homogeneidad	Compara proporciones entre poblaciones	¿La preferencia política es igual en distintas regiones?

Idea clave:

χ^2 mide qué tan grandes son las diferencias entre lo observado y lo esperado.

Propiedades de χ^2

Sea $X \sim \chi^2(k)$, donde k son los **grados de libertad**.

- Surge como la suma de los cuadrados de k variables normales estándar independientes.
- Media: $\mu = k$
- Varianza: $\sigma^2 = 2k$
- Es asimétrica y se desplaza a la derecha a medida que k aumenta.

Aplicaciones de la distribución chi-cuadrado

Ejemplo:

Si $X \sim \chi^2(5)$ entonces:

Media: $\mu = 5$

Varianza: $\sigma^2 = 10$

-> Observa en la gráfica cómo al aumentar los grados de libertad (k):


La distribución se desplaza hacia la derecha.

Se vuelve menos asimétrica.

Se aproxima a una normal cuando k es grande.

¿Dónde se utiliza?

- Pruebas de bondad de ajuste
- Pruebas de independencia
- Pruebas de homogeneidad
- Análisis de varianza (ANOVA)



A medida que aumentan los grados de libertad, la distribución chi-cuadrado se vuelve más simétrica y empieza a parecerse a una normal.



🔍 Comandos + Código ▾ + Texto | ▶ Ejecutar todas ▾

▼ Distribución chi-cuadrado (χ^2)[20]
✓ 0 s

```
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import chi2


x = np.linspace(0, 30, 400)

for df in [1, 2, 5, 10]:
    plt.plot(x, chi2.pdf(x, df=df), label=f"df={df}")

plt.title("Distribución Chi-cuadrado: cambia con los grados de libertad")
plt.xlabel("x")
plt.ylabel("densidad")
plt.legend()
plt.show()
```



▼ ...



Distribución t de Student

La distribución **t de Student** se utiliza cuando:

- Queremos estimar la media poblacional.
- La población es aproximadamente normal.
- El tamaño de muestra es pequeño.
- La varianza poblacional es desconocida.

Sea $T \sim t(k)$, con k grados de libertad. La forma de la curva es similar a la normal, pero con colas más pesadas.

La fórmula de la variable t es:

$$t = \frac{\bar{X} - \mu}{s/\sqrt{n}}$$

donde:

- $\bar{X}$ es la media muestral.
- s es la desviación estándar muestral.
- n es el tamaño de muestra.

La t de Student es como una normal con más cautela cuando no conocemos la desviación estándar poblacional.

Grados de libertad: $k=n-1$

Ejemplo de distribución t de Student

Se desea evaluar si la media poblacional es 70.

Datos de la muestra:

- $n = 10$
- $\bar{X} = 75$
- $s = 8$

Hipótesis: $H_0 : \mu = 70$

$H_1 : \mu \neq 70$

Estadístico t $t = \frac{75 - 70}{8/\sqrt{10}} \approx 1.98$

Grados de libertad: $k = n - 1 = 9$

Interpretación


Se compara el valor $t = 1.98$ con el valor crítico de la tabla t con 9 grados de libertad.

Para $\alpha = 0.05$ (bilateral), el valor crítico $\approx \pm 2.262$.

Como: $1.98 < 2.262$

No se rechaza H_0 .

No hay evidencia suficiente para afirmar que la media es distinta de 70.





Comandos + Código + Texto ▶ Ejecutar todas

[24]
✓ 0 s


```
x = np.linspace(-5, 5, 600)

dfs = [5, 20, 200] # n=5 -> df=4 (pequeña), n=30 -> df=29 (grande)

plt.plot(x, norm.pdf(x), label="Normal estándar N(0,1)")

for df in dfs:
    plt.plot(x, t.pdf(x, df=df), label=f"t-Student (df={df})")

plt.title("t-Student: n pequeño vs n grande (comparación con Normal)")
plt.xlabel("x")
plt.ylabel("densidad")
plt.legend()
plt.show()
```



Distribución de Fisher (F)

La **distribución F de Fisher-Snedecor** se emplea para comparar **dos varianzas** y en análisis de varianza (**ANOVA**). Es una distribución continua, no simétrica y siempre positiva.

¿Qué mide realmente?

La distribución F mide la relación entre dos fuentes de variabilidad.

$$F = \frac{\text{Varianza 1}}{\text{Varianza 2}}$$

Si ambas varianzas son similares $\rightarrow F \approx 1$

Si una varianza es mucho mayor $\rightarrow F$ será grande

Definición formal

Donde:

$$F = \frac{S_1^2}{S_2^2}$$

- S_1^2 = varianza muestral del numerador
- S_2^2 = varianza muestral del denominador

Tiene **dos grados de libertad**:

- $d_1 \rightarrow$ grados de libertad del numerador
- $d_2 \rightarrow$ grados de libertad del denominador

Aplicación de la distribución F

La distribución F se utiliza para evaluar si la diferencia entre dos varianzas es significativa. Aunque su fórmula es compleja, en la práctica se trabaja con tablas o software estadístico.

¿Cómo se interpreta F?

$$F = \frac{S_1^2}{S_2^2}$$

- Si $F \approx 1 \rightarrow$ las varianzas son similares
- Si $F > 1$ (mucho mayor) $\rightarrow$ hay diferencia importante en la variabilidad

Cuanto mayor es F, mayor es la evidencia contra la igualdad de varianzas.

Ejemplo

En un experimento se comparan dos tratamientos:

- $n_1 = 10$
- $n_2 = 15$
- Se obtiene $F = 2.5$

Grados de libertad:

- $d_1 = 9$
- $d_2 = 14$

Se consulta la tabla F (o software) para determinar si 2.5 es significativo.

¿Para que se usa?

- ANOVA (comparar medias de varios grupos)
- Comparar varianzas
- Regresión (test global del modelo)

En ANOVA, F compara:

Variabilidad entre grupos / Variabilidad dentro de los grupos

Si ese cociente es grande $\rightarrow$ existen diferencias entre medias.



Q Comandos + Código + Texto ▶ Ejecutar todas ▼



[26]

✓ 0 s




```
x = np.linspace(0.001, 5, 600) # evita 0 exacto

# Ejemplos de grados de libertad
pares_df = [(1, 10), (5, 10), (10, 10), (5, 30)]

for df1, df2 in pares_df:
    plt.plot(x, f.pdf(x, dfn=df1, dfd=df2), label=f"df1={df1}, df2={df2}")

plt.title("Distribución F de Fisher (densidad)")
plt.xlabel("x")
plt.ylabel("densidad")
plt.legend()
plt.show()
```



Distribución exponencial

La distribución exponencial modela **el tiempo de espera hasta que ocurre un evento**.

Se usa cuando:

- Los eventos ocurren al azar
- La tasa promedio es constante
- Los eventos son independientes

Ejemplos:

- Tiempo hasta la próxima llamada en un call center
- Tiempo hasta que falla una máquina
- Tiempo entre llegadas de clientes

Distribución exponencial

Idea clave:

- Mide cuánto tiempo esperas hasta el siguiente.
- Es continua y solo toma valores ≥ 0 .

Parámetro

Tiene un solo parámetro: $\lambda > 0$

λ = tasa de ocurrencia

- λ alto $\rightarrow$ los eventos pasan rápido
- λ pequeño $\rightarrow$ los eventos tardan más

Función de densidad

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

Propiedades importantes

Media: $E[X] = \frac{1}{\lambda}$

Varianza: $\text{Var}(X) = \frac{1}{\lambda^2}$

Ejemplo de distribución exponencial

Situación

El tiempo promedio entre llamadas es **5 minutos**.

$$\lambda = 1/5 = 0.2$$

Queremos calcular: ¿Cuál es la probabilidad de que la próxima llamada llegue antes de 2 minutos?

La función acumulada de la exponencial es:

$$P(X < x) = 1 - e^{-\lambda x}$$

Entonces:


$$P(X < 2) = 1 - e^{-0.2(2)}$$

$$P(X < 2) = 1 - e^{-0.4}$$

$$P(X < 2) \approx 1 - 0.67 = 0.33$$

Resultado:

Hay aproximadamente **33% de probabilidad** de que la llamada llegue antes de 2 minutos.





Comandos + Código + Texto ▶ Ejecutar todas



[27]

✓ 0 s



N = 10000

```
# Simulación: tiempos de espera
muestras = np.random.exponential(scale=1/lam, size=N)


plt.hist(muestras, bins=50, density=True, edgecolor="black")
plt.title(f"Distribución Exponencial ( $\lambda=\{lam\}$ ")
plt.xlabel("Tiempo de espera")
plt.ylabel("Densidad")
plt.show()

print("Media estimada:", np.mean(muestras))
print("Media teórica:", 1/lam)
```



v

...

Distribución Exponencial ($\lambda=0.5$)

Media estimada: 1.9549979093804692

Media teórica: 2.0

Comparativos de distribuciones continuas

Distribución	Forma	Parámetros	Soporte	Media	Varianza	¿Para qué se usa?
Uniforme continua	Rectángulo (densidad constante)	a, b	$[a, b]$	$(a+b)/2$	$(b-a)^2 / 12$	Cuando todos los valores en un intervalo son igualmente probables
Normal	Campana simétrica	μ, σ	$(-\infty, \infty)$	μ	σ^2	Fenómenos naturales, errores, mediciones
Normal estándar	Campana centrada en 0	—	$(-\infty, \infty)$	0	1	Estandarizar y calcular probabilidades
Chi-cuadrado (χ^2)	Asimétrica a la derecha	v (gl)	$[0, \infty)$	v	$2v$	Pruebas de varianza, independencia
t de Student	Campana con colas pesadas	v (gl)	$(-\infty, \infty)$	0	$v/(v-2)$ ($v > 2$)	Estimar medias con σ desconocida
F de Fisher	Asimétrica a la derecha	df_1, df_2	$(0, \infty)$	$df_2/(df_2-2)$ ($df_2 > 2$)	Depende de df_1 y df_2	Comparar varianzas, ANOVA
Exponencial	Decreciente	λ	$[0, \infty)$	$1/\lambda$	$1/\lambda^2$	Tiempo hasta que ocurre un evento

Actividad: ¿Qué distribución usarías?

1. Número de clientes que llegan a una tienda en una hora.
2. Tiempo que tarda en fallar un servidor.
3. Puntaje de una prueba estandarizada (media conocida, comportamiento simétrico).
4. Proporción de piezas defectuosas en una muestra pequeña (σ desconocida).
5. Comparar la variabilidad de ventas entre dos sucursales.
6. Número de éxitos en 20 intentos (éxito/fracaso).
7. Tiempo hasta que llegue la próxima llamada al call center.
8. Verificar si existe relación entre género y preferencia de producto (tabla de contingencia).
9. Medición de altura de personas adultas.
10. Comparar medias de tres grupos distintos.

Regla rápida:

- Conteos en tiempo/espacio $\rightarrow$ Poisson
- Tiempos de espera $\rightarrow$ Exponencial
- Mediciones simétricas $\rightarrow$ Normal
- Media con σ desconocida (muestra chica) $\rightarrow$ t
- Varianzas / ANOVA $\rightarrow$ F
- Tablas categóricas $\rightarrow \chi^2$
- Éxitos en n intentos $\rightarrow$ Binomial

Respuestas

1. Número de clientes que llegan a una tienda en una hora
→ Poisson, Porque es conteo de eventos en un intervalo de tiempo con una tasa promedio.
2. Tiempo que tarda en fallar un servidor
→ Exponencial Porque modela tiempo de espera hasta que ocurra un evento (falla).
3. Puntaje de una prueba estandarizada (comportamiento simétrico)
→ Normal Porque es una variable continua que suele concentrarse en torno a una media y es aproximadamente simétrica.
4. Estimar la media con muestra pequeña y σ desconocida
→ t de Student Porque cuando σ es desconocida y la muestra es pequeña, la estadística usa t (colas más pesadas).
5. Comparar la variabilidad de ventas entre dos sucursales
→ F de Fisher Porque compara varianzas (razón de varianzas), típica en ANOVA/varianzas.
6. Número de éxitos en 20 intentos (éxito/fracaso)
→ Binomial Porque hay n fijo (20), ensayos independientes, probabilidad constante y se cuentan éxitos.
7. Tiempo hasta que llegue la próxima llamada al call center
→ Exponencial Otra vez tiempo de espera; si la tasa es constante, la exponencial es el modelo natural.
8. Relación entre género y preferencia de producto (tabla de contingencia)
→ Chi-cuadrado (χ^2) de independencia Porque se compara observado vs esperado en una tabla para ver si hay independencia.
9. Medición de altura de personas adultas
→ Normal (aprox.) Es continua y típicamente se aproxima bien a una campana (aunque depende del grupo/medición).
10. Comparar medias de tres grupos distintos
→ ANOVA (usa F de Fisher) El test global se basa en un estadístico F, comparando variabilidad entre y dentro de grupos.

Recomendaciones para la elección de una distribución

La correcta elección de una distribución depende del **tipo de variable**, la **naturaleza del fenómeno** y la **forma de la distribución empírica** observada.

Clasificar la variable

¿Es discreta o continua?

Analizar la forma de los datos

Simetría, sesgo, presencia de colas.

Verificar supuestos

Independencia, homogeneidad de varianza, normalidad.

Comparar con histogramas teóricos

Usando software como Excel, R o Python.

Aplicar pruebas de ajuste

Como Kolmogorov-Smirnov, Chi-cuadrado o Anderson-Darling.

Ejemplos de selección de distribuciones



Conteo de eventos por tiempo

Si se cuentan eventos por unidad de tiempo
→ Distribución de Poisson.



Tiempo hasta ocurrencia

Si se mide tiempo hasta ocurrencia →
Distribución Exponencial.



Medias de pequeñas muestras

Si se estudian medias de pequeñas muestras
→ Distribución t de Student.



Comparación de varianzas

Si se desea comparar varianzas →
Distribución F de Fisher.



Variables continuas simétricas

Si la variable es continua y simétrica →
Distribución Normal.

La elección adecuada mejora la precisión de inferencias, reduce errores tipo I y II, y permite aplicar modelos correctamente fundamentados.

Características de la distribución normal

La distribución normal tiene múltiples propiedades que la convierten en la **más utilizada en estadística**. Entre ellas:

Simetría

Respecto a su media μ . La mediana y la moda coinciden.

Campana de Gauss

Forma clásica de campana, donde la mayoría de valores se agrupan cerca de la media.

Regla empírica

El 68%, 95% y 99.7% de los datos están dentro de 1, 2 y 3 desviaciones estándar, respectivamente.

Continuidad

Permite calcular probabilidades mediante el área bajo la curva.

Función de densidad de la distribución normal


La función de densidad es:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Ejemplo: Si $X \sim N(0,1)$, la probabilidad de que X esté entre -1 y 1 es:

$$P(-1 < X < 1) \approx 0.68$$

Estas características hacen que la normal sea usada para inferencia, control de calidad, análisis de regresión, entre otros.



$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Forma funcional y cálculo de probabilidad con la distribución normal

El cálculo de probabilidades con la distribución normal se basa en la integral de la función de densidad:

Sin embargo, esta integral no tiene solución analítica simple, por lo que se recurre a:

Tablas Z (cuando se usa la normal estándar).

Software como Excel, R, Python, SPSS.

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

Normalización de variables

Para usar la tabla Z, primero se **normaliza** la variable:

$$Z = \frac{X - \mu}{\sigma}$$

Ejemplo: Si $X \sim N(80, 10^2)$, calcular $P(X < 95)$:

$$Z = \frac{95 - 80}{10} = 1.5 \Rightarrow P(Z < 1.5) \approx 0.9332$$


Si se busca $P(70 < X < 90)$, se transforman ambos valores:

$$Z_1 = \frac{70 - 80}{10} = -1 \quad Z_2 = \frac{90 - 80}{10} = 1 \Rightarrow P(-1 < Z < 1) \approx 0.6826$$

Estos cálculos permiten evaluar eventos en contextos reales como pruebas estandarizadas, procesos industriales y análisis financieros.

Z-SCORE NORMALIZATION PROCESS


VALUE



x

$$z = \frac{x_j - \mu}{\sigma}$$

NORMALIZED VA




0

z

Distribuciones de probabilidad en la práctica

El estudio de las distribuciones de probabilidad es un pilar fundamental del análisis estadístico. A lo largo de esta lección, se abordaron tanto las distribuciones **discretas** (como Bernoulli, binomial, Poisson) como las **continuas** (uniforme, normal, t-Student, chi-cuadrado, Fisher, exponencial), junto con las propiedades que permiten describir y predecir el comportamiento de variables aleatorias.

Aplicaciones de las distribuciones de probabilidad



Campos de aplicación específicos

Distribución binomial

- Control de calidad (piezas defectuosas)
- Encuestas de opinión
- Genética (herencia de características)
- Análisis de riesgos

Distribución normal

- Mediciones físicas (altura, peso)
- Errores de medición
- Calificaciones en exámenes
- Indicadores económicos


Distribución de Poisson

- Llegadas a un sistema (clientes, llamadas)
- Fallos en equipos
- Accidentes en un período
- Mutaciones genéticas

Importancia de la selección adecuada

Se mostró cómo cada distribución tiene su propio campo de aplicación, dependiendo del tipo de variable, el contexto del experimento y las condiciones del fenómeno observado. Asimismo, se introdujeron herramientas clave para el cálculo de probabilidades, especialmente con la distribución normal y su forma estandarizada.

El conocimiento y aplicación correcta de estas distribuciones permiten realizar inferencias estadísticas sólidas, diseñar experimentos adecuados y tomar decisiones fundamentadas. En este sentido, dominar este contenido fortalece la capacidad de análisis crítico y riguroso en escenarios reales.



Criterios para la selección de distribuciones



Naturaleza del fenómeno

¿Qué tipo de evento estamos midiendo? ¿Es un conteo, una medición, un tiempo de espera?



Características de los datos

¿Son discretos o continuos? ¿Tienen límites naturales? ¿Son simétricos o sesgados?



Verificación de supuestos

¿Los datos cumplen con las condiciones necesarias para aplicar una distribución específica?



Pruebas de ajuste

Aplicar tests estadísticos para confirmar que la distribución elegida se ajusta adecuadamente a los datos.

Herramientas para el análisis de distribuciones

1

Histogramas

Representación gráfica que muestra la frecuencia de los datos en intervalos, permitiendo visualizar la forma de la distribución.

2

Gráficos Q-Q

Comparan los cuantiles de los datos con los cuantiles teóricos de una distribución, útiles para verificar normalidad.

3

Pruebas de bondad de ajuste

Tests estadísticos como Kolmogorov-Smirnov, Chi-cuadrado o Shapiro-Wilk que evalúan formalmente si los datos siguen una distribución específica.

4


Software estadístico

Programas como R, Python, SPSS o Excel que facilitan el análisis de distribuciones y el cálculo de probabilidades.


Distribuciones en el análisis de datos reales

En la práctica, los datos reales rara vez siguen perfectamente una distribución teórica. Sin embargo, las distribuciones de probabilidad siguen siendo modelos útiles que:

- Aproximan adecuadamente muchos fenómenos naturales y sociales
- Permiten hacer predicciones y estimaciones
- Facilitan la inferencia estadística
- Proporcionan un marco teórico para el análisis



CENTRAL LIMIT THEOREM



Distribuciones y el Teorema del Límite Central

El Teorema del Límite Central es uno de los resultados más importantes en estadística y explica por qué la distribución normal es tan prevalente:

La suma (o promedio) de un gran número de variables aleatorias independientes e idénticamente distribuidas tiende a seguir una distribución normal, independientemente de la distribución original de estas variables.

Este teorema justifica el uso de métodos basados en la normalidad en muchas aplicaciones estadísticas, incluso cuando los datos originales no son normales.

Distribuciones en la inferencia estadística

1

Estimación puntual

Uso de distribuciones para calcular estimadores de parámetros poblacionales como la media o la varianza.

2

Intervalos de confianza

Construcción de rangos que contienen el verdadero valor del parámetro con cierta probabilidad, basados en distribuciones como la normal o t de Student.

3




Pruebas de hipótesis

Evaluación de afirmaciones sobre parámetros poblacionales utilizando distribuciones como referencia para la toma de decisiones.

4

Análisis de varianza

Comparación de medias entre grupos utilizando la distribución F para evaluar la significancia de las diferencias.



Distribuciones en el modelado estadístico

Las distribuciones de probabilidad son componentes esenciales en el desarrollo de modelos estadísticos avanzados:

- Modelos lineales generalizados
- Series temporales
- Análisis bayesiano
- Modelos de supervivencia
- Métodos de remuestreo

En estos modelos, la elección de la distribución adecuada es crucial para capturar correctamente la naturaleza de los datos y hacer inferencias válidas.

Distribuciones en la era de los datos masivos

Incluso en la era del big data y el aprendizaje automático, las distribuciones de probabilidad siguen siendo relevantes:

Modelado de incertidumbre

Cuantificación de la incertidumbre en predicciones y estimaciones.

Detección de anomalías

Identificación de valores atípicos basada en distribuciones esperadas.

Generación de datos sintéticos

Creación de datos artificiales para entrenamiento o simulación.

Validación de modelos

Evaluación de residuos y errores en modelos predictivos.

Más allá de las distribuciones clásicas

Aunque este manual se ha centrado en las distribuciones más comunes, existen muchas otras distribuciones especializadas para casos específicos:



Distribución Weibull

Utilizada en análisis de fiabilidad y tiempo hasta el fallo.



Distribución Gamma

Modelado de tiempos de espera y precipitaciones.



Distribución Beta

Modelado de proporciones y probabilidades.



Distribución Lognormal

Común en finanzas e ingresos.

El estudio de estas distribuciones especializadas puede ser necesario en campos específicos o para modelar fenómenos particulares.

Consejos prácticos para el uso de distribuciones

1 Explorar los datos antes de elegir una distribución

Siempre examine gráficamente sus datos y calcule estadísticas descriptivas antes de decidir qué distribución utilizar.

2 Verificar los supuestos

Asegúrese de que los datos cumplen con los supuestos de la distribución elegida mediante pruebas formales.

3 Considerar transformaciones


Si los datos no siguen una distribución deseada, considere transformaciones (logarítmica, raíz cuadrada, etc.) que puedan normalizarlos.

4 Utilizar software estadístico

Aproveche las herramientas computacionales disponibles para ajustar y evaluar distribuciones.

Conclusiones sobre las distribuciones de probabilidad


Finalmente, recordar que el buen uso de las distribuciones no sólo implica conocer sus fórmulas, sino entender sus supuestos, reconocer sus aplicaciones y seleccionar con criterio cuál utilizar en cada situación. Este es un paso esencial en el camino hacia una práctica estadística profesional y confiable. El conocimiento de las distribuciones de probabilidad proporciona una base sólida para el análisis estadístico y la toma de decisiones basada en datos, permitiendo extraer conclusiones válidas y confiables a partir de la información disponible.



Despedida

El estudio de las distribuciones de probabilidad es un pilar fundamental del análisis estadístico. A lo largo de esta lección, se abordaron tanto las distribuciones **discretas** (como Bernoulli, binomial, Poisson) como las **continuas** (uniforme, normal, t-Student, chi-cuadrado, Fisher, exponencial), junto con las propiedades que permiten describir y predecir el comportamiento de variables aleatorias.

¡Nos vemos de nuevo, más adelante!





Ejercicio

Elige tu distribución

Elegí tu distribución

Contexto: 🙌

Eres un analista de datos y tienes que elegir la distribución adecuada para modelar estos fenómenos.

Consigna: 📝

Casos a analizar:

1. Producción defectuosa en una línea de ensamblado:

En una muestra de 20 piezas, la probabilidad de que una sea defectuosa es 0.1.

→ ¿Qué distribución te conviene usar?

2. Llegadas de mensajes de error por minuto en un servidor:

En promedio, se reciben 2 por minuto.

→ ¿Qué distribución aplicarías?

3. Cantidad de respuestas correctas al azar en un test de opción múltiple de 10 preguntas:

Cada pregunta tiene dos opciones y se responde sin saber.

→ ¿Qué distribución modela este fenómeno?

Tiempo 🕒: 40 Minutos

Elegí tu distribución

Paso a paso: 

1. Identifique si hay una cantidad fija de intentos o un intervalo de tiempo
2. Determine si los eventos son raros o tienen alta probabilidad
3. Asocie la distribución correcta: binomial o Poisson
4. Justifique tu elección con base en sus características
5. Grafique o esquematice cómo se vería la probabilidad en cada caso

¿Alguna consulta?





¡Ponte a prueba!

Momento de ejercitación

*Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.*

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< ¡Muchas gracias! >

