



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Fundamentos del aprendizaje de máquina- Parte II

Aprendizaje Esperado 1: Explicar conceptos fundamentales del aprendizaje de máquina supervisado para la resolución de un problema distinguiendo entre tareas de clasificación y de regresión.


Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos




Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?





Objetivos de aprendizaje

¿Qué aprenderás?



- Comprender la diferencia entre clasificación y regresión
- Reconocer cuándo aplicar cada tipo de tarea
- Identificar ejemplos reales de regresión
- Explorar distintos algoritmos de regresión
- Entender fortalezas y limitaciones de cada algoritmo

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :


- Qué es el aprendizaje automático
- Diferencias entre aprendizaje supervisado y no supervisado
- Tareas de clasificación y regresión
- Aplicaciones comunes en la vida real

Fundamentos del aprendizaje de máquina


Tipos de Aprendizaje de Máquina

El aprendizaje de máquina se puede clasificar en diferentes tipos, dependiendo de la forma en que el algoritmo recibe la información y aprende de los datos. Esta clasificación permite seleccionar el enfoque más adecuado para cada problema, considerando la naturaleza de los datos y el objetivo del análisis.

Types of Machine Learning Approaches



SUPERVISED LEARNING PROCESS WITH LABELED DATA



Aprendizaje supervisado

Definición

El primer tipo es el **aprendizaje supervisado**. En este enfoque, los datos de entrada están etiquetados, es decir, cada conjunto de datos incluye tanto las características como el resultado esperado.


Funcionamiento

El modelo aprende a partir de estos datos etiquetados para predecir resultados en datos nuevos. Ejemplos típicos incluyen la predicción de precios de viviendas, la detección de fraudes y la clasificación de correos electrónicos como spam o no spam.


Aprendizaje no supervisado

En segundo lugar, encontramos el **aprendizaje no supervisado**. En este caso, los datos no están etiquetados, por lo que el modelo debe encontrar patrones y estructuras ocultas dentro de los datos sin una guía explícita.

Los problemas más comunes son la agrupación o clustering y la reducción de dimensionalidad. Un ejemplo de aplicación es la segmentación de clientes basada en comportamientos de compra.



Aprendizaje semi-supervisado



Enfoque híbrido

Existe también un enfoque intermedio conocido como **aprendizaje semi-supervisado**, en el cual el modelo se entrena con un conjunto reducido de datos etiquetados y una gran cantidad de datos no etiquetados.




Ventaja de costos

Este enfoque es útil cuando el etiquetado manual de los datos es costoso o complejo, pero existe gran cantidad de datos sin clasificar.

Aprendizaje por refuerzo

Otro tipo relevante es el **aprendizaje por refuerzo**. En este método, el modelo aprende mediante la interacción con un entorno. No recibe etiquetas, sino recompensas o penalizaciones según las acciones que realiza.

Este tipo de aprendizaje es utilizado en áreas como la robótica, videojuegos y sistemas de recomendación en tiempo real.



Tareas dentro del aprendizaje supervisado



Regresión

Busca predecir un valor numérico continuo, como el precio de una casa o la temperatura.



Clasificación

Intenta asignar un dato a una categoría o clase específica, como spam/no spam o diagnóstico médico.

Dentro del aprendizaje supervisado, se pueden identificar dos grandes familias de tareas: **regresión** y **clasificación**.

Tareas dentro del aprendizaje no supervisado

1

Clustering

Consiste en agrupar elementos similares, como segmentación de clientes o agrupación de documentos por tema.

2

Reducción de dimensionalidad


Permite simplificar los datos eliminando información redundante, facilitando su visualización y procesamiento.

En el caso del aprendizaje no supervisado, el enfoque más común es el **clustering** y la **reducción de dimensionalidad**.


Aprendizaje por refuerzo en detalle

El aprendizaje por refuerzo se basa en un proceso continuo de prueba y error. El modelo toma decisiones, recibe un feedback positivo o negativo y ajusta su comportamiento en consecuencia, optimizando sus acciones para maximizar la recompensa a largo plazo.


Comprender los distintos tipos de aprendizaje de máquina es fundamental para elegir la estrategia adecuada en función del problema y los datos disponibles, garantizando así resultados más efectivos y precisos.



Supervised Learning



Unsupervised Learning



Aprendizaje Supervisado vs No Supervisado

El aprendizaje supervisado y el aprendizaje no supervisado son dos de las categorías fundamentales dentro del aprendizaje de máquina, y comprender sus diferencias es clave para decidir qué enfoque aplicar según el problema que se desea resolver.

Características del aprendizaje supervisado

Datos etiquetados

El **aprendizaje supervisado** se basa en el uso de datos etiquetados. Esto significa que, para cada entrada, se conoce de antemano el resultado esperado.


Objetivo

El objetivo del modelo es aprender la relación entre las variables de entrada y la etiqueta o resultado para poder realizar predicciones futuras. Un ejemplo clásico es la detección de correos electrónicos como spam, donde se entrena un modelo con ejemplos de correos etiquetados como "spam" o "no spam".

Características del aprendizaje no supervisado

Por el contrario, el **aprendizaje no supervisado** trabaja con datos sin etiquetar. El algoritmo debe analizar los datos y descubrir patrones, relaciones o estructuras ocultas sin que se le indique explícitamente qué buscar.

Un caso típico es la segmentación de clientes basada en sus patrones de compra, donde no existen categorías predefinidas y el algoritmo identifica grupos con características similares.



Complejidad y preparación de datos

Aprendizaje supervisado

Requiere mayor esfuerzo en la preparación de los datos, ya que es necesario contar con una cantidad significativa de datos etiquetados. Sin embargo, una vez entrenado, el modelo ofrece resultados más precisos para tareas concretas.

Aprendizaje no supervisado

Permite descubrir información nueva y desconocida, aunque los resultados pueden ser menos predecibles o más difíciles de interpretar.

Tareas comunes por tipo de aprendizaje

Aprendizaje supervisado

En el aprendizaje supervisado, las tareas más comunes son la **clasificación** y la **regresión**. La clasificación consiste en asignar una categoría a cada entrada, mientras que la regresión busca predecir un valor numérico.

1

2


Aprendizaje no supervisado

Por su parte, en el aprendizaje no supervisado, las tareas más frecuentes son el **clustering** (agrupamiento) y la **reducción de dimensionalidad**.

Evaluación de resultados

Otra diferencia clave radica en la evaluación de los resultados. En aprendizaje supervisado, es posible medir la precisión del modelo utilizando métricas objetivas, ya que se conocen las etiquetas verdaderas.

En aprendizaje no supervisado, en cambio, la evaluación es más subjetiva, pues no existen resultados "correctos" con los que comparar.



Recursos necesarios


Aprendizaje supervisado

Requiere un conjunto de datos más elaborado y costoso de obtener, ya que implica la labor de etiquetar cada entrada.

Aprendizaje no supervisado

Es más flexible, al poder trabajar directamente con los datos sin etiquetar, aunque el análisis y validación de los resultados pueden demandar un mayor esfuerzo.

Regression Algorithm
Predicting Continuous Values



Algoritmos regresivos

Los **algoritmos regresivos** son un tipo de algoritmos de *aprendizaje supervisado* que se utilizan en *Machine Learning* y estadística para **predecir un valor continuo** en lugar de una clase o categoría. Su objetivo principal es **encontrar relaciones entre una variable dependiente (la que queremos predecir) y una o más variables independientes (las que usamos para predecirla)**.

Características clave de los algoritmos regresivos

1

Salida continua

A diferencia de los algoritmos de clasificación que predicen etiquetas (como "spam" o "no spam"), los algoritmos regresivos predicen valores numéricos, como el precio de una casa, la temperatura, o los ingresos mensuales.

2

Modelan relaciones

Intentan modelar la relación matemática entre variables. Por ejemplo, cómo el tamaño de una casa (variable independiente) afecta su precio (variable dependiente).


3

Aplican funciones matemáticas

Muchos algoritmos regresivos utilizan funciones lineales, polinomiales o incluso más complejas para ajustar los datos y hacer predicciones.

Visualización de regresión lineal simple


La regresión lineal simple busca encontrar la mejor línea recta que minimice la distancia entre los puntos de datos y la línea. Esta línea representa la relación entre la variable independiente (eje X) y la variable dependiente (eje Y).



¿Qué es una tarea de regresión?

En el contexto del aprendizaje supervisado, una **tarea de regresión** consiste en predecir un valor numérico y continuo a partir de un conjunto de variables o características de entrada. A diferencia de las tareas de clasificación, donde el objetivo es predecir una categoría o clase, en la regresión el resultado es siempre un número real dentro de un rango posible.

Las tareas de regresión son esenciales para problemas donde el objetivo es cuantificar un resultado, y suelen ser la base de análisis financieros, meteorológicos, de salud, logística, entre otros.



Ejemplos de tareas de regresión



Inmobiliaria

Predicción del precio de un inmueble basado en características como ubicación, tamaño, antigüedad y amenidades.



Demanda

Estimación de la demanda de un producto según temporada, precio, competencia y tendencias del mercado.



Meteorología

Cálculo de la temperatura futura en una región basado en datos históricos y condiciones actuales.



Finanzas

Proyección de ingresos anuales de una empresa considerando factores económicos y rendimiento pasado.

Características clave de una tarea de regresión


Característica	Descripción
Tipo de salida	Numérica y continua.
Datos de entrada	Variables independientes (números, categorías, fechas, etc.).
Objetivo	Predecir una cantidad.
Ejemplos típicos	Precio, tiempo, cantidad, distancia, velocidad, entre otros.
Métricas de evaluación	Error Cuadrático Medio (MSE), Error Absoluto Medio (MAE), R^2 .

Algoritmos más utilizados para regresión


A lo largo de los años, se han desarrollado múltiples algoritmos para resolver problemas de regresión. A continuación, se detallan los más relevantes:

Comparison of Regression Algorithms


Linear Regression




Polynomial Regression



Ridge Regression



Lasso Regression



Regresión Lineal

Es el algoritmo más simple y utilizado como base en muchos problemas de predicción. Busca establecer una relación lineal entre una variable dependiente y una o varias variables independientes.

Fórmula básica: $y=mx+b$

donde:

- y es la variable objetivo.
- m es la pendiente.
- x es la variable independiente.
- b es el término independiente.

✓ Ventajas


- Fácil de interpretar.
- Computacionalmente eficiente.
- Bueno para relaciones lineales simples.

✗ Limitaciones

- No capta relaciones no lineales.
- Sensible a valores atípicos.

Regresión Polinómica

Es una extensión de la regresión lineal que permite capturar relaciones no lineales mediante la incorporación de términos polinomiales.



✓ Ventajas

- Aumenta la capacidad de ajuste frente a datos no lineales.

✗ Limitaciones

- Riesgo de sobreajuste si el grado del polinomio es muy alto.
- Interpretación menos intuitiva.

Árboles de Decisión para Regresión

Dividen el espacio de entrada en segmentos y ajustan un modelo simple (como la media) en cada segmento. Cada nodo del árbol representa una decisión basada en una característica del conjunto de datos.


✓ Ventajas

- Capturan relaciones no lineales.
- Interpretación sencilla.

✗ Limitaciones

- Sensibles a pequeñas variaciones en los datos.
- Pueden sobreajustarse.

Decision Tree for Regression



Random Forest Regressor


Es un ensamble de árboles de decisión que mejora la precisión y estabilidad de los resultados, reduciendo el sobreajuste.

✓ Ventajas

- Alta precisión.
- Maneja bien datos faltantes y escalas diferentes

✗ Limitaciones

- Difícil de interpretar.
- Elevado costo computacional.



Redes Neuronales para Regresión


Las redes neuronales pueden configurarse para realizar tareas de regresión ajustando su función de pérdida y salida.

✓ Ventajas

- Capturan relaciones complejas y no lineales.
- Escalables para grandes volúmenes de datos.

✗ Limitaciones

- Requieren grandes cantidades de datos.
- Mayor complejidad en la implementación y ajuste.



Comparativa de algoritmos de regresión


Algoritmo	Relación que modela	Tolerancia a datos atípicos	Complejidad	Interpretabilidad
Regresión Lineal	Lineal	Baja	Baja	Alta
Regresión Polinómica	No lineal simple	Baja	Media	Media
Árbol de Decisión	No lineal segmentada	Media	Baja	Alta
Random Forest Regressor	No lineal compleja	Alta	Alta	Baja
Redes Neuronales	No lineal compleja	Media/Alta	Muy alta	Muy baja

Algoritmos de Clasificación

¿Qué es una tarea de clasificación?

La **clasificación** es un tipo de problema en el aprendizaje supervisado donde el objetivo es predecir una categoría o clase para un conjunto de datos de entrada. A diferencia de las tareas de regresión, que predicen un valor numérico continuo, en clasificación el resultado es una etiqueta discreta.

Classification Task



Ejemplos de tareas de clasificación



Filtrado de correo

Determinar si un correo electrónico es spam o no (clasificación binaria).



Reconocimiento de imágenes

Clasificar un conjunto de imágenes según la categoría (perro, gato, pájaro).



Análisis de sentimiento

Detectar el sentimiento de un comentario como positivo, neutro o negativo.




Etiquetado múltiple

Asignar etiquetas múltiples a un documento (clasificación multi-etiqueta).

Este tipo de tareas es fundamental en áreas como la seguridad informática, la medicina, las finanzas y el marketing digital.

TYPES OF CLASSIFICATION TASKS



Tipos de tarea de clasificación

Existen diferentes tipos de problemas de clasificación según la cantidad y naturaleza de las etiquetas:

Clasificación Binaria

Consiste en predecir entre dos posibles clases.

Ejemplos:

- Aprobado / Reprobado
- Spam / No spam
- Cliente que compra / Cliente que no compra

✓ Ventajas

Sencilla de implementar y evaluar.

✗ Limitaciones

No aplicable para problemas con múltiples categorías.




Gráfico de dispersión con frontera de decisión entre dos clases.

Clasificación Multiclase y Multi-etiqueta

Clasificación Multiclase

Aquí el objetivo es asignar una única clase a cada instancia, pero hay más de dos categorías posibles.

Ejemplos:

- Clasificación de tipos de vehículos: coche, camión, moto, bicicleta.
- Detección del estado de un dispositivo: encendido, apagado, en espera.

Clasificación Multi-etiqueta

Permite asignar varias clases simultáneamente a una instancia.

Ejemplos:

- Etiquetado de imágenes con múltiples objetos: "persona", "bicicleta", "árbol".
- Clasificación de un documento en varias categorías temáticas.


Dimensiones y la Maldición de la Dimensionalidad

En el contexto del aprendizaje de máquina, el término **dimensión** se refiere al número de variables o características (features) que describen un conjunto de datos. A medida que la cantidad de dimensiones aumenta, también lo hace la complejidad del análisis y del modelo que se necesita para procesar esos datos.

La **maldición de la dimensionalidad** es un fenómeno que ocurre cuando el número de dimensiones en un conjunto de datos es tan alto que afecta negativamente el rendimiento de los algoritmos de aprendizaje de máquina. Este concepto fue introducido por Richard Bellman en 1961 y se presenta, principalmente, cuando el volumen del espacio de búsqueda crece exponencialmente con cada nueva dimensión añadida.

Cuando los datos tienen muchas dimensiones, la distancia entre los puntos de datos pierde significado, aumenta el riesgo de sobreajuste, se requiere un mayor volumen de datos y la capacidad de generalización del modelo disminuye.

Curse of Dimensionality



Live Coding

¿En qué consistirá la Demo?

trabajaremos un caso de regresión simple aplicando regresión lineal sobre un conjunto de datos sintéticos.

1. Cargar los datos de ejemplo
2. Visualizar la relación entre variables
3. Ajustar un modelo de regresión lineal
4. Analizar la ecuación generada
5. Evaluar el rendimiento del modelo con R^2
6. Interpretar los coeficientes
7. Comparar con regresión polinómica
8. Discusión grupal de resultados



Momento:

Time-out!



5 -10 min.





Ejercicio

Clasificación o regresión: ¿cuál aplico?

Clasificación o regresión: ¿cuál aplico?

Contexto: 🙌

En este ejercicio deberemos analizar diferentes situaciones del mundo real y decidir si la tarea a resolver corresponde a una clasificación o una regresión.

Consigna: 📝

Lee cada uno de los casos presentados. Luego, indique si el problema corresponde a una tarea de regresión o de clasificación, justificando brevemente tu elección.

Paso a paso: ⚙️

1. Leer cada caso
2. Analizar el tipo de salida esperada (número o categoría)
3. Identificar variables involucradas
4. Elegir tipo de tarea y justificar
5. Comparar respuestas en grupo

Tiempo 🕒: 45 Minutos

Clasificación o regresión: ¿cuál aplico?

Casos a analizar:

1. Predecir el precio de una casa en función de su superficie, ubicación y número de habitaciones.
2. Detectar si un correo electrónico es spam o no a partir de su contenido.
3. Estimar el consumo energético de un electrodoméstico según sus características técnicas.
4. Determinar el tipo de flor (iris-setosa, iris-versicolor o iris-virginica) según el ancho y largo de pétalos y sépalos.
5. Pronosticar la temperatura del día siguiente en grados Celsius.
6. Predecir si un cliente abandonará un servicio en los próximos 30 días

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Diferenciamos tareas de regresión y clasificación**
- ✓ **Comprendimos cómo y cuándo aplicar regresión**
- ✓ **Conocimos los algoritmos principales de regresión**
- ✓ **Realizamos una demo completa con regresión lineal**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

