



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Regresiones- Parte I

Aprendizaje Esperado 4: Elaborar un modelo predictivo utilizando algoritmos de regresión para resolver un problema de dado de acuerdo a las buenas prácticas de la industria.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Introducción a regresiones

en esta clase conocerás los fundamentos de los modelos de regresión y su aplicación en problemas de predicción numérica.

¿Qué es una regresión?

Diferencias entre clasificación y regresión

Casos de uso y aplicaciones reales

Regresión lineal vs no lineal

Relación entre variables

Elección del modelo

Objetivos de aprendizaje

¿Qué aprenderás?

- Entender el concepto de regresión en aprendizaje supervisado
- Distinguir entre regresión lineal y no lineal
- Aplicar modelos de regresión a conjuntos de datos reales
- Visualizar la relación entre variables predictoras y respuesta
- Interpretar coeficientes del modelo y evaluar con métricas
- Preparar datos correctamente para entrenamiento de regresión

Repaso clase anterior

¿Quedó alguna duda?





En la clase anterior trabajamos :

- El preprocesamiento de datos para modelos supervisados
- Métodos de limpieza, codificación y escalamiento
- Cómo preparar los datos antes del entrenamiento
- Aplicamos normalización, codificamos variables categóricas y tratamos valores faltantes

Regresiones

DATA ANALYSIS

REGRESSION MODELS



REGRESIONES

El análisis de regresión es uno de los métodos fundamentales en el campo del aprendizaje automático supervisado. Su principal objetivo es predecir un valor numérico continuo a partir de un conjunto de datos que contienen variables independientes. A diferencia de los problemas de clasificación, donde el objetivo es asignar etiquetas, los problemas de regresión buscan establecer relaciones cuantitativas entre variables.

La regresión es ampliamente utilizada en distintas áreas, como economía, medicina, ingeniería y ciencias sociales, para entender cómo una o varias variables independientes influyen en una variable dependiente. Además, permite identificar patrones, realizar pronósticos y facilitar la toma de decisiones basada en datos.

Problemas de regresión

Definición

Los problemas de regresión son aquellos en los que el objetivo es predecir un valor continuo a partir de uno o varios atributos o variables independientes. A diferencia de los problemas de clasificación, donde el resultado es una etiqueta o categoría, en la regresión el resultado es un número real.

Aplicaciones

Estos problemas son frecuentes en la vida real y en distintas áreas, como economía, salud, meteorología y negocios. Un problema típico de regresión consiste, por ejemplo, en predecir el precio de una vivienda a partir de características como el tamaño, la ubicación y el número de habitaciones.

El análisis de regresión permite establecer una relación funcional entre las variables independientes y la variable dependiente. El propósito no solo es hacer predicciones, sino también entender el impacto que cada variable tiene sobre el resultado, lo que facilita la toma de decisiones.

Tipos de regresión

1

Regresión lineal

Es la forma más simple y utilizada. En ella, se asume que la relación entre las variables es lineal, es decir, que un cambio en la variable independiente provoca un cambio proporcional en la variable dependiente.

2

Regresión no lineal

Algunos problemas presentan relaciones no lineales entre las variables. En estos casos, es necesario utilizar modelos de regresión más complejos, como la regresión polinómica, la regresión logística (para problemas binarios) o técnicas basadas en árboles y redes neuronales.

La calidad de un modelo de regresión se evalúa mediante métricas específicas, como el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **coeficiente de determinación R^2** . Estas métricas permiten medir la diferencia entre los valores predichos y los valores reales, evaluando así la precisión del modelo.

Data Preprocessing Workflow



Preprocesamiento de datos


Una característica importante de los problemas de regresión es la necesidad de un buen preprocesamiento de los datos. La limpieza, codificación y escalamiento de las variables es fundamental para que los modelos funcionen correctamente y no se vean afectados por valores extremos o diferencias de magnitud.

- Limpieza de datos para eliminar valores atípicos
- Codificación de variables categóricas
- Escalamiento para normalizar magnitudes
- Tratamiento de valores faltantes

Ejemplo práctico: Consumo de combustible

Supongamos que tenemos un conjunto de datos con la información de varios automóviles, incluyendo el peso del vehículo y su consumo de combustible medido en millas por galón (MPG). El objetivo es predecir el consumo de un automóvil según su peso. Este es un clásico problema de regresión, ya que la variable objetivo (MPG) es continua.

Vehículo	Peso (Kg)	Consumo (MPG)
1	1500	35
2	1800	30
3	2000	28
4	2500	22



Un modelo de regresión podría encontrar una relación negativa entre el peso del automóvil y su consumo, es decir, que a mayor peso, menor eficiencia de combustible.

Casos de uso y ejemplos



Predicción de precios inmobiliarios

Empresas del sector inmobiliario utilizan modelos de regresión para estimar el valor de una vivienda en función de variables como la ubicación, el tamaño, la antigüedad y el número de habitaciones.



Predicción de activos financieros

En el sector financiero, los modelos de regresión son empleados para predecir el precio de acciones o activos financieros. Estos modelos consideran factores como el comportamiento histórico del mercado, indicadores económicos y noticias relevantes.



Predicción en salud

Los sistemas de predicción de riesgo médico utilizan regresión para estimar la probabilidad de que un paciente desarrolle una determinada enfermedad o para prever la evolución de ciertos parámetros clínicos.

Más casos de uso



Pronósticos meteorológicos

En el área de la meteorología, los modelos de regresión son empleados para pronosticar variables climáticas, como la temperatura, la humedad o la velocidad del viento, a partir de datos históricos y condiciones atmosféricas actuales.



Predicción de ventas

Empresas de retail utilizan estos modelos para anticipar la demanda de un producto, considerando factores como la estacionalidad, promociones y comportamiento del consumidor.



Ingeniería y sistemas físicos

En la industria automotriz, se pueden predecir las emisiones de un vehículo en función de parámetros como la velocidad y la aceleración.


En marketing digital, los modelos de regresión permiten estimar el **retorno de inversión (ROI)** de una campaña publicitaria, considerando variables como el presupuesto, el canal de distribución y las características del público objetivo.

Ejemplo práctico: E-commerce

Un caso real de aplicación sería una tienda de e-commerce que desea predecir el monto de compra promedio de un cliente según variables como la edad, el tiempo que pasa en la tienda online y la cantidad de productos vistos. El objetivo es estimar cuánto gastará un cliente nuevo en función de estas características para optimizar las campañas de marketing.

Un modelo de regresión podría ser entrenado para predecir el monto de compra esperado de un nuevo cliente que pase, por ejemplo, 18 minutos en la tienda y vea 6 productos.

Cliente	Edad	Tiempo en la tienda (min)	Productos vistos	Monto compra (USD)
1	25	15	5	120
2	30	20	8	150
3	22	10	3	80
4	35	25	10	200



Visualización del modelo de regresión multivariable

Esta es una visualización en 3D de un modelo de regresión lineal multivariable que predice el monto de compra (USD) en función del tiempo en tienda y la cantidad de productos vistos.

- Los puntos azules representan los datos reales de los clientes.
- El plano verde es la superficie ajustada por el modelo de regresión, que muestra las predicciones en función de las variables independientes.

Problemas lineales vs no lineales

Regresión lineal

Un problema de regresión se considera **lineal** cuando la relación entre las variables independientes y la variable dependiente puede representarse mediante una línea recta en un espacio de dos dimensiones, o un hiperplano en espacios de mayor dimensión.

La regresión lineal tiene la siguiente forma general:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

donde Y es la variable dependiente, X_i son las variables independientes, β_i son los coeficientes del modelo y ε es el término de error.

Regresión no lineal

Existen muchos casos en los que los datos presentan una relación **no lineal**. Esto significa que no es posible encontrar una única línea recta que explique adecuadamente la relación entre las variables.


Las relaciones no lineales requieren el uso de técnicas de modelado más complejas, como:

- Regresión polinómica
- Regresión con kernels
- Redes neuronales
- Modelos basados en árboles

Elección entre modelos lineales y no lineales

La elección entre un modelo lineal y uno no lineal debe basarse en el análisis exploratorio de los datos. La visualización gráfica de los datos es una herramienta clave para identificar patrones y determinar si existe una tendencia lineal o si, por el contrario, la relación requiere un modelo más flexible.

Además, es importante considerar que los modelos no lineales, aunque pueden ofrecer un mejor ajuste, son más complejos y propensos al **sobreajuste**. Por ello, siempre debe buscarse un equilibrio entre la capacidad predictiva del modelo y su capacidad de generalización.



Ejemplo práctico: Horas de estudio y calificaciones

Relación lineal


Horas estudiadas	Calificación
1	50
2	55
3	65
4	70
5	85
6	90

Si representamos estos datos en un gráfico, observamos una tendencia aproximadamente lineal: a medida que aumentan las horas de estudio, la calificación mejora. Por lo tanto, un modelo de regresión lineal podría ser adecuado.

Relación no lineal

Horas estudiadas	Calificación
1	50
2	70
3	90
4	85
5	60
6	55

En este caso, la relación sería no lineal (forma de campana), y un modelo de regresión polinómica o no lineal sería más apropiado para capturar la tendencia.



Visualización de relaciones lineales y no lineales

En la imagen se pueden observar dos gráficos que ilustran la diferencia entre una relación lineal (izquierda) y una relación no lineal (derecha) entre las horas de estudio y las calificaciones obtenidas.

En el primer caso, un modelo de regresión lineal (línea roja) captura adecuadamente la tendencia de los datos. En el segundo caso, se requiere un modelo no lineal (curva roja) para representar correctamente la relación entre las variables.

Implementación con la librería Scikit-Learn

Importar librerías

Primero se importan las librerías necesarias como Scikit-Learn, NumPy y Pandas para el manejo de datos y la implementación del modelo.

Cargar y dividir datos

Los datos son cargados y divididos en un conjunto de entrenamiento y otro de prueba utilizando la función `train_test_split`.

Crear y entrenar el modelo

Se crea una instancia del modelo de regresión utilizando la clase `LinearRegression` y se entrena con el método `fit`.

Realizar predicciones

Se utiliza el método `predict` para realizar predicciones sobre nuevos datos o sobre el conjunto de prueba.

Evaluar el modelo

Se calculan métricas como MSE, MAE y R^2 para evaluar el desempeño del modelo.

Flujo de trabajo con Scikit-Learn

La librería **Scikit-Learn** es una de las herramientas más utilizadas en el ecosistema Python para la construcción de modelos de aprendizaje automático. Dentro de sus múltiples funcionalidades, ofrece módulos específicos para la implementación de modelos de regresión, facilitando la creación, entrenamiento y evaluación de estos modelos.

Para problemas de regresión lineal, Scikit-Learn proporciona la clase `LinearRegression`, que permite ajustar un modelo lineal a los datos de entrada. Este modelo asume que existe una relación lineal entre las variables independientes y la variable objetivo.

Integración con otras herramientas

Pipeline

Scikit-Learn permite integrar los modelos de regresión dentro de un **Pipeline**, junto con otras tareas de preprocesamiento como la imputación de valores faltantes, la codificación de variables categóricas y el escalamiento de datos.

Métricas de evaluación


La librería proporciona funciones para calcular métricas de evaluación, como el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **coeficiente de determinación R^2** .

Visualización

Aunque Scikit-Learn no incluye herramientas de visualización, se integra perfectamente con bibliotecas como Matplotlib y Seaborn para crear gráficos que ayuden a interpretar los resultados.

Entrenamiento del algoritmo regresivo

El **entrenamiento de un algoritmo regresivo** consiste en ajustar los parámetros del modelo utilizando un conjunto de datos de entrenamiento. Durante este proceso, el modelo analiza las relaciones entre las variables independientes y la variable dependiente para aprender una función que minimice la diferencia entre los valores predichos y los valores reales. En el caso de la **regresión lineal**, el proceso de entrenamiento implica encontrar los coeficientes (β) que mejor ajusten la línea recta a los datos. Este ajuste se realiza mediante la minimización de una función de coste, generalmente el **Error Cuadrático Medio (MSE)**, que mide la suma de las diferencias al cuadrado entre los valores reales y los valores predichos.



Factores que afectan el entrenamiento

Calidad y cantidad de datos

El entrenamiento de un modelo de regresión puede verse afectado por la calidad y cantidad de los datos disponibles. Datos insuficientes o de baja calidad pueden llevar a modelos poco precisos.

Valores atípicos

La presencia de valores atípicos (outliers) puede distorsionar significativamente el modelo, especialmente en regresión lineal, que es sensible a estos valores extremos.


Multicolinealidad

La multicolinealidad entre las variables independientes puede dificultar la interpretación del modelo y reducir su estabilidad. Ocurre cuando dos o más variables están altamente correlacionadas.

Por estos factores, es fundamental realizar un adecuado preprocesamiento antes de iniciar el entrenamiento.

Técnicas de optimización

Gradient Descent



Gradiente descendente

Durante el proceso de entrenamiento, el modelo ajusta iterativamente sus parámetros utilizando técnicas de optimización, como el método de **gradiente descendente**. Este algoritmo busca minimizar la función de coste ajustando los parámetros en la dirección opuesta al gradiente.

Resolución directa

En algunos casos, como en la regresión lineal simple, es posible obtener los parámetros óptimos directamente mediante fórmulas matemáticas, sin necesidad de un proceso iterativo.


Es importante dividir el conjunto de datos en dos subconjuntos: uno para el entrenamiento y otro para la prueba. Esto permite evaluar el desempeño del modelo en datos no vistos durante el entrenamiento, garantizando que no se produzca un **sobreajuste**.

Validación cruzada

Para evitar que el modelo dependa excesivamente de un único conjunto de prueba, es recomendable utilizar técnicas de validación cruzada, como **K-Fold Cross Validation**, que permiten obtener una estimación más robusta del desempeño del modelo.

El proceso de entrenamiento debe incluir un monitoreo continuo de las métricas de evaluación para detectar posibles problemas, como un error alto o una baja capacidad de generalización. En caso de obtener resultados insatisfactorios, se pueden aplicar técnicas de regularización, ajustar la complejidad del modelo o mejorar la calidad de los datos.

K-FOLD CROSS VALIDATION



Ejemplo práctico: Entrenamiento del modelo

En la imagen se muestra un ejemplo de código Python para entrenar un modelo de regresión lineal utilizando Scikit-Learn. El código incluye:

- Importación de las librerías necesarias
- Creación de un conjunto de datos de ejemplo
- División de los datos en conjuntos de entrenamiento y prueba
- Creación y entrenamiento del modelo de regresión lineal
- Evaluación del modelo utilizando el coeficiente de determinación R^2

```
# Separar variables
X = datos[['Horas_Estudio']]
y = datos['Calificacion']

# Dividir en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.33, random_state=42)

# Crear y entrenar el modelo
modelo = LinearRegression()
modelo.fit(X_train, y_train)
```

```
# Ver los coeficientes del modelo
print("Intercepto ( $\beta_0$ ):", modelo.intercept_)
print("Coeficiente ( $\beta_1$ ):", modelo.coef_[0])
```

Salida:

```
Intercepto ( $\beta_0$ ): 37.5
Coeficiente ( $\beta_1$ ): 8.75
```

Predicciones con el modelo regresivo

1

Preparación de datos

Es importante que los datos utilizados para la predicción tengan la misma estructura y formato que los datos utilizados durante el entrenamiento. Esto incluye el orden y la escala de las variables, así como cualquier transformación aplicada previamente.

2

Realización de predicciones


La predicción se realiza utilizando el método `predict()` del modelo en Scikit-Learn. Este método recibe como entrada un conjunto de datos con las características independientes y devuelve los valores estimados de la variable objetivo.

3

Evaluación de resultados

La calidad de las predicciones debe evaluarse utilizando métricas específicas, como el **Error Cuadrático Medio (MSE)**, el **Error Absoluto Medio (MAE)** y el **coeficiente de determinación R^2** .

Single Point Prediction in Regression Model



Tipos de predicciones

Predicciones puntuales

Un modelo regresivo puede realizar predicciones puntuales, es decir, un único valor para una observación específica. Por ejemplo, predecir el precio exacto de una casa con determinadas características.

Predicciones para conjuntos

También puede realizar predicciones para un conjunto de datos completo. Estas predicciones pueden ser utilizadas para la toma de decisiones, el análisis de escenarios futuros o la automatización de procesos.

Además, las predicciones pueden utilizarse para identificar patrones o tendencias. Por ejemplo, un modelo de regresión puede predecir la evolución de las ventas de un producto, permitiendo a la empresa anticiparse a la demanda y planificar su producción.

Consideraciones importantes

⚠ Es fundamental recordar que las predicciones solo serán fiables si el modelo fue entrenado adecuadamente y si los datos utilizados para la predicción son representativos y siguen la misma distribución que los datos de entrenamiento.

Algunos factores que pueden afectar la calidad de las predicciones son:

- Cambios en la distribución de los datos (concept drift)
- Presencia de valores atípicos en los nuevos datos
- Variables no consideradas durante el entrenamiento
- Sobreajuste del modelo a los datos de entrenamiento

Por ello, es recomendable monitorear continuamente el desempeño del modelo y reentrenarlo periódicamente si es necesario.

Ejemplo práctico: Predicción de calificaciones

Continuando con el ejemplo anterior de calificaciones, una vez entrenado el modelo, podemos utilizarlo para predecir la calificación de un estudiante que ha estudiado 3.5 horas:

```
# Realizar predicción para 3.5 horas de estudio
horas_nuevas = [[3.5]]
calificacion_predicha = modelo.predict(horas_nuevas)
print(f"Calificación predicha: {calificacion_predicha[0]:.2f}")
print(f"R² del modelo: {modelo.score(X_test, y_test):.2f}")
```

Salida:

- ❶ El modelo predice que un estudiante que estudie 3.5 horas obtendrá una calificación aproximada de 68.13. Además, el modelo presenta un buen desempeño, con un R^2 de 0.96, indicando que explica el 96% de la variabilidad de los datos.




Selección del modelo

La **selección del modelo** es una de las etapas más importantes en el desarrollo de un sistema de aprendizaje automático basado en regresión. Elegir el modelo adecuado no solo implica seleccionar un algoritmo, sino también determinar la complejidad y los parámetros que mejor se ajusten al problema y a los datos disponibles.


Uno de los criterios principales para la selección del modelo es la **capacidad de generalización**. Un modelo adecuado debe ser capaz de realizar buenas predicciones no solo sobre los datos de entrenamiento, sino también sobre datos nuevos, evitando tanto el **sobreajuste** como el **subajuste**.

Model Selection


Linear
Regression




Ridge
Regression



Lasso
Regression



Polynomial
Regression



Métricas de evaluación



Error Cuadrático Medio (MSE)

Mide el promedio de los errores al cuadrado entre los valores predichos y los valores reales. Es sensible a valores atípicos debido al cuadrado.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$



Error Absoluto Medio (MAE)

Mide el promedio de los valores absolutos de los errores. Es menos sensible a valores atípicos que el MSE.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$



Coefficiente de determinación (R²)

Indica la proporción de la varianza en la variable dependiente que es predecible a partir de las variables

independientes. Varía entre 0 y 1, donde 1 indica un ajuste perfecto.

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$


Validación cruzada para selección de modelos

La técnica de **validación cruzada** es clave para obtener una estimación robusta del desempeño de los modelos. La validación cruzada de K-iteraciones (K-Fold Cross Validation) consiste en dividir el conjunto de datos en K subconjuntos y evaluar el modelo K veces, utilizando un subconjunto diferente como prueba en cada iteración.

Esta técnica permite:

- Obtener una estimación más confiable del error de generalización
- Reducir el impacto de la variabilidad en la división de los datos
- Aprovechar al máximo los datos disponibles para el entrenamiento
- Detectar problemas de sobreajuste o subajuste

K-fold Cross-Validation



Complejidad del modelo

1

Modelos simples

Un modelo sencillo, como la regresión lineal, es fácil de interpretar y rápido de entrenar, pero puede ser insuficiente para problemas con relaciones no lineales.

2

Modelos intermedios

Modelos como la regresión polinómica o los árboles de decisión ofrecen un equilibrio entre complejidad y capacidad de ajuste.

3

Modelos complejos

Un modelo excesivamente complejo puede ajustarse demasiado a los datos de entrenamiento, capturando el ruido y perdiendo capacidad de generalización.

Por ello, es fundamental equilibrar la complejidad y el rendimiento, buscando un modelo que logre un buen ajuste sin caer en el sobreajuste.

Live Coding

¿En qué consistirá la Demo?

Vamos a construir e interpretar un modelo de regresión lineal que predice el consumo de combustible (MPG) a partir del peso del vehículo.

1. Generar y Cargar dataset (auto-mpg.csv)
2. Inspeccionar variables y limpiar valores faltantes
3. Dividir en variables predictoras (X) y objetivo (y)
4. Separar en train y test (80/20)
5. Entrenar con `LinearRegression()`
6. Visualizar recta de regresión
7. Evaluar con R^2 y MAE
8. Interpretar el coeficiente de regresión



Momento:

Time-out!



5 -10 min.





Ejercicio

Modelando el precio de bicicletas

Modelando el precio de bicicletas

Contexto: 🙌

Trabajás en una tienda online de bicicletas. Contás con un dataset histórico con datos sobre precio, peso, tamaño del cuadro, cantidad de marchas y tipo de bicicleta. Querés desarrollar un modelo que prediga el precio de una bicicleta nueva a partir de sus características.

Consigna: 📝

Entrene un modelo de regresión lineal múltiple para predecir el precio de una bicicleta. Evalúe el modelo con métricas y genere visualizaciones útiles.

Paso a paso: ⚙️

1. Cargue el dataset bicicletas.csv
2. Explore y limpie los datos si es necesario
3. Defina X (variables predictoras) y y (precio)
4. Separe en conjunto de entrenamiento y prueba
5. Entrene el modelo con LinearRegression
6. Obtenga e interprete los coeficientes
7. Realice predicciones sobre el set de prueba
8. Evalúe el rendimiento con R^2 y MAE
9. Visualice precios reales vs. predichos
10. Reflexione: ¿el modelo es útil para el negocio?

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Comprendimos qué es una regresión y cómo aplicarla**
- ✓ **Distinguimos entre tareas de clasificación y regresión**
- ✓ **Entrenamos un modelo de regresión lineal con Scikit-learn**
- ✓ **Evaluamos el modelo con métricas y visualizaciones**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

