



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Regresiones- Parte II

Aprendizaje Esperado 4: Elaborar un modelo predictivo utilizando algoritmos de regresión para resolver un problema de dado de acuerdo a las buenas prácticas de la industria.


Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Evaluación de modelos de regresión

vamos a analizar cómo medir el rendimiento de un modelo de regresión de manera objetiva y comparativa.

Métricas para regresión

R^2 , MAE, MSE y RMSE

Interpretación y comparación entre modelos

Regularización

Ridge y Lasso

Impacto en el ajuste y en los coeficientes

Objetivos de aprendizaje

¿Qué aprenderás?

- Comprender los supuestos fundamentales en regresión lineal.
- Evaluar modelos de regresión utilizando múltiples métricas.
- Aplicar técnicas de regularización (Lasso, Ridge, ElasticNet).
- Explorar modelos no lineales de regresión: árboles, SVR, redes neuronales.
- Implementar modelos de regresión en casos reales con buenas prácticas.

Repaso clase anterior


¿Quedó alguna duda?

En la clase anterior trabajamos :

- Regresión lineal simple, múltiple y polinómica.
- Regularización con Lasso, Ridge y ElasticNet.
- Árboles de decisión y Random Forest para regresión.
- Validación cruzada para elegir el mejor modelo.

Regresiones

Predicted vs. Actual Values



Análisis de residuos

También es recomendable realizar un análisis gráfico de los residuos y la dispersión de las predicciones para detectar patrones anómalos o errores sistemáticos que indiquen que el modelo no está capturando adecuadamente la estructura de los datos.

Los residuos son las diferencias entre los valores observados y los valores predichos por el modelo. Un buen modelo debería tener residuos que:

- Se distribuyan aleatoriamente alrededor de cero
- No muestren patrones o tendencias
- Tengan una varianza constante (homocedasticidad)
- Sigam aproximadamente una distribución normal

Ejemplo práctico: Comparación de modelos

Supongamos que estamos comparando dos modelos de regresión para predecir las calificaciones de los estudiantes en función de las horas de estudio: un modelo lineal y un modelo polinómico de grado 2. Aplicamos validación cruzada y calculamos las métricas de evaluación:

```
# Comparación de modelos
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.pipeline import Pipeline
from sklearn.model_selection import cross_val_score
import numpy as np


# Modelo lineal
modelo_lineal = LinearRegression()
mse_lineal = -cross_val_score(modelo_lineal, X, y, cv=5,
                              scoring='neg_mean_squared_error')

# Modelo polinómico
modelo_poli = Pipeline([
    ('poly', PolynomialFeatures(degree=2)),
    ('linear', LinearRegression())
])
mse_poli = -cross_val_score(modelo_poli, X, y, cv=5,
                             scoring='neg_mean_squared_error')

print(f"MSE modelo lineal: {np.mean(mse_lineal):.2f}")
print(f"MSE modelo polinómico: {np.mean(mse_poli):.2f}")
```

Salida:

En este caso, el modelo polinómico presenta un menor error cuadrático medio, lo que indica un mejor ajuste. Sin embargo, antes de elegirlo, sería recomendable analizar el riesgo de sobreajuste y comprobar que el modelo no está capturando ruido de los datos.



Regresión lineal simple

La regresión lineal simple es el tipo más básico de regresión, donde se modela la relación entre una variable independiente y una variable dependiente mediante una línea recta.

La ecuación de la regresión lineal simple es:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$


Donde:

- Y es la variable dependiente (lo que queremos predecir)
- X es la variable independiente (el predictor)
- β_0 es la intersección con el eje Y (cuando $X=0$)
- β_1 es la pendiente de la línea
- ε es el término de error aleatorio

La regresión lineal simple es útil cuando:

- Solo hay una variable predictora relevante
- La relación entre las variables es aproximadamente lineal
- Se busca un modelo sencillo y fácil de interpretar
- Se quiere entender el impacto directo de una variable sobre otra

Simple linear regression



Regresión lineal múltiple

La regresión lineal múltiple extiende el concepto de la regresión lineal simple para incluir múltiples variables independientes. Esto permite modelar relaciones más complejas y considerar varios factores que pueden influir en la variable dependiente.

La ecuación de la regresión lineal múltiple es:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n + \varepsilon$$

Donde:


- Y es la variable dependiente
- $X_1, X_2, \dots, X_n$ son las variables independientes
- $\beta_0, \beta_1, \dots, \beta_n$ son los coeficientes del modelo
- ε es el término de error aleatorio

La regresión lineal múltiple es útil cuando:

- Hay múltiples factores que influyen en la variable objetivo
- Se quiere controlar el efecto de variables confusoras
- Se busca un modelo que capture interacciones complejas
- Se necesita entender la importancia relativa de diferentes predictores

Multiple Linear Regression

with several independent variables



Regresión polinómica

La regresión polinómica es una extensión de la regresión lineal que permite modelar relaciones no lineales entre variables. En lugar de ajustar una línea recta, ajusta una curva polinómica a los datos.

La ecuación de la regresión polinómica de grado n es:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots + \beta_n X^n + \varepsilon$$

Donde:


- Y es la variable dependiente
- X es la variable independiente
- $X^2, \dots, X^n$ son los términos polinómicos
- $\beta_0, \beta_1, \dots, \beta_n$ son los coeficientes del modelo
- ε es el término de error aleatorio

La regresión polinómica es útil cuando:

- La relación entre las variables no es lineal
- Los datos muestran curvaturas o patrones cíclicos
- Un modelo lineal simple no captura adecuadamente la tendencia
- Se necesita modelar puntos de inflexión o umbrales

Sin embargo, es importante tener cuidado con el grado del polinomio, ya que grados muy altos pueden llevar al sobreajuste.

Polynomial Regression Curve Fitting to Non-linear Data



Regresión Ridge

La regresión Ridge es una técnica de regularización que se utiliza para abordar problemas de multicolinealidad en la regresión lineal. Añade un término de penalización a la función de coste basado en la suma de los cuadrados de los coeficientes.

La función de coste de la regresión Ridge es:

$$J(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^p \beta_j^2$$


Donde:

- El primer término es el error cuadrático medio
- El segundo término es la penalización Ridge
- α es el parámetro de regularización
- β_j son los coeficientes del modelo

La regresión Ridge es útil cuando:

- Hay multicolinealidad entre las variables independientes
- El número de predictores es grande en relación con el número de observaciones
- Se quiere reducir la varianza del modelo a costa de un pequeño aumento en el sesgo
- Se busca evitar el sobreajuste en modelos complejos

El parámetro α controla la fuerza de la regularización: valores más altos reducen más la magnitud de los coeficientes.



Regresión Lasso

La regresión Lasso (Least Absolute Shrinkage and Selection Operator) es otra técnica de regularización que, además de reducir la magnitud de los coeficientes, puede llevar algunos de ellos exactamente a cero, realizando así una selección de características.

La función de coste de la regresión Lasso es:

$$J(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \sum_{j=1}^p |\beta_j|$$

Donde:

- El primer término es el error cuadrático medio
- El segundo término es la penalización Lasso
- α es el parámetro de regularización
- $|\beta_j|$ es el valor absoluto de los coeficientes


La regresión Lasso es útil cuando:

- Se sospecha que solo algunas variables son realmente importantes
- Se quiere un modelo más simple y fácil de interpretar
- Hay muchas variables y se necesita seleccionar las más relevantes
- Se busca reducir el sobreajuste eliminando variables irrelevantes

La principal diferencia con Ridge es que Lasso puede eliminar completamente variables del modelo, mientras que Ridge solo reduce su influencia.

Lasso Regression

Feature Selection with Some Coefficients Reduced to Zero



Regresión ElasticNet

ElasticNet combina las penalizaciones de Ridge y Lasso para aprovechar las ventajas de ambos métodos. Utiliza tanto la norma L1 (valor absoluto) como la norma L2 (cuadrado) en su término de regularización.

La función de coste de ElasticNet es:

$$J(\beta) = \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \alpha \rho \sum_{j=1}^p |\beta_j| + \alpha(1 - \rho) \sum_{j=1}^p \beta_j^2$$

Donde:

- α controla la fuerza general de la regularización
- ρ controla el balance entre las penalizaciones L1 y L2
- Cuando $\rho = 1$, ElasticNet se convierte en Lasso
- Cuando $\rho = 0$, ElasticNet se convierte en Ridge

ElasticNet es útil cuando:

- Hay grupos de variables correlacionadas
- Se quiere seleccionar variables pero manteniendo grupos de predictores correlacionados
- El número de predictores es mayor que el número de observaciones
- Se busca un equilibrio entre la selección de variables y la reducción de la varianza

ElasticNet ofrece mayor flexibilidad que Ridge o Lasso por separado, permitiendo ajustar el tipo de regularización según las características del problema.

ElasticNet Regression



Regresión con árboles de decisión

Los árboles de decisión también pueden utilizarse para problemas de regresión. En lugar de predecir clases, un árbol de regresión predice un valor numérico continuo dividiendo recursivamente el espacio de características en regiones y asignando un valor constante a cada región.


El algoritmo busca divisiones que minimicen la varianza dentro de cada nodo, creando regiones cada vez más homogéneas en términos de la variable objetivo.

La predicción final para una nueva observación es el valor promedio de las observaciones de entrenamiento en la región (hoja) a la que pertenece.

Los árboles de regresión son útiles cuando:

- Las relaciones entre variables son no lineales y complejas
- Hay interacciones importantes entre las variables
- Se necesita un modelo fácil de interpretar visualmente
- Los datos contienen tanto variables numéricas como categóricas
- No se requieren suposiciones sobre la distribución de los datos

Decision Tree Regression Model



Random Forest para regresión

Random Forest es un método de conjunto que combina múltiples árboles de decisión para mejorar la precisión y reducir el sobreajuste. Para problemas de regresión, la predicción final es el promedio de las predicciones de todos los árboles individuales.


Cada árbol en el bosque se entrena con:

- Una muestra bootstrap de los datos originales (bagging)
- Un subconjunto aleatorio de características en cada división

Esta aleatorización reduce la correlación entre los árboles, lo que mejora la generalización del modelo.

Random Forest para regresión es útil cuando:

- Se busca mayor precisión que con un solo árbol
- Se quiere reducir el sobreajuste
- Hay relaciones no lineales complejas en los datos
- Se necesita un modelo robusto frente a valores atípicos
- Es importante conocer la importancia relativa de las variables



Gradient Boosting para regresión

Gradient Boosting es otro método de conjunto que construye árboles secuencialmente, donde cada nuevo árbol corrige los errores de los árboles anteriores. A diferencia de Random Forest, que entrena árboles independientes, Gradient Boosting es un proceso iterativo y adaptativo.

El algoritmo funciona así:

1. Se inicia con un modelo simple (generalmente un árbol pequeño)
2. Se calculan los residuos (errores) de este modelo
3. Se entrena un nuevo árbol para predecir estos residuos
4. Se añade este árbol al modelo, con un peso determinado por la tasa de aprendizaje
5. Se repiten los pasos 2-4 hasta alcanzar un número predefinido de árboles

Gradient Boosting para regresión es útil cuando:

- Se busca la máxima precisión predictiva
- Los datos tienen relaciones complejas y no lineales
- Hay suficientes datos para evitar el sobreajuste
- Se pueden ajustar hiperparámetros mediante validación cruzada

Implementaciones populares incluyen XGBoost, LightGBM y CatBoost, que ofrecen mejoras en eficiencia y precisión sobre el algoritmo básico.

Support Vector Regression (SVR)


Support Vector Regression (SVR) es una adaptación de las Máquinas de Vectores de Soporte (SVM) para problemas de regresión. En lugar de encontrar un hiperplano que separe clases, SVR busca un hiperplano que se ajuste a los datos con un margen de tolerancia ϵ .

El objetivo de SVR es encontrar una función que tenga como máximo una desviación ϵ de los valores reales para todos los datos de entrenamiento, y al mismo tiempo sea lo más plana posible.

SVR puede manejar relaciones no lineales utilizando diferentes funciones kernel, como el kernel lineal, polinómico, RBF (Radial Basis Function) o sigmoide.

SVR es útil cuando:

- Los datos tienen relaciones no lineales complejas
- Se busca un buen equilibrio entre ajuste y generalización
- El conjunto de datos es de tamaño pequeño o mediano
- Se quiere controlar explícitamente el error de aproximación
- Es importante la robustez frente a valores atípicos



Redes neuronales para regresión

Las redes neuronales artificiales pueden aplicarse a problemas de regresión, ofreciendo gran flexibilidad para modelar relaciones complejas y no lineales. Para regresión, la capa de salida típicamente tiene una sola neurona con función de activación lineal.

La arquitectura de una red neuronal para regresión incluye:


- Una capa de entrada con tantas neuronas como variables predictoras
- Una o más capas ocultas con funciones de activación no lineales (ReLU, tanh, etc.)
- Una capa de salida con una neurona y activación lineal

El entrenamiento se realiza minimizando una función de pérdida como el error cuadrático medio (MSE).

Las redes neuronales para regresión son útiles cuando:

- Hay relaciones altamente no lineales y complejas
- El conjunto de datos es grande
- Los datos tienen muchas dimensiones
- Se dispone de suficientes recursos computacionales
- La interpretabilidad del modelo no es una prioridad


Neural Network for Regression



Regresión con series temporales

La regresión con series temporales se utiliza para predecir valores futuros basándose en observaciones pasadas. A diferencia de la regresión estándar, las series temporales tienen una dependencia temporal que debe ser considerada. Algunos modelos comunes para series temporales incluyen:

- ARIMA (AutoRegressive Integrated Moving Average)
- SARIMA (Seasonal ARIMA)
- Modelos de suavizado exponencial
- Prophet (desarrollado por Facebook)
- LSTM (Long Short-Term Memory) y otras redes neuronales recurrentes
- La regresión con series temporales es útil para:
- Pronóstico de ventas
- Predicción de demanda
- Análisis de tendencias del mercado
- Predicción de variables económicas
- Pronóstico meteorológico
- Análisis de datos de sensores a lo largo del tiempo



Evaluación de modelos de regresión

Métricas de error

- Error Cuadrático Medio (MSE)
- Raíz del Error Cuadrático Medio (RMSE)
- Error Absoluto Medio (MAE)
- Error Porcentual Absoluto Medio (MAPE)

Métricas de ajuste

- Coeficiente de determinación (R^2)
- R^2 ajustado
- Criterio de información de Akaike (AIC)
- Criterio de información bayesiano (BIC)

Técnicas de validación

- Validación cruzada k-fold
- Validación cruzada leave-one-out
- Validación cruzada temporal (para series temporales)
- Backtesting

Una evaluación completa debe considerar tanto el rendimiento predictivo como la complejidad del modelo, buscando un equilibrio que evite tanto el sobreajuste como el subajuste.

Interpretación de modelos de regresión

Coefficientes

En modelos lineales, los coeficientes indican el cambio esperado en la variable dependiente por cada unidad de cambio en la variable independiente, manteniendo constantes las demás variables.

Importancia de variables

En modelos basados en árboles, se puede calcular la importancia de cada variable según su contribución a la reducción de la varianza o el error.

Efectos parciales


Los gráficos de dependencia parcial muestran cómo cambia la predicción al variar una variable mientras se mantienen constantes las demás.

SHAP values

Los valores SHAP (SHapley Additive exPlanations) proporcionan una medida de la contribución de cada variable a la predicción para una observación específica.

LIME

LIME (Local Interpretable Model-agnostic Explanations) crea un modelo interpretable localmente que aproxima las predicciones del modelo original en un entorno cercano a la observación de interés.



Regularización en regresión

1

¿Qué es la regularización?

La regularización es una técnica que añade una penalización a la función de coste para reducir la complejidad del modelo y prevenir el sobreajuste. Esto se logra limitando la magnitud de los coeficientes.

El parámetro de regularización (α) controla la fuerza de la penalización y debe ser ajustado mediante validación cruzada para encontrar el valor óptimo que equilibre el ajuste y la generalización.

2

Tipos de regularización

Los principales tipos son la regularización L1 (Lasso), que puede llevar coeficientes a cero, y la regularización L2 (Ridge), que reduce la magnitud de todos los coeficientes. ElasticNet combina ambos enfoques.

3

Beneficios

La regularización mejora la generalización del modelo, reduce la varianza, ayuda a manejar la multicolinealidad y puede simplificar el modelo eliminando variables irrelevantes.

Preprocesamiento para regresión



Limpieza de datos

Detección y tratamiento de valores atípicos, manejo de valores faltantes mediante imputación o eliminación, y corrección de errores en los datos.



Transformación de variables

Normalización o estandarización de variables numéricas, codificación de variables categóricas (one-hot, target encoding), y transformaciones para corregir la asimetría (logarítmica, raíz cuadrada).



Selección de características

Eliminación de variables irrelevantes o redundantes mediante métodos como la selección basada en correlación, la importancia de características o técnicas de regularización.



Ingeniería de características

Creación de nuevas variables derivadas de las originales, como interacciones, polinomios, agregaciones o características basadas en el dominio del problema.

Validación de supuestos en regresión lineal

La regresión lineal se basa en varios supuestos que deben validarse para garantizar la fiabilidad del modelo:

Linealidad: La relación entre variables independientes y dependiente debe ser lineal. Se verifica mediante gráficos de dispersión y residuos.


Independencia: Las observaciones deben ser independientes entre sí. Especialmente importante en series temporales y datos espaciales.

Homocedasticidad: La varianza de los errores debe ser constante. Se verifica con gráficos de residuos vs valores ajustados.

Normalidad: Los residuos deben seguir una distribución normal. Se comprueba con histogramas y gráficos Q-Q.

Cuando no se cumplen estos supuestos, se pueden aplicar diferentes soluciones:

- Transformaciones de variables (logarítmica, Box-Cox)
- Inclusión de términos no lineales
- Uso de errores estándar robustos
- Cambio a modelos más flexibles que no requieran estos supuestos



Detección y tratamiento de valores atípicos

Métodos de detección

Visualización: Diagramas de caja, gráficos de dispersión

Regla del rango intercuartílico (IQR): Valores fuera de $Q1 - 1.5 \cdot IQR$ o $Q3 + 1.5 \cdot IQR$

Z-score: Valores con Z-score > 3 o < -3

Distancia de Mahalanobis: Para detectar valores atípicos multivariantes

DBSCAN: Algoritmo de agrupación que identifica puntos aislados

Estrategias de tratamiento


Eliminación: Cuando hay evidencia de error o contaminación

Transformación: Aplicar transformaciones para reducir la influencia de valores extremos

Winsorización: Reemplazar valores extremos por percentiles (ej. P5 y P95)

Modelos robustos: Usar algoritmos menos sensibles a valores atípicos

Análisis separado: Estudiar los valores atípicos como casos especiales



Multilinealidad en regresión

La multicolinealidad ocurre cuando dos o más variables independientes están altamente correlacionadas entre sí, lo que puede causar problemas en la estimación e interpretación de los coeficientes del modelo.

Efectos de la multicolinealidad:

- Coeficientes inestables y con alta varianza
- Dificultad para determinar la importancia individual de cada variable
- Signos inesperados o contraintuitivos en los coeficientes
- Intervalos de confianza muy amplios

Detección y solución:

Matriz de correlación: Identificar pares de variables con alta correlación


Factor de inflación de la varianza (VIF): Valores > 10 indican multicolinealidad

Eliminación de variables: Quitar una de las variables correlacionadas

Análisis de componentes principales: Crear nuevas variables no correlacionadas

Regularización: Usar Ridge o Lasso para estabilizar los coeficientes

MULTICOLLINEARITY IN REGRESSION



Selección de características para regresión



Métodos de filtro

Seleccionan variables basándose en sus propiedades estadísticas, independientemente del modelo:

- Correlación con la variable objetivo
- Test estadísticos (chi-cuadrado, ANOVA)
- Información mutua



Métodos de envoltura

Evalúan subconjuntos de variables utilizando el modelo de regresión:

- Selección hacia adelante
- Eliminación hacia atrás
- Selección paso a paso
- Búsqueda exhaustiva



Métodos integrados

La selección de características forma parte del proceso de entrenamiento:

- Lasso (regularización L1)
- Elastic Net
- Importancia de características en árboles
- LARS (Least Angle Regression)

Ingeniería de características para regresión

Transformaciones matemáticas

- Logarítmica: para variables con distribución asimétrica positiva
- Raíz cuadrada: para datos con varianza proporcional a la media
- Box-Cox: familia de transformaciones potencia
- Polinomios: para capturar relaciones no lineales

Interacciones

- Productos entre variables: $X_1 \times X_2$
- Interacciones de orden superior
- Interacciones entre variables categóricas y numéricas

Características temporales

- Extracción de componentes (día, mes, año)
- Variables cíclicas (seno, coseno para estacionalidad)
- Rezagos y diferencias
- Ventanas móviles (promedios, máximos, mínimos)

Agrupaciones y agregaciones

- Estadísticas por grupo (media, mediana, desviación)
- Conteos y proporciones
- Características basadas en vecinos cercanos

Ajuste de hiperparámetros

Los hiperparámetros son configuraciones que no se aprenden durante el entrenamiento y deben ser establecidos antes. Su correcta selección es crucial para el rendimiento del modelo.

Métodos de ajuste:

Búsqueda en cuadrícula (Grid Search): Evalúa todas las combinaciones posibles de un conjunto predefinido de valores para cada hiperparámetro.

Búsqueda aleatoria (Random Search): Prueba combinaciones aleatorias dentro de rangos especificados, más eficiente para espacios grandes.

Optimización bayesiana: Construye un modelo probabilístico del rendimiento y selecciona los puntos más prometedores para evaluar.

Hiperparámetros comunes en regresión:


Regresión lineal regularizada: Parámetro de regularización (α), ratio de mezcla en ElasticNet

Árboles de decisión: Profundidad máxima, mínimo de muestras por hoja, criterio de división

Random Forest/Gradient Boosting: Número de árboles, tasa de aprendizaje, submuestra de características

SVR: Parámetro de regularización (C), parámetro de kernel (γ), epsilon

Redes neuronales: Arquitectura, tasa de aprendizaje, función de activación, regularización



Manejo de datos desbalanceados en regresión

Aunque el desbalance de datos se asocia más con problemas de clasificación, también puede afectar a la regresión cuando hay una distribución no uniforme de los valores objetivo.

Problemas del desbalance:

- Sesgo hacia la predicción de valores más frecuentes
- Dificultad para capturar patrones en rangos con pocos datos
- Métricas de evaluación engañosas (dominadas por regiones densas)

Estrategias de manejo:


Remuestreo: Sobremuestreo de regiones poco representadas o submuestreo de regiones sobrerrepresentadas

Ponderación: Asignar mayor peso a observaciones en regiones poco frecuentes

Transformación de la variable objetivo: Logarítmica, Box-Cox para reducir la asimetría

Modelos por partes: Entrenar modelos separados para diferentes rangos de la variable objetivo

Técnicas de generación sintética: SMOTE adaptado para regresión



Regresión para grandes volúmenes de datos

Desafíos

- Tiempo de entrenamiento prolongado
- Limitaciones de memoria
- Complejidad computacional
- Dificultad para explorar y visualizar

Algoritmos eficientes

- Regresión lineal con descenso de gradiente estocástico
- Implementaciones optimizadas (XGBoost, LightGBM)
- Algoritmos de aprendizaje online

Estrategias de escalabilidad

- Muestreo de datos
- Entrenamiento por lotes (batch training)
- Computación distribuida (Spark, Dask)
- Reducción de dimensionalidad

Para conjuntos de datos extremadamente grandes, es fundamental equilibrar la precisión del modelo con la eficiencia computacional, eligiendo algoritmos y estrategias que escalen adecuadamente con el volumen de datos.

Implementación en producción

Exportación del modelo

Serialización del modelo entrenado utilizando herramientas como pickle, joblib o formatos específicos como ONNX o PMML para garantizar la portabilidad.

Monitoreo

Seguimiento continuo del rendimiento del modelo, detección de degradación (concept drift) y alertas automáticas cuando las métricas caen por debajo de umbrales predefinidos.

Integración

Incorporación del modelo en la infraestructura existente, ya sea como servicio web (API REST), como parte de un pipeline de datos o integrado en una aplicación.

Actualización

Reentrenamiento periódico con nuevos datos, evaluación de mejoras potenciales y despliegue de nuevas versiones siguiendo prácticas de MLOps.

Consideraciones éticas en regresión

Sesgos y equidad

Los modelos de regresión pueden perpetuar o amplificar sesgos presentes en los datos de entrenamiento, llevando a predicciones injustas para ciertos grupos. Es importante:

- Analizar la representatividad de los datos
- Evaluar el rendimiento del modelo en diferentes subgrupos
- Implementar técnicas de mitigación de sesgos cuando sea necesario

Transparencia y explicabilidad

Especialmente en aplicaciones de alto impacto, es crucial poder explicar cómo el modelo llega a sus predicciones:

- Preferir modelos interpretables cuando sea posible
- Utilizar técnicas de explicabilidad para modelos complejos
- Documentar las limitaciones y suposiciones del modelo
- Proporcionar intervalos de confianza para las predicciones



Tendencias futuras en regresión



Aprendizaje automático automatizado (AutoML)

Herramientas que automatizan la selección de modelos, la ingeniería de características y el ajuste de hiperparámetros, democratizando el acceso a técnicas avanzadas de regresión.



Aprendizaje profundo para regresión

Arquitecturas de redes neuronales especializadas para problemas de regresión complejos, capaces de capturar patrones sutiles y relaciones no lineales en datos de alta dimensionalidad.



Modelos interpretables

Desarrollo de técnicas que combinan la alta precisión de modelos complejos con la transparencia de modelos más simples, permitiendo entender mejor las predicciones.



Regresión en dispositivos de borde

Implementación de modelos de regresión optimizados para funcionar en dispositivos con recursos limitados, permitiendo predicciones en tiempo real sin necesidad de conexión a servidores.

Conclusiones

La regresión es una técnica fundamental en el aprendizaje automático supervisado, ya que permite establecer y cuantificar relaciones entre variables, facilitando la predicción de valores continuos. A lo largo de esta presentación, hemos explorado los conceptos clave asociados a los problemas de regresión, sus aplicaciones prácticas, y las diferencias entre modelos lineales y no lineales.

Además, hemos desarrollado un flujo de trabajo completo utilizando la librería **Scikit-Learn**, desde la preparación de los datos y el entrenamiento del modelo hasta la realización de predicciones y la evaluación de su desempeño. También hemos analizado la importancia de la correcta selección del modelo, resaltando el uso de métricas de evaluación y técnicas como la validación cruzada.

El conocimiento y dominio de estas técnicas proporcionan al profesional de la ciencia de datos las herramientas necesarias para enfrentar problemas predictivos en diferentes contextos. La capacidad de seleccionar, ajustar y evaluar modelos de regresión de manera adecuada es clave para garantizar resultados precisos y confiables.

Finalmente, recordemos que ningún modelo es universal. La naturaleza de los datos y los objetivos del análisis determinarán qué técnica y qué nivel de complejidad son los más apropiados. Por ello, es fundamental complementar la teoría con la práctica continua y el análisis crítico de los resultados.



Live Coding

¿En qué consistirá la Demo?

Entrenar y comparar varios modelos de regresión (lineal, polinómica, Ridge y SVR) usando un dataset real. Se utilizará scikit-learn para:

1. Preprocesar los datos.
2. Entrenar modelos con validación cruzada.
3. Comparar métricas: MSE, MAE, R^2 .
4. Visualizar residuos y predicciones.
5. Aplicar regularización y evaluar el impacto.
6. Explicar predicciones con SHAP.
7. Exportar modelo entrenado con joblib.
8. Simular despliegue e inferencia.



Momento:

Time-out!



5 -10 min.





Ejercicio

Predicción de precio de autos

Predicción de precio de autos

Contexto: 🙌

Una empresa automotriz desea predecir el precio de vehículos usados en función de variables como año, marca, kilometraje, tipo de combustible y potencia del motor. El objetivo es construir un modelo predictivo robusto, interpretar sus resultados y prepararlo para producción.

Consigna: 📝

1. Cargar el dataset autos.csv.
2. Realizar limpieza básica (valores nulos, outliers).
3. Preprocesar variables categóricas con one-hot encoding.
4. Entrenar los siguientes modelos con validación cruzada ($k=5$):
 - a. Regresión Lineal
 - b. Ridge con ajuste de hiperparámetro α
 - c. SVR con kernel RBF
 - d. Árbol de decisión
5. Evaluar con métricas MSE, MAE, R^2 .
6. Analizar los residuos del mejor modelo.
7. Visualizar la importancia de variables.
8. Guardar el modelo y hacer una predicción con nuevos datos.

Paso a paso: ⚙️

1. Explorar el dataset y eliminar columnas irrelevantes.
2. Imputar valores faltantes.
3. Estandarizar variables numéricas.
4. Separar en X (features) e y (target).
5. Aplicar Pipeline y GridSearchCV para cada modelo.
6. Graficar resultados y comparar.
7. Explicar con SHAP la predicción de un ejemplo puntual.
8. Exportar el modelo con joblib.

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Comparamos múltiples modelos de regresión.**
- ✓ **Aplicamos técnicas de regularización para evitar sobreajuste.**
- ✓ **Evaluamos modelos con métricas y gráficos de residuos.**
- ✓ **Incorporamos interpretabilidad al análisis predictivo.**
- ✓ **Preparamos un modelo para producción aplicando buenas prácticas.**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

