



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Métricas de desempeño de un algoritmo de regresión- Parte I

Aprendizaje Esperado 6: Aplicar métricas de desempeño para la evaluación de algoritmos de clasificación y regresión de acuerdo al caso planteado.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

6.

Evaluación en regresión

veremos cómo cuantificar la diferencia entre predicciones y valores reales.

Principales métricas

MAE, MSE, RMSE,
 R^2

Cuándo usar cada una

Implementación con
Scikit-Learn

Funciones
mean_absolute_error,
mean_squared_error,
r2_score

Cálculo manual vs
automático

Objetivos de aprendizaje

¿Qué aprenderás?

- Aplicar métricas de evaluación para algoritmos de regresión y clasificación.
- Interpretar los resultados de MAE, MSE, RMSE y R^2 .
- Calcular métricas usando Scikit-Learn sobre datos reales.
- Analizar casos donde una métrica puede ser más útil que otra.
- Comparar distintos modelos de forma objetiva.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- *Cómo funcionan los algoritmos de clasificación.*
- *Ventajas y desventajas del KNN y árboles de decisión.*
- *Qué significa sobreajuste y cómo evaluarlo.*
- *Cómo se estructura un pipeline de entrenamiento y test.*

Métricas de desempeño de un algoritmo de regresión

MÉTRICAS DE DESEMPEÑO DE UN MODELO

Evaluar el desempeño de un modelo de aprendizaje automático es un paso fundamental en cualquier proyecto de Machine Learning. Las métricas de evaluación permiten cuantificar la calidad de las predicciones realizadas por un modelo, ayudando a identificar su nivel de ajuste, su capacidad de generalización y su eficacia al resolver un problema específico.

Existen diversas métricas que pueden aplicarse dependiendo del tipo de problema: regresión o clasificación. En los problemas de regresión, el objetivo es predecir valores continuos, por lo que las métricas se enfocan en medir la diferencia entre los valores predichos y los valores reales. En cambio, en los problemas de clasificación, el objetivo es asignar una categoría, y las métricas se centran en evaluar la precisión y la capacidad del modelo para identificar correctamente las clases.

Métricas de Desempeño de un Modelo

Regresión

Evalúan la diferencia entre valores predichos y valores reales observados


- Error Absoluto Medio (MAE)
- Error Cuadrático Medio (MSE)
- Raíz del Error Cuadrático Medio (RMSE)
- Coeficiente de determinación R^2

Clasificación

Evalúan la capacidad del modelo para asignar categorías correctamente

- Matriz de Confusión
- Precisión (Precision)
- Exactitud (Accuracy)
- Sensibilidad (Recall)
- Especificidad
- Curva ROC-AUC

Predicted vs. Actual Values



Métricas de desempeño de un modelo regresivo


Las métricas de desempeño en problemas de regresión permiten evaluar la diferencia entre los valores predichos por un modelo y los valores reales observados. Estas métricas cuantifican el error cometido por el modelo y proporcionan información valiosa sobre su precisión y capacidad de generalización.

Una de las métricas más utilizadas es el **Error Absoluto Medio (MAE)**. Esta métrica calcula la media de las diferencias absolutas entre los valores predichos y los reales. Su interpretación es sencilla, ya que indica en promedio cuánto se equivoca el modelo al realizar sus predicciones.


Error Cuadrático Medio (MSE)

Otra métrica común es el **Error Cuadrático Medio (MSE)**. A diferencia del MAE, el MSE eleva al cuadrado las diferencias entre los valores predichos y los reales antes de promediarlas. Esto penaliza más los errores grandes, haciendo que el modelo intente evitar predicciones con grandes desviaciones.

La **Raíz del Error Cuadrático Medio (RMSE)** es simplemente la raíz cuadrada del MSE. Su ventaja es que mantiene la misma unidad de medida que la variable objetivo, facilitando la interpretación de los resultados.




Coeficiente de determinación R^2



El **coeficiente de determinación R^2** es una métrica que indica qué proporción de la variabilidad de la variable dependiente puede ser explicada por el modelo. Un valor de R^2 cercano a 1 indica que el modelo explica bien la variabilidad de los datos, mientras que un valor cercano a 0 sugiere que el modelo no captura la estructura de los datos.

Cada una de estas métricas tiene sus propias ventajas e inconvenientes. Por ejemplo, el MAE es menos sensible a los valores atípicos que el MSE o el RMSE, mientras que estas últimas penalizan fuertemente los errores grandes, lo que puede ser deseable en ciertos contextos.

CROSS-VALIDATION PROCESS FOR REGRESSION MODELS



Uso conjunto de métricas de regresión

Uso complementario

Es recomendable utilizar varias métricas de manera conjunta para obtener una visión más completa del desempeño del modelo.

Elección adecuada

La elección de la métrica adecuada dependerá de los objetivos del análisis y de las características del conjunto de datos.

Validación

Estas métricas deben ser calculadas utilizando un conjunto de prueba o mediante técnicas de validación cruzada para garantizar que reflejan la capacidad de generalización del modelo.

Ejemplo práctico de regresión

Supongamos que hemos construido un modelo de regresión para predecir el precio de un automóvil. Los precios reales y predichos para cinco autos son:

Auto	Precio real (USD)	Precio predicho (USD)
1	20000	1
2	25000	24000
3	30000	31000
4	22000	23000
5	27000	26500

Podemos calcular el MAE, MSE, RMSE y R^2 para evaluar el desempeño de este modelo y cuantificar su error promedio.

MAE, MSE, RMSE y R²: definición y cálculo

1

Error Absoluto Medio (MAE)

Calcula la media de las diferencias absolutas entre los valores predichos y los valores reales.

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

donde y_i es el valor real, $\hat{y}_i$ es el valor predicho y n es el número de observaciones. El MAE ofrece una interpretación directa: indica, en promedio, cuánto se equivoca el modelo.

2

Error Cuadrático Medio (MSE)

Calcula la media de los errores al cuadrado:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

Esta métrica penaliza fuertemente los errores grandes, ya que las diferencias se elevan al cuadrado. Por ello, el MSE es útil cuando se desea evitar grandes desviaciones.

RMSE y R²: definición y cálculo

1

Raíz del Error Cuadrático Medio (RMSE)

Es simplemente la raíz cuadrada del MSE:

$$RMSE = \sqrt{MSE}$$

El RMSE es útil porque expresa el error en la misma unidad que la variable objetivo, facilitando la interpretación para usuarios no técnicos.

2

Coeficiente de determinación R²

Mide la proporción de la varianza de la variable dependiente que es explicada por el modelo. Su fórmula es:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

donde $\bar{y}$ es la media de los valores reales. Un valor de R² cercano a 1 indica un modelo con buen ajuste, mientras que un valor cercano a 0 refleja un modelo que no explica la variabilidad de los datos.

Implementación con Scikit-Learn

Estas métricas pueden calcularse fácilmente utilizando la librería **Scikit-Learn**, que ofrece funciones específicas para cada una de ellas, como `mean_absolute_error`, `mean_squared_error` y `r2_score`.

```
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

# Valores reales y predichos
y_true = [20000, 25000, 30000, 22000, 27000]
y_pred = [1, 24000, 31000, 23000, 26500]

# Cálculo de métricas
mae = mean_absolute_error(y_true, y_pred)
mse = mean_squared_error(y_true, y_pred)
rmse = np.sqrt(mse)
r2 = r2_score(y_true, y_pred)

print(f"MAE: {mae}")
print(f"MSE: {mse}")
print(f"RMSE: {rmse}")
print(f"R²: {r2}")
```


Ejemplo práctico y resolución

Continuando con el ejemplo anterior de predicción de precios de automóviles:

Estos resultados indican que, en promedio, el modelo se equivoca por 600 dólares, con un error cuadrático medio de 450,000 dólares y un buen nivel de ajuste (R^2 de 0.94).

```
MAE: 600.00  
MSE: 450000.00  
RMSE: 670.82  
R²: 0.94
```

Classification Model Performance



Métricas de desempeño en un algoritmo de clasificación

En los problemas de clasificación, el objetivo es asignar una etiqueta o categoría a cada observación. Para evaluar la calidad de un modelo de clasificación, es necesario utilizar métricas específicas que permitan cuantificar qué tan bien está funcionando el modelo al identificar correctamente las clases.

Matriz de Confusión

Una de las métricas fundamentales en clasificación es la **Matriz de Confusión**. Esta herramienta permite visualizar el rendimiento del modelo mostrando la cantidad de predicciones correctas e incorrectas, clasificadas según la clase real y la clase predicha.

La matriz tiene cuatro elementos clave:

- Verdaderos Positivos (VP)
- Falsos Positivos (FP)
- Verdaderos Negativos (VN)
- Falsos Negativos (FN)

		Predicted label	
		Positive	Negative
Actual label	Positive	TRUE POSITIVE	FALSE POSITIVE
	Negative	FALSE NEGATIVE	TRUE NEGATIVE

Métricas derivadas de la Matriz de Confusión

Precisión (Precision)

Mide la proporción de predicciones positivas correctas respecto al total de predicciones positivas realizadas por el modelo:

$$\text{Precision} = \frac{VP}{VP + FP}$$

Exactitud (Accuracy)

Mide la proporción de predicciones correctas sobre el total de predicciones:

$$\text{Exactitud} = \frac{VP + VN}{VP + FP + FN + VN}$$

Sensibilidad o Recall


Indica la capacidad del modelo para identificar correctamente las observaciones positivas. Se calcula como:

$$\text{Sensibilidad} = \frac{VP}{VP + FN}$$

Especificidad

Mide la capacidad del modelo para identificar correctamente las observaciones negativas:

$$\text{Especificidad} = \frac{VN}{VN + FP}$$



Importancia de las métricas en clasificación

Estas métricas ofrecen una visión más detallada del desempeño del modelo, especialmente cuando las clases están desbalanceadas. Por ejemplo, en un problema donde una clase es mucho más frecuente que la otra, la exactitud puede ser engañosa y no reflejar la verdadera capacidad del modelo para identificar la clase minoritaria.

Ejemplo de matriz de confusión

Esta matriz de confusión muestra:

- Verdaderos Positivos (VP): Casos correctamente identificados como positivos
- Falsos Positivos (FP): Casos incorrectamente identificados como positivos
- Verdaderos Negativos (VN): Casos correctamente identificados como negativos
- Falsos Negativos (FN): Casos incorrectamente identificados como negativos

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

Ejemplo práctico de clasificación

Supongamos que tenemos los siguientes datos de predicciones y clases reales:

Real	Predicho
1	1
0	0
1	0
0	0
1	1

La matriz de confusión sería:

	Predicho 0	Predicho 1
Real 0	2	0
Real 1	1	2

Cálculo de métricas de clasificación

A partir de los valores de la matriz de confusión:

- VP = 2
- VN = 2
- FP = 0
- FN = 1

Las métricas serían:

1.0

Precisión

$$2 / (2 + 0) = 1.0$$

0.8

Exactitud

$$(2 + 2) / 5 = 0.8$$

0.67

Sensibilidad

$$2 / (2 + 1) \approx 0.67$$

1.0

Especificidad

$$2 / (2 + 0) = 1.0$$

Interpretación de las métricas

Estas métricas permiten identificar las fortalezas y debilidades del modelo, como su alta precisión y especificidad, pero baja sensibilidad.

Alta precisión (1.0)

Todas las predicciones positivas fueron correctas. El modelo no comete errores al clasificar casos como positivos.

Buena exactitud (0.8)

El 80% de todas las predicciones fueron correctas, lo que indica un buen desempeño general.

Sensibilidad moderada (0.67)


El modelo identifica correctamente el 67% de los casos positivos reales, lo que sugiere que hay margen de mejora.

Alta especificidad (1.0)

El modelo identifica correctamente todos los casos negativos, sin falsos positivos.


Curva ROC-AUC

La **Curva ROC (Receiver Operating Characteristic)** es una herramienta visual utilizada para evaluar el desempeño de un modelo de clasificación binaria. Esta curva representa la relación entre la **tasa de verdaderos positivos** (Sensibilidad) y la **tasa de falsos positivos** ($1 - \text{Especificidad}$) para diferentes umbrales de clasificación.




Umbrales de clasificación

En un modelo de clasificación, el umbral por defecto para decidir si una predicción es positiva o negativa suele ser 0.5. Sin embargo, este umbral puede ajustarse para cambiar el comportamiento del modelo. La Curva ROC muestra cómo varían la sensibilidad y la especificidad a medida que se modifican estos umbrales.



Área bajo la curva ROC (AUC)



El área bajo la curva ROC, conocida como **AUC (Area Under Curve)**, es una métrica que resume el desempeño del modelo en todos los posibles umbrales. El valor del AUC varía entre 0 y 1.

- Un AUC de 1 indica un modelo perfecto
- Un valor de 0.5 indica un modelo que no tiene capacidad de discriminación (equivalente a una predicción aleatoria)

Interpretación de la curva ROC-AUC

La interpretación práctica de la curva ROC-AUC es clara: cuanto más cercana esté la curva al vértice superior izquierdo del gráfico, mejor es el desempeño del modelo. Un modelo ideal tendrá una curva que sube rápidamente hacia el 100% de sensibilidad y mantiene una baja tasa de falsos positivos.

Ventajas

Permite comparar modelos de clasificación independientemente del umbral seleccionado, facilitando la evaluación objetiva entre diferentes algoritmos o configuraciones.

Limitaciones

Puede ser menos informativa en contextos donde las clases están muy desbalanceadas. En estos casos, la **curva Precision-Recall** puede ser más adecuada, ya que se centra en la clase positiva.

Implementación de la curva ROC-AUC

El cálculo de la curva ROC y el AUC puede realizarse fácilmente utilizando la librería **Scikit-Learn**, que proporciona las

```
from sklearn.metrics import roc_curve, roc_auc_score
import matplotlib.pyplot as plt

# Probabilidades predichas y valores reales
y_true = [1, 0, 1, 0, 1]
y_prob = [0.90, 0.40, 0.80, 0.35, 0.70]

# Cálculo de la curva ROC
fpr, tpr, thresholds = roc_curve(y_true, y_prob)
auc = roc_auc_score(y_true, y_prob)

# Visualización
plt.figure()
plt.plot(fpr, tpr, label=f'AUC = {auc:.2f}')
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel('Tasa de Falsos Positivos')
plt.ylabel('Tasa de Verdaderos Positivos')
plt.title('Curva ROC')
plt.legend()
plt.show()
```


Ejemplo práctico de ROC-AUC


Supongamos que tenemos un modelo de clasificación binaria que genera las siguientes probabilidades de predicción para la clase positiva:

Real	Probabilidad
1	0.90
0	0.40
1	0.80
0	0.35
1	0.70

Podemos calcular y graficar la curva ROC-AUC de la siguiente manera:

Visualización de la curva ROC-AUC


La curva obtenida permitirá visualizar el desempeño del modelo para distintos umbrales y, mediante el AUC, cuantificar su capacidad de clasificación.



```
# Graficar
plt.plot(fpr, tpr, label=f'AUC = {auc:.2f}')
plt.plot([0, 1], [0, 1], 'k--') # Línea aleatoria
plt.xlabel('Tasa de Falsos Positivos (1 - Especificidad)')
plt.ylabel('Tasa de Verdaderos Positivos (Sensibilidad)')
plt.title('Curva ROC')
plt.legend(loc='lower right')
plt.grid(True)
plt.show()
```

Resultado de la curva ROC-AUC

En este ejemplo, podemos observar que la curva ROC se acerca al vértice superior izquierdo, lo que indica un buen desempeño del modelo. El valor del AUC es cercano a 1, confirmando la capacidad del modelo para discriminar entre las clases positiva y negativa.



```
from sklearn.metrics import  
    accuracy_score, precision_score,  
    recall_score, f1_score
```

```
y_true = [0,1, 0]  
y_pred = [0,0, 1]
```

```
accuracy =  
    accuracy_score  
(y_true, y_prd)
```

```
precision =  
    precision_score(y_true, y_prd)
```

```
recall =  
    recall_score(y_true, y_prd)
```

```
f1 =  
    f1_score(y_true, y_prd)
```



Cálculo de métricas utilizando la librería Scikit-Learn

La librería **Scikit-Learn** es una de las más utilizadas en el ecosistema Python para la implementación y evaluación de modelos de aprendizaje automático. Esta herramienta incluye funciones específicas para calcular todas las métricas de desempeño que hemos abordado en este manual, tanto para modelos de regresión como de clasificación.

Funciones de Scikit-Learn para regresión



mean_absolute_error

Calcula el Error Absoluto Medio (MAE) entre los valores reales y predichos.



mean_squared_error

Calcula el Error Cuadrático Medio (MSE) y puede devolver la Raíz del Error Cuadrático Medio (RMSE) si se establece el parámetro `squared=False`.



r2_score

Calcula el coeficiente de determinación R^2 que indica la proporción de varianza explicada por el modelo.

Funciones de Scikit-Learn para clasificación



confusion_matrix

Genera la matriz de confusión para evaluar la precisión de la clasificación.



accuracy_score

Calcula la exactitud, que es la fracción de predicciones correctas.



precision_score, recall_score

Calculan la precisión y la sensibilidad (recall) respectivamente.



roc_curve, roc_auc_score

Calculan la curva ROC y el área bajo la curva (AUC).

Live Coding

¿En qué consistirá la Demo?

Evaluaremos un modelo de regresión con distintos tipos de métricas, y luego compararemos su rendimiento con otro modelo en una tarea de clasificación.

1. Crear arrays `y_true` y `y_pred` con precios reales y predichos.
2. Calcular MAE, MSE, RMSE y R^2 a mano.
3. Repetir el cálculo con funciones de Scikit-Learn.
4. Mostrar cómo interpretar cada métrica.
5. Simular un problema de clasificación binaria.
6. Construir matriz de confusión, y calcular precisión, exactitud, sensibilidad y especificidad.
7. Generar curva ROC y calcular AUC.



Momento:

Time-out!



5 -10 min.





Ejercicio

**¿Que tiene mejor
rendimiento?**

¿Que tiene mejor rendimiento?

Contexto: 🙌

Una empresa de seguros quiere predecir el monto del próximo reclamo de cada cliente. Se entrenaron dos modelos de regresión. El equipo necesita decidir cuál utilizar según los datos que obtuvieron.

Consigna: 📝

A partir de los valores reales y predichos, deberás:

- ✓ Calcule MAE, MSE, RMSE y R^2 para cada modelo.
- ✓ Interprete cuál métrica da mejor información en este contexto.
- ✓ Justifique cuál modelo debería recomendar.

Cliente	Real	Modelo A	Modelo B
1	1200	1300	1100
2	2500	2400	2600
3	1800	1750	1950
4	3100	3300	3000
5	1500	1400	1550

Tiempo 🕒: 45 Minutos

¿Que tiene mejor rendimiento?

Paso a paso:

1. Calcule todas las métricas con fórmulas o Scikit-Learn.
2. Compare resultados entre modelos.
3. Explique cuál es más robusto y por qué.
4. Comparte conclusiones en grupo

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Comprendimos qué métricas usar en regresión y clasificación**
- ✓ **Aplicamos métricas MAE, MSE, RMSE y R^2**
- ✓ **Calculamos métricas usando Scikit-Learn**
- ✓ **Interpretamos el significado práctico de cada resultado**
- ✓ **Evaluamos cuándo usar varias métricas combinadas**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

