



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Aprendizaje de máquina no supervisado- Parte I

Aprendizaje Esperado 1: Explicar los principales conceptos y técnicas asociadas al aprendizaje de máquina no supervisado para resolver un problema.

Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA
NO SUPERVISADO

1

REDUCCIÓN
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN
DIMENSIONAL

5

CLUSTERIZACIÓN Y SUS
PRINCIPALES ALGORITMOS

2

ALGORITMOS DE
CLUSTERIZACIÓN

4

Learning Path

¿Cuáles temas trabajaremos hoy?

1.

Aplicar técnicas de aprendizaje no supervisado para análisis exploratorio.

En esta clase abordaremos cómo identificar patrones ocultos en conjuntos de datos sin etiquetas. Aprenderás a reducir la complejidad de los datos y a agrupar observaciones de manera automática mediante algoritmos como PCA, t-SNE, K-means y DBSCAN.

Clusterización

K-means y
DBSCAN

Clusterización
jerárquica

Reducción de
Dimensionalidad

PCA y t-SNE

Visualización y
elección de técnica

Objetivos de aprendizaje


¿Qué aprenderás?

- Comprender los fundamentos del aprendizaje no supervisado.
- Reconocer las principales técnicas de clusterización.
- Aplicar métodos de reducción de dimensionalidad como PCA y t-SNE.
- Identificar aplicaciones reales de técnicas no supervisadas en la industria.
- Evaluar la utilidad de estas técnicas frente a problemas sin etiquetar.

Aprendizaje de máquina no supervisado

Aprendizaje de Máquina No Supervisado

El aprendizaje de máquina no supervisado representa uno de los campos más interesantes del análisis de datos modernos. Su principal característica es la capacidad de trabajar con datos no etiquetados, lo que permite descubrir patrones ocultos, relaciones y estructuras sin intervención humana directa. Esto lo hace sumamente valioso en contextos donde no se dispone de datos previamente clasificados o donde se busca un enfoque exploratorio.



Características del Aprendizaje No Supervisado

A diferencia del aprendizaje supervisado, que depende de una salida esperada o "verdad conocida" para entrenar sus modelos, el aprendizaje no supervisado intenta comprender la organización interna de los datos. Se utiliza para entender cómo se agrupan, cómo varían y qué dimensiones resultan más relevantes.

Esta metodología se apoya en algoritmos que pueden agrupar elementos similares (clusterización), reducir la cantidad de variables sin perder información (reducción de dimensionalidad), y encontrar relaciones o anomalías interesantes.

Propósito de este Manual

Guía Teórica y Práctica

Este manual tiene como objetivo ofrecer una guía teórica y práctica sobre los aspectos más relevantes del aprendizaje no supervisado.

Conceptos Clave

Se abordarán los conceptos clave, las tareas típicas que resuelve, las principales técnicas y algoritmos utilizados.

Aplicaciones Reales


Conocerás las aplicaciones reales en la industria y cómo interpretar sus resultados.

Al finalizar, contarás con una base sólida para identificar cuándo aplicar este tipo de aprendizaje y cómo interpretar sus resultados.

¿Qué es el Aprendizaje de Máquina No Supervisado?

El aprendizaje de máquina no supervisado es un enfoque dentro del campo del machine learning donde los algoritmos intentan encontrar patrones en los datos sin que exista una respuesta o etiqueta predefinida. En lugar de predecir una variable de salida como en el aprendizaje supervisado, el objetivo es descubrir la estructura subyacente de los datos.

UNSUPERVISED MACHINE LEARNING



Utilidad del Aprendizaje No Supervisado

Datos No Etiquetados

Este tipo de aprendizaje es útil en situaciones donde no se dispone de datos etiquetados.

Comprensión de Datos

Permite comprender mejor la distribución y organización de los datos.

Análisis Exploratorio

Se utiliza en análisis exploratorio, reducción de ruido, detección de anomalías y segmentación.



Ventajas del Aprendizaje No Supervisado

Entre sus principales ventajas se encuentra la posibilidad de trabajar con grandes volúmenes de datos no estructurados, como texto, imágenes o registros sin clasificar. También permite encontrar relaciones o agrupamientos que no son evidentes a simple vista.

Desafíos del Aprendizaje No Supervisado

Validación de Resultados

La validación de los resultados suele ser más difícil que en modelos supervisados, ya que no se cuenta con una "respuesta correcta" para comparar.

A pesar de estas limitaciones, el aprendizaje no supervisado es una herramienta poderosa y fundamental en el análisis moderno de datos, y su dominio es esencial para cualquier profesional del área.

Elección e Interpretación

La elección del algoritmo y su interpretación requieren experiencia.



Tareas que Resuelve el Aprendizaje No Supervisado

1

Clusterización

Permite descubrir grupos naturales dentro de los datos, lo cual es útil en segmentación de clientes, agrupamiento de imágenes o análisis de comportamiento.

2

Reducción de Dimensionalidad

Se utiliza para simplificar datos complejos, facilitando su visualización y análisis posterior.

3


Detección de Anomalías

Permite detectar eventos inusuales en los datos, como fraudes financieros o fallos en sensores industriales.

4

Análisis de Asociaciones

Permite encontrar reglas de co-ocurrencia, comúnmente usado en retail (ej.: los clientes que compran pan también compran mantequilla).



Data pipeline showing multiple unsupervised learning techniques working together

Combinación de Tareas

Estas tareas no son mutuamente excluyentes y, en muchos casos, se utilizan combinadas para obtener una comprensión más profunda de los datos. Por ejemplo, se puede aplicar reducción de dimensionalidad antes de realizar una clusterización.

Es importante seleccionar la técnica adecuada según el tipo de problema, el objetivo del análisis y la naturaleza de los datos. De esta forma, se garantiza que el modelo no solo sea útil, sino también interpretable y eficiente.


Tipos de Aprendizaje No Supervisado

Clusterización

Segmenta datos en grupos sin conocer de antemano a qué grupo pertenece cada observación.

Detección de Anomalías

Identifica datos que se desvían significativamente del comportamiento general.



Reducción de Dimensionalidad


Disminuye la cantidad de variables manteniendo la mayor cantidad de información posible.

Análisis de Asociaciones

Busca reglas o correlaciones dentro de grandes bases de datos.


Clusterización en Detalle

La clusterización permite segmentar datos en grupos, sin conocer de antemano a qué grupo pertenece cada observación. Es útil en marketing, biología, visión por computadora y más. Por ejemplo, el algoritmo K-means crea "k" grupos minimizando la distancia entre los puntos del mismo clúster.



Reducción de Dimensionalidad en Detalle

La reducción de dimensionalidad tiene como objetivo disminuir la cantidad de variables manteniendo la mayor cantidad de información posible. Técnicas como PCA o t-SNE permiten representar los datos en 2D o 3D para visualizarlos fácilmente o prepararlos para otros modelos.




Análisis de Asociaciones en Detalle

El análisis de asociaciones busca reglas o correlaciones dentro de grandes bases de datos, como los sistemas de recomendación. Un ejemplo clásico es el análisis de cestas de supermercado, donde se identifican patrones como "si compras leche, probablemente compres pan".

MARKET BASKET ANALYSIS



Anomaly Detection



Detección de Anomalías en Detalle

Concepto

La detección de anomalías consiste en identificar datos que se desvían significativamente del comportamiento general.


Aplicaciones

Se usa en ciberseguridad, mantenimiento predictivo y detección de fraudes.

Implementación

Aunque no siempre se menciona como tipo central, su implementación suele basarse en técnicas no supervisadas.

DATA CLUSTERING



Clusterización: Definición

La clusterización es una técnica que agrupa datos similares en subconjuntos llamados clústeres. El objetivo es maximizar la similitud entre los elementos de un mismo grupo y minimizarla entre grupos distintos. Es ideal para explorar estructuras naturales en conjuntos de datos.

Algoritmo K-means

Definición de K

Requiere definir el número de clústeres (k) de antemano.

Recálculo

Recalcula los centroides basados en los puntos asignados.

Es eficiente, pero sensible a valores atípicos y a la elección de k .


Asignación

Asigna cada punto al clúster más cercano al centroide.

Iteración

Repite hasta que los centroides se estabilicen.

DBSCAN Clustering




● Density-based clusters ● Noise

Algoritmo DBSCAN

Otro método popular es DBSCAN, que agrupa según densidad y no necesita especificar el número de clústeres. Puede identificar clústeres de formas irregulares y detectar valores atípicos automáticamente.

Hierarchical Clustering

Hierarchical clustering crea una estructura jerárquica de clústeres que se puede visualizar con un dendrograma. Permite decidir a posteriori cuántos clústeres considerar y es útil para exploración.



Aplicaciones Prácticas de la Clusterización



Segmentación de Clientes

Agrupa clientes con comportamientos similares para estrategias de marketing personalizadas.



Organización de Documentos

Clasifica documentos por temas o contenido similar sin etiquetas previas.



Agrupación de Imágenes


Organiza imágenes por características visuales similares.



Análisis Genómico

Identifica patrones en datos genéticos para investigación médica.

DATA SCIENTIST



Limitaciones de la Clusterización

Normalización

Necesidad de normalizar los datos para evitar que variables con escalas mayores dominen el análisis.

Sensibilidad

Sensibilidad al método de distancia elegido, que puede afectar significativamente los resultados.

Validación


Validar los resultados sin etiquetas puede ser complejo y requiere métodos adicionales como el índice de Silhouette.

Reducción de Dimensionalidad: Definición

La reducción de dimensionalidad busca representar conjuntos de datos complejos con menos variables, manteniendo la información esencial. Es crucial cuando se trabaja con muchos atributos, ya que mejora la visualización, reduce el ruido y disminuye el costo computacional.

PCA (Análisis de Componentes Principales)

PCA (Análisis de Componentes Principales) es una técnica lineal que transforma las variables originales en un nuevo conjunto de variables no correlacionadas llamadas componentes principales. Los primeros componentes capturan la mayor parte de la varianza.



t-SNE

Otra técnica popular es t-SNE, que proyecta datos de alta dimensión en dos o tres dimensiones para visualización, preservando relaciones locales. A diferencia de PCA, t-SNE es no lineal y puede capturar estructuras más complejas, aunque su interpretación es más limitada.

Aplicaciones de la Reducción de Dimensionalidad



Genética

Análisis de expresión génica con miles de variables.



Procesamiento de Lenguaje Natural

Reducción de espacios vectoriales en análisis de texto.



Procesamiento de Imágenes

Compresión y reconocimiento de patrones visuales.



Análisis de Clientes

Reducción de 50 variables a 2 o 3 dimensiones para exploración visual.

Elección de Técnicas de Reducción


Factores a Considerar

- Tipo de datos disponibles
- Objetivo del análisis
- Necesidad de interpretación

Comparación


PCA es más fácil de entender y justificar, mientras que t-SNE es más potente para explorar estructuras complejas pero menos interpretable.

CA




Component 1

t-SNE



t-SNE

DIVERSE INDUSTRY APPLICATIONS OF UNSUPERVISED LEARNING



ANOMALY
DETECTION



CUSTOMER
SEGMENTATION



IMAGE
SEGMENTATION



RECOMMENDATION
SYSTEMS

Aplicaciones del Aprendizaje No Supervisado

El aprendizaje no supervisado tiene una amplia gama de aplicaciones en múltiples industrias. Su capacidad para encontrar estructuras ocultas en los datos lo convierte en una herramienta esencial en escenarios donde no existen etiquetas o categorías predefinidas.

Aplicaciones en Marketing

19

Segmentación de Clientes

Agrupación según comportamiento, frecuencia de compra o intereses.



Personalización

Adaptación de campañas a segmentos específicos.



Experiencia del Usuario

Mejora basada en patrones de comportamiento.




Optimización de Recursos

Distribución eficiente de presupuestos publicitarios.

Aplicaciones en Salud


En salud, se aplica para identificar subtipos de enfermedades basados en síntomas, resultados clínicos o expresiones genéticas. Esto facilita diagnósticos más precisos y tratamientos personalizados.

Medical Data Clustering for Disease Subtypes



Aplicaciones en Seguridad Informática

En seguridad informática, se emplea para detectar patrones anómalos en el tráfico de red, lo que permite prevenir ataques cibernéticos antes de que ocurran. La detección temprana de fraudes financieros también se beneficia de estas técnicas.



Otras Aplicaciones

Motores de Recomendación

Sistemas que sugieren productos o contenidos basados en patrones de comportamiento similares.

Procesamiento de Imágenes

Clasificación automática y reconocimiento de patrones visuales.

Exploración de Texto

Análisis de temas y sentimientos en grandes volúmenes de documentos.

Clasificación de Documentos

Organización automática de archivos según su contenido.

Live Coding

¿En qué consistirá la Demo?

Realizaremos una demo completa de análisis no supervisado sobre un dataset de clientes, aplicando reducción de dimensionalidad y clusterización para segmentarlos y visualizarlos.

1. Carga y exploración del dataset
2. Normalización de datos
3. Aplicación de PCA
4. Visualización 2D
5. Aplicación de K-means
6. Evaluación de silueta
7. DBSCAN sobre el mismo set
8. Comparación de resultados



Momento:

Time-out!



5 -10 min.





Ejercicio

Explorando agrupamientos y visualización con PCA y DBSCAN

Explorando agrupamientos y visualización con PCA y DBSCAN

Contexto: 🙌

Una empresa quiere segmentar a sus clientes sin tener etiquetas previas. Sólo cuenta con datos de comportamiento, compras y demografía. Tu objetivo es identificar grupos naturales para futuras campañas.

Consigna: 📝

Utiliza técnicas de reducción de dimensionalidad y clusterización para identificar al menos 3 segmentos bien definidos. Compara resultados con distintos algoritmos y analiza su coherencia.

Paso a paso: ⚙️

1. Carga y exploración inicial
2. Limpieza y escalamiento
3. Aplicación de PCA o t-SNE
4. Visualización de reducción
5. K-means con validación (inercia, silueta)
6. DBSCAN y análisis de outliers
7. Comparación de segmentos
8. Conclusión escrita

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ Entendimos qué es el aprendizaje no supervisado
- ✓ Vimos técnicas de reducción y clusterización
- ✓ Aplicamos PCA y t-SNE para visualizar datos
- ✓ Segmentamos clientes reales sin etiquetas



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

