



Recibe una cálida:

# ¡Bienvenida!

---

Te estábamos esperando 😊 +




# › Aprendizaje de máquina no supervisado- Parte II

**Aprendizaje Esperado 1:** Explicar los principales conceptos y técnicas asociadas al aprendizaje de máquina no supervisado para resolver un problema.

# Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



# Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA  
NO SUPERVISADO

1

REDUCCIÓN  
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN  
DIMENSIONAL


5

CLUSTERIZACIÓN Y SUS  
PRINCIPALES ALGORITMOS

ALGORITMOS DE  
CLUSTERIZACIÓN

# Learning Path

¿Cuáles temas trabajaremos hoy?



# Objetivos de aprendizaje

¿Qué aprenderás?

- Identificar diferentes técnicas de clusterización según el tipo de datos
- Aplicar algoritmos jerárquicos y densidad para segmentación
- Visualizar agrupamientos complejos usando t-SNE y UMAP
- Introducir nociones de detección de anomalías
- Explorar casos prácticos en contextos reales

# Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Exploramos los fundamentos del aprendizaje no supervisado
- Aplicamos técnicas de reducción de dimensionalidad como PCA
- Implementamos algoritmos de clusterización como K-Means y DBSCAN
- Analizamos visualmente los clústeres y su coherencia

# Aprendizaje de máquina no supervisado



# Versatilidad del Aprendizaje No Supervisado

Su versatilidad lo hace fundamental en cualquier disciplina que trabaje con grandes volúmenes de datos no etiquetados. Desde el análisis de comportamiento de usuarios hasta la investigación científica, estas técnicas permiten descubrir información valiosa que de otro modo permanecería oculta.

# Clusterización: Profundizando

## Definición

Técnica que agrupa datos similares en subconjuntos llamados clústeres.

## Objetivo

Maximizar la similitud intra-grupo y minimizarla entre grupos distintos.

## Utilidad

Ideal para explorar estructuras naturales en conjuntos de datos sin etiquetas previas.

# K-means: Funcionamiento Detallado

## Inicialización

Se seleccionan  $k$  puntos aleatorios como centroides iniciales.

## Actualización

Se recalculan los centroides como el promedio de todos los puntos asignados a cada clúster.

## Asignación

Cada punto se asigna al centroide más cercano según una métrica de distancia.

## Convergencia

Se repiten los pasos 2 y 3 hasta que los centroides se estabilicen o se alcance un número máximo de iteraciones.


# Ventajas y Desventajas de K-means

## Ventajas

- Simple de implementar
- Eficiente en grandes conjuntos de datos
- Resultados fáciles de interpretar

## Desventajas

- Requiere definir k de antemano
- Sensible a valores atípicos
- Asume clústeres convexos y de tamaño similar




# DBSCAN:

## Características Principales

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) es un algoritmo que define clústeres como áreas de alta densidad separadas por regiones de baja densidad. No requiere especificar el número de clústeres y puede identificar formas arbitrarias.

DBSCAN Clustering



- Core point
- Boundary point
- Noise

# Parámetros de DBSCAN

## Epsilon ( $\epsilon$ )

Radio que define la vecindad de un punto. Determina qué tan cerca deben estar los puntos para considerarse parte del mismo clúster.

## MinPts

Número mínimo de puntos requeridos en la vecindad de un punto para considerarlo como punto central de un clúster.

La elección adecuada de estos parámetros es crucial para obtener resultados significativos con DBSCAN.


# Ventajas y Desventajas de DBSCAN

## Ventajas

- No requiere especificar el número de clústeres
- Puede encontrar clústeres de formas arbitrarias
- Robusto a valores atípicos

## Desventajas

- Sensible a los parámetros  $\epsilon$  y MinPts
- Dificultad con clústeres de densidades muy diferentes
- Mayor complejidad computacional que K-means



# Hierarchical Clustering:

## Enfoque

Hierarchical clustering crea una estructura jerárquica de clústeres que se puede visualizar con un dendrograma. Existen dos enfoques principales: aglomerativo (de abajo hacia arriba) y divisivo (de arriba hacia abajo).

# Proceso de Clustering Jerárquico Aglomerativo

## Inicialización

Cada punto comienza como su propio clúster.

## Actualización

Se recalculan las distancias entre el nuevo clúster y los demás.

## Fusión

Se fusionan los dos clústeres más cercanos según una métrica de distancia.

## Iteración

Se repiten los pasos 2 y 3 hasta que todos los puntos estén en un solo clúster.

# Ventajas del Clustering Jerárquico

## Flexibilidad

Permite decidir el número de clústeres después del análisis, observando el dendrograma.

## Visualización

El dendrograma proporciona una representación visual intuitiva de la estructura jerárquica.


## No Paramétrico

No requiere definir el número de clústeres de antemano como K-means.

# PCA: Funcionamiento Detallado

PCA (Análisis de Componentes Principales) es una técnica lineal que transforma las variables originales en un nuevo conjunto de variables no correlacionadas llamadas componentes principales. El proceso implica encontrar los eigenvectores y eigenvalores de la matriz de covarianza de los datos.

## PCA Transformation Process



# Pasos del PCA

## **Estandarización**

Normalizar los datos para que cada variable tenga media cero y desviación estándar uno.

## **Cálculo de Covarianza**

Obtener la matriz de covarianza que muestra las relaciones entre variables.

## **Eigenvectores**

Calcular los eigenvectores y eigenvalores de la matriz de covarianza.

## **Selección**

Ordenar los componentes por varianza explicada y seleccionar los más importantes.

## **Proyección**

Proyectar los datos originales en el nuevo espacio dimensional reducido.


# Ventajas y Limitaciones del PCA

## Ventajas

- Reduce la dimensionalidad efectivamente
- Elimina la multicolinealidad
- Reduce el ruido en los datos
- Facilita la visualización

## Limitaciones

- Asume relaciones lineales entre variables
- Sensible a la escala de los datos
- Los componentes pueden ser difíciles de interpretar



# t-SNE: Características Principales

t-SNE (t-Distributed Stochastic Neighbor Embedding) es una técnica no lineal que proyecta datos de alta dimensión en espacios de baja dimensión, preservando principalmente las relaciones locales entre puntos. Es especialmente útil para visualización.

# Funcionamiento de t-SNE

## Similitudes

Calcula las similitudes entre puntos en el espacio de alta dimensión usando distribuciones gaussianas.


## Proyección

Proyecta los puntos a un espacio de baja dimensión (generalmente 2D o 3D).

## Optimización


Minimiza la divergencia de Kullback-Leibler entre las distribuciones de probabilidad en ambos espacios.

# Comparación entre PCA y t-SNE



## PCA

Preserva la varianza global y las distancias a gran escala. Más rápido y determinista. Útil como paso previo a otros algoritmos.



## t-SNE

Preserva estructuras locales y relaciones de vecindad. Mejor para visualización de datos complejos. Más lento y no determinista.

# Detección de Anomalías: Profundizando

La detección de anomalías identifica observaciones que se desvían significativamente del comportamiento normal de los datos. Estas anomalías pueden representar errores, fraudes, defectos o eventos raros de interés especial.

# Técnicas de Detección de Anomalías



## Métodos Estadísticos

Utilizan distribuciones estadísticas para identificar valores atípicos, como Z-score o test de Grubbs.



## Métodos Basados en Distancia

Identifican puntos alejados de sus vecinos, como k-NN o LOF (Local Outlier Factor).



## Métodos Basados en Densidad

Detectan puntos en regiones de baja densidad, como DBSCAN adaptado.



## Métodos Basados en Modelos

Construyen un modelo del comportamiento normal y detectan desviaciones, como One-Class SVM o autoencoders.

# Aplicaciones de la Detección de Anomalías

## Seguridad

- Detección de intrusiones en redes
- Identificación de fraudes financieros
- Detección de comportamientos sospechosos

## Industria

- Mantenimiento predictivo
- Control de calidad
- Monitoreo de sensores


## Salud

- Detección de patrones anormales en imágenes médicas
- Identificación de valores atípicos en señales vitales
- Vigilancia epidemiológica


## ANOMALY DETECTION APPLICATIONS IN DIFFERENT INDUSTRIES



FINANCE



HEALTH CARE



MANUFACTURING




CYBERSECURITY

# Análisis de Asociaciones: Profundizando

El análisis de asociaciones busca descubrir relaciones interesantes entre variables en grandes conjuntos de datos. La forma más común es el análisis de reglas de asociación, que identifica patrones del tipo "si ocurre A, entonces probablemente ocurre B".

## Market Basket Analysis with Product Association Rules



# Algoritmo Apriori

## Identificación de Items Frecuentes

Encuentra conjuntos de elementos que aparecen juntos con frecuencia.

## Evaluación

Evalúa las reglas según métricas como soporte, confianza y lift.

## Generación de Reglas

Crea reglas de asociación a partir de los conjuntos frecuentes.

## Selección

Selecciona las reglas más relevantes según umbrales predefinidos.

# Métricas en Reglas de Asociación

## Soporte

Frecuencia con la que aparece un conjunto de elementos en el dataset. Indica qué tan común es una regla.

## Confianza

Probabilidad de que ocurra B cuando ocurre A. Mide la fiabilidad de la regla.

## Lift

Relación entre la confianza observada y la esperada si A y B fueran independientes. Valores mayores a 1 indican asociación positiva.

# Aplicaciones del Análisis de Asociaciones



## Retail

Análisis de cestas de compra para diseño de tiendas, promociones cruzadas y recomendaciones.



## E-commerce

Sistemas de recomendación basados en "los clientes que compraron esto también compraron..."




## Salud

Identificación de combinaciones de síntomas o efectos secundarios de medicamentos.



## Finanzas

Detección de patrones en transacciones financieras para prevención de fraudes.



UNSUPERVISED  
LEARNING

# Desafíos en el Aprendizaje No Supervisado

A pesar de su potencial, el aprendizaje no supervisado presenta varios desafíos que deben considerarse al implementar estas técnicas en problemas reales.

# Principales Desafíos

## **Evaluación de Resultados**

Sin etiquetas de referencia, es difícil determinar objetivamente la calidad de los resultados obtenidos.

## **Selección de Algoritmos**

Elegir el algoritmo adecuado requiere experiencia y conocimiento del dominio específico.

## **Interpretabilidad**

Los patrones descubiertos pueden ser difíciles de interpretar y traducir en acciones concretas.

## **Escalabilidad**

Algunos algoritmos tienen dificultades con conjuntos de datos muy grandes o de alta dimensionalidad.

# Estrategias para Superar los Desafíos


## Validación

- Utilizar métricas internas como Silhouette o Davies-Bouldin
- Validar con expertos del dominio
- Combinar con datos etiquetados cuando sea posible

## Implementación


- Probar múltiples algoritmos y parámetros
- Utilizar visualizaciones para interpretar resultados
- Combinar con técnicas supervisadas en enfoques híbridos

### VALIDATION TECHNIQUES FOR UNSUPERVISED LEARNING RESULTS



# Tendencias Futuras

El campo del aprendizaje no supervisado continúa evolucionando rápidamente, con nuevas técnicas y aplicaciones emergentes que amplían sus posibilidades.



# Direcciones Emergentes



## Aprendizaje Profundo No Supervisado

Autoencoders, GANs y modelos generativos que aprenden representaciones complejas sin etiquetas.



## Aprendizaje Auto-Supervisado

Técnicas que generan automáticamente etiquetas a partir de los propios datos para entrenar modelos más robustos.



## Aprendizaje Federado

Entrenamiento distribuido que preserva la privacidad al mantener los datos en sus fuentes originales.



## Interpretabilidad Mejorada

Nuevos métodos para explicar y visualizar los resultados de modelos complejos no supervisados.

# Resumen

## Exploración de Datos

El aprendizaje de máquina no supervisado es una poderosa herramienta para la exploración de datos y el descubrimiento de patrones ocultos.

## Técnicas Principales

A través de técnicas como la clusterización y la reducción de dimensionalidad, se pueden extraer conocimientos significativos sin requerir etiquetas.

## Selección Adecuada

Es importante seleccionar el algoritmo adecuado según el contexto del problema, así como reconocer las limitaciones y desafíos inherentes.

# Conclusión

Dominar el aprendizaje no supervisado es una competencia fundamental para todo analista o científico de datos. Su aplicación se extiende a múltiples sectores y te permitirá abordar situaciones donde los datos son abundantes pero carecen de categorización previa.

Este conocimiento te posiciona mejor para diseñar soluciones exploratorias y proactivas en escenarios reales. La interpretación correcta de los resultados de modelos no supervisados es tan importante como su ejecución.



# Live Coding

## ¿En qué consistirá la Demo?

Vamos a realizar una implementación guiada de técnicas avanzadas de clusterización y reglas de asociación con Python.

1. Carga y preparación de datos
2. Aplicación de DBSCAN
3. Visualización 2D con t-SNE
4. Agrupamiento jerárquico y dendrogramas
5. Aplicación de Apriori (mlxtend)
6. Filtrado de reglas significativas
7. Visualización de soporte/confianza/lift



Momento:

# Time-out!



5 -10 min.





Ejercicio

# Explorando asociaciones inesperadas

# Explorando asociaciones inesperadas

## Contexto: 🙌

Un supermercado quiere descubrir patrones de compra que puedan usarse para sugerencias automatizadas. Dispones de una lista de tickets de productos adquiridos por cliente.

## Consigna: 📝

Implementa un análisis de reglas de asociación utilizando el algoritmo Apriori o FP-Growth. Genera reglas con al menos 0.5 de soporte y 0.7 de confianza. Luego visualiza las relaciones más relevantes entre

## Paso a paso: ⚙️

1. Genera y Carga un dataset tipo market basket (puede ser groceries.csv)
2. Transformalo a formato de transacciones
3. Aplica Apriori y obtiene las reglas
4. Visualiza soporte vs confianza
5. Explica el significado de las reglas más importantes

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





# Resumen

¿Qué logramos en esta clase?



- ✓ **Comprendimos técnicas avanzadas de agrupamiento como DBSCAN y jerárquico**
- ✓ **Aplicamos visualizaciones para entender clústeres complejos**
- ✓ **Exploramos estrategias para detección de valores atípicos**
- ✓ **Descubrimos reglas de asociación aplicadas a ventas reales**



## ¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

