



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Clusterización y sus principales algoritmos- Parte I

Aprendizaje Esperado 2: Describir las principales características de las técnicas de clusterización, sus principales algoritmos y problemas que resuelve.

Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA
NO SUPERVISADO

1

REDUCCIÓN
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN
DIMENSIONAL

5

CLUSTERIZACIÓN Y SUS
PRINCIPALES ALGORITMOS

ALGORITMOS DE
CLUSTERIZACIÓN

Learning Path

¿Cuáles temas trabajaremos hoy?

2.

Clusterización y sus principales algoritmos

Exploraremos las técnicas de agrupamiento más comunes utilizadas en Aprendizaje No Supervisado, sus fundamentos y aplicaciones reales.

Fundamentos de la Clusterización

¿Qué es la clusterización?

Aplicaciones multidisciplinares

Principales algoritmos de Clusterización

K-Means y Clustering Jerárquico

DBSCAN y Mezcla Gaussiana (GMM)

Objetivos de aprendizaje

¿Qué aprenderás?

- Comprender el concepto de clusterización en el aprendizaje no supervisado.
- Reconocer diferentes aplicaciones de la clusterización en campos diversos.
- Describir el funcionamiento de los algoritmos K-Means, DBSCAN, Clustering Jerárquico y GMM.
- Analizar las ventajas y limitaciones de cada técnica de clusterización.
- Valorar la importancia del preprocesamiento e interpretación de resultados.

Repaso clase anterior

¿Quedó alguna duda?


En la clase anterior trabajamos :

- *Introducción al aprendizaje no supervisado*
- *Diferencia entre supervisado y no supervisado*
- *Importancia del análisis exploratorio*
- *Aplicaciones generales del aprendizaje no supervisado*

Clusterización y sus principales algoritmos

Técnicas de Clusterización: Fundamentos y Aplicaciones

En el mundo del análisis de datos y el aprendizaje automático, la clusterización es una de las técnicas más representativas del aprendizaje no supervisado. Esta herramienta permite descubrir estructuras y patrones dentro de los datos sin necesidad de tener etiquetas o categorías predefinidas. Mediante la agrupación de datos similares, se pueden obtener valiosos conocimientos ocultos que son útiles en diversos campos como el marketing, la biología, la segmentación de usuarios y más.



DATA CLUSTERING

VISUALIZATION IN
MULTIDIMENSIONAL SPACE

¿Qué es la Clusterización?

La técnica de clusterización consiste esencialmente en agrupar objetos que presentan similitudes entre sí, de forma que aquellos pertenecientes al mismo grupo (o clúster) se parezcan más entre ellos que a los de otros grupos. Esto permite no solo entender mejor los datos, sino también tomar decisiones basadas en comportamientos, tendencias o características compartidas entre subconjuntos.



Clusterización: Una Técnica Exploratoria

La clusterización es una técnica de análisis exploratorio que busca agrupar un conjunto de objetos de tal manera que los objetos en el mismo grupo (o clúster) sean más similares entre sí que con los de otros grupos. Esta técnica no requiere etiquetas previas, lo que la convierte en una herramienta poderosa para descubrir patrones ocultos.

Aplicaciones Multidisciplinarias

Marketing

Segmentación de clientes según patrones de compra

Biología

Agrupación de genes o especies con características similares

Análisis Web


Comprensión de perfiles de usuarios según su navegación

Compresión de Datos

Reducción de ruido en imágenes y compresión de información

Importancia del Preprocesamiento

Para aplicar la clusterización, es importante contar con un buen preprocesamiento de los datos: limpieza, escalado y selección de variables influyen directamente en la calidad de los clústeres obtenidos. Además, la elección del número de clústeres, en caso de ser requerida, también condiciona los resultados.



Interpretación de Resultados

La interpretación de los resultados de la clusterización requiere conocimiento contextual, ya que los algoritmos por sí solos no definen el significado de cada grupo. Es tarea del analista traducir estas agrupaciones en información accionable.



Clusterización como Base para Otros Modelos



Clusterización

Agrupación inicial de datos sin etiquetas



Segmentación

División de población en grupos significativos



Modelos Predictivos

Desarrollo de modelos específicos por segmento



Personalización

Estrategias adaptadas a cada grupo

Aplicaciones en Marketing

Las técnicas de clusterización son ampliamente utilizadas en diversas industrias. En marketing, permiten segmentar consumidores según patrones de compra o comportamiento. Esto facilita la creación de campañas personalizadas y estrategias de fidelización más efectivas.



Aplicaciones en Biología

En biología, las técnicas de clusterización agrupan genes o especies con características similares. Esto permite identificar patrones evolutivos, relaciones taxonómicas y comportamientos compartidos entre organismos.

Aplicaciones en Análisis Web

Perfiles de Navegación

Agrupación de usuarios según páginas visitadas y tiempo de permanencia

Análisis de Conversión


Identificación de patrones comunes en usuarios que completan objetivos

Personalización de Contenido


Adaptación de la experiencia web según el grupo al que pertenece el usuario

Detección de Anomalías

Otra aplicación común es en la detección de anomalías. Los objetos que no encajan en ningún clúster o se ubican en zonas periféricas pueden considerarse atípicos, lo que resulta útil en seguridad informática, detección de fraudes o monitoreo de sistemas.



Document Clustering for Natural Language Processing



Procesamiento del Lenguaje Natural

En el ámbito del procesamiento del lenguaje natural, la clusterización permite agrupar documentos, noticias o comentarios según temas, sin necesidad de entrenamiento previo. Esto resulta útil en tareas de minería de opiniones o análisis de contenido.

Aplicaciones en Ingeniería

1

Agrupación de Sensores

Identificación de sensores con lecturas similares para facilitar el monitoreo de sistemas complejos

2

Detección de Fallas


Reconocimiento de patrones anómalos que pueden indicar problemas en equipos industriales

3

Optimización de Procesos

Identificación de configuraciones óptimas basadas en agrupaciones de parámetros efectivos

PATIENT CLUSTERING ANALYSIS



Aplicaciones en Medicina

La clusterización se utiliza para clasificar pacientes según síntomas, respuesta a tratamientos o evolución clínica. Esto permite desarrollar protocolos médicos más específicos y personalizados.

Versatilidad de la Clusterización

Su versatilidad y bajo requerimiento de supervisión la convierten en una técnica atractiva para explorar y estructurar información en múltiples dominios. La clusterización puede aplicarse prácticamente en cualquier campo donde existan datos que puedan beneficiarse de una agrupación basada en similitudes.




CUSTOMER SEGMENTATION
CLUSTERING TECHNIQUES



IMAGE SEGMENTATION
CLUSTERING TECHNIQUES




DOCUMENT CLUSTERING
CLUSTERING TECHNIQUES



ANOMALY DETECTION
CLUSTERING TECHNIQUES

Comparison of Clustering Algorithms



Principales Algoritmos de Clusterización

Existen diversos algoritmos de clusterización, cada uno con características particulares. Entre los más utilizados se encuentran K-Means, Clustering Jerárquico, DBSCAN y Mezcla Gaussiana. Cada uno tiene sus propias fortalezas y debilidades que los hacen más adecuados para ciertos tipos de problemas.

K-Means: Fundamentos

K-Means agrupa los datos en K clústeres basándose en la distancia a los centroides. Es uno de los algoritmos más populares debido a su simplicidad conceptual y eficiencia computacional.

K-Means: Características

Velocidad

Es rápido y eficiente para grandes volúmenes de datos

Parámetros

Requiere definir el número de clústeres previamente

Sensibilidad

Es sensible a valores atípicos y a la inicialización de centroides

Forma

Funciona mejor con clústeres esféricos de tamaño similar

K-Means:

Funcionamiento

Inicialización

Selección aleatoria de K puntos como centroides iniciales

Actualización

Recálculo de la posición de cada centroide como el promedio de los puntos asignados

Asignación


Cada punto se asigna al centroide más cercano

Iteración

Repetición de los pasos 2 y 3 hasta convergencia o número máximo de iteraciones

Clustering Jerárquico: Fundamentos

El Clustering Jerárquico construye una jerarquía de clústeres mediante un enfoque aglomerativo (de abajo hacia arriba) o divisivo (de arriba hacia abajo). No requiere definir K inicialmente.



Clustering Jerárquico:

Características

Visualización

Produce un dendrograma útil para análisis visual de la estructura jerárquica

Flexibilidad

No requiere especificar el número de clústeres a priori

Complejidad


Su complejidad computacional lo hace ineficiente en datasets muy grandes

Sensibilidad

Es sensible a errores iniciales que se propagan en la jerarquía


Clustering Jerárquico: Enfoques

Agglomerative



VS

Divisive



Enfoque Aglomerativo

Comienza con cada punto como un clúster individual y va fusionando los más cercanos hasta obtener un único clúster que contiene todos los puntos.

Enfoque Divisivo


Comienza con un único clúster que contiene todos los puntos y va dividiéndolo sucesivamente hasta que cada punto forma su propio clúster.

DBSCAN:

Fundamentos

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) identifica regiones densas de datos sin requerir el número de clústeres a priori. Es especialmente útil para detectar clústeres de formas arbitrarias.

DBSCAN Clustering Identifying Dense Regions



DBSCAN: Características

Robustez

Es robusto frente a outliers, clasificándolos como ruido

Flexibilidad

Detecta clústeres de forma arbitraria, no solo esféricos

Parámetros

No requiere especificar el número de clústeres a priori

Limitación

Su rendimiento puede deteriorarse con variaciones de densidad entre clústeres

DBSCAN:

Funcionamiento

Definición de Parámetros

Definición de la vecindad (ϵ) y el número mínimo de puntos (minPts)

Expansión de Clústeres

Expansión de los clústeres conectando puntos núcleo y sus vecinos

Clasificación de Puntos


Clasificación de los puntos núcleo, frontera y ruido según su densidad

Finalización

Asignar etiquetas de clúster a todos los puntos no clasificados como ruido

Mezcla Gaussiana (GMM): Fundamentos

La Mezcla Gaussiana (GMM) asume que los datos provienen de una combinación de distribuciones gaussianas. Este enfoque probabilístico permite modelar clústeres con formas elípticas y diferentes tamaños.



Mezcla Gaussiana:

Características

Flexibilidad

Ofrece mayor flexibilidad que K-Means al modelar formas elípticas

Asignación

Probabilística
Proporciona probabilidades de pertenencia a cada clúster

Complejidad

Requiere estimar más parámetros que otros algoritmos

Sensibilidad

Es sensible a la inicialización y puede converger a óptimos locales

Mezcla Gaussiana: Funcionamiento

Inicialización

Establecer parámetros iniciales para cada componente gaussiana

Maximization

Actualizar los parámetros de cada componente basándose en las probabilidades

Expectation

Calcular la probabilidad de que cada punto pertenezca a cada componente

Iteración

Repetir los pasos de expectation y maximization hasta convergencia

Live Coding

¿En qué consistirá la Demo?

Se mostrará una demostración guiada (no técnica) del funcionamiento de 3 algoritmos de clusterización aplicados sobre un mismo conjunto de datos. El objetivo es que las y los estudiantes observen y describan cómo cada algoritmo agrupa los datos, qué características presenta y qué limitaciones se evidencian.

1. Presentación del dataset (simulado con 3 grupos + ruido)
2. Visualización de resultados con K-Means (forma esférica, sensibilidad a outliers)
3. Visualización de resultados con DBSCAN (detección de outliers, clústeres de forma libre)
4. Visualización de resultados con Mezcla Gaussiana (formas elípticas, asignación probabilística)
5. Breve comparación visual entre las tres técnicas
6. Preguntas orientadoras:
 - a. ¿Qué patrón detecta cada algoritmo?
 - b. ¿Qué diferencias notas en cómo forman los grupos?
 - c. ¿Cuál parece más sensible a valores atípicos?



Momento:

Time-out!



5 -10 min.





Ejercicio

Investigación comparativa de técnicas de clusterización

Investigación comparativa de técnicas de clusterización

Contexto: 🙌

Tu equipo fue convocado para asesorar a una organización que busca segmentar datos (clientes, sensores, documentos, etc.). Debes investigar y describir qué algoritmo de clusterización sería el más adecuado según el problema.

Consigna: 📝

Investiga los algoritmos K-Means, Clustering Jerárquico, DBSCAN y Mezcla Gaussiana, y responde:

1. ¿Cómo funciona cada técnica de forma general?
2. ¿Qué características presentan (ventajas y limitaciones)?
3. ¿Qué tipo de estructuras pueden detectar mejor?
4. ¿Cómo tratan los valores atípicos?
5. ¿Qué parámetros necesitan definir antes de ejecutarse?
6. ¿En qué contextos o industrias se suele aplicar cada uno?

Tiempo 🕒: 45 Minutos

Paso a paso: ⚙️

1. Lee material de clase y busca fuentes confiables (manual, sitios académicos, libros, papers)
2. Resume lo más importante de cada algoritmo
3. Completa una tabla comparativa
4. Elige uno y justifica en qué problema real lo aplicarías
5. Prepara una conclusión personal que conecte lo aprendido con una aplicación práctica

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Comprendimos qué es la clusterización y su rol en el análisis exploratorio.**
- ✓ **Vimos sus aplicaciones en marketing, medicina, biología, ingeniería y más.**
- ✓ **Estudiamos los algoritmos K-Means, Clustering Jerárquico, DBSCAN y GMM.**
- ✓ **Analizamos fortalezas, limitaciones y funcionamiento de cada algoritmo.**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

