



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Clusterización y sus principales algoritmos- Parte II

Aprendizaje Esperado 2: Describir las principales características de las técnicas de clusterización, sus principales algoritmos y problemas que resuelve.

Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA
NO SUPERVISADO

1

REDUCCIÓN
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN
DIMENSIONAL


5

CLUSTERIZACIÓN Y SUS
PRINCIPALES ALGORITMOS

ALGORITMOS DE
CLUSTERIZACIÓN

Learning Path

¿Cuáles temas trabajaremos hoy?



Objetivos de aprendizaje

¿Qué aprenderás?

- Comparar los principales algoritmos de clusterización según sus ventajas y limitaciones
- Analizar casos reales de aplicación de técnicas de clusterización
- Reconocer los desafíos más comunes en tareas de agrupamiento
- Explorar estrategias para seleccionar la técnica adecuada
- Conocer tendencias emergentes en clusterización moderna

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Qué es la clusterización y su función en el aprendizaje no supervisado
- Principales algoritmos: K-Means, Clustering Jerárquico, DBSCAN y GMM
- Aplicaciones de clusterización en marketing, biología, análisis web y más
- Importancia del preprocesamiento e interpretación de resultados

Clusterización y sus principales algoritmos

Comparativa de Algoritmos: Ventajas

Algoritmo	Ventajas
K-Means	Rápido, eficiente, fácil de interpretar
Jerárquico	No necesita K, genera dendrogramas
DBSCAN	Detecta clústeres de cualquier forma, ignora outliers
Mezcla Gaussiana	Modela formas complejas, asignación probabilística

Comparativa de Algoritmos:

Desventajas

Algoritmo	Desventajas
K-Means	Requiere definir K, sensible a outliers y forma de clúster
Jerárquico	Poco escalable, sensible a errores iniciales
DBSCAN	No funciona bien con densidades muy dispares
Mezcla Gaussiana	Requiere buen ajuste de parámetros, más complejo

Selección del Algoritmo Adecuado

1

Naturaleza de los Datos

Considerar la forma esperada de los clústeres y la presencia de outliers

2

Tamaño del Dataset

Evaluar la eficiencia computacional requerida según el volumen de datos

3

Conocimiento Previo

Determinar si se conoce o no el número aproximado de clústeres

4

Objetivo del Análisis

Definir si se busca interpretabilidad, precisión o flexibilidad


Casos de Uso: Segmentación de Clientes

La segmentación de clientes por patrones de compra es uno de los casos de uso más comunes de la clusterización.

Permite identificar grupos de consumidores con comportamientos similares para desarrollar estrategias de marketing personalizadas.

Customer Segmentation


By Age Group




By Gender




By Spending Score



By Spending Score



By Purchases



Segmentación de Clientes: Proceso



Recopilación de Datos

Historial de compras, demografía, interacciones



Preprocesamiento

Limpieza, normalización y selección de variables

3

Clusterización

Aplicación del algoritmo seleccionado



Interpretación

Análisis de características de cada segmento

Segmentación de Clientes: Beneficios

Personalización

Ofertas y comunicaciones adaptadas a cada segmento

Eficiencia

Optimización de recursos de marketing

Retención

Estrategias específicas para grupos de alto valor


Innovación

Desarrollo de productos basado en necesidades de segmentos


Casos de Uso: Clasificación de Documentos

La clasificación de documentos según temáticas es otra aplicación importante de la clusterización. Permite organizar grandes volúmenes de texto sin necesidad de etiquetado previo.


Document Clustering Visualization




topic 1



topic 2



topic 3



topic 4

Clasificación de Documentos:

Proceso

Preprocesamiento

Tokenización, eliminación de stopwords, stemming o lematización

Clusterización


Aplicación de algoritmos como K-Means o Clustering Jerárquico

Vectorización

Transformación de textos a representaciones numéricas (TF-IDF, word embeddings)

Etiquetado

Identificación de términos representativos para cada clúster



Casos de Uso: Agrupamiento de Imágenes

El agrupamiento de imágenes con características similares permite organizar colecciones fotográficas, identificar patrones visuales y facilitar la búsqueda en grandes repositorios.

Agrupamiento de Imágenes: Proceso



Extracción de Características

Obtención de descriptores visuales o uso de redes neuronales



Representación Vectorial

Transformación a espacios de características comparables

3

Clusterización

Aplicación de algoritmos como K-Means o DBSCAN




Organización

Agrupación visual según similitudes identificadas

Casos de Uso: Detección de Fallos

La detección de fallos en sistemas industriales mediante clusterización permite identificar patrones anómalos en el funcionamiento de maquinaria y anticipar posibles averías.



Detección de Fallos: Proceso

Monitoreo

Recopilación continua de datos de sensores y sistemas

Detección

Identificación de desviaciones respecto a los patrones normales


Modelado

Creación de clústeres que representen el funcionamiento normal

Alerta

Generación de avisos ante comportamientos anómalos

Network Traffic Analysis



Casos de Uso: Análisis de Tráfico

El análisis de tráfico en redes o sistemas mediante clusterización permite identificar patrones de uso, detectar comportamientos anómalos y optimizar la asignación de recursos.

Análisis de Tráfico: Aplicaciones

Seguridad

Detección de patrones sospechosos que podrían indicar ataques

Optimización

Distribución eficiente de recursos según demanda

Planificación


Anticipación de necesidades futuras basada en patrones identificados

Monitoreo

Seguimiento de la salud del sistema y detección temprana de problemas

Casos de Uso: Agrupamiento Geográfico

El agrupamiento de regiones geográficas por clima o características socioeconómicas permite identificar zonas con condiciones similares para planificación urbana, estudios ambientales o estrategias de desarrollo.



Agrupamiento Geográfico: Variables



Climáticas

Temperatura, precipitaciones, humedad, vientos



Urbanísticas

Densidad poblacional, infraestructura, servicios



Económicas

Ingresos, empleo, actividades productivas



Sociales

Educación, salud, seguridad, calidad de vida




Desafíos en la Clusterización

A pesar de sus múltiples aplicaciones, la clusterización presenta varios desafíos que deben considerarse para obtener resultados significativos y útiles.

Desafío: Selección del Número de Clústeres

Determinar el número óptimo de clústeres es uno de los principales desafíos, especialmente en algoritmos como K-Means que requieren este parámetro a priori.



Métodos para Determinar el Número de Clústeres

Método del Codo

Analiza la variación de la suma de errores cuadráticos al aumentar el número de clústeres

Coeficiente de Silueta

Evalúa la calidad de los clústeres midiendo la similitud interna y la separación entre grupos

Criterio de Información Bayesiano

Equilibra la bondad de ajuste con la complejidad del modelo


Gap Statistic

Compara la dispersión intra-clúster con la esperada bajo una distribución nula

Desafío: Maldición de la Dimensionalidad

En espacios de alta dimensionalidad, las distancias entre puntos tienden a volverse similares, dificultando la identificación de clústeres significativos.

CURSE OF DIMENSIONALITY IN CLUSTERING



Estrategias para Alta Dimensionalidad

Reducción de Dimensionalidad

Aplicación de técnicas como PCA o t-SNE antes de la clusterización

Selección de Características

Identificación de las variables más relevantes para el análisis

Algoritmos Específicos

Uso de métodos diseñados para espacios de alta dimensionalidad

Métricas Alternativas

Empleo de medidas de distancia adaptadas a espacios de muchas dimensiones

Desafío: Interpretación de Resultados

La interpretación de los clústeres obtenidos requiere conocimiento del dominio y análisis contextual para traducir agrupaciones matemáticas en información accionable.



Estrategias de Interpretación

Análisis de Centroides

Estudio de las características promedio de cada clúster

Comparación Estadística

Análisis de diferencias significativas entre grupos

Visualización

Representación gráfica de los clústeres en espacios reducidos

Validación con Expertos

Contraste de resultados con conocimiento especializado del dominio

Desafío: Evaluación de la Calidad


Evaluar la calidad de los clústeres obtenidos es complejo debido a la naturaleza no supervisada del problema, que carece de etiquetas de referencia.

Clustering Quality Evaluation Metrics


Silhouette
Score




Dunn Index



Davies-Bouldin
Index



Rand Index



Métricas de Evaluación

Índice de Silueta

Mide qué tan similar es un objeto a su propio clúster en comparación con otros clústeres

Índice Davies-Bouldin

Evalúa la separación entre clústeres en relación con su dispersión interna

Índice Calinski-Harabasz

Compara la varianza entre clústeres con la varianza dentro de los clústeres

Índice Dunn

Identifica clústeres compactos y bien separados



Tendencias Actuales en Clusterización

El campo de la clusterización continúa evolucionando con nuevos enfoques y aplicaciones que amplían sus capacidades y ámbitos de uso.

Tendencias Emergentes

Deep Clustering

Integración de redes neuronales profundas con técnicas de clusterización

Clustering Espectral

Uso de propiedades espectrales de matrices de similitud para mejorar resultados

Clustering Incremental

Adaptación continua de clústeres con la llegada de nuevos datos

Clustering Multi-vista

Combinación de múltiples perspectivas o fuentes de datos para la clusterización

Conclusiones: Importancia de la Clusterización

La clusterización es una técnica esencial en el repertorio del científico de datos moderno. Su aplicación transversal permite extraer valor incluso de datos no etiquetados, facilitando la exploración, la segmentación y el análisis automatizado.



Fundamentos Adquiridos

1

Conceptos Básicos

Comprensión de los principios fundamentales de la clusterización y su papel en el aprendizaje no supervisado

2

Algoritmos Principales

Conocimiento de K-Means, Clustering Jerárquico, DBSCAN y Mezcla Gaussiana, con sus ventajas y limitaciones

3

Aplicaciones Prácticas

Identificación de casos de uso y contextos donde la clusterización aporta valor

4

Desafíos y Soluciones

Reconocimiento de los principales retos y estrategias para abordarlos efectivamente

Selección de Técnicas

En esta lección exploraste los fundamentos de la clusterización, entendiste cómo se aplican sus algoritmos principales y qué ventajas o limitaciones presentan. Aprendiste también a seleccionar la técnica adecuada según el tipo de problema y el contexto de uso.

Proyección Profesional

Dominar la clusterización te permitirá enfrentar desafíos complejos en distintos sectores, desde el marketing hasta la biotecnología, pasando por la ingeniería o la economía. Este conocimiento es clave para construir soluciones analíticas sólidas.



Live Coding

¿En qué consistirá la Demo?

Se mostrará cómo los distintos algoritmos de clusterización responden ante distintos tipos de datos y problemas reales. El objetivo es observar, comparar y reflexionar sobre cuándo conviene usar cada técnica.

1. Visualización de segmentación con K-Means
2. Visualización de jerarquías con Clustering Jerárquico
3. Detención de outliers con DBSCAN
4. Agrupamiento probabilístico con GMM
5. Análisis comparativo: ¿qué algoritmo conviene según el contexto?
6. Factores clave: forma de datos, presencia de ruido, cantidad de grupos esperados



Momento:

Time-out!



5 -10 min.





Ejercicio

¿Qué técnica usarías tú?

¿Qué técnica usarías tú?

Contexto: 🙌

Una empresa busca aplicar técnicas de clusterización en distintas áreas. Debes investigar, analizar y justificar cuál sería el algoritmo más adecuado para cada escenario, según lo visto en clase.

Consigna: 📝

1. Completa una tabla comparativa con ventajas, desventajas y usos típicos:

Algoritmo	Ventajas	Limitaciones	Casos de uso típicos
K-Means			
Jerárquico			
DBSCAN			
GMM			

Tiempo 🕒: 45 Minutos

¿Qué técnica usarías tú?

Paso a paso:

1. Selecciona dos casos reales (segmentación de clientes, agrupamiento de imágenes, fallas industriales, etc.) y responde:
 - ¿Qué técnica usarías? ¿Por qué?
2. Reflexiona:
 - ¿Qué desafíos puede haber (número de clústeres, dimensionalidad, interpretación)?
 - ¿Qué estrategia usarías para abordarlos?

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Comparamos ventajas y limitaciones de cada técnica de clusterización**
- ✓ **Identificamos casos de uso reales aplicables a cada algoritmo**
- ✓ **Reconocimos desafíos como número de clústeres o dimensionalidad**
- ✓ **Exploramos nuevas tendencias en el campo de la clusterización**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

