



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Reducción dimensional- Parte II

Aprendizaje Esperado 3: Describir las principales características de las técnicas de reducción de dimensionalidad, sus principales algoritmos y problemas que resuelve.

Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA
NO SUPERVISADO

1

REDUCCIÓN
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN
DIMENSIONAL

5

CLUSTERIZACIÓN Y SUS
PRINCIPALES ALGORITMOS

2

ALGORITMOS DE
CLUSTERIZACIÓN

4

Learning Path

¿Cuáles temas trabajaremos hoy?

3.

Reducción Dimensional

Aplicar y evaluar técnicas de reducción de dimensionalidad en problemas reales.

Técnicas y Aplicaciones

PCA, t-SNE, LDA,
Autoencoders y su uso en
visualización y modelado

Casos de uso: clientes,
fraude, texto, imágenes

Implementación y
Evaluación

Preprocesamiento, selección
de componentes, ajuste de
hiperparámetros

Métricas y
consideraciones
avanzadas

Objetivos de aprendizaje

¿Qué aprenderás?

- Identificar cómo se aplican las técnicas de reducción de dimensionalidad en problemas reales
- Reconocer su impacto en visualización, eficiencia y precisión de modelos
- Conocer pasos y buenas prácticas para su implementación
- Evaluar la calidad de una reducción dimensional usando métricas concretas
- Explorar casos reales en industria, medicina, redes sociales y más

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Qué es la reducción de dimensionalidad y para qué se usa
- Diferencias entre selección y extracción de características
- Algoritmos principales: PCA, t-SNE, LDA, Autoencoders
- Comparación entre técnicas lineales y no lineales

Reducción dimensional

Caso de Estudio: Análisis de Sentimientos

Problema

Miles de reseñas de productos con vocabulario extenso.

Aplicación

Reducción de la matriz término-documento mediante técnicas como LSA (Latent Semantic Analysis).

Resultado

Clasificación eficiente de reseñas positivas y negativas con mayor precisión.

Técnicas Específicas para Texto

LSA/LSI

Latent Semantic Analysis/Indexing
utiliza SVD para encontrar
relaciones semánticas ocultas.

LDA

Latent Dirichlet Allocation para
modelado de tópicos y reducción
dimensional.


Word Embeddings

Representaciones vectoriales de
palabras como Word2Vec o GloVe
que capturan significado
semántico.

Visualización de Clústeres


La reducción de dimensionalidad permite representar resultados de clusterización en 2D o 3D, facilitando la interpretación visual de agrupaciones en los datos.

3D visualization of data clusters
after dimensionality reduction



Caso de Estudio: Segmentación de Clientes

Utilizando t-SNE para visualizar segmentos de clientes basados en múltiples variables de comportamiento y demográficas.



Ventajas para la Visualización



Interpretabilidad

Facilita la comprensión de patrones complejos mediante representaciones visuales.



Descubrimiento

Permite identificar relaciones y estructuras no evidentes en los datos originales.




Comunicación

Mejora la presentación de resultados a audiencias no técnicas.

Preprocesamiento para Modelos

La reducción de dimensionalidad se utiliza como paso previo al entrenamiento de modelos para evitar el sobreajuste al eliminar ruido o redundancia en los datos.

MACHINE LEARNING PIPELINE



Caso de Estudio: Predicción de Fraude

Problema

Cientos de variables transaccionales para detectar operaciones fraudulentas.

Aplicación

PCA para reducir dimensiones antes de entrenar un modelo de clasificación.

Resultado

Mejora en la precisión y reducción del tiempo de entrenamiento del modelo.

Beneficios para el Modelado

Reducción de Sobreajuste

Menos dimensiones significan menos parámetros a estimar, lo que reduce el riesgo de sobreajuste.

Eficiencia Computacional

Modelos más rápidos de entrenar y ejecutar con menos variables.

Estabilidad

Mayor robustez frente a variaciones en los datos de entrenamiento.

Aplicaciones en Otros Campos

Finanzas

- Análisis de riesgo
- Detección de anomalías
- Predicción de mercados

Medicina

- Diagnóstico por imágenes
- Análisis de señales biomédicas

Industria

- Mantenimiento predictivo
- Control de calidad

Redes Sociales

- Análisis de redes
- Recomendación de contenido

Implementación Práctica

La aplicación efectiva de técnicas de reducción de dimensionalidad requiere conocimientos prácticos sobre su implementación.



Preprocesamiento de Datos

Limpieza

Eliminar valores faltantes y atípicos que puedan afectar el análisis.

Estandarización

Normalizar variables para que tengan media cero y desviación estándar uno.

Transformación

Aplicar transformaciones como logarítmica o Box-Cox para variables sesgadas.

Implementación de PCA


```
# Ejemplo en Python con scikit-learn
from sklearn.decomposition
import PCAfrom sklearn.preprocessing
import StandardScaler

# Estandarizar los datos
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Aplicar PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)#
    Varianza explicada
explained_variance = pca.explained_variance_ratio_
```

Selección del Número de Componentes

La elección del número óptimo de componentes es crucial para balancear la reducción de dimensionalidad con la preservación de información relevante.



Métodos para Seleccionar Componentes

Regla del Codo

Identificar el punto donde la varianza explicada adicional se reduce significativamente.

Umbral de Varianza

Seleccionar componentes hasta alcanzar un porcentaje acumulado de varianza explicada (ej. 95%).

Validación Cruzada

Evaluar el rendimiento de modelos con diferentes números de componentes.

Implementación de t-SNE

```
# Ejemplo en Python con scikit-learnfrom sklearn.manifold import TSNEimport matplotlib.pyplot as plt# Aplicar t-SNEtsne = TSNE(n_components=2, perplexity=30, random_state=42)X_tsne = tsne.fit_transform(X)# Visualizar resultadosplt.scatter(X_tsne[:, 0], X_tsne[:, 1], c=y)plt.colorbar()plt.show()
```

Ajuste de Hiperparámetros en t-SNE

Perplejidad

Controla el equilibrio entre la preservación de estructura local y global (valores típicos: 5-50).

Tasa de Aprendizaje


Afecta la convergencia del algoritmo y la calidad de la visualización final.

Número de Iteraciones

Determina cuánto tiempo se optimiza la representación (generalmente 1000-2000).

Evaluación de Resultados

Es fundamental evaluar la calidad de la reducción de dimensionalidad para asegurar que se preserve la información relevante.



Métricas de Evaluación

Varianza Explicada

Porcentaje de la variabilidad original capturada por los componentes seleccionados.

Reconstrucción del Error

Diferencia entre los datos originales y su reconstrucción desde el espacio reducido.

Rendimiento de Modelos


Comparación del desempeño de algoritmos antes y después de la reducción.

Preservación de Distancias

Correlación entre las distancias en el espacio original y el reducido.

Visualización de Resultados

La visualización efectiva de los resultados de reducción de dimensionalidad es clave para comunicar hallazgos y patrones descubiertos.



Técnicas de Visualización



Gráficos de Dispersión

Representación de puntos en 2D o 3D, coloreados según categorías o valores.



Mapas de Calor

Visualización de matrices de correlación o similitud entre observaciones.



Animaciones

Representación dinámica de la transformación entre espacios dimensionales.

Consideraciones Avanzadas


Para obtener resultados óptimos con la reducción de dimensionalidad, es importante considerar aspectos avanzados de su aplicación.

Datlrboardaights

Matrice

Matric A	53.564
Matric B	28.371
Matric C	13.87%
Matric D	7.21%

Y.ONE



UKAP



Value: Over Time



Category: Distribution

Category	Cuven	Pasenlage
Category A	3.380	21.7%
Category B	4.391	16.2%
Category C	5.075	15.4%
Category D	8.171	13.3%
Category E	2.044	8.9%

Value: Over Time



Category: Distribution

Category	Cuven	Passenting
Category A	5.999	21.7%
Category B	4.281	15.0%
Category C	8.058	13.4%
Category E	3.044	8.0%

Reducción de Dimensionalidad para Datos Masivos

Algoritmos Incrementales

Versiones de PCA y otros métodos que procesan datos por lotes para manejar grandes volúmenes.

Muestreo

Aplicar la reducción a una muestra representativa antes de procesar el conjunto completo.


Computación Distribuida

Utilizar frameworks como Spark para paralelizar cálculos en múltiples máquinas.

Reducción de Dimensionalidad para Series Temporales

Las series temporales presentan desafíos específicos debido a la dependencia temporal entre observaciones.

- Técnicas específicas: Dynamic Time Warping (DTW)
- Transformaciones: Wavelets, Fourier
- Embedding: Takens' embedding theorem



Reducción de Dimensionalidad para Datos Heterogéneos

Variables Mixtas

Técnicas para manejar simultáneamente variables numéricas y categóricas.

Datos Multimodales

Métodos para integrar información de diferentes fuentes (texto, imágenes, señales).

Datos Faltantes

Estrategias para aplicar reducción dimensional con información incompleta.

Tendencias Futuras



Métodos Basados en Redes Neuronales

Autoencoders profundos y variantes para capturar relaciones altamente no lineales.



Reducción Dimensional para Grafos


Técnicas especializadas para redes y estructuras relacionales complejas.



Métodos en Tiempo Real

Algoritmos para reducción dimensional en flujos continuos de datos.

TRANSFORMATION OF COMPLEX HIGH DIMENSIONAL DATA INTO SIMPLE, CLEAR PATTERNS



Conclusiones

La reducción de dimensionalidad no solo es una técnica de eficiencia, sino una puerta hacia una mejor comprensión de los datos. Al aplicar estos métodos, logramos transformar complejidad en claridad, facilitando análisis y modelos más efectivos.

Beneficios Clave

Visualización

Con herramientas como PCA o t-SNE, es posible visualizar agrupaciones, identificar correlaciones y descubrir estructuras en conjuntos de datos aparentemente caóticos.

Eficiencia


La reducción de dimensiones permite procesar datos más rápidamente y con menos recursos computacionales.

Precisión

Al eliminar ruido y redundancia, los modelos pueden capturar mejor los patrones subyacentes en los datos.


Consideraciones Finales

Elegir el método adecuado es clave, según el objetivo y la naturaleza de los datos. Cada técnica tiene sus fortalezas y debilidades, por lo que es importante entender el contexto del problema antes de aplicar cualquier algoritmo de reducción dimensional.



Mensaje Final

Dominar la reducción de dimensionalidad te permitirá abordar problemas reales con mayor confianza y habilidad, mejorando tus procesos analíticos y potenciando tus resultados predictivos.





Live Coding

¿En qué consistirá la Demo?

Mostraremos cómo implementar y ajustar técnicas de reducción de dimensionalidad con un enfoque práctico. El objetivo es observar cómo aplicarlas y evaluar su impacto.

1. Visualización de resultados con PCA y gráfica de varianza explicada
2. Aplicación de t-SNE ajustando hiperparámetros (perplejidad, tasa de aprendizaje)
3. Comparación de visualizaciones: interpretabilidad y agrupamientos
4. Evaluación con métricas: varianza explicada, preservación de distancias
5. Discusión guiada: ¿cómo elegimos el número de componentes?, ¿qué tan bien se preserva la información?



Momento:

Time-out!



5 -10 min.





Ejercicio

¿Cómo implementarías la reducción?

¿Cómo implementarías la reducción?

Contexto: 🙌

Tu equipo debe aplicar reducción de dimensionalidad en un proyecto real. Se te asigna el análisis de cómo implementarla correctamente, seleccionando el algoritmo adecuado y evaluando su impacto.

Consigna: 📝

1. Selecciona uno de estos contextos reales:
 - Análisis de sentimientos en reseñas de productos
 - Segmentación de clientes para campañas
 - Predicción de fraude bancario
 - Diagnóstico médico a partir de imágenes
2. Para ese caso, responde:
 - ¿Qué técnica(s) aplicarías y por qué?
 - ¿Qué pasos seguirías para preprocesar los datos?
 - ¿Cómo decidirías el número de componentes?
 - ¿Qué métrica usarías para evaluar la reducción?
3. Reflexiona:
 - ¿Qué beneficios obtendrás?
 - ¿Qué limitaciones podrían surgir y cómo las abordarías?

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ Entendimos cómo aplicar reducción de dimensionalidad en contextos reales
- ✓ Vimos cómo mejora la visualización y el rendimiento de los modelos
- ✓ Analizamos pasos clave de implementación: estandarización, selección de componentes, evaluación
- ✓ Exploramos métricas para medir la calidad de la reducción



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

