



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Reducción dimensional- Parte I

Aprendizaje Esperado 3: Describir las principales características de las técnicas de reducción de dimensionalidad, sus principales algoritmos y problemas que resuelve.

Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA
NO SUPERVISADO

1

REDUCCIÓN
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN
DIMENSIONAL

5

CLUSTERIZACIÓN Y SUS
PRINCIPALES ALGORITMOS

2

ALGORITMOS DE
CLUSTERIZACIÓN

4

Learning Path

¿Cuáles temas trabajaremos hoy?

3.

Reducción de dimensionalidad

Técnicas utilizadas para transformar datasets con muchas variables en representaciones más compactas, manteniendo la información esencial.

Fundamentos y enfoques

¿Qué es la reducción de dimensionalidad y por qué es importante?

Selección vs. extracción de características

Algoritmos y aplicaciones

PCA, t-SNE, UMAP, LDA, Autoencoders

Aplicaciones en genética, imágenes y minería de texto

Objetivos de aprendizaje

¿Qué aprenderás?

- Comprender el objetivo y los beneficios de reducir dimensiones en un dataset
- Identificar las diferencias entre selección y extracción de características
- Describir los algoritmos más utilizados: PCA, t-SNE y otros
- Reconocer las aplicaciones reales de la reducción de dimensionalidad
- Reflexionar sobre los desafíos y limitaciones que presentan estas técnicas

Repaso clase anterior

¿Quedó alguna duda?


En la clase anterior trabajamos :

- Fundamentos de la clusterización y sus algoritmos principales
- Comparación entre técnicas (K-Means, DBSCAN, GMM, Jerárquico)
- Aplicaciones prácticas en marketing, imágenes, tráfico, fallas y biología
- Desafíos comunes: número de clústeres, dimensionalidad, interpretación

Reducción dimensional

Reducción de Dimensionalidad en Aprendizaje Automático

La reducción de dimensionalidad es una técnica fundamental en el aprendizaje automático que permite simplificar conjuntos de datos complejos sin perder información relevante. Este enfoque es especialmente útil en contextos donde la alta dimensionalidad puede dificultar el análisis, afectar el rendimiento de los modelos o generar problemas como el sobreajuste.




Introducción a la Reducción de Dimensionalidad

Al reducir el número de variables o características, se mejora la eficiencia computacional, se facilita la visualización de los datos y se incrementa la interpretabilidad de los modelos. Esta técnica se ha convertido en una herramienta clave para científicos de datos que trabajan con grandes volúmenes de información.



¿Qué es la Reducción de Dimensionalidad?

La reducción de dimensionalidad consiste en transformar un conjunto de datos con muchas variables (o características) en una representación de menor dimensión sin perder información significativa. Esta técnica es útil para combatir la "maldición de la dimensionalidad", un fenómeno en el que los datos se vuelven dispersos e ineficaces para muchos algoritmos de aprendizaje automático.



Enfoques Principales

Selección de Características

Consiste en elegir las variables más relevantes del conjunto original de datos, descartando aquellas que aportan menos información.

Extracción de Características

Implica crear nuevas variables a partir de combinaciones de las existentes, como ocurre con métodos como PCA y t-SNE.

En este manual nos centraremos principalmente en la extracción de características.

Beneficios de la Reducción de Dimensionalidad



Mejora de Generalización

Aumenta la capacidad de los modelos para generalizar a partir de los datos de entrenamiento.



Visualización

Permite representaciones gráficas en dos o tres dimensiones para facilitar el análisis visual.




Identificación de Patrones

Ayuda a descubrir patrones ocultos en los datos que no serían evidentes en dimensiones superiores.

Consideraciones Importantes



La reducción de dimensionalidad también puede llevar a la pérdida de interpretabilidad o información importante si no se realiza correctamente.



Proceso de Aplicación

Estandarización

Normalizar los datos para que todas las variables tengan la misma escala.

Selección de Algoritmo

Elegir el método de reducción más apropiado según el problema y los datos.

Validación

Comprobar que la nueva representación conserve la estructura esencial del problema.

Campos de Aplicación

- Genética
- Análisis de imágenes
- Minería de texto
- Reconocimiento de patrones
- Análisis financiero

La versatilidad de la reducción de dimensionalidad la convierte en una herramienta imprescindible para los analistas de datos en diversos dominios.




Principales Algoritmos de Reducción de Dimensionalidad

Existen diversos métodos para reducir la dimensionalidad de los datos, cada uno con sus propias características, ventajas y limitaciones.

PCA (Análisis de Componentes Principales)

PCA es uno de los métodos más conocidos y utilizados. Transforma las variables originales en un nuevo conjunto de variables llamadas componentes principales, que son combinaciones lineales de las originales. Estos componentes están ordenados según la varianza que explican.



Funcionamiento de PCA



Cálculo de la Matriz de Covarianza

Se determina cómo se relacionan las variables entre sí.



Obtención de Autovalores y Autovectores

Estos representan la dirección y magnitud de la varianza.



Selección de Componentes

Se eligen los componentes que explican la mayor parte de la varianza.

Ventajas de PCA

Simplicidad


Es un método matemáticamente sencillo y bien establecido.

Rapidez

Computacionalmente eficiente, incluso con grandes conjuntos de datos.

Detección de Correlaciones

Excelente para identificar relaciones lineales entre variables.




Limitaciones de PCA

- Solo capta relaciones lineales entre variables
- La interpretación puede ser difícil si se usan muchos componentes
- No es óptimo para datos con distribuciones no gaussianas

Aplicaciones Ideales de PCA


PCA es útil cuando los datos presentan redundancia o correlaciones altas, permitiendo eliminar esas redundancias sin perder la esencia del fenómeno estudiado.



t-SNE (t-distributed Stochastic Neighbor Embedding)

t-SNE es una técnica no lineal especializada en la visualización de datos de alta dimensión en espacios bidimensionales o tridimensionales. A diferencia de PCA, preserva mejor la estructura local del conjunto de datos, agrupando observaciones similares.

t-SNE visualization showing clusters of similar data points in 2D space



Funcionamiento de t-SNE

Cálculo de Similitudes

Determina la similitud entre puntos en el espacio original mediante distribuciones de probabilidad.

Creación del Espacio Reducido

Genera un espacio de baja dimensión donde se mantienen las similitudes locales.

Optimización

Minimiza la divergencia entre las distribuciones de probabilidad de los espacios original y reducido.

Aplicaciones de t-SNE

Este algoritmo es muy utilizado en tareas exploratorias, especialmente cuando se trabaja con datos de texto, imágenes o secuencias genéticas. Es particularmente eficaz para identificar grupos o patrones que no serían evidentes con métodos lineales.

Ventajas de t-SNE

Preservación Local

Mantiene la estructura de vecindad entre puntos similares.

Visualización Efectiva

Excelente para representar datos complejos en 2D o 3D.


Detección de Clusters

Revela agrupaciones naturales en los datos que otros métodos podrían no detectar.


Limitaciones de t-SNE

- ❌ • Computacionalmente costoso para grandes conjuntos de datos
- Los resultados pueden variar según los hiperparámetros utilizados (como la perplejidad)
- No es útil como técnica de preprocesamiento para modelos, ya que la transformación no es fácilmente invertible
- No preserva bien la estructura global de los datos

Before t-SNE



After t-SNE




Importancia de t-SNE

A pesar de sus limitaciones, t-SNE sigue siendo una herramienta poderosa para revelar estructuras ocultas y descubrir agrupaciones en datos complejos.

Comparación de PCA y t-SNE

Característica	PCA	t-SNE
Tipo de técnica	Lineal	No lineal
Velocidad	Alta	Media a baja
Preservación de estructura	Global	Local
Interpretabilidad	Alta	Baja
Uso común	Reducción previa, análisis	Visualización de datos complejos
Reproducibilidad	Alta	Baja (dependiente de parámetros)



Visualización Comparativa

La imagen muestra cómo PCA y t-SNE representan el mismo conjunto de datos. Mientras PCA preserva la estructura global, t-SNE revela mejor los agrupamientos locales.

Otros Algoritmos de Reducción de Dimensionalidad

LDA (Análisis Discriminante Lineal)

Técnica supervisada que busca maximizar la separación entre clases.

UMAP

Método reciente que combina velocidad y preservación de estructura local y global.

Isomap


Preserva las distancias geodésicas entre puntos en el espacio de alta dimensión.

Autoencoders

Redes neuronales que aprenden representaciones comprimidas de los datos.

Aplicaciones y Casos Resueltos con Reducción de Dimensionalidad

La reducción de dimensionalidad se aplica en numerosos campos para resolver problemas complejos de análisis de datos.




Análisis de Datos Genéticos

En genómica, la reducción de dimensionalidad permite analizar miles de genes simultáneamente, identificando patrones y relaciones que serían imposibles de detectar manualmente.

Esta técnica ha sido fundamental para descubrir biomarcadores, clasificar enfermedades y entender mecanismos biológicos complejos.

GENE EXPRESSION PATTERNS



Caso de Estudio: Clasificación de Cáncer

Problema


Datos de expresión de miles de genes para diferentes tipos de cáncer.

Aplicación

PCA para reducir a componentes principales que explican la mayor variabilidad.

Resultado

Identificación de subtipos de cáncer y genes relevantes para el diagnóstico.




Dimensionality Reduction Applied to Facial Recognition

Procesamiento de Imágenes

En el análisis de imágenes, la reducción de dimensionalidad permite disminuir la resolución sin perder información crítica, facilitando tareas como reconocimiento facial, detección de objetos y clasificación de imágenes.

Caso de Estudio: Reconocimiento Facial Eigenfaces

Aplicación de PCA para extraer características faciales principales, reduciendo miles de píxeles a unas pocas dimensiones significativas.



Beneficios en Procesamiento de Imágenes

Eficiencia

Reduce el tiempo de procesamiento al trabajar con menos dimensiones.


Eliminación de Ruido

Filtra información irrelevante o redundante en las imágenes.

Mejora de Algoritmos

Aumenta la precisión de los modelos de clasificación y detección.

Document Clustering
After Dimensionality Reducction



Minería de Texto

En el análisis de texto, la reducción de dimensionalidad permite representar documentos como vectores de menor dimensión, facilitando tareas como clasificación, agrupamiento y búsqueda semántica.



Live Coding

¿En qué consistirá la Demo?

A través de una visualización guiada, observaremos cómo PCA y t-SNE reducen un mismo conjunto de datos a 2 dimensiones. Compararemos los resultados y discutiremos sus características.

1. Visualización con PCA: estructura global y componentes principales
2. Visualización con t-SNE: agrupamientos locales no lineales
3. Comparación de resultados: ¿cuál preserva qué tipo de información?
4. Discusión guiada: ¿cuándo usar cada técnica?, ¿cuál es más interpretable?, ¿qué problemas resuelve?



Momento:

Time-out!



5 -10 min.





Ejercicio

**¿Qué técnica reduce
mejor?**

¿Qué técnica reduce mejor?

Contexto: 🙌

Un equipo de análisis necesita aplicar técnicas de reducción dimensional en distintos contextos (biología, imágenes, texto). Quieren tu asesoramiento para decidir cuál es la más adecuada en cada caso.

Consigna: 📝

1. Completa la siguiente tabla con características de los algoritmos:

Algoritmo	Tipo (lineal/no lineal)	¿Preserva estructura local?	¿Sirve para visualización?	Caso de uso típico
PCA				
t-SNE				
UMAP				
LDA				
Autoencoder				

Paso a paso: ⚙️

Elige dos casos prácticos (genética, imágenes, texto, etc.) y explica:

- ¿Qué técnica usarías?
- ¿Qué ventajas aporta y qué limitaciones tiene?

Reflexiona:

- ¿Qué riesgos hay al reducir variables?
- ¿Cómo evitar perder información importante?

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Comprendimos el concepto y el propósito de reducir dimensionalidad**
- ✓ **Vimos la diferencia entre selección y extracción de características**
- ✓ **Exploramos los algoritmos más comunes: PCA, t-SNE, UMAP y más**
- ✓ **Reconocimos sus aplicaciones en genética, imágenes y minería de texto**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

