



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Algoritmos de clusterización- › Parte II

Aprendizaje Esperado 4: Implementar un modelo predictivo aplicando algoritmos de clusterización utilizando lenguaje python para resolver un problema.

Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA
NO SUPERVISADO

1

REDUCCIÓN
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN
DIMENSIONAL

5

CLUSTERIZACIÓN Y SUS
PRINCIPALES ALGORITMOS

ALGORITMOS DE
CLUSTERIZACIÓN

Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Ajuste fino e interpretación de modelos de clusterización

Aplicación práctica avanzada de técnicas de clusterización en diversos contextos, incluyendo casos reales, evaluación, desafíos y tendencias emergentes.

Preparación y visualización

Limpieza, normalización, reducción de dimensionalidad

Visualización con scatter plots, PCA, t-SNE, heatmaps 2

Evaluación y casos reales

Métricas: silueta, Davies-Bouldin, Calinski-Harabasz

Clusterización aplicada en marketing, biología, imágenes, documentos, series temporales y grafos

Objetivos de aprendizaje

¿Qué aprenderás?

- Aplicar métricas para evaluar la calidad de un agrupamiento
- Interpretar los resultados obtenidos con distintos algoritmos
- Ajustar parámetros como eps, número de clusters, centroides
- Implementar clusterización en diferentes dominios (clientes, texto, imágenes, etc.)
- Conocer variantes modernas como HDBSCAN, clustering difuso y espectral

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Implementación en Python de los algoritmos K-Means, DBSCAN y Jerárquico
- Visualización de resultados con gráficos y métricas
- Comparación de agrupamientos en distintos contextos
- Evaluación de agrupaciones usando coeficiente de silueta

Algoritmos de clusterización

CLUSTERING

Implementación Práctica

La implementación de estas técnicas no sólo requiere conocer la teoría, sino también practicar con código real, evaluar métricas, ajustar parámetros y visualizar los resultados.

Herramientas en Python



Scikit-learn

Biblioteca principal para implementación de algoritmos de machine learning, incluidos los de clusterización.



Matplotlib

Herramienta para visualización de datos y resultados de clusterización.



SciPy

Proporciona funciones científicas avanzadas, incluyendo algoritmos de agrupamiento jerárquico.

Python y sus bibliotecas (scikit-learn, matplotlib, scipy) proporcionan un entorno robusto para experimentar, analizar y validar modelos de clusterización.



Desarrollo de Habilidades

Dominar estas técnicas fortalece habilidades clave para el análisis exploratorio de datos, resolución de problemas no supervisados y desarrollo de soluciones predictivas sin necesidad de etiquetas.

Comparación de Algoritmos

Algoritmo	Forma de Clusters	Escalabilidad	Sensibilidad a Outliers
K-Means	Esférica	Alta	Alta
Jerárquico	Arbitraria	Baja	Alta
DBSCAN	Arbitraria	Media	Baja

Preparación de Datos para Clusterización

Limpieza de datos

Eliminación de valores faltantes y tratamiento de outliers.

Reducción de dimensionalidad

Aplicación de técnicas como PCA para facilitar la visualización y mejorar el rendimiento.

Normalización


Estandarización de variables para evitar que las escalas afecten al agrupamiento.

Selección de características

Identificación de las variables más relevantes para el análisis de clusters.

Visualización de Clusters

La visualización es fundamental para interpretar los resultados de la clusterización. Algunas técnicas comunes incluyen:



Técnicas de Visualización

Scatter plots

Gráficos de dispersión que muestran la distribución de puntos coloreados por cluster.

PCA

Reducción a 2 o 3 dimensiones para visualizar clusters en datos multidimensionales.

t-SNE

Técnica no lineal para visualizar estructuras complejas preservando relaciones locales.

Heatmaps

Mapas de calor que muestran similitudes entre observaciones o características por cluster.

Métricas de Evaluación

Coeficiente de Silueta

Mide qué tan similar es un objeto a su propio cluster comparado con otros clusters. Rango: $[-1, 1]$.

Índice Davies-Bouldin

Evalúa la separación entre clusters. Valores más bajos indican mejor agrupamiento.

Índice Calinski-Harabasz

También conocido como criterio de razón de varianza. Valores más altos indican mejor definición de clusters.

Caso de Estudio: Segmentación de Clientes


La segmentación de clientes es una aplicación común de la clusterización en marketing. Permite agrupar clientes según su comportamiento de compra, demografía y preferencias.

Utilizando K-Means, una empresa puede identificar segmentos como "compradores frecuentes", "clientes de alto valor" o "compradores ocasionales" para personalizar estrategias.



DOCUMENT CLUSTERING

with text analysis




Caso de Estudio: Análisis de Documentos

La clusterización de documentos permite organizar grandes volúmenes de texto por temáticas similares sin necesidad de etiquetado previo.

Utilizando técnicas como TF-IDF para vectorizar los textos y luego aplicando algoritmos como el agrupamiento jerárquico, se pueden descubrir categorías emergentes en colecciones de documentos.

ANOMALY DETECTION



Caso de Estudio: Detección de Anomalías


DBSCAN es particularmente útil para detectar anomalías en datos, ya que clasifica naturalmente los puntos aislados como ruido.


Esta capacidad se aplica en detección de fraudes, monitoreo de sistemas y control de calidad, donde identificar comportamientos atípicos es crucial.

Clusterización en Biología

En biología, la clusterización se utiliza para analizar datos genómicos, agrupar proteínas por función similar o identificar patrones en expresión génica.

El agrupamiento jerárquico es especialmente popular en este campo debido a su capacidad para mostrar relaciones evolutivas o funcionales.





Clusterización en Astronomía

Los astrónomos utilizan algoritmos de clusterización para clasificar objetos celestes como estrellas, galaxias o cuerpos planetarios según sus propiedades espectrales y físicas.

DBSCAN resulta útil para identificar estructuras como cúmulos estelares o regiones de formación estelar en grandes conjuntos de datos astronómicos.

Clusterización en Procesamiento de Imágenes

En procesamiento de imágenes, K-Means se utiliza frecuentemente para la segmentación y compresión de imágenes, agrupando píxeles con características similares.

Esta técnica permite reducir el número de colores en una imagen o separar objetos del fondo, facilitando tareas de reconocimiento y análisis visual.




Desafíos en Alta Dimensionalidad



La "maldición de la dimensionalidad" afecta significativamente a los algoritmos de clusterización cuando trabajan con datos de muchas dimensiones.

En espacios de alta dimensión, los conceptos de distancia se vuelven menos intuitivos y las diferencias entre puntos tienden a homogeneizarse, dificultando la identificación de clusters significativos.

Curse of Dimensionality



Técnicas para Alta Dimensionalidad

PCA (Análisis de Componentes Principales)

Reduce dimensiones preservando la varianza máxima en los datos.

t-SNE

Preserva relaciones locales para visualización de estructuras complejas.

UMAP

Técnica más reciente que equilibra preservación de estructura local y global.

Selección de características


Identificación de las variables más relevantes para el análisis.

Clusterización Espectral


La clusterización espectral es una técnica avanzada que utiliza los eigenvectores de la matriz de similitud para reducir dimensiones antes de aplicar K-Means.

Es especialmente efectiva para identificar clusters con formas complejas no lineales que K-Means por sí solo no podría detectar.

Spectral Clustering with Complex Shapes



FUZZY CLUSTERING



Clusterización Difusa (Fuzzy Clustering)


A diferencia de los métodos tradicionales donde cada punto pertenece a un único cluster, en la clusterización difusa cada punto tiene un grado de pertenencia a múltiples clusters.

El algoritmo Fuzzy C-Means es el más representativo de esta categoría, útil cuando los límites entre grupos no son claros.

DENSITY-BASED CLUSTERING COMPARISON

DBSCAN

HDBSCAN




Clusterización Basada en Densidad

Además de DBSCAN, existen otros algoritmos basados en densidad como OPTICS y HDBSCAN que mejoran algunas limitaciones del primero.

HDBSCAN extiende DBSCAN eliminando la necesidad de especificar el parámetro ϵ , adaptándose automáticamente a clusters de diferentes densidades.

Mini-Batch K-Means Algorithm



Mini-Batch K-Means

Mini-Batch K-Means es una variante de K-Means diseñada para conjuntos de datos muy grandes, utilizando subconjuntos aleatorios (mini-batches) en cada iteración.

Esta aproximación reduce significativamente el tiempo de cómputo manteniendo resultados similares al K-Means tradicional, ideal para aplicaciones con restricciones de memoria o tiempo.

Agrupamiento Jerárquico Aglomerativo

En el agrupamiento jerárquico aglomerativo, la elección del método de enlace afecta significativamente los resultados:

Enlace Simple (Single)

Utiliza la distancia mínima entre puntos de diferentes clusters. Tiende a crear clusters alargados.

Enlace Completo (Complete)

Utiliza la distancia máxima. Genera clusters más compactos y de tamaño similar.

Enlace Promedio (Average)

Utiliza la distancia promedio. Ofrece un equilibrio entre los métodos anteriores.

Método de Ward

Minimiza la varianza dentro de los clusters. Suele producir grupos de tamaño similar.

Inicialización de K-Means

La inicialización de centroides en K-Means puede afectar significativamente la convergencia y calidad de los resultados:

Inicialización Aleatoria

Selecciona K puntos al azar como centroides iniciales. Simple pero puede llevar a resultados subóptimos.

K-Means++

Selecciona centroides iniciales distantes entre sí, mejorando la convergencia y resultados finales.


Múltiples Inicializaciones

Ejecuta el algoritmo varias veces con diferentes inicializaciones y selecciona el mejor resultado.

Selección de Parámetros en DBSCAN

La selección adecuada de los parámetros `eps` y `min_samples` en DBSCAN es crucial para obtener buenos resultados:

- El gráfico k-distance puede ayudar a determinar un valor apropiado para `eps`.
- `min_samples` debe ajustarse según la densidad esperada de los clusters y el nivel de ruido.
- En conjuntos con densidades variables, HDBSCAN puede ser una mejor alternativa.



Clusterización de Series Temporales

La clusterización de series temporales requiere considerar la estructura temporal de los datos:

Dynamic Time Warping (DTW)

Medida de distancia que alinea series temporales para comparar patrones similares con desfases.


Extracción de características

Transformación de series en vectores de características como tendencia, estacionalidad o autocorrelación.

Modelos específicos

Algoritmos como K-Shape diseñados específicamente para agrupar series temporales.

Time Series Clustering





Clusterización de Grafos

La clusterización de grafos, también conocida como detección de comunidades, busca identificar grupos de nodos densamente

Algoritmo de Louvain

Método basado en la optimización de la modularidad, eficiente para redes grandes.

Propagación de etiquetas

Técnica donde los nodos adoptan las etiquetas más frecuentes de sus vecinos.

Corte espectral

Utiliza los eigenvectores de la matriz laplaciana del grafo para particionar la red.

Clusterización Online

La clusterización online permite procesar datos en tiempo real, actualizando los clusters a medida que llegan nuevas observaciones:

Recepción de datos

Llegada continua de nuevas observaciones al sistema.

Actualización de modelos

Ajuste de centroides o parámetros del modelo con los nuevos datos.

Asignación a clusters

Determinación del cluster más cercano para cada nueva observación.

Reevaluación periódica


Reconsideración ocasional de la estructura completa de clusters.

Clusterización Semi-supervisada

La clusterización semi-supervisada combina elementos del aprendizaje supervisado y no supervisado, utilizando una pequeña cantidad de datos etiquetados para guiar el proceso de agrupamiento.

Esta aproximación es útil cuando se dispone de algunas etiquetas o restricciones conocidas (como pares de puntos que deben o no deben estar en el mismo cluster).

Semi-Supervised Clustering



Validación Cruzada en Clusterización

Aunque la validación cruzada tradicional no es directamente aplicable a la clusterización no supervisada, existen técnicas adaptadas:

Estabilidad de clusters

Evalúa si clusters similares aparecen en diferentes submuestras de los datos.

Validación externa

Compara los resultados con etiquetas conocidas cuando están disponibles (por ejemplo, en conjuntos de prueba).

Validación interna

Utiliza métricas como silueta o índice Davies-Bouldin para evaluar la calidad de los clusters.

Interpretación de Resultados

La interpretación de los clusters obtenidos es tan importante como el proceso técnico de agrupamiento:

-  **Caracterización de clusters**
Identificar las características distintivas de cada grupo mediante estadísticas descriptivas o visualizaciones.
-  **Validación con expertos**
Contrastar los resultados con el conocimiento de especialistas en el dominio para verificar su relevancia práctica.
-  **Aplicación a casos de uso**
Evaluar cómo los clusters identificados pueden aplicarse para resolver el problema original o generar nuevas hipótesis.

Tendencias Futuras

Deep Clustering

Integración de redes neuronales profundas con técnicas de clusterización para manejar datos complejos como imágenes o texto.

Clusterización federada

Algoritmos que permiten agrupar datos distribuidos sin necesidad de centralizar la información, preservando la privacidad.

Clusterización explicable

Desarrollo de métodos que no solo agrupen datos sino que también proporcionen explicaciones interpretables sobre las razones de cada agrupamiento.

Conclusiones

Versatilidad

La clusterización ofrece soluciones flexibles para descubrir patrones en datos no etiquetados en diversos campos.

Complementariedad

Cada algoritmo tiene fortalezas y debilidades específicas, por lo que es importante seleccionar el adecuado según el problema.

Interpretabilidad

El valor real de la clusterización está en la capacidad de interpretar y aplicar los patrones descubiertos a problemas prácticos.

La implementación de estas técnicas no sólo requiere conocer la teoría, sino también practicar con código real, evaluar métricas, ajustar parámetros y visualizar los resultados.

Live Coding

¿En qué consistirá la Demo?

Se mostrará cómo interpretar, ajustar y evaluar modelos de clusterización en distintos contextos prácticos.

1. Generar y cargar un dataset.
2. Visualización de clústeres con PCA y t-SNE
3. Evaluación con coeficiente de silueta, Davies-Bouldin y Calinski-Harabasz
4. Comparación de resultados de K-Means, DBSCAN y HDBSCAN sobre un mismo dataset
5. Ajuste de parámetros y análisis de sensibilidad
6. Clusterización aplicada a clientes, textos y series temporales (visión exploratoria)



Momento:

Time-out!



5 -10 min.





Ejercicio

Clusterizando datos reales con Python

Clusterizando datos reales con Python

Contexto: 🙌

Una empresa de e-commerce desea segmentar a sus clientes para personalizar promociones. Te entregan un conjunto de datos reales de comportamiento (frecuencia, monto, recencia de compra) y te piden implementar un modelo de clusterización.

Consigna: 📝

Implementa en Python un modelo de clusterización para agrupar clientes según sus características de compra.

Paso a paso: ⚙️

1. Carga el dataset provisto (clientes.csv)
2. Explora los datos: valores nulos, estadísticas descriptivas
3. Aplica escalado con StandardScaler
4. Prueba al menos dos algoritmos:
 - KMeans
 - DBSCAN
5. Elige el número óptimo de clusters con el método del codo (en KMeans)
6. Calcula el coeficiente de silueta para evaluar los resultados
7. Visualiza los agrupamientos con matplotlib o seaborn (PCA o t-SNE opcional)
8. Escribe una conclusión:
 - ¿Cuántos grupos se identifican?
 - ¿Qué características tienen?
 - ¿Qué modelo funcionó mejor y por qué?

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ Evaluamos agrupamientos mediante múltiples métricas
- ✓ Ajustamos parámetros para mejorar los resultados de clusterización
- ✓ Aplicamos técnicas en distintos contextos reales
- ✓ Profundizamos en métodos avanzados como HDBSCAN, espectral y fuzzy



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

