



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Técnicas de reducción dimensional- Parte II

Aprendizaje Esperado 5: Implementar un modelo predictivo utilizando técnicas de reducción dimensional utilizando python para resolver un problema.

Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?

APRENDIZAJE DE MÁQUINA
NO SUPERVISADO

1

REDUCCIÓN
DIMENSIONAL

3

TÉCNICAS DE REDUCCIÓN
DIMENSIONAL

5

CLUSTERIZACIÓN Y SUS
PRINCIPALES ALGORITMOS

ALGORITMOS DE
CLUSTERIZACIÓN

Learning Path

¿Cuáles temas trabajaremos hoy?

5.

Dominio práctico de técnicas de reducción dimensional

Exploraremos cómo ajustar, evaluar e integrar técnicas como PCA, t-SNE, UMAP y KernelPCA en flujos reales de machine learning.

Ajustes, visualización y evaluación

Selección de número de componentes, perplejidad, iteraciones

Métricas de evaluación

Técnicas avanzadas y combinación de métodos

Kernel PCA, UMAP y reducción híbrida

Casos de uso industriales y mejores prácticas

Objetivos de aprendizaje

¿Qué aprenderás?

- Ajustar hiperparámetros en t-SNE para mejorar la visualización
- Seleccionar componentes óptimos en PCA con base en varianza explicada
- Implementar técnicas avanzadas como KernelPCA y UMAP
- Combinar múltiples técnicas (PCA + t-SNE) para análisis más robustos
- Evaluar si la reducción dimensional mejora el rendimiento de un modelo predictivo

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Implementamos técnicas de reducción dimensional como PCA y t-SNE en Python
- Aplicamos preprocesamiento y escalado para asegurar resultados óptimos
- Visualizamos los datos reducidos en 2D, identificando patrones y agrupamientos
- Comparamos el uso de PCA y t-SNE según distintos contextos

Técnicas de reducción dimensional


```
cet : Bnpdnetk8scenworpapelet petcek.yot()
tet : natsos uotling.peast.euse

idl : Udp coalv5bfet.eusth2.tutil()
tentt adnexapping nrg(jaat (buc, daseas()

cet : O.ken:.upettmtt(p:2)
eppar lin.uusbing not(Unxanrc PSH. na7.xor6tc()

rrun[ : cbeltreeb.soaik()
thi fmg ausnans Retli; seccb ((bmt).sum6ts()
```



Implementación Práctica

A continuación, veremos cómo implementar estas técnicas en proyectos reales de ciencia de datos.

Flujo de Trabajo Recomendado



Preparación de Datos

Normalización

Escala los datos para que todas las variables tengan media 0 y desviación estándar 1, lo cual es crucial para PCA.

```
from sklearn.preprocessing import  
StandardScaler  
scaler = StandardScaler()  
X_scaled = scaler.fit_transform(X)
```

Manejo de Valores Faltantes


Imputa o elimina valores faltantes antes de aplicar técnicas de reducción dimensional.

```
from sklearn.impute import  
SimpleImputer  
imputer = SimpleImputer(strategy='mean')  
X_imputed = imputer.fit_transform(X)
```

Selección del Número de Componentes en PCA

Una decisión crucial al aplicar PCA es determinar cuántos componentes principales conservar. Existen varios métodos para tomar esta decisión:

- Varianza explicada acumulada (ej. conservar componentes hasta explicar el 95% de la varianza)
- Regla del codo (observar dónde la varianza explicada adicional se estabiliza)
- Criterios basados en el problema específico



Código para Selección de Componentes

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA

# Aplicar PCA
pca = PCA()
pca.fit(X_scaled)


# Calcular varianza explicada acumulada
cumsum = np.cumsum(pca.explained_variance_ratio_)

# Visualizar
plt.figure(figsize=(10, 6))
plt.plot(cumsum, 'bo-')
plt.grid(True)
plt.xlabel('Número de Componentes')
plt.ylabel('Varianza Explicada Acumulada')
plt.axhline(y=0.95, color='r', linestyle='--')
plt.title('Varianza Explicada vs. Número de Componentes')
plt.show()
```

Ajuste de Hiperparámetros en t-SNE

El rendimiento de t-SNE depende en gran medida de sus hiperparámetros. Es recomendable probar diferentes valores para encontrar la mejor visualización:

- Perplejidad: prueba valores entre 5 y 50
- Número de iteraciones: generalmente 1000-2000 son suficientes
- Tasa de aprendizaje: el valor predeterminado suele funcionar bien, pero puede ajustarse



Código para Experimentar con t-SNE

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.manifold import TSNE

# Lista de valores de perplejidad para probar
perplexities = [5, 30, 50, 100]

# Crear subplots
fig, axes = plt.subplots(2, 2, figsize=(15, 15))
axes = axes.flatten()

# Aplicar t-SNE con diferentes perplejidades
for i, perplexity in enumerate(perplexities):
    tsne = TSNE(n_components=2, perplexity=perplexity, n_iter=1000, random_state=42)
    X_tsne = tsne.fit_transform(X_scaled)

    # Visualizar
    axes[i].scatter(X_tsne[:, 0], X_tsne[:, 1], c=y, cmap='viridis')
    axes[i].set_title(f'Perplejidad: {perplexity}')
    axes[i].set_xlabel('t-SNE 1')
    axes[i].set_ylabel('t-SNE 2')

plt.tight_layout()
plt.show()
```

Visualización de Resultados

1

Gráficos de Dispersión

Visualiza los datos reducidos en un espacio 2D o 3D para identificar patrones y agrupaciones.

2

Coloración por Clases

Si tienes etiquetas, colorea los puntos según su clase para evaluar la separabilidad.

3

Animaciones

Para datos temporales, considera crear animaciones que muestren cómo evolucionan las estructuras.

Evaluación de la Reducción Dimensional



Varianza Explicada (PCA)

Mide qué porcentaje de la varianza original se conserva en los componentes seleccionados.



Rendimiento de Modelos Posteriores

Evalúa si los modelos entrenados con datos reducidos mantienen un buen rendimiento.




Interpretabilidad Visual

Verifica si las visualizaciones revelan patrones significativos y útiles para tu análisis.

Casos de Uso Específicos


Facial Recognition System Using Dimensionality Reduction



Reconocimiento Facial

PCA se utiliza para extraer "eigenfaces" que capturan las características principales de los rostros.


Gene Expression Data (t-SNE)



Análisis Genómico

t-SNE ayuda a visualizar datos de expresión génica para identificar tipos de células y patrones de expresión.

Document Clustering using Dimensionality Reduction



Análisis de Texto

Ambas técnicas se usan para visualizar similitudes entre documentos o palabras en espacios vectoriales de alta dimensión.

Técnicas Avanzadas

Kernel PCA


Extensión no lineal de PCA que utiliza el "truco del kernel" para capturar relaciones no lineales.

```
from sklearn.decomposition import KernelPCA
kPCA = KernelPCA(n_components=2, kernel='rbf')
X_kPCA = kPCA.fit_transform(X_scaled)
```

UMAP

Uniform Manifold Approximation and Projection, una alternativa más rápida a t-SNE que preserva mejor la estructura global.

```
import umap
reducer = umap.UMAP()
X_umap = reducer.fit_transform(X_scaled)
```



Combinación de Técnicas

PCA como Preprocesamiento

Aplica PCA primero para reducir el ruido y la dimensionalidad.

t-SNE para Visualización

Usa t-SNE en los datos preprocesados para obtener visualizaciones más claras.

Modelado con Datos Reducidos

Entrena modelos de machine learning utilizando las características reducidas.

Código para Combinar PCA y t-SNE

```
from sklearn.decomposition import PCAfrom sklearn.manifold import TSNEimport matplotlib.pyplot as plt# Paso 1: Aplicar PCA para reducir a 50
dimensionespca = PCA(n_components=50)X_pca = pca.fit_transform(X_scaled)# Paso 2: Aplicar t-SNE a los resultados de PCA
tsne = TSNE(n_components=2, perplexity=30, n_iter=1000)X_tsne = tsne.fit_transform(X_pca)# Visualizar resultados
plt.figure(figsize=(10, 8))plt.scatter(X_tsne[:, 0], X_tsne[:, 1], c=y, cmap='viridis')plt.colorbar()plt.title('Visualización PCA + t-SNE')plt.xlabel('t-SNE
1')plt.ylabel('t-SNE 2')plt.show()
```

Errores Comunes a Evitar

No Escalar los Datos

Especialmente en PCA, la falta de escalado puede hacer que variables con mayor magnitud dominen los resultados.

Sobreinterpretar t-SNE

t-SNE puede distorsionar distancias globales y tamaños de clusters, lo que puede llevar a conclusiones erróneas.

Ignorar la Aleatoriedad

t-SNE tiene componentes aleatorios, por lo que es importante fijar una semilla para reproducibilidad.

Aplicar Reducción sin Exploración Previa

Es crucial entender tus datos antes de aplicar técnicas de reducción dimensional.

Mejores Prácticas



Exploración Previa

Realiza un análisis exploratorio detallado antes de aplicar técnicas de reducción dimensional.



Experimentación

Prueba diferentes técnicas y parámetros para encontrar la mejor representación para tus datos.



Validación

Verifica que la reducción dimensional preserve la información relevante para tu análisis.



Documentación

Documenta tus decisiones y resultados para facilitar la reproducibilidad y comunicación.


Recursos Adicionales

Bibliotecas de Python

- scikit-learn: Implementaciones de PCA, t-SNE y otras técnicas
- UMAP-learn: Implementación de UMAP
- Matplotlib y Seaborn: Visualización de resultados
- Plotly: Visualizaciones interactivas

Recursos de Aprendizaje

- Documentación oficial de scikit-learn
- Artículo original de t-SNE por Laurens van der Maaten y Geoffrey Hinton
- Tutoriales en Towards Data Science y Medium
- Cursos en plataformas como Coursera y edX



Conclusiones

Las técnicas de reducción dimensional, como PCA y t-SNE, son herramientas poderosas para simplificar datos complejos y mejorar la eficiencia de los procesos analíticos. Aplicarlas correctamente permite obtener representaciones más compactas, sin sacrificar el valor informativo esencial.

Comparación Final: PCA vs t-SNE



PCA

Ideal para compresión y modelado supervisado. Rápido, lineal y preserva la varianza global. Excelente como paso de preprocesamiento.



t-SNE

Ofrece ventajas inigualables en la visualización de agrupaciones y relaciones no evidentes. Mejor para exploración visual y descubrimiento de patrones.


Conocer cuándo usar cada una es clave para lograr interpretaciones valiosas.

Beneficios del Dominio de Estas Técnicas

Dominar estas técnicas brinda una ventaja significativa en proyectos de ciencia de datos y aprendizaje automático, especialmente cuando se trabaja con datasets amplios y de alta dimensión.



**Exploratory
Analysis**



```
graph TD; A[Exploratory Analysis] --> B[Dimensionality Reduction]; B --> C[Cross-Validation];
```

**Dimensionality
Reduction**

**Cross-
Validation**

Recomendación Final



Se recomienda combinar estas herramientas con un análisis exploratorio previo y una validación cruzada posterior para asegurar que la transformación no distorsione la información crítica.


Aplicaciones en la Industria

Salud

Análisis de datos médicos, imágenes diagnósticas y descubrimiento de biomarcadores.

Investigación

Análisis de datos científicos complejos en física, química y biología.



Finanzas

Detección de fraudes, análisis de riesgos y segmentación de clientes.

Retail

Análisis de comportamiento de compra y sistemas de recomendación.

Manufactura

Control de calidad, mantenimiento predictivo y optimización de procesos.

Tendencias Futuras

Técnicas Híbridas

Combinación de múltiples métodos de reducción dimensional para aprovechar las fortalezas de cada uno.

Escalabilidad

Algoritmos más eficientes para manejar conjuntos de datos extremadamente grandes y de alta dimensión.

1

2

3

4

Interpretabilidad Mejorada

Desarrollo de métodos que faciliten la interpretación de las dimensiones reducidas en términos de las variables originales.

Integración con Deep Learning

Mayor uso de autoencoders y otras técnicas de aprendizaje profundo para reducción de dimensionalidad no lineal.

Ejercicios Prácticos Recomendados

1

Comparación de Técnicas

Aplica PCA, t-SNE y UMAP al mismo conjunto de datos y compara los resultados visualmente.

2

Optimización de Hiperparámetros

Experimenta con diferentes valores de perplejidad en t-SNE y observa cómo afectan las visualizaciones.

3

Preprocesamiento

Evalúa el impacto de diferentes técnicas de escalado en los resultados de PCA.

4

Aplicación Real

Utiliza reducción dimensional como paso previo a un algoritmo de clasificación y mide la mejora en rendimiento.

Preguntas Frecuentes

¿Cuántos componentes debo conservar en PCA?

Depende del objetivo. Para visualización, 2-3 componentes. Para preservar información, suficientes para explicar el 80-95% de la varianza.

¿Por qué t-SNE es lento con grandes conjuntos de datos?

t-SNE calcula similitudes entre todos los pares de puntos, lo que tiene complejidad cuadrática. Para datasets grandes, considera aplicar PCA primero o usar implementaciones optimizadas.

¿Puedo usar t-SNE para proyectar nuevos datos?

No directamente. t-SNE no aprende una transformación que pueda aplicarse a nuevos datos. Para esto, considera técnicas como PCA o autoencoders.

Glosario de Términos

Término	Definición
Dimensionalidad	Número de variables o características en un conjunto de datos.
Componente Principal	Nueva variable creada por PCA que representa una dirección de máxima varianza.
Perplejidad	Hiperparámetro de t-SNE que controla el equilibrio entre estructuras locales y globales.
Varianza Explicada	Proporción de la variabilidad total de los datos que es capturada por un componente o conjunto de componentes.
Embedding	Representación de datos en un espacio de menor dimensión.

Consejos para Presentar Resultados



Simplifica

Evita gráficos sobrecargados. Usa colores y formas para destacar patrones importantes.



Contextualiza

Explica qué representan los ejes o clusters en términos del problema original.



Compara

Muestra visualizaciones antes y después de la reducción dimensional para evidenciar su valor.



Interactividad

Cuando sea posible, usa herramientas que permitan explorar los datos de forma interactiva.

Casos de Estudio

Análisis de Imágenes Médicas

Uso de PCA para reducir la dimensionalidad de imágenes de resonancia magnética, facilitando la detección de patrones asociados con enfermedades neurológicas.

Análisis de Sentimientos

Aplicación de t-SNE para visualizar embeddings de palabras en análisis de sentimientos, revelando agrupaciones semánticas no evidentes con otros métodos.

Segmentación de Clientes

Combinación de PCA y clustering para identificar segmentos de clientes basados en comportamiento de compra y datos demográficos.

Reflexiones Finales

La reducción de dimensionalidad no es solo una técnica para mejorar la eficiencia computacional, sino una herramienta fundamental para descubrir patrones ocultos y estructuras significativas en datos complejos.

El verdadero arte está en seleccionar la técnica adecuada para cada problema específico y en interpretar correctamente los resultados obtenidos.





Live Coding

¿En qué consistirá la Demo?

Se mostrará cómo combinar PCA y t-SNE, ajustar hiperparámetros en t-SNE y aplicar UMAP como alternativa moderna.

1. Preprocesamiento y escalado del dataset
2. Aplicación de PCA para reducción a 50 dimensiones
3. Aplicación de t-SNE sobre los componentes de PCA
4. Visualización comparativa: t-SNE con distintas perplejidades
5. Aplicación de UMAP como técnica alternativa
6. Discusión guiada: ¿Cuál técnica mostró mejor estructura?



Momento:

Time-out!



5 -10 min.





Ejercicio

PCA, t-SNE y UMAP en acción

PCA, t-SNE y UMAP en acción

Contexto: 🙌

Cuentas con un conjunto de datos con muchas variables (más de 30). Quieres explorar visualmente si existen grupos, anomalías o patrones que puedan ayudarte a decidir estrategias de segmentación o análisis predictivo. Para esto, vas a aplicar diferentes técnicas de reducción dimensional y observar cuál permite entender mejor la estructura del dataset.

Consigna: 📝

Aplica y compara al menos tres técnicas de reducción dimensional para visualizar los datos. Evalúa los resultados y argumenta cuál técnica resulta más útil según el tipo de información que quieres extraer.

Paso a paso: ⚙️

1. Carga un dataset multivariable (por ejemplo: digits, wine, cancer o cualquier otro que tenga muchas columnas).
2. Preprocesa (limpieza, normalización con StandardScaler).
3. Aplica PCA, elige 2 componentes y genera un scatter plot.
4. Aplica t-SNE, probando al menos dos valores distintos de perplexidad.
5. Aplica UMAP y visualiza los datos.
6. Compara las visualizaciones obtenidas:
 - ¿Cuál muestra agrupamientos más claros?
 - ¿Qué técnica fue más sensible al cambio de parámetros?
7. Escribe una conclusión razonada con tu elección preferida para este dataset.

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Ajustamos y evaluamos técnicas de reducción dimensional en profundidad**
- ✓ **Comparamos PCA, t-SNE y UMAP en distintos escenarios**
- ✓ **Visualizamos el impacto de hiperparámetros como la perplejidad en t-SNE**
- ✓ **Aprendimos a combinar técnicas para obtener mejores resultados**
- ✓ **Conectamos estas técnicas con la mejora de modelos predictivos reales**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

