



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Deep learning- Parte I

Aprendizaje Esperado 2: Aplicar el concepto de deep learning reconociendo sus principales usos, arquitecturas y frameworks de trabajo para su implementación.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**




Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?





Objetivos de aprendizaje

¿Qué aprenderás?



- Comprender el concepto de Deep Learning y su lugar dentro de IA y ML.
- Reconocer las características clave que diferencian DL de ML tradicional.
- Identificar los principales usos y aplicaciones del Deep Learning.
- Conocer las arquitecturas más utilizadas y sus características.
- Diferenciar los frameworks principales para implementar modelos de Deep Learning.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Analizamos el ciclo completo de entrenamiento de una red neuronal artificial.
- Comprendimos los pasos de forward pass, cálculo de error y backpropagation.
- Estudiamos el descenso de gradiente y sus variantes (batch, mini-batch y stochastic).
- Vimos el impacto de los hiperparámetros (learning rate, batch size, épocas) y técnicas de regularización.

Deep learning



Deep Learning: Fundamentos y Aplicaciones

El Deep Learning, o aprendizaje profundo, ha revolucionado el campo de la inteligencia artificial en los últimos años. Gracias a su capacidad para aprender representaciones jerárquicas directamente desde los datos, ha permitido avances notables en áreas como el reconocimiento de voz, la visión artificial, la generación de texto y la traducción automática.

¿Qué es Deep Learning?

El Deep Learning es un subcampo del Machine Learning que utiliza redes neuronales artificiales con múltiples capas (deep neural networks) para modelar datos con altos niveles de abstracción. Estas redes aprenden de manera jerárquica, es decir, extraen características simples en capas bajas y representaciones más complejas en capas superiores.



Características principales del Deep Learning

Redes neuronales de múltiples capas

Arquitecturas profundas que permiten modelar relaciones altamente complejas y no lineales entre datos.

Aprendizaje automático

Capacidad de aprender a partir de grandes volúmenes de datos sin intervención humana.

Recursos computacionales

Requiere altos recursos de procesamiento, generalmente utilizando GPUs para acelerar el entrenamiento.

Técnicas avanzadas

Usa funciones de activación no lineales y técnicas de regularización avanzadas para mejorar el rendimiento.

Ventajas del Deep Learning

Una de las claves del Deep Learning es su capacidad de trabajar con datos no estructurados como imágenes, audio o texto, sin necesidad de ingeniería de características manual.


A través del entrenamiento con grandes volúmenes de datos y el uso de unidades de procesamiento gráfico (GPU), las redes profundas pueden aprender tareas específicas con alto rendimiento.

Diferencias entre IA, ML y DL

Estos tres conceptos están interrelacionados, pero representan niveles distintos de abstracción:


Concepto	Definición breve	Ejemplo
Inteligencia Artificial	Ciencia que busca crear sistemas que imiten la inteligencia humana	Sistemas expertos, asistentes virtuales
Machine Learning	Subconjunto de IA que aprende de los datos sin ser explícitamente programado	Árboles de decisión, regresión
Deep Learning	Rama del ML que utiliza redes neuronales profundas	Reconocimiento facial, GPT, DALL·E

Relación jerárquica: IA, ML y DL



IA es el campo más amplio, ML es una técnica dentro de IA, y DL es una técnica avanzada de ML.

Diferencias clave entre ML y DL



- El ML tradicional requiere ingeniería de características manual; el DL aprende automáticamente desde los datos.
- DL generalmente necesita más datos y recursos computacionales que ML.
- DL puede trabajar directamente con datos no estructurados.

Elección de técnicas según el problema

Comprender estas diferencias permite elegir la técnica adecuada según el tipo de problema, la cantidad de datos disponible y la capacidad de cómputo.

1

ML Tradicional

- Datos estructurados
- Conjuntos pequeños
- Recursos limitados
- Interpretabilidad importante

2

Deep Learning

- Datos no estructurados
- Grandes volúmenes
- Alta capacidad computacional
- Precisión sobre interpretabilidad



Aplicaciones del Deep Learning

El Deep Learning se ha aplicado con éxito en múltiples dominios gracias a su precisión y capacidad de generalización.


Visión por computadora

Aplicaciones principales:

- Detección de objetos
- Clasificación de imágenes
- Segmentación semántica
- Reconocimiento facial



Procesamiento de lenguaje natural



NLP Insights

Natural Language Processing System

Aplicaciones principales:

- Traducción automática
- Análisis de sentimientos
- Generación de texto
- Chatbots avanzados

Reconocimiento de voz y audio



Asistentes virtuales

Sistemas como Siri, Alexa y Google Assistant que interpretan comandos de voz.



Subtitulado automático

Transcripción de audio a texto en tiempo real para videos y contenido multimedia.



Análisis de audio

Identificación de música, detección de emociones en voz y clasificación de sonidos.

Aplicaciones en medicina

Principales

usos:

- Diagnóstico por imagen
- Predicción de enfermedades
- Análisis genético
- Descubrimiento de fármacos



Aplicaciones en automoción



Conducción autónoma

Sistemas que permiten a los vehículos navegar sin intervención humana mediante el análisis de su entorno.



Detección de peatones

Reconocimiento de personas y obstáculos en la vía para prevenir accidentes.



Mantenimiento predictivo

Anticipación de fallos mecánicos mediante el análisis de datos de sensores.

Diseño de redes según el tipo de datos

La clave del éxito de estas aplicaciones está en el diseño de redes adecuadas para cada tipo de dato.



Imágenes

Redes Convolucionales (CNN)

T

Texto

RNN, LSTM o Transformers




Audio

RNN, LSTM o Transformers

Modelos preentrenados

El uso de modelos preentrenados (como BERT, GPT, ResNet) ha facilitado la transferencia del aprendizaje, reduciendo el tiempo de entrenamiento y mejorando el rendimiento en tareas específicas.



Arquitecturas de Redes Neuronales

Existen diversas arquitecturas dentro del Deep Learning, cada una con ventajas según el tipo de dato o tarea a resolver:

Arquitectura	Aplicación principal	Características clave
Redes densas (DNN)	Clasificación y regresión genérica	Totalmente conectadas, versátiles
CNN	Visión por computadora	Detectan patrones espaciales locales
RNN / LSTM	Procesamiento secuencial (texto, audio)	Memoria de secuencia, manejo de contexto
Autoencoders	Compresión y reducción de dimensionalidad	Aprendizaje no supervisado
Transformers	NLP y visión moderna	Paralelismo, atención, transfer learning

Redes Neuronales Densas (DNN)

Las redes neuronales densas o fully connected son la arquitectura más básica del Deep Learning. Cada neurona está conectada con todas las neuronas de la capa anterior.

- Versátiles para problemas generales
- Buenas para datos tabulares
- Base para entender otras arquitecturas



Redes Neuronales Convolucionales (CNN)


Características principales:

- Funcionan bien con imágenes
- Utilizan filtros que detectan bordes, formas y patrones
- Reducen parámetros mediante convoluciones
- Invariantes a la traslación

Redes Neuronales Recurrentes (RNN/LSTM)

Características principales:

- Adecuadas para datos secuenciales
- Mantienen memoria del contexto
- LSTM mejora el problema de gradientes que desaparecen
- Pueden tener problemas con secuencias largas





Autoencoders

1

Codificador

Comprime la información en un espacio latente de menor dimensión

2

Espacio latente

Representación comprimida de los datos originales

3

Decodificador


Reconstruye los datos originales a partir del espacio latente

Transformers

Los transformers han revolucionado el procesamiento de lenguaje natural y están expandiéndose a la visión por computadora.

Características clave:

- Mecanismo de atención
- Procesamiento paralelo
- Base de modelos como GPT y BERT



Elección de arquitectura

Cada arquitectura tiene ventajas y limitaciones. La elección depende del problema, del tamaño del conjunto de datos y del tiempo de entrenamiento disponible.

Tipo de datos

Imágenes (CNN), secuencias (RNN/Transformer), tabulares (DNN)

Volumen de datos

Arquitecturas más complejas requieren más datos para entrenar

Recursos disponibles

Tiempo de entrenamiento, memoria, capacidad de procesamiento

Complejidad del problema

Problemas más complejos pueden requerir arquitecturas híbridas

Frameworks para Deep Learning

Los frameworks son bibliotecas de programación que facilitan la implementación de modelos de Deep Learning. Los más utilizados actualmente son:

Framework	Lenguaje base	Características principales
TensorFlow	Python / C++	Soporta producción, escalable, mantiene Google, alto rendimiento
Keras	Python	API de alto nivel sobre TensorFlow, muy fácil de usar
PyTorch	Python / C++	Flexible, dinámico, preferido en investigación

[illegible]

- Desarrollado por Google
- Muy eficiente para desplegar modelos en producción (web, móviles, edge)
- Tiene herramientas como TensorBoard para visualización
- Amplia comunidad y documentación

Keras

Características principales:

- Orientado a principiantes
- Más legible y amigable que TensorFlow puro
- Ideal para prototipado rápido
- Ahora integrado con TensorFlow



PyTorch



Características principales:

- Desarrollado por Facebook (Meta)
- Muy utilizado en entornos de investigación
- Permite una depuración más intuitiva gracias a su naturaleza dinámica
- Creciente adopción en la industria

Elección del framework

1

Prototipado rápido

Keras es ideal por su simplicidad y facilidad de uso para principiantes.

2

Investigación

PyTorch ofrece mayor flexibilidad y control para experimentación.

3

Producción

TensorFlow se destaca por su robustez y herramientas de despliegue.

La elección del framework depende del objetivo: si se busca rapidez y simplicidad, Keras es ideal; si se necesita control y flexibilidad, PyTorch es la opción preferida; y para producción robusta, TensorFlow se destaca.

Live Coding

¿En qué consistirá la Demo?

Exploraremos de forma conceptual cómo se diseñan y seleccionan arquitecturas de Deep Learning en función del tipo de datos y problema.

1. Analizar la relación jerárquica entre IA, ML y DL.
2. Ver ejemplos de datos estructurados vs no estructurados y cuándo usar DL.
3. Comparar arquitecturas (DNN, CNN, RNN, Transformers) y su aplicación según el tipo de datos.
4. Entender el impacto de los modelos preentrenados y el aprendizaje por transferencia.
5. Presentar los principales frameworks de trabajo (TensorFlow, Keras, PyTorch) y cuándo conviene usar cada uno.



Momento:

Time-out!



5 -10 min.





Ejercicio N° 1

Investiga y explica el ecosistema del Deep Learning

Investiga y explica el ecosistema del Deep Learning

Contexto: 🙌

Vamos a realizar una investigación conceptual sobre los usos y arquitecturas del Deep Learning.

Consigna: 📝

1. Define qué es el Deep Learning y en qué se diferencia de ML tradicional.
2. Investiga tres áreas de aplicación (ej: visión por computadora, procesamiento de lenguaje natural, audio, medicina, automoción).
3. Explica al menos tres arquitecturas de Deep Learning y el tipo de problemas que resuelven.
4. Describe qué es el aprendizaje por transferencia y por qué es útil.
5. Investiga los frameworks principales y cuándo elegir TensorFlow, Keras o PyTorch.

Paso a paso: ⚙️

1. Busca fuentes confiables (manuales, papers o documentación oficial).
2. Prepara un resumen claro de cada punto con ejemplos de aplicaciones.
3. Relaciona los conceptos con beneficios y limitaciones.

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ Entendimos el concepto y las ventajas del Deep Learning.
- ✓ Vimos las diferencias clave con el ML tradicional.
- ✓ Identificamos las áreas de aplicación más importantes.
- ✓ Conocimos las arquitecturas más utilizadas y sus usos.
- ✓ Exploramos los principales frameworks para implementar DL.



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

