



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Deep learning- Parte II

Aprendizaje Esperado 2: Aplicar el concepto de deep learning reconociendo sus principales usos, arquitecturas y frameworks de trabajo para su implementación.


Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

1.

Profundización en el
entrenamiento, desafíos y
tendencias del Deep Learning

Abordaremos el ciclo completo de entrenamiento de modelos de Deep Learning, los principales desafíos, técnicas para mejorar el rendimiento, y las tendencias emergentes en el campo.

Proceso de entrenamiento
y desafíos del Deep
Learning

Preparación de datos y
diseño de la arquitectura.

Entrenamiento, evaluación
y despliegue de modelos.

Técnicas avanzadas y
tendencias actuales

Regularización, optimización
de hiperparámetros y
Transfer Learning.

Redes generativas, modelos
de difusión y aprendizaje por
refuerzo profundo.



Objetivos de aprendizaje

¿Qué aprenderás?



- Comprender el ciclo completo de entrenamiento de un modelo de Deep Learning.
- Conocer los desafíos actuales y técnicas para mitigarlos (regularización, hiperparámetros).
- Identificar métodos avanzados como Transfer Learning, redes generativas y modelos de difusión.
- Reconocer el impacto de la ética y el impacto social en el desarrollo de DL.
- Analizar tendencias emergentes y el futuro del Deep Learning.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Definimos qué es el Deep Learning y su relación con IA y Machine Learning.
- Analizamos las ventajas y diferencias frente al ML tradicional.
- Identificamos los principales usos y aplicaciones (visión, NLP, audio, medicina, automoción).
- Exploramos las arquitecturas más comunes (DNN, CNN, RNN/LSTM, Autoencoders, Transformers).

Deep learning

Proceso de entrenamiento en Deep Learning

Preparación de datos

Recopilación, limpieza y preprocesamiento de los datos de entrenamiento.

Diseño de la arquitectura

Selección del tipo de red y configuración de capas según el problema.

Entrenamiento

Ajuste de pesos mediante algoritmos de optimización y backpropagation.

Evaluación

Medición del rendimiento con datos de validación y prueba.

Despliegue

Implementación del modelo en un entorno de producción.

Preparación de datos

Pasos clave:

1. Recopilación de datos relevantes
2. Limpieza y manejo de valores faltantes
3. Normalización y estandarización
4. Aumento de datos (data augmentation)
5. División en conjuntos de entrenamiento, validación y prueba



Diseño de la arquitectura

Selección del tipo de red

CNN, RNN, Transformer según el tipo de datos y problema

Número de capas

Determina la profundidad y capacidad de abstracción

Neuronas por capa

Afecta la capacidad de representación y el riesgo de sobreajuste

Funciones de activación

ReLU, Sigmoid, Tanh según la capa y el objetivo

Entrenamiento del modelo

Componentes clave:

- Función de pérdida (loss function)
- Algoritmo de optimización (SGD, Adam)
- Tasa de aprendizaje (learning rate)
- Tamaño de lote (batch size)
- Número de épocas (epochs)

Evaluación del modelo

Métricas de clasificación

Precisión, recall, F1-score, matriz de confusión

Métricas de regresión

MSE, MAE, R^2 , RMSE

Validación cruzada

K-fold para evaluar la robustez del modelo

Curvas de aprendizaje

Análisis de sobreajuste y subajuste

Despliegue del modelo

Opciones de despliegue:

- Servidores en la nube (AWS, GCP, Azure)
- Dispositivos móviles (TensorFlow Lite)
- Navegadores web (TensorFlow.js)
- Dispositivos edge (NVIDIA Jetson)



Desafíos del Deep Learning

Necesidad de datos

Requiere grandes volúmenes de datos etiquetados para entrenar modelos efectivos.

Recursos computacionales

El entrenamiento demanda GPUs potentes y puede ser costoso en tiempo y energía.


Interpretabilidad

Los modelos funcionan como "cajas negras" difíciles de explicar, lo que limita su uso en áreas sensibles.

Sobreajuste

Riesgo de memorizar los datos de entrenamiento sin generalizar correctamente.

Técnicas para mejorar el rendimiento



Regularización:

- Dropout: desactiva aleatoriamente neuronas durante el entrenamiento
- L1/L2: penaliza pesos grandes
- Batch Normalization: normaliza activaciones
- Data Augmentation: genera variaciones de los datos

Optimización de hiperparámetros



Grid Search

Prueba todas las combinaciones posibles de hiperparámetros en una cuadrícula predefinida.



Random Search

Prueba combinaciones aleatorias, más eficiente que Grid Search para espacios grandes.



Optimización Bayesiana


Utiliza resultados previos para guiar la búsqueda hacia regiones prometedoras.

Transfer Learning

El Transfer Learning permite aprovechar modelos preentrenados en grandes conjuntos de datos para aplicarlos a problemas específicos con menos datos disponibles.

Ventajas:

- Reduce tiempo de entrenamiento
- Requiere menos datos
- Mejora rendimiento en tareas específicas



Modelos preentrenados populares

1

Visión

- ResNet
- VGG
- Inception
- EfficientNet

2

NLP

- BERT
- GPT
- T5
- RoBERTa

3

Audio


- Wav2Vec
- Whisper
- HuBERT

Aprendizaje por refuerzo profundo

Combinación de Deep Learning con Reinforcement Learning donde un agente aprende a tomar decisiones mediante prueba y error.

Aplicaciones:

- Juegos (AlphaGo, Atari)
- Robótica
- Sistemas de recomendación
- Optimización de recursos



Redes generativas



Generador

Crea datos sintéticos a partir de ruido aleatorio



Discriminador

Distingue entre datos reales y generados



Equilibrio

Competencia que mejora ambas redes

Aplicaciones de redes generativas




Generación de arte

Creación de imágenes artísticas originales basadas en estilos aprendidos.



Rostros sintéticos

Generación de rostros humanos que no existen en la realidad.



Transformación de imágenes


Conversión entre dominios visuales (día a noche, verano a invierno).

Modelos de difusión

Los modelos de difusión son un tipo de modelo generativo que ha ganado popularidad recientemente, especialmente para la generación de imágenes.

Ejemplos:

- DALL-E
- Stable Diffusion
- Midjourney



Ética en Deep Learning

Sesgos

Los modelos pueden perpetuar o amplificar sesgos presentes en los datos de entrenamiento.

Privacidad

Riesgos asociados al uso de datos personales para entrenar modelos.

Transparencia

Dificultad para explicar decisiones tomadas por modelos complejos.

Impacto social

Efectos en el empleo, la desinformación y la autonomía humana.


Futuro del Deep Learning



Tendencias emergentes:

- Modelos más eficientes energéticamente
- Aprendizaje con menos datos (few-shot learning)
- Modelos multimodales
- Sistemas auto-supervisados
- Integración con conocimiento simbólico

Modelos multimodales



Aprendizaje auto-supervisado

Características:

- Aprende de datos no etiquetados
- Genera sus propias tareas de supervisión
- Reduce la necesidad de anotaciones manuales
- Base de modelos como BERT y GPT



Integración con conocimiento simbólico

1

Deep Learning

- Aprendizaje desde datos
- Patrones estadísticos
- Representaciones distribuidas

2

IA Simbólica


- Reglas lógicas
- Conocimiento estructurado
- Razonamiento explícito

3

Sistemas híbridos

- Combina ambos enfoques
- Mayor interpretabilidad
- Razonamiento mejorado

Computación neuromórfica



La computación neuromórfica busca imitar la estructura y funcionamiento del cerebro humano en hardware especializado.

Ventajas:

- Mayor eficiencia energética
- Procesamiento en tiempo real
- Aprendizaje continuo
- Tolerancia a fallos

Edge AI y dispositivos inteligentes



Dispositivos móviles

Reconocimiento facial, asistentes de voz y procesamiento de imágenes directamente en el teléfono.



IoT

Sensores inteligentes que procesan datos localmente sin necesidad de enviarlos a la nube.



Robótica

Robots autónomos con capacidad de toma de decisiones en tiempo real sin conexión constante.

Eficiencia computacional

Técnicas para reducir recursos:

- Cuantización: reducir precisión numérica
- Poda: eliminar conexiones poco importantes
- Destilación: transferir conocimiento a modelos más pequeños
- Arquitecturas eficientes: MobileNet, EfficientNet



Impacto ambiental del Deep Learning

300

Toneladas de CO₂

Emisiones aproximadas del entrenamiento
de un modelo grande de lenguaje.

85%

Reducción posible

Potencial de disminución de emisiones con
técnicas de eficiencia energética.

1.5M

kWh de energía

Consumo energético del entrenamiento de
modelos de gran escala.


Democratización del Deep Learning



Factores que contribuyen:

- Herramientas de bajo código/sin código
- Plataformas cloud accesibles
- Comunidades open source
- Cursos y recursos educativos gratuitos
- APIs preentrenadas

Herramientas de AutoML



Campos emergentes en Deep Learning

Aprendizaje federado

Entrenamiento distribuido que preserva la privacidad de los datos.

Aprendizaje continuo

Modelos que siguen aprendiendo después del despliegue sin olvidar lo aprendido.

Redes neuronales bayesianas

Incorporan incertidumbre en las predicciones para mayor robustez.

Neuroevolución

Uso de algoritmos genéticos para optimizar arquitecturas de redes neuronales.

Aprendizaje federado

Ventajas:

- Preserva la privacidad de los datos
- Reduce transferencia de información
- Permite colaboración entre organizaciones
- Cumple con regulaciones como GDPR



Aprendizaje continuo



Retos y oportunidades futuras



Causalidad

Desarrollar modelos que entiendan relaciones causales, no solo correlaciones.



Creatividad

Sistemas capaces de generar ideas verdaderamente originales, no solo imitaciones.




Robustez

Modelos resistentes a ataques adversarios y cambios en la distribución de datos.

Conclusión

El Deep Learning ha marcado un antes y un después en el campo de la inteligencia artificial. En este manual hemos explorado sus fundamentos, sus diferencias con otros enfoques, las aplicaciones más relevantes y las arquitecturas que lo sustentan. También conocimos los frameworks más importantes que facilitan su implementación práctica.

Comprender estos elementos es esencial para diseñar soluciones modernas, efectivas y escalables, ya sea en la industria, la investigación o el desarrollo personal de proyectos. En futuras lecciones se profundizará en su implementación con ejemplos reales y ejercicios prácticos.



Live Coding

¿En qué consistirá la Demo?

Analizaremos conceptualmente el entrenamiento de un modelo de Deep Learning, las técnicas para mejorar su rendimiento y las tendencias emergentes.

1. Técnicas de regularización: dropout, L1/L2, batch normalization, data augmentation.
2. Optimización de hiperparámetros: grid search, random search y optimización bayesiana.
3. Transfer Learning y modelos preentrenados más usados (ResNet, BERT, GPT).
4. Redes generativas y modelos de difusión (GAN, Stable Diffusion, DALL·E).
5. Futuro del DL: aprendizaje federado, multimodal y auto-supervisado.



Momento:

Time-out!



5 -10 min.





Ejercicio N° 1

Investiga y explica las técnicas y tendencias del Deep Learning

Investiga y explica las técnicas y tendencias del Deep Learning

Contexto: 🙌

Queremos reforzar el entendimiento de las técnicas avanzadas y las tendencias más importantes en Deep Learning.

Consigna: 📝

1. Describe el ciclo de entrenamiento de un modelo de Deep Learning.
2. Investiga dos técnicas de regularización y explica su propósito.
3. Explica en qué consiste el Transfer Learning y da ejemplos de modelos preentrenados.
4. Investiga qué son las redes generativas y menciona al menos un modelo de difusión actual.
5. Menciona dos tendencias emergentes en Deep Learning (ej. aprendizaje federado, auto-supervisado, modelos multimodales).

Paso a paso: ⚙️

1. Revisa fuentes confiables (manuales, artículos, documentación).
2. Resume el propósito de cada técnica y tendencia.
3. Relaciona los conceptos con sus aplicaciones y beneficios.

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ **Profundizamos en el entrenamiento, evaluación y despliegue de modelos DL.**
- ✓ **Conocimos los desafíos y técnicas para mitigarlos.**
- ✓ **Exploramos métodos avanzados: regularización, hiperparámetros y Transfer Learning.**
- ✓ **Analizamos redes generativas, modelos de difusión y el aprendizaje por refuerzo profundo.**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

