



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




Redes neuronales convolutivas-

› Parte II

Aprendizaje Esperado 4: Implementar un modelo predictivo utilizando redes neuronales convolutivas para el reconocimiento de imágenes en python.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**




Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?



Objetivos de aprendizaje

¿Qué aprenderás?

- Aplicar técnicas de optimización para mejorar el rendimiento de una CNN.
- Evaluar modelos usando métricas avanzadas (Precision, Recall, F1-Score).
- Conocer arquitecturas avanzadas (VGG, ResNet, MobileNet) y sus características.
- Implementar Transfer Learning y entender sus ventajas.
- Explorar aplicaciones avanzadas: detección de objetos, segmentación y GANs.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :


- Comprendimos la arquitectura y componentes clave de las redes neuronales convolutivas (CNN).
- Analizamos el rol de las capas convolutivas, ReLU, pooling y fully connected.
- Identificamos ventajas y aplicaciones de las CNN en el reconocimiento de imágenes.
- Revisamos las métricas de evaluación para tareas de clasificación de imágenes.

Redes neuronales convolutivas

Matriz de Confusión

La matriz de confusión es una herramienta poderosa para visualizar el rendimiento de un modelo de clasificación. Muestra:

- Verdaderos Positivos (VP): predicciones correctas de la clase positiva
- Falsos Positivos (FP): predicciones incorrectas de la clase positiva
- Verdaderos Negativos (VN): predicciones correctas de la clase negativa
- Falsos Negativos (FN): predicciones incorrectas de la clase negativa



Precision, Recall y F1-Score

Precision

$$VP / (VP + FP)$$

Mide qué proporción de identificaciones positivas fue realmente correcta.

Recall

$$VP / (VP + FN)$$

Mide qué proporción de positivos reales fue identificada correctamente.

F1-Score

$$2 * (Precision * Recall) / (Precision + Recall)$$

Media armónica de precision y recall, útil cuando las clases están desbalanceadas.

Técnicas de Optimización


Para optimizar el rendimiento, se pueden aplicar diversas técnicas que mejoran la capacidad de generalización del modelo.




Dropout

El **Dropout** evita el sobreajuste desactivando neuronas aleatoriamente durante el entrenamiento. Esto fuerza a la red a aprender características más robustas y no depender de neuronas específicas.


Durante la inferencia, todas las neuronas están activas pero sus pesos se escalan según la probabilidad de dropout utilizada durante el entrenamiento.



(A)




(B)



Aumento de Datos (Data Augmentation)


El **aumento de datos** genera variantes artificiales de las imágenes de entrenamiento mediante transformaciones como rotaciones, traslaciones, cambios de escala, etc. Esto aumenta efectivamente el tamaño del conjunto de datos y mejora la robustez del modelo.

Técnicas de Aumento de Datos




Rotación

Girar la imagen en diferentes ángulos.



Volteo

Reflejar la imagen horizontal o verticalmente.




Zoom

Acercar o alejar partes de la imagen.

Early Stopping

El **Early Stopping** detiene el entrenamiento si la red deja de mejorar en el conjunto de validación durante un número determinado de épocas. Esto evita el sobreajuste y ahorra tiempo de entrenamiento.



Ajuste de Hiperparámetros

Learning Rate

Controla el tamaño de los pasos durante la optimización. Un valor demasiado grande puede causar divergencia, mientras que uno demasiado pequeño puede hacer que el entrenamiento sea muy lento.

Tamaño de Lotes (Batch Size)


Determina cuántas muestras se procesan antes de actualizar los pesos. Afecta tanto la velocidad de entrenamiento como la calidad de la convergencia.

Número de Épocas

Cuántas veces se procesa todo el conjunto de datos. Demasiadas épocas pueden llevar al sobreajuste.

Arquitectura de la Red

Número y tamaño de las capas, tipos de activación, etc. La arquitectura óptima depende del problema específico.



Impacto de las Técnicas de Optimización

Estas técnicas mejoran la capacidad de generalización del modelo, haciéndolo útil para trabajar con datos reales y variados.

Non-optimized

Optimized


Conclusiones sobre las CNN

Las redes neuronales convolutivas son la herramienta por excelencia para abordar problemas de reconocimiento y clasificación de imágenes. Su arquitectura permite extraer patrones espaciales y jerárquicos de forma eficiente, logrando resultados superiores a métodos tradicionales.

Aplicación del Conocimiento

El conocimiento adquirido te permitirá no solo construir modelos funcionales para tareas de visión por computadora, sino también evaluar su rendimiento y mejorarlos con técnicas de regularización y optimización.

Importancia de las CNN en la Tecnología Actual




Reconocimiento Facial

Sistemas de seguridad y autenticación basados en el análisis de rostros.



Conducción Autónoma

Sistemas de percepción visual para vehículos sin conductor.



Diagnóstico por Imagen

Detección automática de patologías en imágenes médicas.



Habilidades Clave

Las CNN son la base de tecnologías como el reconocimiento facial, la conducción autónoma y el diagnóstico por imagen, por lo que dominarlas es una habilidad clave para cualquier profesional del aprendizaje automático.

Próximos Pasos

Dominar los Fundamentos

Comprender a fondo los conceptos básicos de las CNN presentados en este manual.

Explorar Arquitecturas Avanzadas


Investigar modelos más complejos como VGG, ResNet o MobileNet.

Experimentar con Implementaciones

Practicar con el código de ejemplo y adaptarlo a diferentes conjuntos de datos.

Aplicar a Proyectos Reales

Utilizar lo aprendido en aplicaciones prácticas y proyectos del mundo real.



Arquitecturas Avanzadas

A medida que avances, podrás experimentar con arquitecturas más complejas como VGG, ResNet o MobileNet, e incluso trabajar con modelos preentrenados para tareas específicas.

Arquitectura VGG

VGG es una arquitectura CNN desarrollada por el Visual Geometry Group de Oxford. Se caracteriza por:


- Uso de filtros pequeños (3x3) en todas las capas convolutivas
- Múltiples capas convolutivas seguidas antes del pooling
- Incremento gradual del número de filtros en capas más profundas

Es conocida por su simplicidad y profundidad, aunque requiere muchos parámetros.

Arquitectura ResNet

ResNet (Residual Network) introdujo las conexiones residuales para solucionar el problema de la degradación en redes muy profundas. Características principales:

- Conexiones de salto (skip connections) que permiten que la información fluya directamente a capas posteriores
- Capacidad para entrenar redes extremadamente profundas (50, 101, 152 capas)
- Mejor gradiente de flujo durante el entrenamiento



Arquitectura MobileNet


MobileNet está diseñada específicamente para aplicaciones móviles y dispositivos con recursos limitados:

- Uso de convoluciones separables en profundidad para reducir parámetros
- Balance entre precisión y eficiencia computacional
- Hiperparámetros para ajustar el tamaño y velocidad del modelo

Transfer Learning

El Transfer Learning permite aprovechar modelos preentrenados en grandes conjuntos de datos para aplicarlos a problemas específicos con menos datos:

- Utiliza los pesos de un modelo entrenado en millones de imágenes
- Reemplaza solo las últimas capas para adaptarlo a nuevas clases
- Requiere mucho menos datos de entrenamiento
- Reduce significativamente el tiempo de entrenamiento



Aplicación de Transfer Learning

1

Seleccionar Modelo Base

Elegir una arquitectura preentrenada como VGG16, ResNet50 o MobileNet.

2

Congelar Capas

Mantener fijos los pesos de las capas convolutivas que extraen características generales.

3

Añadir Nuevas Capas

Reemplazar las capas densas finales con nuevas capas adaptadas a tu problema específico.

4


Fine-Tuning

Opcionalmente, entrenar algunas de las capas superiores del modelo base para adaptarlas mejor a los nuevos datos.

Detección de Objetos con CNN

La detección de objetos va más allá de la clasificación, ya que también localiza objetos dentro de la imagen:

- R-CNN, Fast R-CNN y Faster R-CNN: utilizan propuestas de regiones
- YOLO (You Only Look Once): enfoque de una sola pasada, más rápido
- SSD (Single Shot Detector): balance entre velocidad y precisión



Segmentación Semántica

La segmentación semántica clasifica cada píxel de la imagen en una categoría específica:

- U-Net: arquitectura en forma de U con conexiones de salto
- SegNet: codificador-decodificador con índices de pooling
- DeepLab: utiliza convoluciones atrous para campos receptivos más grandes


Es crucial en aplicaciones médicas, conducción autónoma y análisis de imágenes satelitales.

Redes Generativas Adversarias (GANs)

Las GANs utilizan CNN tanto en el generador como en el discriminador para crear imágenes nuevas:


- El generador crea imágenes cada vez más realistas
- El discriminador intenta distinguir entre imágenes reales y generadas
- Ambas redes mejoran a través de un proceso adversarial

Aplicaciones de GANs




Arte Generativo

Creación de obras de arte originales basadas en estilos aprendidos.



Traducción de Imágenes

Convertir imágenes de un dominio a otro (día a noche, verano a invierno).



Super-resolución

Mejorar la resolución de imágenes de baja calidad.

Desafíos en el Entrenamiento de CNN

Desvanecimiento del Gradiente

En redes profundas, los gradientes pueden volverse muy pequeños, dificultando el entrenamiento de las primeras capas.

Sobreajuste

El modelo puede memorizar los datos de entrenamiento en lugar de aprender patrones generalizables.

Requisitos Computacionales

Las CNN profundas requieren hardware especializado (GPUs, TPUs) y mucho tiempo de entrenamiento.

Datos Limitados

Muchos problemas reales no tienen suficientes datos etiquetados para entrenar modelos desde cero.

Soluciones a los Desafíos

1

Inicialización de Pesos

Técnicas como la inicialización de He o Xavier ayudan a mantener gradientes estables.

2

Normalización por Lotes

Estabiliza y acelera el entrenamiento normalizando las activaciones en cada mini-lote.

3

Arquitecturas Residuales

Las conexiones de salto en ResNet permiten entrenar redes muy profundas sin degradación.

4

Aprendizaje por Transferencia

Utilizar modelos preentrenados reduce la necesidad de grandes conjuntos de datos.

Tendencias Futuras en CNN

Eficiencia Energética

Desarrollo de arquitecturas que requieren menos potencia computacional para funcionar en dispositivos con recursos limitados.

Aprendizaje Auto-Supervisado

Métodos que permiten a las redes aprender representaciones útiles sin necesidad de etiquetas manuales.

Arquitecturas Neuronales Híbridas

Combinación de CNN con otros tipos de redes como Transformers para aprovechar las fortalezas de cada una.

Consideraciones Éticas

El uso de CNN en aplicaciones del mundo real plantea importantes consideraciones éticas:

- Privacidad en sistemas de reconocimiento facial
- Sesgos en los datos de entrenamiento que pueden perpetuar discriminación
- Transparencia y explicabilidad de las decisiones tomadas por los modelos
- Impacto social y laboral de la automatización basada en visión artificial



Conclusión Final

Las redes neuronales convolutivas han revolucionado el campo de la visión por computadora y continúan evolucionando rápidamente. Dominar sus fundamentos te proporciona una base sólida para explorar aplicaciones más avanzadas y contribuir a este emocionante campo.

Este manual te ha proporcionado los conocimientos esenciales para comenzar tu viaje en el mundo de las CNN, desde la teoría básica hasta la implementación práctica. ¡El siguiente paso depende de ti!





Live Coding

¿En qué consistirá la Demo?

Mostraremos el flujo completo para optimizar e implementar un modelo predictivo CNN en Python para reconocimiento de imágenes.

1. Evaluación de una CNN usando matriz de confusión y métricas (Precision, Recall, F1).
2. Aplicar data augmentation para mejorar la robustez del modelo.
3. Implementar dropout y early stopping para evitar sobreajuste.
4. Introducir el uso de modelos preentrenados (ej. VGG16) mediante Transfer Learning.
5. Generar predicciones y analizar resultados.



Momento:

Time-out!



5 -10 min.





Ejercicio N° 1

Optimiza e implementa tu CNN

Optimiza e implementa tu CNN

Contexto: 🙌

En este ejercicio consolidarás la implementación de un modelo CNN agregando técnicas avanzadas de optimización y validación.

Consigna: 📝

1. Toma la CNN que diseñaste en la Parte 1.
2. Evalúa el modelo con métricas avanzadas (Precision, Recall y F1).
3. Aplica al menos dos técnicas de optimización: dropout, data augmentation, early stopping o ajuste de hiperparámetros.
4. Implementa Transfer Learning con un modelo preentrenado y compara resultados.
5. Documenta los resultados obtenidos y los cambios en el rendimiento.

Paso a paso: ⚙️

1. Evalúa el modelo actual y registra sus métricas.
2. Aplica técnicas de optimización y vuelve a entrenar.
3. Prueba Transfer Learning con VGG16 o ResNet.
4. Compara el desempeño de los modelos y presenta conclusiones.

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





Resumen

¿Qué logramos en esta clase?



- ✓ Evaluamos CNN con métricas avanzadas (Precision, Recall, F1).
- ✓ Aplicamos técnicas de optimización para mejorar el rendimiento.
- ✓ Conocimos arquitecturas avanzadas (VGG, ResNet, MobileNet).
- ✓ Implementamos Transfer Learning con modelos preentrenados.
- ✓ Exploramos aplicaciones avanzadas de CNN (detección de objetos, segmentación y GANs).



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

