

Análisis de Caso

Introducción a Machine Learning escalable con
MLlib 



Análisis de Caso

Nombre del tema: *Introducción a Machine Learning escalable con MLlib*

Situación inicial

Una empresa de e-commerce está experimentando un aumento significativo en la cantidad de datos que recibe diariamente de sus clientes: registros de navegación, historial de compras y calificaciones de productos. El equipo de datos de la empresa se enfrenta al desafío de analizar estos datos para predecir si un cliente realizará una compra en los próximos días, con el fin de personalizar campañas publicitarias y mejorar la experiencia de usuario.

Hasta ahora, los analistas han utilizado soluciones de Machine Learning tradicionales, pero el volumen actual de datos supera la capacidad de procesamiento de sus herramientas. Por esta razón, la empresa decidió implementar un modelo de Machine Learning escalable utilizando **Apache Spark MLlib**, que les permita procesar millones de registros de forma distribuida y eficiente.

Descripción del Caso

Como parte del equipo de datos, asúmís el rol de **Data Scientist** encargado de diseñar e implementar una solución predictiva utilizando MLlib. Tu tarea principal será construir un modelo de clasificación supervisada que prediga la probabilidad de compra de los clientes, integrando la solución en un flujo de procesamiento distribuido.

Además, deberás encargarte de preparar los datos, seleccionar las variables relevantes, ajustar los hiperparámetros del modelo y evaluar el desempeño utilizando métricas adecuadas. Todo esto deberá ser implementado respetando las buenas prácticas de escalabilidad y eficiencia.

Instrucciones

Para completar este caso, deberás:

1. Preparar los datos de entrada, asegurándote de que contengan las características necesarias y la etiqueta objetivo.

2. Utilizar las herramientas de **MLlib** para transformar y vectorizar las características.
3. Implementar un modelo supervisado de clasificación (Regresión Logística o Random Forest).
4. Dividir los datos en conjunto de entrenamiento y prueba.
5. Ajustar los hiperparámetros del modelo utilizando validación cruzada.
6. Evaluar el desempeño del modelo utilizando métricas como **Área bajo la curva ROC** y **Precisión**.
7. Presentar un informe con los resultados obtenidos y sugerencias para futuras mejoras.

Entregables

- Código fuente de la implementación en PySpark.
- Informe con la descripción del flujo de trabajo, resultados y métricas del modelo.
- Recomendaciones sobre posibles mejoras o ajustes en el modelo y la infraestructura.

¡Muchas gracias!

Nos vemos en la próxima lección

