



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Big data- Parte II

Aprendizaje Esperado 1: Explicar las características fundamentales de big data y su ecosistema para el manejo de grandes volúmenes de datos.


Roadmap de lecciones

¿Cuáles **lecciones** estaremos estudiando en este módulo?




Hoja de ruta

¿Cuáles skills conforman el programa? Fundamentos de Ciencia de Datos



Learning Path

¿Cuáles temas trabajaremos hoy?



Objetivos de aprendizaje

¿Qué aprenderás?

- Comprender qué es un sistema distribuido y sus ventajas en Big Data.
- Identificar los componentes de una arquitectura típica de datos masivos.
- Reconocer las tecnologías emergentes del ecosistema Big Data y su evolución.
- Analizar cómo se integran herramientas de aprendizaje automático y cloud computing.
- Evaluar soluciones escalables para grandes volúmenes de datos en diferentes contextos.

Repaso clase anterior

¿Quedó alguna duda?

En la clase anterior trabajamos :

- Definimos qué es Big Data y cuáles son sus diferencias respecto al enfoque tradicional.
- Analizamos las 5V's (Volumen, Velocidad, Variedad, Veracidad y Valor) que caracterizan al fenómeno.
- Identificamos los tipos de datos que gestiona (estructurados, semiestructurados y no estructurados).
- Exploramos tecnologías del ecosistema: bases NoSQL, sistemas distribuidos y procesamiento paralelo.

Big data

ADVANTAGES OF DISTRIBUTED COMPUTING



Sistemas Distribuidos

Por otro lado, un **sistema distribuido** está conformado por un conjunto de nodos o máquinas interconectadas que trabajan de manera coordinada para almacenar y procesar grandes volúmenes de datos. La principal ventaja de este enfoque es que permite dividir las tareas entre múltiples nodos, incrementando la capacidad de almacenamiento y procesamiento de forma escalable y flexible.

Ventajas de los Sistemas Distribuidos

En los sistemas distribuidos, la información se fragmenta en bloques y se distribuye entre los diferentes nodos. Esto no solo permite almacenar más datos, sino también realizar operaciones de manera paralela, mejorando significativamente los tiempos de respuesta y reduciendo los cuellos de botella.

Mayor Capacidad

Almacenamiento expandible mediante la adición de nuevos nodos al sistema.

Procesamiento Paralelo

Ejecución simultánea de tareas en múltiples nodos para mayor velocidad.


Alta Disponibilidad

Continuidad operativa incluso cuando algunos nodos fallan.

Escalabilidad

Capacidad de crecer horizontalmente añadiendo más equipos según necesidad.

Ensure redundant components fail independently



Tolerancia a Fallos

Además, los sistemas distribuidos ofrecen una mayor tolerancia a fallos. Si un nodo falla, los datos y las tareas pueden ser replicados o reasignados a otros nodos, garantizando la continuidad del servicio. Este aspecto es fundamental en entornos Big Data, donde la pérdida de datos o la interrupción del servicio puede tener un alto impacto económico y operativo.

Desafíos de los Sistemas Distribuidos

Sin embargo, la implementación de sistemas distribuidos también conlleva desafíos técnicos. La sincronización y comunicación entre los nodos, la gestión de la consistencia de los datos y la seguridad de la información son aspectos que deben ser cuidadosamente diseñados y gestionados.



Sincronización entre Nodos

Mantener la coordinación entre múltiples máquinas que operan simultáneamente requiere protocolos complejos y mecanismos de comunicación eficientes.



Consistencia de Datos

Garantizar que todos los nodos tengan la misma versión de los datos o gestionar las inconsistencias temporales es un reto significativo.





Seguridad Distribuida

Proteger la información en múltiples puntos aumenta la superficie de ataque y requiere estrategias de seguridad más sofisticadas.

Ejemplos de Sistemas Distribuidos

Un ejemplo claro de sistema distribuido es **Hadoop Distributed File System (HDFS)**, que divide los archivos en bloques y los distribuye en diferentes nodos de un clúster. Otro ejemplo es **Apache Spark**, que también aprovecha el procesamiento distribuido para realizar análisis de datos masivos de forma eficiente.




HDFS: Sistema de archivos distribuido que permite almacenar grandes volúmenes de datos en múltiples nodos.

Apache Spark: Framework de procesamiento distribuido que permite análisis de datos en memoria a gran escala.


Transición a Sistemas Distribuidos

En conclusión, la transición de sistemas locales a sistemas distribuidos ha sido clave para posibilitar el desarrollo y la adopción de soluciones Big Data. Esta arquitectura permite a las organizaciones gestionar y analizar volúmenes de datos que antes eran imposibles de procesar en un solo equipo.



Tecnologías de Big Data

El ecosistema de Big Data está compuesto por un conjunto diverso de tecnologías que permiten gestionar, almacenar, procesar y analizar grandes volúmenes de datos. Estas herramientas han sido diseñadas para resolver las limitaciones de los sistemas tradicionales y facilitar la explotación eficiente de los datos masivos.



Aspect	SQL Databases	NoSQL Databases
Definition	Relational databases using Structured Query Language.	Non-relational databases with flexible schemas.
Structure	Tables with rows and columns.	Documents, key-value pairs, graphs, or wide columns.
Schema	Fixed, predefined schema.	Dynamic, flexible schema.
Query Language	SQL (Structured Query Language).	Various (e.g., JSON, XML, YAML).
Scalability	Vertical (adding more power to servers).	Horizontal (adding more servers).
Performance	Good for complex queries and transactions.	High performance for large-scale and unstructured data.
Security	Strong (access control, authentication, encryption).	Varies; some offer strong features (e.g., MongoDB).
Data Integrity	High data integrity with ACID properties.	Varies; often more relaxed.
Use Cases	Financial systems, e-commerce, CRM systems.	Real-time analytics, social media, big data.
Examples	MySQL, Oracle, PostgreSQL, Microsoft SQL Server.	MongoDB, Cassandra, Redis, Neo4j, CouchDB, Elasticsearch.
Pros	Strong consistency, robust queries, well-understood integrity.	Flexible models, high scalability, ideal for large data volumes.
Cons	Rigid schema, difficult to change schema, single point of failure without replication.	Limited ACID support, less mature querying, potential consistency issues.

Bases de Datos NoSQL

Las **bases de datos NoSQL** son un componente esencial en entornos Big Data. A diferencia de las bases de datos relacionales, que requieren un esquema fijo y estructurado, las bases NoSQL están diseñadas para almacenar datos no estructurados y semiestructurados, como documentos JSON, grafos o pares clave-valor. Estas bases de datos ofrecen alta escalabilidad y flexibilidad, permitiendo almacenar datos heterogéneos y adaptarse fácilmente a los cambios. Algunos ejemplos destacados son **MongoDB**, **Cassandra** y **Redis**.

Tipos de Bases de Datos NoSQL



Bases de Datos Documentales

Almacenan datos en formato de documentos (JSON, BSON).
Ejemplos: MongoDB, CouchDB.



Bases de Datos Columnares

Organizan datos por columnas en lugar de filas. Ejemplos:
Cassandra, HBase.



Bases de Datos Clave-Valor


Almacenan datos como pares de clave-valor. Ejemplos: Redis,
DynamoDB.



Bases de Datos de Grafos

Representan datos como nodos y relaciones. Ejemplos: Neo4j,
JanusGraph.

Real-Time Processing



© 2022 Copyright Velotio

Procesamiento en Tiempo Real

El **procesamiento en tiempo real** es otra tecnología clave en el mundo Big Data. Este enfoque permite analizar los datos al mismo tiempo que se generan, lo que resulta fundamental para aplicaciones que requieren respuestas inmediatas, como la detección de fraudes, la monitorización de redes o el análisis de redes sociales. Herramientas como **Apache Kafka**, **Apache Storm** y **Apache Flink** son ampliamente utilizadas para la gestión y análisis de flujos de datos en tiempo real.

Almacenamiento Distribuido

El **almacenamiento distribuido** es esencial para gestionar grandes volúmenes de datos que no pueden ser alojados en un solo servidor. Este tipo de almacenamiento divide los datos en bloques y los distribuye entre diferentes nodos de un clúster, permitiendo escalabilidad y alta disponibilidad. Un ejemplo emblemático es el **Hadoop Distributed File System (HDFS)**, que garantiza la redundancia de los datos y la tolerancia a fallos.

División de Datos

Los archivos se dividen en bloques de tamaño fijo

Distribución

Los bloques se distribuyen entre múltiples nodos

Replicación


Cada bloque se replica en varios nodos para redundancia

Gestión

Un nodo maestro coordina las operaciones del sistema

Procesamiento Distribuido

En cuanto al **procesamiento distribuido**, esta tecnología permite dividir las tareas de análisis entre múltiples nodos, ejecutando operaciones de manera paralela. Este enfoque mejora significativamente la eficiencia y el rendimiento al trabajar con conjuntos de datos masivos. Uno de los motores de procesamiento distribuido más utilizados es **Apache Spark**, que ofrece capacidades avanzadas de procesamiento en memoria y soporta diversas tareas como consultas SQL, aprendizaje automático y análisis de grafos.



Frameworks de Big Data

Por último, los **frameworks de Big Data** proporcionan un entorno estructurado para el desarrollo y ejecución de aplicaciones de análisis de datos a gran escala. Estos frameworks integran diferentes componentes de almacenamiento, procesamiento y análisis, facilitando la implementación de soluciones Big Data. Algunos de los más conocidos son **Hadoop**, **Spark**, **Flink** y **Beam**.

Hadoop

Framework para procesamiento distribuido de grandes conjuntos de datos en clústeres de computadoras.

Spark

Motor de análisis unificado para procesamiento de datos a gran escala con APIs en Java, Scala, Python y R.

Flink

Framework de procesamiento de flujos de datos distribuido con garantías de consistencia.


Beam

Modelo unificado para definir trabajos de procesamiento de datos por lotes y streaming.

Integración de Tecnologías

El uso combinado de estas tecnologías permite a las organizaciones construir infraestructuras robustas y escalables para gestionar y explotar datos masivos. La elección de las herramientas dependerá de las necesidades específicas de cada caso, considerando factores como el volumen y la velocidad de los datos, la complejidad del análisis y los recursos disponibles.

En síntesis, el ecosistema tecnológico de Big Data es amplio y en constante evolución, ofreciendo múltiples opciones para abordar los desafíos asociados al manejo de grandes volúmenes de información y extraer valor de ellos.



Arquitecturas típicas de Big Data

El diseño de una arquitectura adecuada es un factor clave para el éxito de cualquier solución de Big Data. Estas arquitecturas permiten integrar diferentes tecnologías y procesos que trabajan en conjunto para capturar, almacenar, procesar y analizar grandes volúmenes de datos. En esta sección, exploraremos los componentes más comunes que conforman una arquitectura típica de Big Data.

Capa de Adquisición de Datos

Una arquitectura Big Data suele comenzar con una **capa de adquisición de datos**, encargada de recopilar información desde múltiples fuentes. Estas pueden incluir bases de datos, sensores IoT, registros de aplicaciones, redes sociales, entre otros. La ingesta de datos puede realizarse en lotes o en tiempo real, dependiendo de las necesidades del negocio.



Bases de Datos

Sistemas transaccionales, CRM, ERP y otras fuentes estructuradas.



Dispositivos IoT

Sensores, dispositivos conectados y sistemas de telemetría.



Redes Sociales

Plataformas sociales, blogs, foros y contenido generado por usuarios.




Logs y Eventos

Registros de aplicaciones, servidores y sistemas operativos.

Capa de Almacenamiento

Posteriormente, los datos recopilados son enviados a la **capa de almacenamiento**, donde son alojados en sistemas diseñados para soportar grandes volúmenes de información. En esta etapa, se emplean tecnologías como **HDFS**, bases de datos **NoSQL** o sistemas de almacenamiento en la nube. El almacenamiento distribuido garantiza la disponibilidad y escalabilidad de los datos.



Capa de Procesamiento

Una vez almacenados, los datos pasan a la **capa de procesamiento**, donde se llevan a cabo tareas de transformación, limpieza y análisis. Esta capa puede estar compuesta por motores de procesamiento por lotes, como **Apache Hadoop MapReduce**, o motores de procesamiento en memoria y tiempo real, como **Apache Spark** o **Apache Flink**. El procesamiento distribuido permite dividir las tareas entre varios nodos, acelerando el análisis.

Procesamiento por Lotes

- Hadoop MapReduce
- Hive
- Pig

Ideal para grandes volúmenes de datos históricos que no requieren procesamiento inmediato.

Procesamiento en Tiempo Real

- Apache Spark Streaming
- Apache Flink
- Apache Storm

Necesario para análisis instantáneo de datos en flujo continuo.

Capa de Acceso y Consulta

Las arquitecturas Big Data también incluyen una **capa de acceso y consulta**, que facilita a los usuarios la obtención de información relevante a partir de los datos procesados. Aquí se integran herramientas como **Apache Hive, Impala** o motores de consultas SQL adaptados a grandes volúmenes de datos.

Capa de Análisis Avanzado

Adicionalmente, muchas arquitecturas incorporan una **capa de análisis avanzado**, donde se aplican técnicas de inteligencia artificial, aprendizaje automático y minería de datos para descubrir patrones, predecir tendencias y generar valor a partir de los datos.

Aprendizaje Supervisado

Algoritmos de clasificación y regresión para predecir resultados basados en datos etiquetados.

Aprendizaje No Supervisado

Técnicas de clustering y reducción de dimensionalidad para descubrir patrones ocultos.

Procesamiento de Lenguaje Natural

Análisis de texto para extraer significado, sentimiento y entidades de datos textuales.

Análisis Predictivo

Modelos estadísticos y de machine learning para anticipar comportamientos futuros.




Capa de Seguridad y Gobernanza

Un componente esencial en estas arquitecturas es la **capa de seguridad y gobernanza**, que garantiza la protección, integridad y privacidad de los datos. Esta capa incluye mecanismos de autenticación, autorización, auditoría y cumplimiento de normativas legales.


Capa de Visualización e Informes

Por último, las arquitecturas Big Data suelen contar con herramientas de **visualización e informes**, que permiten presentar los resultados del análisis de manera clara y accesible para los usuarios finales, facilitando la toma de decisiones.




Dashboards Interactivos

Paneles personalizables con métricas clave y visualizaciones dinámicas.



Informes Analíticos

Reportes detallados con análisis profundo de datos y tendencias.




Narrativa de Datos

Presentación de insights mediante storytelling visual para facilitar comprensión.

Integración de Capas

En conclusión, una arquitectura típica de Big Data está compuesta por múltiples capas interconectadas que permiten gestionar el ciclo completo de vida de los datos, desde su adquisición hasta su análisis y visualización. La correcta integración de estas capas es fundamental para garantizar la eficiencia, escalabilidad y seguridad de las soluciones Big Data.



Evolución de las tecnologías de Big Data

El ecosistema de Big Data ha experimentado una evolución constante desde sus inicios, impulsada por la necesidad creciente de procesar y analizar volúmenes de datos cada vez mayores. Esta evolución ha estado marcada por el desarrollo de tecnologías y frameworks que han transformado la manera en que las organizaciones gestionan y aprovechan sus datos.

Apache Hadoop: El Pionero

Uno de los primeros hitos en la historia de Big Data fue la creación de **Apache Hadoop** en 2006. Hadoop introdujo el concepto de procesamiento distribuido mediante el paradigma **MapReduce**, permitiendo dividir grandes tareas de procesamiento en pequeñas sub-tareas que podían ejecutarse de manera paralela en diferentes nodos. Además, Hadoop incorporó el **Hadoop Distributed File System (HDFS)**, un sistema de almacenamiento distribuido diseñado para gestionar datos a gran escala y tolerar fallos de hardware.



Limitaciones de Hadoop

Aunque Hadoop revolucionó el tratamiento de datos masivos, también presentó algunas limitaciones. Su modelo de procesamiento basado en discos era ineficiente para tareas que requerían respuestas en tiempo real o procesamiento iterativo, como el aprendizaje automático. Esta situación impulsó el desarrollo de nuevas tecnologías más flexibles y rápidas.

Procesamiento por Lotes

Hadoop MapReduce está optimizado para procesamiento por lotes, lo que lo hace ineficiente para análisis en tiempo real o consultas interactivas.

Operaciones en Disco


Las operaciones de lectura y escritura en disco ralentizan significativamente el procesamiento de datos, especialmente en aplicaciones iterativas.

Complejidad de Programación

El modelo de programación MapReduce resulta complejo y verboso para muchos desarrolladores, dificultando la implementación de algoritmos avanzados.

Apache Spark: Procesamiento en Memoria

En este contexto surgió **Apache Spark**, una plataforma de procesamiento distribuido que mejoró significativamente el rendimiento de Hadoop al permitir el **procesamiento en memoria**. Spark no solo es más rápido que MapReduce, sino que también ofrece una API más sencilla y soporta múltiples tareas, como consultas SQL, procesamiento de flujos de datos en tiempo real, análisis de grafos y aprendizaje automático.



The Overview Of Apache Spark

Ventajas de Spark

- Procesamiento hasta 100x más rápido que MapReduce
- API unificada para diferentes tipos de procesamiento
- Soporte nativo para SQL, streaming, ML y análisis de grafos
- Compatibilidad con múltiples lenguajes: Java, Scala, Python, R
- Integración con el ecosistema Hadoop existente

Procesamiento en Tiempo Real

Además de Hadoop y Spark, han emergido otras tecnologías que han ampliado el ecosistema Big Data. Por ejemplo, **Apache Flink** y **Apache Storm** son herramientas especializadas en el procesamiento de datos en tiempo real, brindando capacidades avanzadas para la toma de decisiones inmediata basada en flujos de datos continuos.



Generación de Datos

Sensores, aplicaciones y sistemas generan flujos continuos de datos



Procesamiento Inmediato

Los datos son analizados al instante sin almacenamiento previo




Análisis Continuo

Algoritmos detectan patrones y anomalías en tiempo real



Acción Inmediata

Respuestas automatizadas basadas en los resultados del análisis



Bases de Datos NoSQL

La evolución también ha sido impulsada por la necesidad de gestionar diferentes tipos de datos. Así, surgieron bases de datos **NoSQL** como **MongoDB**, **Cassandra** y **HBase**, diseñadas para almacenar datos no estructurados y garantizar la escalabilidad horizontal.

Big Data en la Nube

Paralelamente, el auge de los servicios en la nube ha favorecido el desarrollo de plataformas Big Data como **Amazon EMR**, **Google BigQuery** y **Azure Data Lake**, que permiten implementar infraestructuras escalables y flexibles sin necesidad de gestionar hardware físico.

Amazon Web Services

EMR, Redshift, Kinesis, Athena y otros servicios para procesamiento y análisis de datos masivos.


Google Cloud

BigQuery, Dataflow, Dataproc y Pub/Sub para análisis de datos a escala global.

Microsoft Azure

Data Lake, HDInsight, Synapse Analytics y Stream Analytics para soluciones Big Data completas.

AI integration



alamy

Image ID: 2WMS3HD
www.alamy.com

Integración con Aprendizaje Automático

Otro aspecto clave en la evolución de Big Data ha sido la integración de herramientas de **aprendizaje automático** y **análisis avanzado**, que permiten extraer conocimiento y valor a partir de los datos. Frameworks como **MLlib (de Spark)** o plataformas como **TensorFlow** y **H2O.ai** se han convertido en componentes habituales dentro de las arquitecturas Big Data.

Conclusión: El Futuro de Big Data

En resumen, la evolución de las tecnologías de Big Data ha sido constante y dinámica, pasando de modelos basados en almacenamiento y procesamiento por lotes, como Hadoop, a plataformas más rápidas y versátiles como Spark y Flink. Esta evolución ha permitido a las organizaciones gestionar y aprovechar grandes volúmenes de datos de manera eficiente, adaptándose a los nuevos retos y necesidades del entorno digital.

El fenómeno de **Big Data** ha revolucionado la forma en que las organizaciones gestionan, procesan y analizan la información. Gracias al avance de tecnologías y arquitecturas especializadas, hoy es posible transformar grandes volúmenes de datos en conocimiento útil para la toma de decisiones y la creación de valor en múltiples industrias.

Comprender los fundamentos de Big Data es esencial para cualquier profesional del ámbito tecnológico y de los datos. Esta comprensión permitirá abordar con éxito los desafíos asociados al tratamiento de datos masivos y aprovechar las oportunidades que surgen en un mundo cada vez más orientado a la información.



Momento:

Time-out!



5 -10 min.





Ejercicio

Explora una arquitectura Big Data

Explora una arquitectura Big Data

Contexto: 🙌

Queremos que reconozcas los elementos clave en una solución moderna de Big Data y cómo se integran entre sí.

Consigna: 📝

1. Investiga y representa gráficamente una arquitectura típica de Big Data, identificando:
 - Capa de adquisición
 - Capa de almacenamiento
 - Capa de procesamiento
 - Capa de análisis
 - Capa de visualización
2. Elige una tecnología real para cada componente (ej: Kafka, Spark, MongoDB, Tableau, etc.).
3. Explica brevemente el rol de cada componente y su importancia dentro del flujo completo.

Paso a paso: ⚙️

1. Usa la clase como guía para identificar cada capa.
2. Investiga tecnologías concretas que puedan ocupar ese rol.
3. Realiza un esquema visual claro (puede ser a mano o digital) con etiquetas.
4. Agrega una breve descripción textual por cada capa.

Tiempo 🕒: 45 Minutos

¿Alguna consulta?



Resumen

¿Qué logramos en esta clase?

- ✓ **Comprendimos qué es un sistema distribuido y sus beneficios clave: escalabilidad, tolerancia a fallos y procesamiento paralelo.**
- ✓ **Estudiamos la estructura de una arquitectura Big Data moderna por capas.**
- ✓ **Conocimos tecnologías clave: Hadoop, Spark, Kafka, MongoDB, entre otras.**
- ✓ **Analizamos la evolución del ecosistema desde Hadoop hasta plataformas en la nube.**
- ✓ **Exploramos la integración entre Big Data, Machine Learning y cloud computing como tendencia actual.**



¡Ponte a prueba!

Momento de ejercitación

Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< **¡Muchas gracias!** >

