

M9: FUNDAMENTOS DE BIG DATA

1. **Big Data:** Conjunto masivo y diverso de datos cuya gestión excede herramientas tradicionales.
2. **5V de Big Data:** Volumen, Velocidad, Variedad, Veracidad y Valor; dimensiones clave del fenómeno.
3. **Sistema distribuido:** Conjunto de nodos que almacenan/procesan datos en paralelo con tolerancia a fallos.
4. **Apache Spark:** Motor de procesamiento distribuido en memoria para análisis masivo de datos.
5. **SparkContext:** Punto de entrada clásico para crear RDDs y coordinar recursos del clúster.
6. **SparkSession:** Punto de entrada unificado para Spark SQL, DataFrames y configuración de la app.
7. **RDD (Resilient Distributed Dataset):** Colección distribuida, inmutable y tolerante a fallos.
8. **Pair RDD:** RDD de pares (clave, valor) útil para agregaciones por clave.
9. **Linaje (Lineage):** Historial de transformaciones que permite recomputar particiones perdidas.
10. **Lazy Evaluation:** Diferimiento de ejecución hasta invocar una acción, permitiendo optimización.
11. **Transformación:** Operación perezosa que genera un nuevo RDD/DataFrame (p. ej., `map`, `filter`).
12. **Acción:** Operación que ejecuta el plan y devuelve resultado (p. ej., `count`, `collect`).
13. **DataFrame:** Colección distribuida tabular con esquema; optimizable por Catalyst.
14. **Dataset:** Estructura tipada (Scala/Java) que combina eficiencia de DataFrame y seguridad de tipos.

- 
15. **Catalyst Optimizer:** Motor que optimiza planes lógicos/físicos de consultas en Spark SQL.
 16. **Tungsten:** Proyecto de optimización de CPU/memoria (codegen, off-heap, vectorización).
 17. **UDF (User Defined Function):** Función personalizada para ampliar operaciones de Spark SQL.
 18. **Parquet:** Formato columnar comprimido y eficiente para analítica en grandes volúmenes.
 19. **MLlib:** Biblioteca de Machine Learning distribuido integrada en Spark.
 20. **Pipeline de ML:** Secuencia reproducible de etapas (transformadores/estimadores) para modelado.