Evaluación del módulo 9

Consigna del proyecto👨🏻‍💻

alkemy

Proyecto: Retail Analytics Pipeline

Evaluación del módulo 9: FUNDAMENTOS DE BIG DATA

Situación inicial 📍

Unidad solicitante: Departamento de Analítica y Machine Learning de la empresa **RetailMax**.

La empresa RetailMax maneja millones de transacciones diarias en su plataforma e-commerce, lo que genera **grandes volúmenes de datos** provenientes de compras, comportamiento de navegación, reseñas y calificaciones. Actualmente, el proceso de análisis es lento y fragmentado: los datos se almacenan en múltiples sistemas y los modelos de Machine Learning tradicionales no pueden escalar a la magnitud del dataset.

El área de analítica solicita desarrollar un **pipeline de Big Data y Machine Learning escalable**, capaz de:

1. Procesar datos estructurados y no estructurados en entornos distribuidos.

2. Ejecutar transformaciones masivas para generar métricas de negocio.

3. Entrenar y evaluar modelos de Machine Learning sobre grandes volúmenes de datos utilizando Spark MLlib.

Nuestro objetivo 📋

Diseñar e implementar un **proyecto integral** que comience con la **ingesta y procesamiento de datos masivos**, continúe con la **transformación y análisis mediante Apache Spark**, y finalice con la **construcción de un modelo de Machine Learning escalable** que permita clasificar usuarios y generar información accionable para el área de marketing.

El proyecto demostrará que el participante es capaz de **aplicar los fundamentos de Big Data y Spark**, trabajando con **RDDs, DataFrames, SQL y MLlib**, en un flujo completo de análisis masivo.

Requerimientos 🤝

- Utilizar **Apache Spark** como motor principal de procesamiento.
- Manejar **datos estructurados y no estructurados** en un entorno distribuido.
- Crear y manipular **RDDs y DataFrames** aplicando transformaciones y acciones.
- Implementar consultas y agregaciones con **Spark SQL**.
- Construir un **pipeline de Machine Learning** usando MLlib (supervisado o no supervisado).
- Documentar **linaje, optimización (cache/persist) y ejecución de Jobs**.
- Entregar **código funcional, resultados analíticos y visualizaciones**.

Paso a paso 👣

Este proyecto refiere exclusivamente al **módulo 9**: *FUNDAMENTOS DE BIG DATA*, y se compone de **5 etapas (lecciones)**, las cuales podrás avanzar de forma progresiva y escalonada con la ayuda de los manuales teóricos y los contenidos desarrollados en las clases en vivo.

Ten en cuenta de invertir **tiempo asincrónicos** para el desarrollo de cada etapa a modo de poder finalizar el módulo y realizar la entrega formal de tu propuesta. Cualquier consulta que surja compártela en los espacios sincrónicos para resolver las dudas en equipo.

A continuación encontrarás las consignas y tareas a desarrollar:

Lección 1: Fundamentos de Big Data

📌 **Objetivo: Reconocer el ecosistema de Big Data y sus componentes básicos.**
📍 **Tareas a desarrollar:**

- Describir las 5V de Big Data y su impacto en proyectos reales.
- Identificar fuentes de datos de RetailMax (transacciones, reseñas, navegación).
- Proponer un diagrama inicial de arquitectura para el proyecto.
- Entregar un informe conceptual que sirva como base para las siguientes etapas.

Lección 2: Apache Spark - Introducción y Configuración

📌 Objetivo: Configurar Spark e iniciar el procesamiento distribuido de datos masivos.
📍 Tareas a desarrollar:

- Configurar SparkContext y SparkSession en un entorno local o clúster.
- Cargar datos iniciales en RDDs y explorar acciones básicas (`count`, `take`).
- Validar conectividad con datasets masivos de prueba.
- Entregar un notebook con la configuración y prueba inicial.

Lección 3: Elementos básicos de Spark (RDD, Transformaciones y Acciones)

📌 Objetivo: Manipular grandes volúmenes de datos mediante RDDs, aplicando transformaciones y acciones.
📍 Tareas a desarrollar:

- Crear RDDs y Pair RDDs a partir de datos de transacciones.
- Aplicar transformaciones (`map`, `filter`, `flatMap`, `distinct`, `sortBy`).
- Ejecutar acciones (`collect`, `sum`, `mean`, `stdev`) y documentar el linaje.

- Entregar notebook con código funcional y explicación del DAG generado.

Lección 4: Procesamiento de datos estructurados (Spark SQL y DataFrames)

📌 Objetivo: Procesar y analizar datos estructurados de manera optimizada usando DataFrames y Spark SQL.
📍 Tareas a desarrollar:

- Transformar los RDDs generados en DataFrames y aplicar esquemas explícitos.
- Ejecutar consultas SQL para generar métricas de negocio (ventas por categoría, top productos).
- Guardar resultados en formato Parquet para la siguiente lección.
- Entregar notebook + archivo Parquet generado.

Lección 5: Introducción a Machine Learning Escalable (Spark MLlib)

📌 Objetivo: Construir un pipeline de MLlib para clasificación y segmentación de usuarios.
📍 Tareas a desarrollar:

- Cargar los DataFrames procesados en la etapa anterior.
- Crear features con `VectorAssembler` e indexar categorías con `StringIndexer`.
- Entrenar un modelo supervisado (Regresión Logística) y uno no supervisado (K-Means).
- Evaluar métricas y generar un reporte final con insights para marketing.
- Entregar pipeline completo en notebook + informe final en PDF.

¿Qué vamos a validar? 🔍

- Comprensión y correcta aplicación de los **conceptos de Big Data**.
- Capacidad de **configurar y operar Spark** en entornos distribuidos.
- Uso de **RDDs, transformaciones, acciones, DataFrames y SQL** de forma eficiente.
- Implementación de un **pipeline de Machine Learning escalable** en MLlib.
- Calidad y claridad del **código, documentación y reportes entregados**.
- Integración **progresiva** de las entregas entre lecciones para formar un proyecto completo.

Referencias 🦺

- Apache Spark Official Docs: https://spark.apache.org/docs/latest/
- Databricks Learning: https://www.databricks.com/learn
- Spark SQL, DataFrames and Datasets Guide: https://spark.apache.org/docs/latest/sql-programming-guide.html
- Spark MLlib: https://spark.apache.org/mllib/
- Fashion-MNIST Dataset: https://github.com/zalandoresearch/fashion-mnist

Recursos 🎁

Blogs técnicos:

- https://towardsdatascience.com
- https://machinelearningmastery.com

Ejemplos de pipelines MLlib:

- https://spark.apache.org/docs/latest/ml-pipeline.html

Entregables ✅

1. **Notebooks de PySpark** con el desarrollo por lección.
2. **Archivos generados (Parquet, CSV, visualizaciones)**.
3. **Informe final PDF** con resultados, métricas y análisis.
4. **Pipeline MLlib funcional** documentado.
5. Repositorio de GitHub

Portafolio 💼

El proyecto **Retail Analytics Pipeline** puede integrarse en tu portafolio profesional como un ejemplo real de **Big Data + ML escalable**.
Se recomienda:

- Subir el **notebook completo** a GitHub.
- Adjuntar **capturas de visualizaciones y métricas**.
- Preparar una **presentación final** mostrando el flujo completo y resultados.

¡Éxitos!

Nos vemos más adelante

alkemy