

Es hora de que pongas en práctica todo lo aprendido. 

Este apartado tiene el objetivo de ayudarte a seguir potenciando tus habilidades, por lo que a continuación encontrarás diferentes **desafíos** que podrás resolver de forma independiente y a tu ritmo.

Más adelante conseguirás las resoluciones para que valides tus respuestas y puedas monitorear tu progreso. 

¡Manos a la obra!

1. Desafío

- Crear un archivo Python (.py o .ipynb) y configurar una sesión Spark local.
- Crear un DataFrame con la siguiente información de empleados:

ID	Nombre	Departamento	Edad	Salario
1	Ana	Finanzas	25	2500
2	Luis	Ventas	30	3000
3	Carla	Finanzas	28	2700
4	Pedro	Recursos	35	3200
5	Sofía	Ventas	22	2200

- Registrar el DataFrame como una vista temporal llamada empleados.
- Realizar las siguientes consultas utilizando SQL:
 - Seleccionar el nombre y salario de los empleados cuyo salario sea mayor a 2500.
 - Calcular el salario promedio por departamento.
- Mostrar los resultados por consola.

2. ¿Dónde se lleva a cabo? 🏠

Visual Studio Code

3. Tiempo de dedicación ⌚

2 horas

4. Recursos 🔧

- <https://spark.apache.org/docs/latest/sql-programming-guide.html>
- <https://www.datacamp.com/es/tutorial/pyspark-tutorial-getting-started-with-pyspark>

5. Plus ➕

✅ Como desafío adicional, podés guardar el resultado de las consultas en formato Parquet o JSON.

6. ⚠ Condición

Esta práctica o ejercitación **no requiere ser entregada y/o evaluada** por el mentor. No obstante puedes compartir tus resultados con el resto de los bootcampers y construir conocimiento en conjunto.

Resolución del desafío

```
from pyspark.sql import SparkSession
```

```
# 1. Crear la sesión Spark
```

```
spark = SparkSession.builder \
    .appName("EjercicioDataFrameSQL") \
    .master("local[*]") \
    .getOrCreate()
```

```
# 2. Crear el DataFrame con la información de empleados
```

```
datos = [
    (1, "Ana", "Finanzas", 25, 2500),
    (2, "Luis", "Ventas", 30, 3000),
    (3, "Carla", "Finanzas", 28, 2700),
    (4, "Pedro", "Recursos", 35, 3200),
    (5, "Sofía", "Ventas", 22, 2200)
]
```

```
columnas = ["ID", "Nombre", "Departamento", "Edad", "Salario"]
```

```
df = spark.createDataFrame(datos, columnas)
```

```
# Mostrar el contenido del DataFrame
```

```
df.show()
```

```
# 3. Registrar el DataFrame como vista temporal
```

```
df.createOrReplaceTempView("empleados")
```

```
# 4. Consultas SQL
```

```
# a) Nombre y salario de los empleados cuyo salario sea mayor a 2500
```

```
consulta1 = spark.sql("""
```

```
SELECT Nombre, Salario
```

```
FROM empleados
```

```
WHERE Salario > 2500
```

```
""")
```

```
print("Empleados con salario mayor a 2500:")
```

```
consulta1.show()
```

```
# b) Salario promedio por departamento
```

```
consulta2 = spark.sql("""
```

```
SELECT Departamento, AVG(Salario) AS Salario_Promedio
```

```
FROM empleados
```

```
GROUP BY Departamento
```

```
""")
```

```
print("Salario promedio por departamento:")
```

```
consulta2.show()
```

5. (Opcional) Guardar el resultado en formato Parquet

```
consulta2.write.mode("overwrite").parquet("salario_promedio_departamen  
to.parquet")
```

Detener la sesión Spark

```
spark.stop()
```

✅ Resultados esperados:

```
+---+-----+-----+---+-----+  
| ID|Nombre|Departamento|Edad|Salario|  
+---+-----+-----+---+-----+  
| 1| Ana| Finanzas| 25| 2500|  
| 2| Luis| Ventas| 30| 3000|  
| 3| Carla| Finanzas| 28| 2700|  
| 4| Pedro| Recursos| 35| 3200|  
| 5| Sofía| Ventas| 22| 2200|  
+---+-----+-----+---+-----+
```

Empleados con salario mayor a 2500:

```
+-----+-----+  
|Nombre|Salario|  
+-----+-----+  
| Luis| 3000|  
  
| Carla| 2700|
```

| Pedro| 3200|

+-----+-----+

Salario promedio por departamento:

+-----+-----+

|Departamento|Salario_Promedio|

+-----+-----+

| Ventas| 2600.0|

| Recursos| 3200.0|

| Finanzas| 2600.0|

+-----+-----+