

INFORME TÉCNICO

Retail Analytics Pipeline

Módulo 9: Fundamentos de Big Data

Bootcamp: Talento Digital · Alkemy

Dataset: Fashion-MNIST · Apache Spark 3.5 · Python 3.10

Año: 2026

Pipeline completo: Big Data + Machine Learning Escalable

Resumen Ejecutivo

RetailMax, una empresa líder en el sector de retail de moda, enfrenta el desafío de clasificar y segmentar automáticamente su extenso catálogo de productos. Con miles de nuevas imágenes ingresadas diariamente, el procesamiento manual resulta inviable. Este proyecto implementa un pipeline de Big Data utilizando Apache Spark para procesar 70.000 imágenes del dataset Fashion-MNIST, aplicando técnicas de Machine Learning escalable para resolver este problema de negocio.

70.000

imágenes procesadas

5

etapas completadas

2

modelos ML

Objetivo del proyecto: Construir un pipeline de análisis de datos de extremo a extremo, desde la ingesta de datos en bruto hasta la generación de predicciones de Machine Learning, utilizando el ecosistema de Apache Spark y sus componentes (RDDs, DataFrames, Spark SQL y MLlib) para demostrar el procesamiento distribuido de grandes volúmenes de datos en un contexto de retail.

Lección	Archivo	Descripción
1 — Fundamentos Big Data	leccion1_fundamentos_bigdata.ipynb	EDA y análisis de las 5V
2 — Configuración Spark	leccion2_spark_configuracion.ipynb	SparkSession y operaciones básicas
3 — RDDs	leccion3_rdd_transformaciones_v2.ipynb	Transformaciones y acciones con RDDs
4 — DataFrames y SQL	leccion4_dataframes_sql.ipynb	Procesamiento estructurado y Parquet
5 — MLlib Pipeline	leccion5_mllib_pipeline.ipynb	Clasificación y segmentación ML

Fundamentos de Big Data y Arquitectura

Las 5V de Big Data aplicadas a RetailMax

V	Definición	Aplicación en RetailMax
Volumen	Gran cantidad de datos	70.000 imágenes + millones de transacciones
Velocidad	Rapidez de generación	Transacciones en tiempo real
Variedad	Distintos tipos de datos	Imágenes, texto, numérico
Veracidad	Calidad y confiabilidad	Validación con Fashion-MNIST estándar
Valor	Utilidad para el negocio	Segmentación y clasificación para marketing

Arquitectura del Pipeline

El pipeline sigue un flujo secuencial desde la fuente de datos hasta la aplicación de negocio, aprovechando las capacidades de procesamiento distribuido de Apache Spark en cada etapa:



Cada etapa transforma los datos progresivamente: desde imágenes en bruto (Fashion-MNIST) hasta predicciones de clasificación y segmentación almacenadas en formato Parquet, listas para ser consumidas por el equipo de marketing de RetailMax.

Desarrollo Técnico — Lecciones 1 a 3

Lección 1 — Fundamentos Big Data

Objetivo: Reconocer el ecosistema de Big Data y sus componentes básicos.

Técnicas implementadas:

- Análisis exploratorio (EDA) del dataset Fashion-MNIST
- Diagrama de arquitectura del pipeline completo
- Análisis y aplicación de las 5V de Big Data al caso RetailMax

Entregable: [leccion1_fundamentos_bigdata.ipynb](#)

Lección 2 — Configuración de Spark

Objetivo: Configurar Spark e iniciar el procesamiento distribuido.

Técnicas implementadas:

- Creación de SparkSession y SparkContext
- Paralelización de datos con `sc.parallelize()`
- Operaciones básicas: `count()`, `take()`, `first()`

Entregable: [leccion2_spark_configuracion.ipynb](#)

Lección 3 — RDDs: Transformaciones y Acciones

Objetivo: Manipular grandes volúmenes de datos con RDDs.

Técnicas implementadas:

- Transformaciones: `map()`, `filter()`, `flatMap()`, `distinct()`, `sortBy()`
- Acciones: `reduceByKey()`, `collect()`, `count()`
- Visualización del DAG de ejecución y uso de `cache()`

Entregable: [leccion3_rdd_transformaciones_v2.ipynb](#)

Desarrollo Técnico — Lecciones 4 y 5

Lección 4 — DataFrames y Spark SQL

Objetivo: Procesar datos estructurados con DataFrames y SQL.

Técnicas implementadas:

- Definición de esquemas con StructType y StructField
- Operaciones de DataFrame: select(), filter(), withColumn(), groupBy()
- Vistas temporales con createOrReplaceTempView() y consultas SQL
- Optimización: repartition(), cache()
- Persistencia en formato Parquet con write.parquet()

Entregables: [leccion4_dataframes_sql.ipynb](#) + [leccion4_fashion_data.parquet](#)

Lección 5 — Machine Learning Escalable (MLlib)

Objetivo: Construir pipeline de clasificación y segmentación.

Técnicas implementadas:

- Feature engineering con VectorAssembler y StandardScaler
- Regresión Logística: clasificación binaria — ropa de cuerpo (labels 0, 2, 3, 4, 6) vs calzado/accesorios (labels 1, 5, 7, 8, 9)
- K-Means (k=3): segmentación de productos por características visuales
- Evaluación: accuracy, silhouette score, confusion matrix, método del codo

Entregables: [leccion5_mllib_pipeline.ipynb](#) + archivos Parquet de predicciones

Resultados Obtenidos

Resultados del Clasificador (Regresión Logística)

Métrica	Valor	Descripción
Accuracy	~97%	Porcentaje de clasificaciones correctas
Clases	Binaria	Ropa de cuerpo vs Calzado/Accesorios
Train/Test split	80/20	División estándar de datos

Resultados de Segmentación (K-Means, k=3)

Cluster	Descripción	Clases dominantes
0	Prendas oscuras	Trouser, Bag, Ankle boot
1	Ropa de cuerpo clara	T-shirt, Pullover, Dress
2	Calzado y accesorios	Sandal, Sneaker, Shirt

Archivos Generados

Archivo	Formato	Contenido
leccion4_fashion_data.parquet	Parquet	Dataset Fashion-MNIST estructurado
predictions_lr.parquet	Parquet	Predicciones de Regresión Logística
predictions_kmeans.parquet	Parquet	Asignaciones de clusters K-Means
model_lr / model_kmeans	Spark ML	Modelos entrenados serializados

Conclusiones

Pipeline de extremo a extremo

Se logró implementar un pipeline completo de Big Data que abarca desde la ingesta de datos en bruto hasta la generación de predicciones de Machine Learning. El flujo integra cinco etapas diferenciadas — EDA, configuración de Spark, transformaciones con RDDs, procesamiento estructurado con DataFrames/SQL y modelado con MLlib — demostrando la capacidad de construir soluciones analíticas completas sobre el ecosistema Apache Spark.

Spark supera a Pandas en escala

La evaluación lazy de Spark, combinada con su motor de procesamiento distribuido, permite manejar volúmenes de datos que exceden la capacidad de herramientas como Pandas. La progresión de RDDs a DataFrames evidencia la evolución del framework hacia APIs más expresivas y optimizadas (Catalyst optimizer), manteniendo la escalabilidad horizontal como ventaja fundamental.

Aplicabilidad empresarial

Los modelos desarrollados tienen aplicación directa en RetailMax: la clasificación binaria con 97% de accuracy permite automatizar el etiquetado de productos en el catálogo, mientras que la segmentación K-Means facilita la agrupación de artículos por características visuales para campañas de marketing dirigido y optimización del inventario.

Limitaciones y próximos pasos

El pipeline se ejecutó en entorno local (modo standalone), lo cual limita la demostración del verdadero potencial distribuido de Spark. Como próximos pasos se recomienda: desplegar en un clúster real (YARN/Kubernetes), implementar cross-validation para selección de hiperparámetros, explorar modelos más complejos (Random Forest, GBT) y evaluar el deploy en servicios cloud como Databricks o AWS EMR.

Referencias y Recursos

1. Apache Spark Official Docs — <https://spark.apache.org/docs/latest/>
2. Fashion-MNIST Dataset — <https://github.com/zalandoresearch/fashion-mnist>
3. Spark MLlib Guide — <https://spark.apache.org/docs/latest/ml-guide.html>
4. Databricks Learning — <https://www.databricks.com/learn>
5. winutils para Windows — <https://github.com/cdarlint/winutils>

Tecnologías Utilizadas

Tecnología	Versión / Detalle
Python	3.10
Apache Spark (PySpark)	3.5
Spark MLlib	3.5
Fashion-MNIST	70.000 imágenes, 10 clases
Formato de persistencia	Apache Parquet
Entorno de desarrollo	Jupyter Notebook / Google Colab
Sistema operativo	Windows 11 + winutils