



Recibe una cálida:

¡Bienvenida!

Te estábamos esperando 😊 +




› Distribución muestral y teorema del límite central

Aprendizaje Esperado 4: Realizar cálculos de probabilidad utilizando la distribución muestral para resolver un problema.


Hoja de ruta

¿Cuáles skills conforman el programa? **Fundamentos de Ciencia de Datos**



Roadmap de lecciones

¿Cuáles *lecciones* estaremos estudiando en este módulo?



Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Comprender el comportamiento de las medias muestrales

Exploraremos cómo se comportan las medias de múltiples muestras tomadas de una población.

Introduciremos el concepto de distribución muestral y el Teorema del Límite Central, clave para entender la inferencia estadística.

Distribución muestral de la media

Qué es y cómo se genera

Relación con la media y la desviación estándar poblacional

Teorema del Límite Central (TLC)

Enunciado e implicancias

Qué sucede al aumentar el tamaño muestral

Learning Path

¿Cuáles temas trabajaremos hoy?

4.

Aplicaciones de la distribución muestral y pruebas estadísticas

Exploraremos cómo se utiliza la distribución muestral en diseño experimental, estudios clínicos, control de calidad, simulaciones y pruebas de hipótesis.

Abordaremos conceptos de potencia, errores y tamaño de muestra, y veremos nuevas estadísticas muestrales como varianza o diferencias.

Aplicaciones y diseño de estudios

Distribuciones muestrales extendidas y simulación

Aplicaciones en encuestas, estudios clínicos, control de calidad

Diseño de estudios y relación entre tamaño muestral y precisión

Diferencias de medias y proporciones, varianza, regresión

Simulaciones, bootstrap y uso en aprendizaje automático

Objetivos de aprendizaje

¿Qué aprenderás?

- Definir qué es una distribución muestral
- Diferenciar entre media poblacional, media muestral y distribución muestral
- Comprender cómo se comporta la media de múltiples muestras
- Aplicar el Teorema del Límite Central en cálculos de probabilidad
- Prepararse para el uso de la distribución normal en inferencias



Objetivos de aprendizaje

¿Qué aprenderás?




- Aplicar la distribución muestral para estimar parámetros en distintos contextos
- Identificar el rol del tamaño muestral en la precisión y potencia estadística
- Reconocer y calcular errores tipo I y II en pruebas de hipótesis
- Utilizar simulaciones y bootstrap para estimar distribuciones muestrales
- Comprender cómo se aplican estos conceptos en ciencia, industria y machine learning

Distribución muestral y teorema del límite central

Distribución muestral y teorema del límite central

La estadística inferencial se fundamenta en la posibilidad de realizar afirmaciones sobre una población a partir del estudio de una muestra.

Para ello, es esencial comprender cómo se comportan las estadísticas muestrales (como la media o la proporción) cuando se toman múltiples muestras de una misma población.




Conceptos fundamentales

La estadística inferencial nos permite realizar afirmaciones sobre una población completa estudiando solo una parte de ella.

Para entender cómo funciona este proceso, debemos comprender tres conceptos clave:

- Distribución muestral
- Ley de los grandes números
- Teorema del límite central



Base de la inferencia estadística

Distribución muestral

Nos permite visualizar cómo varía una estadística de muestra (como la media o la proporción) entre diferentes muestras extraídas aleatoriamente.

Ley de los grandes números

Garantiza que, a medida que se incrementa el tamaño muestral, la media muestral se aproxima cada vez más a la media poblacional.

Teorema del límite central

Asegura que, bajo ciertas condiciones, la distribución de la media muestral tiende a ser normal, sin importar la forma original de la distribución de la población.

Distribución de muestreo

“Imaginen que no tomamos una sola muestra... sino muchas muestras del mismo tamaño.”

Por ejemplo:

Tengo una población grande. Sacó una muestra de 30 personas y cálculo la media.

Luego sacó otra muestra distinta de 30 y vuelvo a calcular la media.

Y otra más.

Y otra más.

¿Las medias serán exactamente iguales?

No. Van a variar un poco.


Entonces lo que estamos mirando acá es:

La distribución de muestreo es la distribución de todas esas medias posibles.

Distribución de muestreo

La **distribución de muestreo** es la distribución de probabilidades de una estadística (como la media, proporción o desviación estándar) obtenida a partir de todas las posibles muestras aleatorias de un tamaño fijo extraídas de una misma población.


Esta distribución es clave en la estadística inferencial porque permite predecir con qué frecuencia una determinada estadística muestral se aproxima al parámetro poblacional que intenta estimar.



Ejemplo de distribución muestral

Supongamos que se desea estudiar el ingreso promedio de una población de 100.000 personas. Es inviable encuestar a todas, por lo que se toman múltiples muestras aleatorias de, por ejemplo, 100 personas.

Para cada muestra se calcula la media de ingreso. Al repetir este proceso muchas veces, se obtiene una distribución de medias muestrales: esa es la **distribución de muestreo de la media**.



Ejemplo numérico simple

Supongamos que la población tiene estos valores: 10, 12, 14, 16

La media poblacional es: $\mu=(10+12+14+16)/4=13$

Ahora vamos a hacer muestras de tamaño 2.

Calculamos la media de todas las posibles muestras de tamaño 2

Muestra	Media
(10,12)	11
(10,14)	12
(10,16)	13
(12,14)	13
(12,16)	14
(14,16)	15

Ejemplo numérico simple

¿Qué estamos mirando?

Ahora no miramos los datos originales.

Miramos **las medias**:

11, 12, 13, 13, 14, 15

Eso es la **distribución de muestreo de la media**.

Fórmula del error estándar

Matemáticamente, si se tienen muchas muestras de tamaño n extraídas de una población con media μ y desviación estándar σ , la media de las medias muestrales será también μ , y su desviación estándar (llamada **error estándar**) estará dada por:

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Este resultado muestra que a mayor tamaño de la muestra, menor será la variabilidad de las medias muestrales, lo cual mejora la precisión de nuestras estimaciones.

Ejemplo:

Imaginen que esta es la altura promedio real de todos los estudiantes del país. 170 cm. Y la dispersión es 10.

Población

$$\mu = 170$$

$$\sigma = 10$$

Ahora no puedo medir a todos. Entonces tomó una muestra de 30 estudiantes.

$$n=30$$


¿Si tomó otra muestra distinta de 30, la media será exactamente 170?

No.

Entonces las medias muestrales varían. Un poco más arriba, un poco más abajo

Si calculo Error estándar = $10 / \sqrt{30} \approx 1,82$

=> El cual es la variabilidad de las *medias*.



Población

$$\mu = 170$$

$$\sigma = 10$$

$$n = 100$$


Error estándar = $10 / \sqrt{100} = 1$ => Es menor, la variabilidad de las medias disminuye. “Más datos → menos incertidumbre.”

“La mayoría de las medias muestrales van a estar aproximadamente entre $170 \pm 1,82$.”

“Mientras más grande sea la muestra, más pequeña será esta dispersión.”

“Si en vez de 30 tomara 100... ¿qué pasaría con 1,82?”


Distribución muestral de la media para distintos tamaños muestrales



“La media de la distribución muestral no cambia.
Lo que cambia es la variabilidad.”

“A mayor tamaño muestral, menor error estándar.”

Distribución muestral de la media para distintos tamaños muestrales



¿Qué pasó cuando aumentamos el tamaño de muestra?

- La media sigue siendo 170
- El error estándar disminuye
- La campana se hace más angosta


Hasta ahora asumimos que la población era normal...

¿Pero qué pasaría si la población no fuera normal?

Propiedad fundamental

Una propiedad fundamental de la distribución muestral es que, incluso si la distribución original de la población no es normal, la distribución de las estadísticas muestrales tiende a ser normal si el tamaño de muestra es suficientemente grande (por ejemplo, $n \geq 30$).

Esta observación es la base del Teorema del Límite Central, que veremos más adelante.



Propiedad fundamental

Esta es una de las ideas más poderosas de la estadística.

Aunque la población sea rara, asimétrica, con picos, con forma extraña...

la distribución de las medias muestrales tiende a ser normal cuando n es suficientemente grande.

Por eso la normal aparece en todos lados.

No porque el mundo sea perfectamente normal...

sino porque los promedios tienden a comportarse normalmente.

Ejemplo: Altura de estudiantes

Volviendo al caso de las estaturas:

Población:

- $\mu = 170$
- $\sigma = 10$

Se mostró:

- $n=30 \rightarrow SE=1.82$
- $n=100 \rightarrow SE=1$
- $n=400 \rightarrow SE=0.5$

No importa si la estatura real no fuera perfectamente normal.

Si yo tomo muestras suficientemente grandes... las medias se van a distribuir aproximadamente normal.

Importancia de la distribución muestral



Estimación de confiabilidad

Si yo saco una muestra y obtengo una media de 170, esa media no es exacta. Puede variar.

La distribución muestral me permite saber cuánto puede variar.



Medición de variabilidad

Cuando n aumenta, el error estándar baja.

La campana se hace más angosta.

La estimación se vuelve más estable.



Base para inferencias

Sienta las bases para realizar inferencias estadísticas rigurosas sobre poblaciones grandes a partir de pequeñas muestras representativas

Ejemplo: Altura de estudiantes

Volviendo al caso de las estaturas:

Población:

- $\mu = 170$
- $\sigma = 10$

Se mostró:

- $n=30 \rightarrow SE=1.82$
- $n=100 \rightarrow SE=1$
- $n=400 \rightarrow SE=0.5$

Fíjense en algo...

Cuando aumentamos n , la distribución de las medias se hace más estrecha.

¿Qué significa eso en simple?


Que es cada vez más difícil que la media muestral se aleje mucho de 170.

Ley de los Grandes Números

La **Ley de los Grandes Números (LGN)** es un principio fundamental de la estadística que establece que, al aumentar el tamaño de una muestra aleatoria, el promedio de los valores observados se aproxima al valor esperado o media poblacional.

Esta ley garantiza la estabilidad a largo plazo de las frecuencias relativas.

“La Ley de los Grandes Números dice algo muy intuitivo: cuando repites un experimento muchas veces, el promedio se estabiliza.”



**LAW OF LARGE
NUMBERS**

Ley de los Grandes Números

Ejemplo simple:

- Lanzar una moneda.
- 5 lanzamientos → puede salir 4 caras.
- 1000 lanzamientos → difícil que salga 80% caras si la moneda es justa.


En el ejemplo de estatura:

Si tomo 3 personas, la media puede salir 165 o 178.

Si tomo 400 personas, la media difícilmente se aleja mucho de 170.

Ley de los Grandes Números

Distribución muestral de la media para distintos tamaños muestrales



Con el gráfico de las tres campanas:

1. Mostrar $n=30$ "Hay bastante dispersión."
2. Mostrar $n=100$ "Empieza a concentrarse."
3. Mostrar $n=400$ "Ahora prácticamente todas las medias están muy cerca de 170."

Eso es exactamente lo que garantiza la Ley de los Grandes Números: a medida que el tamaño muestral crece, la media muestral converge a la media poblacional.

Formulación matemática de la LGN

En términos formales, si $X_1, X_2, \dots, X_n$ son variables aleatorias independientes e idénticamente distribuidas con media μ , entonces:

Esto implica que la media muestral $\bar{X}$ converge a la media poblacional μ a medida que el tamaño muestral n crece.

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n X_i = \mu$$

Cuando el tamaño de muestra crece, la media muestral converge a la media poblacional.

Versiones de la Ley de los Grandes Números

Ley débil

Afirma la convergencia en probabilidad de la media muestral hacia la media poblacional.

Matemáticamente, para cualquier número positivo ε :

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \varepsilon) = 1$$

“Con muestras grandes, es muy probable que estés cerca”.


Ley fuerte

Asegura la convergencia casi segura de la media muestral hacia la media poblacional.

Matemáticamente:

$$P(\lim_{n \rightarrow \infty} \bar{X}_n = \mu) = 1$$

“Si sigues aumentando la muestra, el promedio efectivamente converge al valor real”.




Importancia de la LGN

La Ley de los Grandes Números proporciona la justificación matemática para el uso de la media muestral como una buena estimación de la media poblacional, siempre y cuando se tome un número suficientemente grande de observaciones.

Este principio es fundamental para la validez de muchos métodos estadísticos utilizados en investigación científica, encuestas y análisis de datos.

CENTRAL LIMIT THEOREM



Teorema del Límite Central

El **Teorema del Límite Central (TLC)** es uno de los pilares de la estadística inferencial. Establece que, dado un número suficientemente grande de muestras aleatorias de una población con cualquier tipo de distribución (siempre que tenga media y varianza finitas), la distribución de las medias muestrales se aproxima a una distribución normal.

Ley de los Grandes Números	Teorema del Límite Central
Habla del valor de la media	Habla de la forma de la distribución
Convergencia al promedio	Normalidad de las medias
Estabilidad	Forma gaussiana

Formulación matemática del TLC

Matemáticamente, si se toman muestras aleatorias de tamaño n , y se calcula la media muestral $\bar{X}$, entonces:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad \text{cuando } n \rightarrow \infty$$


Esto significa que, sin importar si la población original es asimétrica o tiene peak, la distribución de las medias muestrales se vuelve aproximadamente normal cuando n es suficientemente grande (comúnmente $n \geq 30$).

*“La Ley de los Grandes Números me dice que me acerco a μ .
El Teorema del Límite Central me dice que además lo hago con forma normal.”*

Ejemplo del TLC

Si la distribución de tiempos de espera en un hospital es altamente asimétrica, al tomar muchas muestras de 40 pacientes y calcular sus promedios, estos promedios seguirán una distribución cercana a la normal.

Este teorema justifica el uso de técnicas estadísticas basadas en la normalidad, como el cálculo de intervalos de confianza o pruebas de hipótesis, incluso cuando la distribución de los datos individuales no es normal.



Importancia del TLC

Universalidad


Funciona para cualquier
distribución poblacional con media
y varianza finitas

Fundamento para inferencia

Permite usar la distribución
normal para calcular
probabilidades e intervalos de
confianza

Aplicabilidad práctica

Justifica el uso de métodos
paramétricos incluso cuando no
conocemos la distribución exacta
de la población



Distribución de la población, distribución de la muestra y distribución muestral

Hasta ahora hemos hablado de promedios... pero ¿promedio de qué exactamente?

Distribución poblacional

¿Qué es?

La distribución real de la variable en toda la población.


Características clave:

- Incluye todos los individuos.
- Tiene parámetros verdaderos: μ , σ .
- Normalmente es desconocida.
- Es el “objeto real” que queremos estudiar.

Ejemplo:

Altura de *todas* las personas de un país.

POPULATION HEIGHT DISTRIBUTION



Distribución muestral

¿Qué es realmente?


La distribución de una estadística (por ejemplo, la media) calculada en muchas muestras diferentes del mismo tamaño.

Características clave:


- No es la distribución de datos, sino de una estadística.
- Es teórica (no la vemos directamente).
- Describe la variabilidad del estimador.
- Su forma se puede predecir con el TLC.
- Tiene media μ y varianza σ^2/n (si hablamos de la media).

Ejemplo:

Si tomo 10.000 muestras de tamaño 100 y calculo la media en cada una, la distribución de esas medias.



HEIGHT DISTRIBUTION



Distribución de la muestra

¿Qué es?

La distribución de los datos observados en una muestra específica.

Características clave:

- Incluye solo los datos recogidos.
- Es observable directamente.
- Cambia si tomó otra muestra.
- Produce estadísticas (media, varianza, etc.).

Ejemplo:

Alturas medidas en 100 personas seleccionadas.

Esta es “lo que veo”.

Diferencia clave

- **Distribución poblacional** → cómo se distribuyen todos los individuos.
- **Distribución muestral** → cómo se distribuye un estadístico cuando repito el muestreo muchas veces.
- **Distribución de la muestra** → cómo se distribuyen los datos que efectivamente recogí.

Son tres niveles distintos.

Comparación de las tres distribuciones

1

Distribución poblacional

- Incluye todos los elementos de la población
- Generalmente desconocida en la práctica
- Es lo que intentamos inferir

2


Distribución de la muestra

- Incluye solo los elementos de una muestra
- Es observable directamente
- Varía de una muestra a otra

3

Distribución muestral

- Distribución de estadísticas calculadas en muchas muestras
- Teórica pero predecible gracias al TLC
- Base para el cálculo de probabilidades



Importancia de la distinción

Estas distinciones permiten entender que trabajar con una muestra no implica conocer la población completa, pero sí que a través de muchas muestras se puede inferir el comportamiento poblacional.

Comprender estas diferencias es fundamental para aplicar correctamente los métodos de inferencia estadística.

Cálculo de probabilidades con la distribución muestral

Gracias al Teorema del Límite Central, podemos calcular probabilidades asociadas a medias muestrales como si fueran distribuciones normales.

Para esto, usamos la siguiente transformación:

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$$

Componentes de la fórmula

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$$

$\bar{X}$

Es la media observada de la muestra

μ

Es la media poblacional

σ

Es la desviación estándar de la población

n

Es el tamaño de la muestra

Ejemplo práctico: Tiempo de espera en un banco

Datos del problema

- Media de espera en un banco: 15 minutos
- Desviación estándar: 5 minutos
- Tamaño de la muestra: 36 personas

Pregunta

¿Cuál es la probabilidad de que el tiempo medio de espera sea mayor a 16 minutos?



Solución del ejemplo

Datos del problema

- $\mu = 15$ minutos
- $\sigma = 5$ minutos
- $n = 36$ personas

Queremos: $P(X > 16)$

Paso 1 — Distribución de la media muestral

Por el TLC:

$$\bar{X} \sim N\left(\mu, \frac{\sigma}{\sqrt{n}}\right)$$

Error estándar:

$$\frac{5}{\sqrt{36}} = \frac{5}{6} \approx 0.8333$$

Solución del ejemplo

Paso 2 — Estandarizamos

$$Z = \frac{16 - 15}{5/\sqrt{36}} = \frac{1}{0.8333} = 1.2$$

Entonces:

$$P(\bar{X} > 16) = P(Z > 1.2)$$

Paso 3 — Cálculo en Python

Error estándar: 0.8333

Z: 1.2

$P(\bar{X} > 16)$: 0.1151

*Hay aproximadamente un **11.5% de probabilidad** de que el tiempo promedio de espera de 36 personas supere los 16 minutos.*

Utilidad del análisis



Evaluación de expectativas

Permite evaluar si una muestra se comporta como se espera según los parámetros poblacionales conocidos



Detección de anomalías

Ayuda a identificar si existen desviaciones significativas que podrían indicar cambios en el proceso



Toma de decisiones

Facilita la toma de decisiones basadas en la probabilidad de obtener ciertos resultados en muestras futuras

Distribución muestral de proporciones

¿y qué pasa si no medimos minutos, sino proporciones?

Cuando se estudian proporciones (como el porcentaje de clientes satisfechos, votantes o enfermos), también se puede construir una distribución muestral.

La proporción muestral p sigue, bajo ciertas condiciones, una distribución normal:

- Tiene media: $E(\hat{p}) = p$

- Tiene desviación estándar (error estándar): $\sigma_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$

La distribución muestral de proporciones nos permite tratar porcentajes como variables normales, bajo ciertas condiciones.

Y si se cumple que:

$$np \geq 5 \quad \text{y} \quad n(1-p) \geq 5$$

entonces:

$$\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$$

Ejemplo: Aprobación de un curso

1

Datos del problema

- El 60% de los estudiantes aprueba un curso
- Tamaño de la muestra: 100 estudiantes

Pregunta

¿Cuál es la probabilidad de que en la muestra, menos del 55% apruebe?

2

Solución

- $p = 0.60, \hat{p} = 0.55, n = 100$
- $\sigma_{\hat{p}} = \sqrt{\frac{0.6(1-0.6)}{100}} = \sqrt{0.0024} = 0.049$
- $Z = \frac{0.55-0.6}{0.049} = -1.02$
- $P(Z < -1.02) \approx 0.1539$

Por lo tanto, hay un 15.39% de probabilidad de que menos del 55% apruebe en la muestra.

Ejemplo: Aprobación de un curso

2

```
from scipy.stats import norm
```

```
# valor de Z
```

```
z = -1.02
```

```
# probabilidad acumulada
```

```
prob = norm.cdf(z)
```

```
print(prob)
```

```
0.15386423037273478
```

Interpretación real

Hay aproximadamente un **15.39% de probabilidad** de que en una muestra de 100 estudiantes, menos del 55% apruebe... aunque en la población real el porcentaje sea 60%.

Condiciones para la aproximación normal

Para que la distribución muestral de proporciones pueda aproximarse mediante una distribución normal, deben cumplirse dos condiciones:

- $np \geq 5$
- $n(1-p) \geq 5$

Donde n es el tamaño de la muestra y p es la proporción poblacional.

Se pide la condición porque:

- La proporción muestral viene de una binomial
- La normal solo es buena aproximación si la binomial es suficientemente simétrica
- Eso ocurre cuando hay suficientes éxitos y fracasos esperados

Si no se cumple, conviene usar directamente la distribución binomial en lugar de la aproximación normal.



**NORMAL APPROXIMATION
TO A BINOMIAL DISTRIBUTION**

Verificación de condiciones en el ejemplo

100

**Tamaño de
muestra (n)**

Número de estudiantes en la
muestra

60%

**Proporción
poblacional (p)**

Porcentaje de estudiantes que
aprueban

60

np

$$100 \times 0.6 = 60 \geq 5 \checkmark$$

40

n(1-p)

$$100 \times 0.4 = 40 \geq 5 \checkmark$$

Ambas condiciones se cumplen, por lo que la aproximación normal es válida.

Live Coding

¿En qué consistirá la Demo?

Vamos a realizar cálculos paso a paso con ejemplos reales de distribución muestral, aplicando el Teorema del Límite Central para resolver problemas de probabilidad.

- 1. Calcular el error estándar de una media muestral*
- 2. Aplicar la fórmula de probabilidad normal con medias muestrales*
- 3. Resolver un caso práctico con muestra de tamaño $n = 36$*
- 4. Consultar la tabla Z para interpretar resultados*
- 5. Identificar condiciones para la aproximación normal en proporciones*
- 6. Calcular la desviación estándar de una proporción muestral*
- 7. Evaluar la probabilidad de un resultado extremo en proporciones*
- 8. Comparar la media poblacional con la media de muestras*



Ejercicio

Cálculo de probabilidades con distribución muestral

Cálculo de probabilidades con distribución muestral

Contexto: 🙌

Una entidad bancaria ha registrado que el tiempo promedio de espera de sus clientes es de 15 minutos, con una desviación estándar de 5 minutos. Se desea evaluar si una muestra de 36 clientes mantiene esa media, o si ha habido un cambio.

Consigna: 📝

Utilizando el Teorema del Límite Central, calcula la probabilidad de que el tiempo promedio de espera para una muestra de 36 personas sea mayor a 16 minutos. Interpreta el resultado y determina si se trata de una diferencia significativa.

Paso a paso: ⚙️

1. Anotar los datos: $\mu = 15$, $\sigma = 5$, $n = 36$, $x = 16$
2. Calcular el error estándar: $\sigma/\sqrt{n} = 5/6 \approx 0.833$
3. Aplicar fórmula Z: $Z = (x - \mu) / (\sigma/\sqrt{n}) = (16 - 15)/0.833 \approx 1.20$
4. Buscar valor en tabla Z: $P(Z > 1.20) \approx 0.1151$
5. Interpretar: 11.51% de probabilidad de que la media muestral supere los 16 minutos

Tiempo 🕒: 40 Minutos



Momento:

Time-out!



5 -10 min.



Distribución muestral y teorema del límite central

Aplicaciones de la distribución muestral de proporciones



Encuestas de opinión

Estimar el margen de error en encuestas políticas o de satisfacción



Estudios clínicos

Calcular la probabilidad de observar cierta tasa de éxito en un tratamiento




Control de calidad

Determinar la probabilidad de encontrar cierto porcentaje de productos defectuosos


Relación entre tamaño muestral y precisión

A medida que aumenta el tamaño de la muestra (n), la desviación estándar de la distribución muestral disminuye, lo que resulta en estimaciones más precisas.

Esta relación es proporcional a la raíz cuadrada de n , lo que significa que para duplicar la precisión (reducir el error estándar a la mitad), necesitamos cuadruplicar el tamaño de la muestra.



Efecto del tamaño muestral en la distribución



Distribución muestral y diseño de estudios



Definir objetivo

Especificar qué parámetro poblacional queremos estimar o contrastar (por ejemplo, la media, una proporción o una diferencia entre grupos). Esto orienta todo el diseño del estudio y determina qué distribución muestral utilizaremos.



Calcular tamaño muestral

Determinar cuántas observaciones necesitamos para alcanzar un nivel de precisión adecuado. Recordemos que el error estándar disminuye con $n\sqrt{n}$, por lo que muestras más grandes producen estimaciones más estables.



Diseñar muestreo

Seleccionar un método de muestreo apropiado (aleatorio simple, estratificado, etc.) que garantice representatividad y permita aplicar correctamente los supuestos estadísticos.



Analizar resultados

Utilizar la distribución muestral para calcular probabilidades, intervalos de confianza o realizar pruebas de hipótesis, con el objetivo de inferir conclusiones sobre la población.


Distribución muestral y error tipo I y II

Error tipo I (α)

Probabilidad de rechazar la hipótesis nula cuando es verdadera (falso positivo)

Error tipo II (β)

Probabilidad de no rechazar la hipótesis nula cuando es falsa (falso negativo)




La distribución muestral permite calcular estas probabilidades de error y diseñar pruebas con la potencia estadística adecuada.

Distribución muestral y potencia estadística

La potencia estadística es la probabilidad de rechazar correctamente una hipótesis nula falsa ($1-\beta$).

La distribución muestral nos permite calcular la potencia de una prueba y determinar el tamaño muestral necesario para detectar un efecto de determinada magnitud con la confianza deseada.



STATISTICAL POWER

Distribución muestral en diferentes contextos

Ciencias sociales

Encuestas de opinión, estudios demográficos,
investigación de mercados

Ciencias de la salud

Ensayos clínicos, estudios epidemiológicos,
investigación biomédica

Economía y finanzas

Análisis de rendimientos, estudios económicos,
predicciones financieras

Ingeniería y control de calidad


Procesos industriales, control de calidad, diseño de
experimentos

Distribución muestral de otras estadísticas

¿Qué distribución uso según el problema?


Además de la media y la proporción, existen distribuciones muestrales para otras estadísticas:

- La variabilidad (σ^2): Varianza muestral (distribución chi-cuadrado)
- Comparar medias: Normal (σ conocida) o t (σ desconocida)
- Comparar proporciones grandes muestras: Diferencia de proporciones (distribución normal)
- Comparar varianzas
 - Comparar varianzas $\rightarrow$ F
 - Inferencia sobre correlación $\rightarrow$ Transformación Z de Fisher




Normal distribution

Normal $\rightarrow$ "Cuando n es grande"




Chi-squared distribution

Chi² $\rightarrow$ "Para varianza"



T-distribution

t $\rightarrow$ "Cuando σ es desconocida"



F-distribution

F $\rightarrow$ "Para comparar varianzas"

Cada estadístico tiene su propia distribución muestral. Elegir bien es clave para que la prueba sea válida.

Distribución muestral de la varianza

Si la población es normal, la varianza muestral no sigue una distribución normal.


Sigue una distribución chi-cuadrado:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2_{n-1}$$

Se usa para:

- Construir intervalos de confianza para σ^2
- Probar si la variabilidad poblacional ha cambiado

Donde n es el tamaño de la muestra, S^2 es la varianza muestral, σ^2 es la varianza poblacional, y χ^2_{n-1} representa una distribución chi-cuadrado con $n-1$ grados de libertad.



Distribución muestral de la diferencia de medias

¿Cómo sabemos si dos grupos realmente son diferentes?

Si $\bar{X}_1$ y $\bar{X}_2$ son las medias de dos muestras independientes de tamaños n_1 y n_2 , entonces la diferencia $\bar{X}_1 - \bar{X}_2$ sigue una distribución normal


con: $\bar{X}_1 - \bar{X}_2 \sim \mathcal{N}(\mu_1 - \mu_2, \sigma_1^2/n_1 + \sigma_2^2/n_2)$

- Media: $\mu_1 - \mu_2$
- Error estándar: $\sqrt{(\sigma_1^2/n_1 + \sigma_2^2/n_2)}$

Media: diferencia real entre las poblaciones

Error estándar: variabilidad esperada de esa diferencia

Nota: Si las varianzas poblacionales son desconocidas, se utiliza la distribución t.



Distribución muestral de la diferencia de proporciones

¿La diferencia observada es real o producto del azar?

Cuando comparamos dos proporciones (por ejemplo, tasa de éxito en dos grupos), la diferencia $\hat{p}_1 - \hat{p}_2$ tiene su propia distribución.

- Valor esperado de la diferencia

$$E(\hat{p}_1 - \hat{p}_2) = p_1 - p_2$$

- Error estándar

$$SE = \sqrt{\frac{p_1(1-p_1)}{n_1} + \frac{p_2(1-p_2)}{n_2}}$$


Esta distribución es fundamental para comparar proporciones entre dos grupos, como en estudios de caso-control o ensayos clínicos.

Simulación de distribuciones muestrales

¿Cómo vemos realmente el Teorema del Límite Central en acción?


Una forma práctica de entender las distribuciones muestrales es mediante simulaciones computacionales:

1. Definir una población (real o teórica)
2. Extraer múltiples muestras aleatorias
3. Calcular la estadística de interés para cada muestra
4. Graficar la distribución de los valores obtenidos




...

Distribución de medias ($n = 5$)



Distribución de medias ($n = 50$)



Ventajas de la simulación



Visualización intuitiva

Permite ver directamente cómo se comporta la distribución muestral



Verificación empírica

Confirma los resultados teóricos del TLC y la LGN



Exploración de casos límite

Permite estudiar situaciones donde las aproximaciones teóricas podrían fallar

Distribución muestral y bootstrap

¿Qué es el bootstrap?

Cuando **no conocemos la distribución poblacional**, usamos la muestra observada como si fuera una “mini población”.

En lugar de volver a la población real, **re-muestreamos desde la propia muestra**.


¿Qué hace exactamente?

1. Tenemos una muestra original de tamaño n .
2. Generamos muchas nuevas muestras del mismo tamaño, tomando datos al azar con reemplazo desde la muestra original.
3. Calculamos la estadística de interés (media, proporción, etc.) en cada muestra.
4. La distribución de esos valores aproxima la **distribución muestral**.

Las muestras bootstrap:

- Tienen el mismo tamaño que la muestra original
- Se generan con reemplazo (un dato puede repetirse)
- No usan la población original

Estamos “simulando” muchas muestras posibles usando solo los datos que tenemos.



BOOTSTRAP

Distribución muestral y bootstrap

Ejemplo:

Muestra original:

[4, 7, 10]

Muestra bootstrap 1:

[7, 4, 7]

Muestra bootstrap 2:

[10, 10, 4]

Cada una produce una media distinta.

Al repetir esto miles de veces, obtenemos una distribución.

Ventajas del bootstrap

No paramétrico

No requiere supuestos sobre la distribución de la población.

-> Ideal cuando la muestra es pequeña o asimétrica

Flexible

Aplicable a casi cualquier estadística, incluso aquellas sin fórmulas analíticas conocidas.

-> Incluso cuando no sabemos la fórmula del error estándar

Práctico

Permite estimar errores estándar e intervalos de confianza con una sola muestra.

-> Solo con los datos disponibles

Distribución muestral y tamaño de efecto


¿La diferencia observada es grande o apenas ruido?

El tamaño de efecto mide qué tan grande es la diferencia real entre poblaciones (por ejemplo, diferencia de medias o de proporciones).

Pero esa diferencia se estima con una muestra, y por lo tanto:

- Puede variar por azar
- Depende del tamaño de muestra
- Se detecta cuando es grande respecto a su error estándar

=> Cuando el tamaño del efecto es grande o el tamaño de muestra aumenta, la potencia del test crece.




Relación entre tamaño muestral, tamaño de efecto y potencia

Tamaño muestral

A mayor tamaño muestral, menor error estándar y mayor potencia.

Nivel de significancia

Criterios más estrictos (α menor) reducen la potencia



Tamaño de efecto

Efectos grandes son más fáciles de detectar con muestras pequeñas

Potencia estadística

Mayor potencia requiere muestras más grandes o efectos más grandes

Distribución muestral en el análisis de varianza

(ANOVA)

¿Qué es ANOVA?

ANOVA significa: **AN**alysis **Of** **VA**riance (Análisis de varianza)

Y sirve para responder esta pregunta: ¿Son iguales las medias de varios grupos o al menos una es diferente?

El problema que resuelve

Imagina que tienes:

- Método A
- Método B
- Método C

Y quieres saber cuál produce mejores resultados.

Podrías comparar A vs B. Luego A vs C. Luego B vs C.

Pero eso se vuelve desordenado y aumenta el error.

ANOVA hace algo más elegante: Compara **todos los grupos al mismo tiempo**.

Distribución muestral en el análisis de varianza

(ANOVA)

La idea central (sin fórmulas todavía)

ANOVA no mira directamente las medias. Se pregunta: ¿La variabilidad entre los grupos es grande comparada con la variabilidad dentro de los grupos?

Porque si:

- Dentro de cada grupo los datos varían mucho
- Pero las medias entre grupos son parecidas

Entonces probablemente las diferencias son solo azar.

Pero si:

- Dentro de cada grupo los datos son relativamente consistentes
- Y las medias entre grupos están bien separadas

Entonces probablemente hay un efecto real.

Distribución muestral en el análisis de varianza

(ANOVA)

Ejemplo intuitivo

Imagina tres cursos con promedios:

- Curso A: 5.1
- Curso B: 5.2
- Curso C: 5.0

Pero cada curso tiene notas que varían entre 3.5 y 6.5.

Aquí la diferencia entre promedios es pequeña comparada con la variación interna. Probablemente no hay diferencia real.

Ahora imagina:

- Curso A: 4.0
- Curso B: 5.5
- Curso C: 6.8

Y dentro de cada curso las notas son bastante similares. Ahí sí parece haber una diferencia real.

Eso es lo que ANOVA detecta.

Distribución muestral en el análisis de varianza (ANOVA)


En ANOVA, la distribución muestral del estadístico F sigue una distribución F de Fisher con grados de libertad determinados por el diseño del estudio.

Esta distribución permite comparar la variabilidad entre grupos con la variabilidad dentro de los grupos para determinar si existen diferencias significativas entre las medias de múltiples grupos.

Distribución muestral en regresión

En análisis de regresión, los coeficientes estimados $\hat{\beta}$ tienen una distribución muestral que sigue una distribución t de Student cuando los errores son normales.

Esta distribución permite construir intervalos de confianza para los coeficientes y realizar pruebas de hipótesis sobre su significancia.




Distribución muestral y métodos bayesianos

En estadística bayesiana, la distribución muestral se combina con una distribución a priori para obtener una distribución posterior:

$$P(\theta | x) \propto P(x | \theta) \times P(\theta)$$

Donde $P(x|\theta)$ es la verosimilitud (basada en la distribución muestral) y $P(\theta)$ es la distribución a priori.



Distribución muestral en muestreo complejo

En diseños de muestreo complejos (estratificado, por conglomerados, etc.), la distribución muestral puede diferir de la teoría estándar:

Efecto de diseño

Mide cuánto se incrementa la varianza debido al diseño complejo

Pesos muestrales

Ajustan las estimaciones para compensar probabilidades desiguales de selección


Correcciones finitas

Ajustan el error estándar cuando la muestra es una fracción significativa de la población

Distribución muestral y big data

En la era del big data, las muestras pueden ser enormes, lo que plantea nuevos desafíos y oportunidades:

- Efectos pequeños se vuelven estadísticamente significativos
- La precisión aumenta, pero los sesgos no desaparecen
- El muestreo sigue siendo relevante por razones de eficiencia computacional



BIG DATA SAMPLING

Distribución muestral y aprendizaje automático

Validación cruzada

Utiliza múltiples muestras para evaluar el rendimiento de modelos

Bagging

Combina predicciones de modelos entrenados en diferentes muestras bootstrap

Boosting

Entrena modelos secuenciales dando más peso a las observaciones mal clasificadas

Estos métodos aprovechan los principios de la distribución muestral para mejorar la generalización y reducir el sobreajuste.

Errores comunes en la interpretación

Confundir distribuciones

Mezclar la distribución poblacional, la distribución de la muestra y la distribución muestral

Ignorar condiciones

Aplicar el TLC sin verificar que el tamaño muestral sea suficiente

Olvidar el contexto

Centrarse solo en la significancia estadística sin considerar la relevancia práctica

Mejores prácticas



Verificar supuestos

Comprobar que se cumplen las condiciones para aplicar el TLC



Tamaño adecuado

Asegurar que el tamaño muestral es suficiente para la precisión deseada



Muestreo aleatorio

Garantizar que las muestras son verdaderamente aleatorias y representativas



Interpretar en contexto

Considerar tanto la significancia estadística como la relevancia práctica

Resumen de conceptos clave

1

Distribución muestral

Distribución de una estadística calculada en muchas muestras aleatorias del mismo tamaño

2

Ley de los Grandes Números

A medida que aumenta el tamaño muestral, la media muestral converge a la media poblacional

3

Teorema del Límite Central

La distribución de medias muestrales tiende a ser normal para muestras suficientemente grandes

4

Error estándar

Desviación estándar de la distribución muestral, que disminuye con la raíz cuadrada del tamaño muestral

Conclusión

La distribución muestral es una herramienta esencial que permite conectar la teoría de la probabilidad con la práctica de la estadística inferencial. Gracias a la ley de los grandes números y al teorema del límite central, podemos confiar en que, con un tamaño muestral adecuado, nuestras estadísticas muestrales reflejan fielmente a la población.

Comprender estas nociones no solo mejora la interpretación de resultados estadísticos, sino que también fortalece la toma de decisiones fundamentadas en evidencia.

Mediante los ejemplos y fórmulas desarrolladas en este manual, se ha demostrado cómo estimar y calcular probabilidades con base en medias y proporciones muestrales, sentando las bases para métodos más complejos como la construcción de intervalos de confianza o la realización de pruebas de hipótesis.



Ejercicio

Comparación de medias entre dos muestras

Comparación de medias entre dos muestras

Contexto: 🙌

Un laboratorio clínico desea saber si un nuevo medicamento produce un cambio significativo en la presión arterial. Se toman dos muestras independientes: un grupo control y un grupo tratado, ambos con 30 pacientes.

Consigna: 📝

Calcule si la diferencia de medias entre los dos grupos es significativa utilizando la fórmula del error estándar para diferencias. Estime también el tamaño del efecto y comente si el resultado tiene relevancia práctica.

Paso a paso: ⚙️

1. Registrar:
 - Media grupo 1 (control): 130, $\sigma_1 = 10$
 - Media grupo 2 (tratado): 125, $\sigma_2 = 12$
 - $n_1 = n_2 = 30$
2. Calcular diferencia de medias: $\Delta = 130 - 125 = 5$
3. Calcular error estándar: $\sqrt{((10^2/30) + (12^2/30))}$
4. Calcular Z: $Z = \Delta / \text{error estándar}$
5. Buscar P en tabla Z y concluir
6. Comentar si es significativo y clínicamente relevante

Tiempo 🕒: 45 Minutos

¿Alguna consulta?





¡Ponte a prueba!

Momento de ejercitación

*Te invitamos a aprovechar esta última sección del espacio sincrónico para realizar de manera individual las **actividades disponibles en la plataforma**. Estas propuestas son clave para afianzar lo trabajado y **forman parte obligatoria del recorrido de aprendizaje**.*

👉 **Análisis de caso** ————— 👉 **Selección Múltiple**

👉 **Comprensión lectora**

Si al resolverlas surge alguna duda, compartela o tráela al próximo encuentro sincrónico.

< ¡Muchas gracias! >

